unir LA UNIVERSIDAD EN INTERNET

Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica ů UNIR
Director: Ricardo Rafael Domínguez Reyes

Documento: `Documento/main.pdf` *Código:* `POCs/qml_v2/`
Práctica: SKG Tecnología

Agenda (línea cronológica del TFM)

1. Motivación
2. Introducción
3. Contexto y estado de la técnica
4. Planteamiento y metodología
5. Resultados de modelos (plots)
6. Conjeturas: cómo llegamos a $\mathcal{Q}$ y QCR
7. Evidencia de las conjeturas
8. Conclusiones y limitaciones
9. Trabajo futuro

Estructura del documento

Marco teórico (Cap. 1–3) $\rightarrow$ Implementación (Cap. 4–5) $\rightarrow$ Discusión y cierre (Cap. 6–8).

Motivación

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

Pregunta práctica

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

Estructura del TFM



Introducción — planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Hipótesis operativa

La ventaja es **real pero condicionada**:

1. coincidencia **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

Introducción — alcance

Familias industriales (4)

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Optimización combinatoria (QAOA)
- Optimización / híbrido (VQE + MDS)

Extendidas a 9 protocolos justos en el documento (anomalías, TSP, lags,...).

Tres capas de datos

1. Sintéticos con estructura cuántica nativa (Liu et al., 2021)
2. Práctica SKG Tecnología
3. Referencia pública

Era NISQ

NISQ (Preskill, 2018)

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

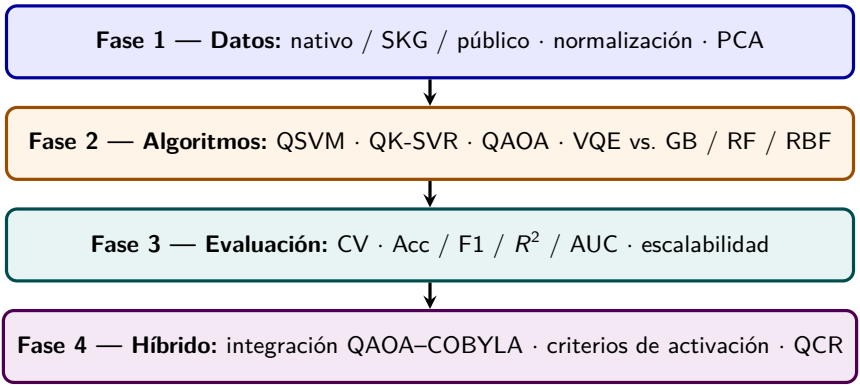
Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Datasets donde el kernel cuántico es óptimo por construcción (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2022).
- Gap empírico: pocos estudios **justos** sobre datos empresariales reales (Fastovets et al., 2019).

Posicionamiento de este TFM

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

Metodología en cuatro fases



Diseño: 4 familias $\times$ 3 capas de datos

Familia	Cuántico	Clásico de referencia
Clasificación	QSVM (ZZ)	GB, RF, SVM-RBF
Regresión	QK-SVR	XGBoost, RF, SVR-RBF, Ridge
Optimización (asignación)	QAOA (p=1)	Greedy, búsqueda local, ILP
Portafolio / cobertura	VQE / QAOA-MDS	Markowitz, fuerza bruta
Anomalías / lags	OCSVM-ZZ / QK-SVR	IF, LOF, Ridge, GB

Cada familia se evalúa, cuando aplica, en: (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia pública**.

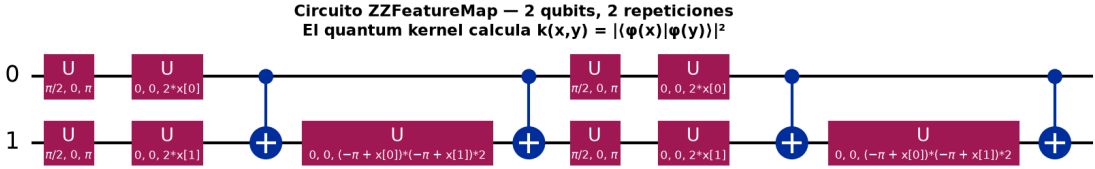
Condición operativa (sin detenerse en formalismo)

Kernels: ventaja si el **generador** coincide con el feature map (ZZ medido aquí). Optimización: QUBO + loop híbrido (QAOA/VQE + COBYLA) a escala viable.

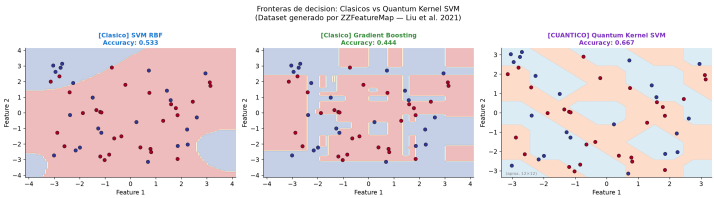
Criterio de activación del módulo cuántico

Problema	**Activar si**	**Módulo Q**	**Fallback**
Clasif. / Regresión	coincidencia mapa–generador *y* vence a GB/RF (no basta $\mathcal{Q} > 0$ vs RBF)	QSVM / QK-SVR	GB / RF
Anomalías	novedad alineada al mapa (`zz_phase`)	OCSVM-ZZ	IF / LOF
Forecasting	target alineado (`zz_lag`)	QK-SVR	Ridge / GB
Optimización / TSP	QUBO factible, *n* viable	QAOA / VQE	Greedy / ILP / 2-opt
Caso general	SKG/Telco sin estructura ZZ o *n* demasiado grande	**no se activa**	pipeline clásico

Resultados — circuito ZZFeatureMap (mapa usado)



Resultados — nativo ZZ: el QSVM ve la frontera



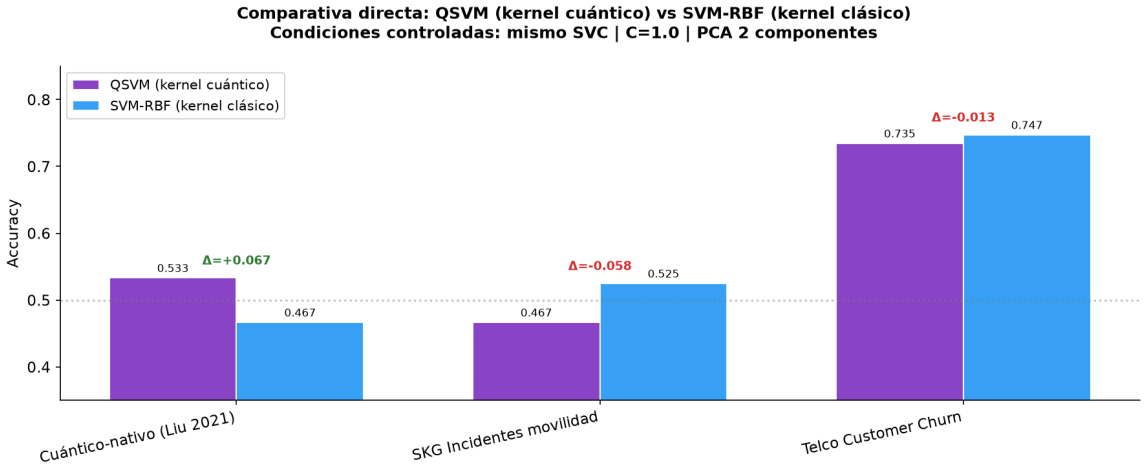
Qué muestra

Etiquetas generadas con el mismo `ZZFeatureMap`.

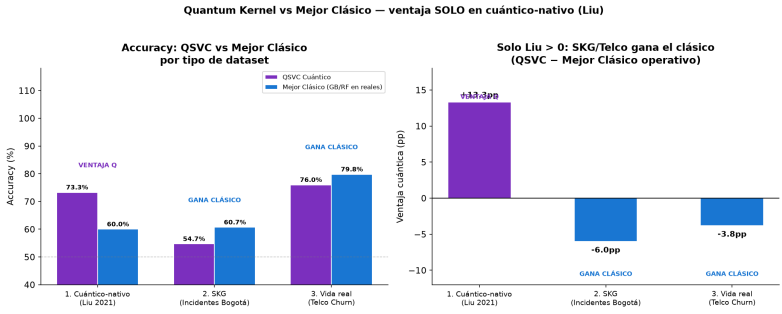
- QSVM recupera la frontera
- RBF / GB $\approx$ azar

Régimen controlado (Liu): no es un dataset empresarial. El punto es la coincidencia mapa–generador, no el tamaño de muestra.

Resultados — QSVM vs SVM (directo)



Resultados — clasificación en 3 capas de datos



Lectura (única)

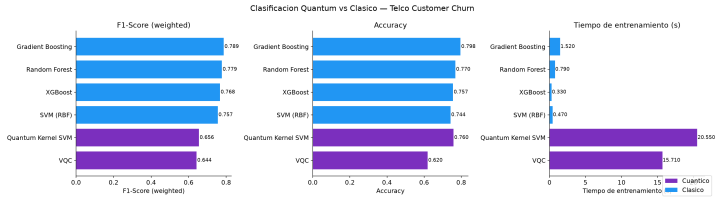
- **Liu:** ventaja Q ($+13.3$ pp)
- **SKG:** gana clásico ($-6{,}0$ pp)
- **Telco:** gana clásico ($-3{,}8$ pp vs GB)

Baseline operativo = GB/RF.

Solo Liu tiene ventaja;

SKG/Telco **no**.

Resultados — Telco: sin estructura ZZ (gana el clásico)

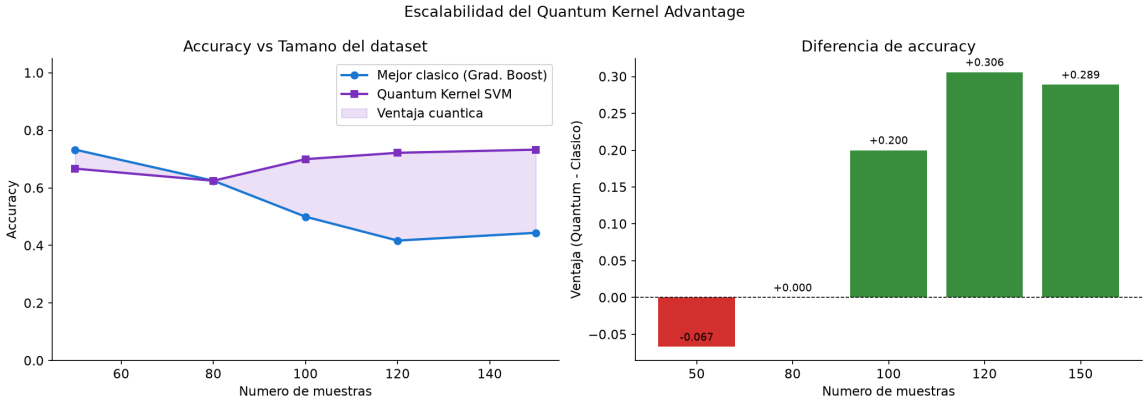


Lectura

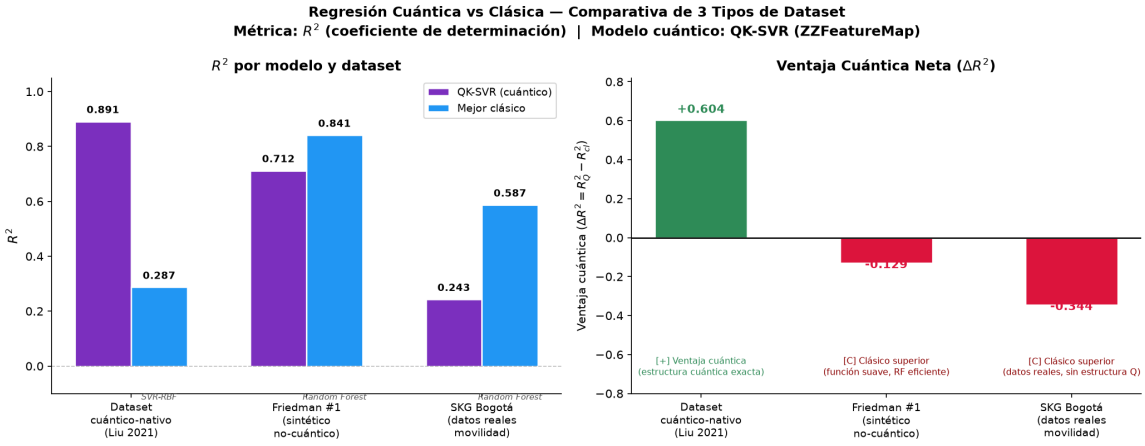
- GB/RF/XGBoost: F1 $\approx$ 0,78–0,79
- QSVM / VQC: F1 $\approx$ 0,64–0,66
- Tiempo: clásico $< 2\,\mathrm{s}$; cuántico $> 15\,\mathrm{s}$
- Velocidad ($\propto 1/t$): clásico ≈ 1; cuántico ≈ 0 (el QSVM es **más lento**)

SKG/Telco no son cuántico-nativos.

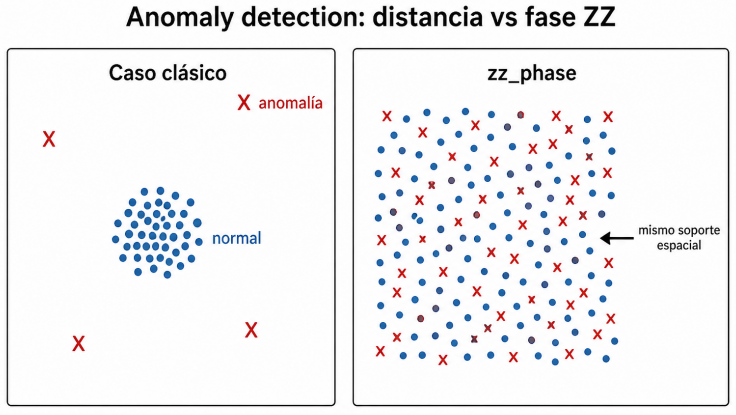
Resultados — coste del kernel cuántico



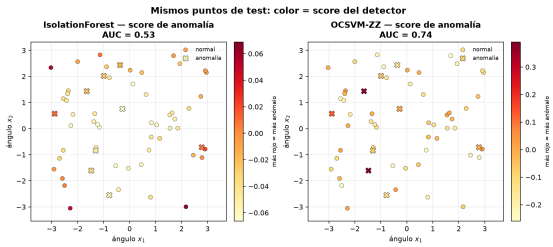
Resultados — regresión (QK-SVR, 3 datasets)

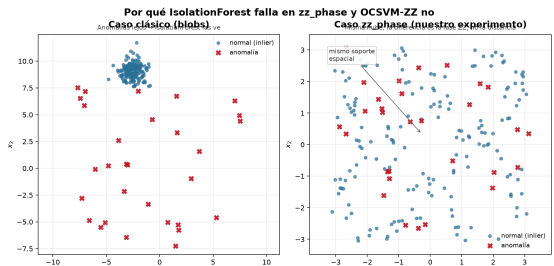


Resultados — anomalías: idea (distancia vs fase ZZ)



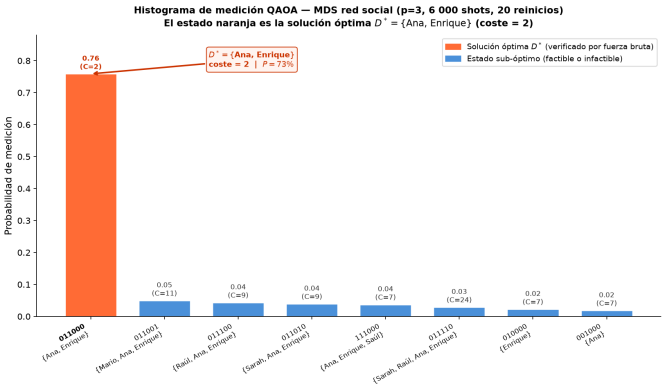
Resultados — anomalías (OCSVM-ZZ)





Ventaja solo en `zz_phase`; en moons/blobs/SKG inyectado gana IsolationForest.

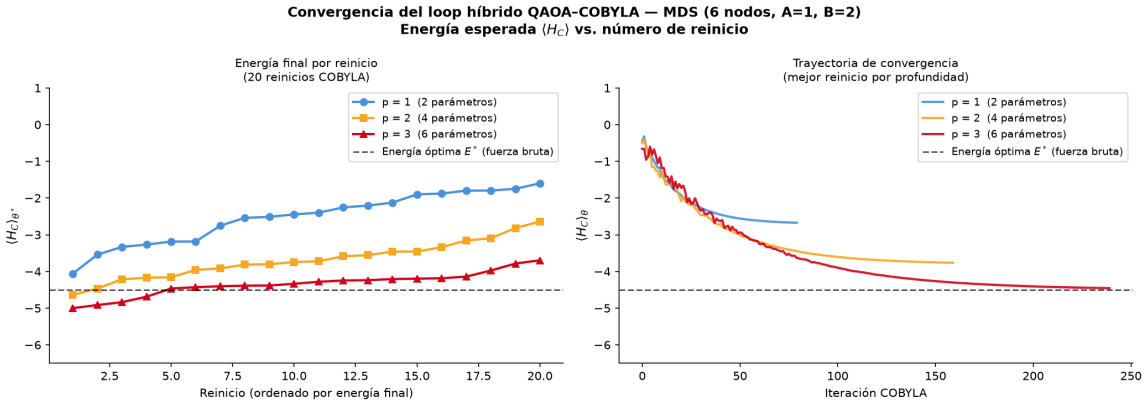
Resultados — QAOA (histograma de medición)



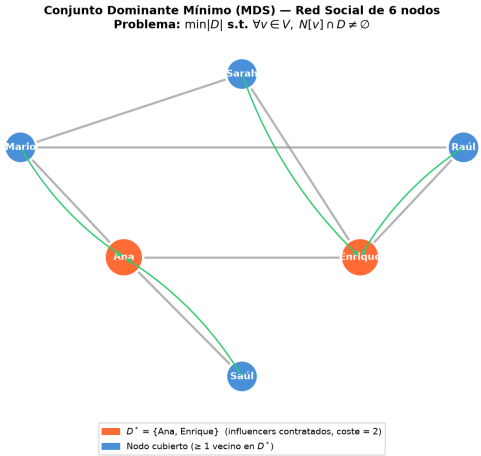
Hallazgos

- QAOA: $-\mathbf{30.3\,\%}$ coste vs. Greedy
- VQE competitivo en portafolio pequeño
- TSP n=4: empate óptimo (modelado, no speedup)

Resultados — loop híbrido QAOA–COBYLA



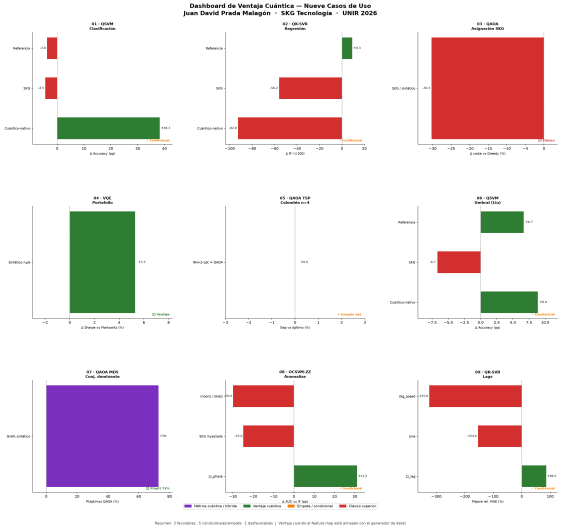
Resultados — MDS (solución en grafo)



Lectura

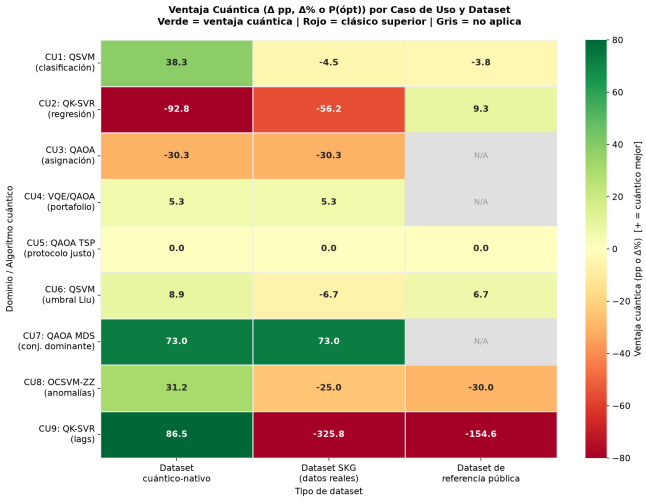
- $D^\star = \{\text{Ana}, \text{Enrique}\}$
- $P(\text{opt}) \approx 73\,\%$ (patrón híbrido)
- Escala moderada; no speedup asintótico

Síntesis — dashboard de 9 casos

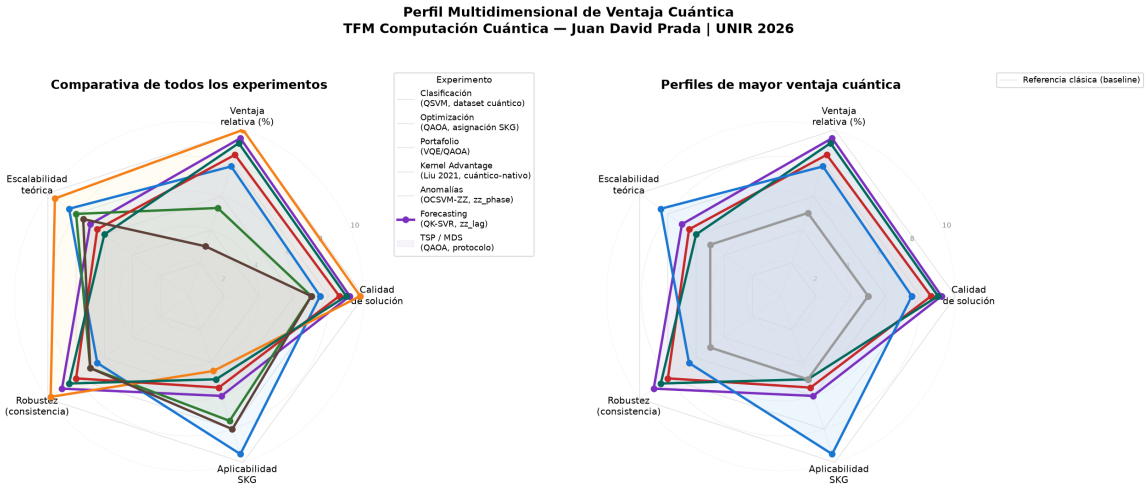


Resumen: 3 favorables · 5 condicionales/empate · 1 desfavorables | Ventajas cuando el feature map está alineado con el generador de datos

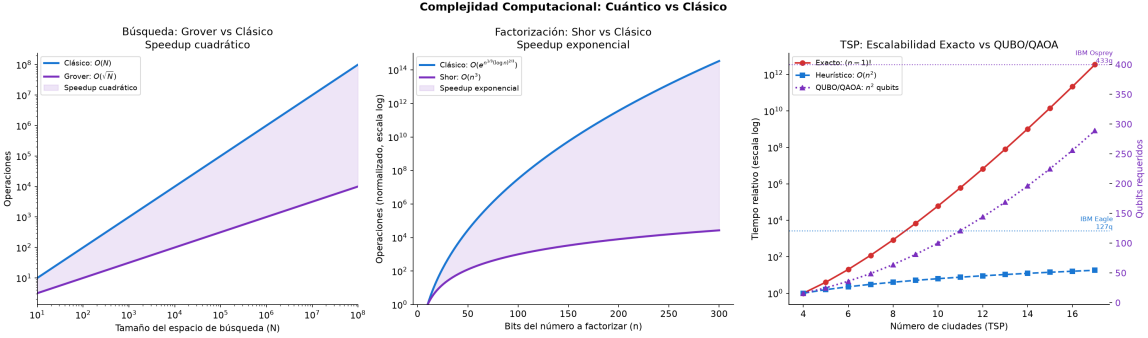
Síntesis — heatmap por dominio



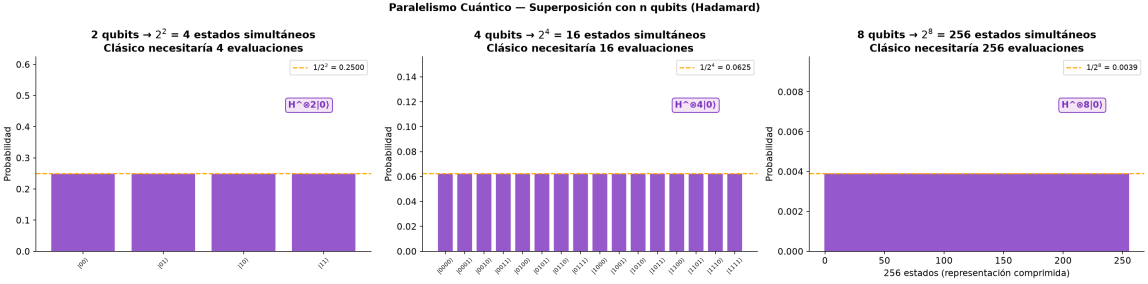
Síntesis — radar multidimensional



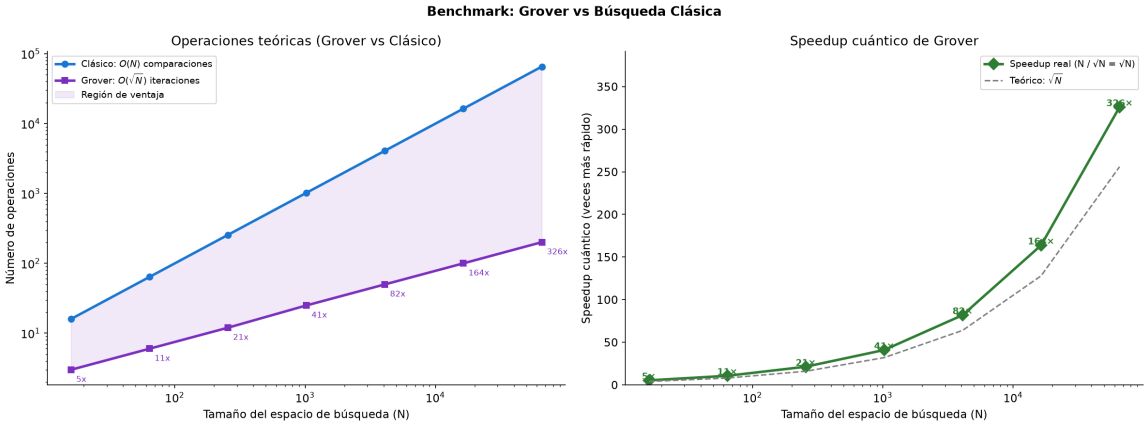
Síntesis — complejidad cuántico vs clásico



Síntesis — paralelismo / superposición (2^n)



Síntesis — benchmark Grover vs búsqueda clásica



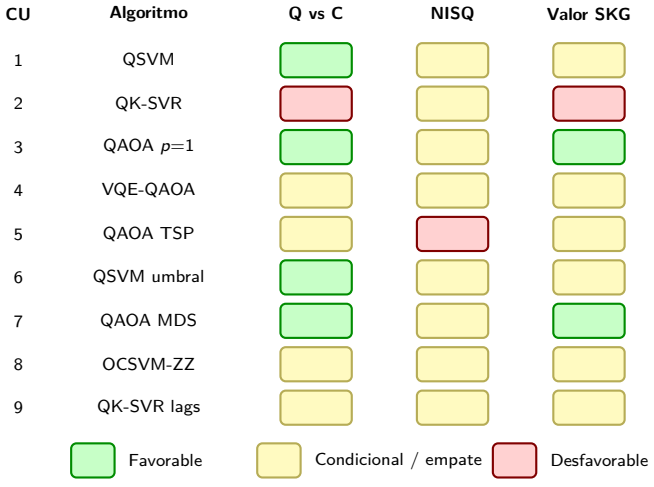
Síntesis — tabla de 9 casos (cifras ancla)

CU	Algoritmo	Nativo	SKG	Referencia
1	QSVM	**+38.3 pp**	-4.5 pp	-3.8 pp
2	QK-SVR	$-0{,}93\,\Delta R^2$	$-0{,}56\,\Delta R^2$	$+0{,}09\,\Delta R^2$
3	QAOA (p=1)	**−30.3 % vs Greedy**		—
4	VQE/QAOA	Óptimo ($n \leq 6$)		—
5	QAOA TSP	empate óptimo (n=4)		gap 0
6	QSVM umbral	**+8.9 pp**	$-6{,}7$ pp	$-3{,}8$ pp (vs GB)
7	QAOA MDS	$P(\mathrm{opt}) \approx 73\,\%$		NP-hard
8	OCSVM-ZZ	**+31 pp AUC** (`zz_phase`)	clásico	clásico
9	QK-SVR lags	**ΔMAE** $-0{,}36$ (`zz_lag`)	clásico	clásico

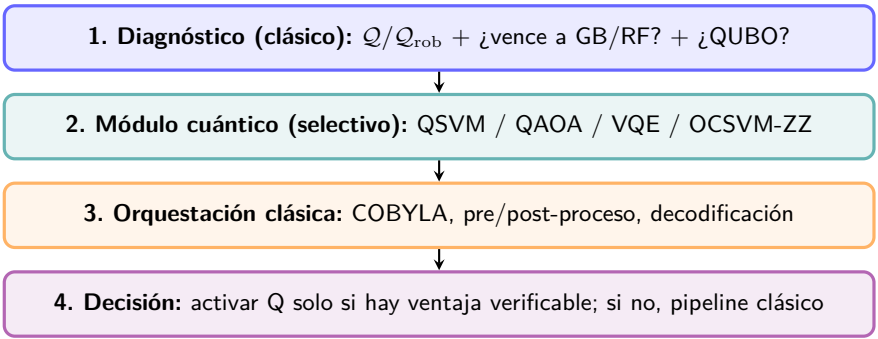
Kernels: ventaja **solo** en nativo

(Liu). SKG/Telco: gana GB/RF (Telco $-3{,}8$ pp).

Síntesis — semáforo por caso de uso



Arquitectura híbrida — 4 capas (prototipo)



Para SKG: herramienta **adicional**, no sustituto del stack actual.

De la evidencia emergen dos preguntas

Tras los 9 casos **no** partimos de $\mathcal{Q}$ ni de QCR: partimos de hechos.

1. Ventaja de kernel **clara** solo cuando el generador coincide con el feature map (ZZ-nativo; también `zz_phase`, `zz_lag`).
2. En SKG/Telco (sin esa estructura) gana GB/RF: **no** son cuántico-nativos.
3. En QUBO híbrido hay valor a escala moderada; TSP n=4 empata al óptimo (modelado $\neq$ speedup).

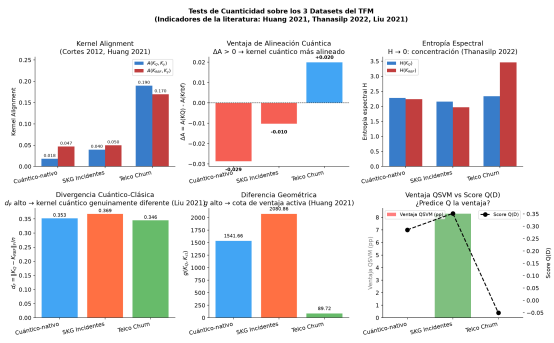
Preguntas originales (Cap. 6)

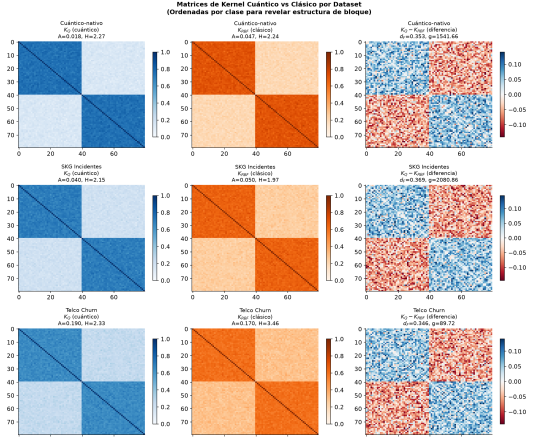
1. **P1 — tests de cuanticidad:** ¿Se puede diagnosticar *a priori* si un dataset admitirá ventaja?
2. **P2 — mapeos cuántico-compatibles:** Si no hay estructura nativa, ¿existe un ψ que la induzca sin destruir la señal?

Camino a la Conjetura 1 (antes de la fórmula)

1. **Literatura:** un solo indicador no basta (Huang et al., 2021; Liu et al., 2021; Thanasilp et al., 2022).
2. **Hecho empírico:** en nativo hay ventaja; en SKG/Telco no (vs. GB/RF).
3. **Notebook 08:** medimos ΔA, d_F, $H(K)$ sobre los tres datasets.
4. **Hallazgo:** d_F rankea mejor; ΔA se degrada con PCA a 2 qubits.
5. **Barrido sintético** en α (fracción de estructura ZZ): $\rho_S(\mathcal{Q}, \text{ventaja}) = 0{,}833$ (p=0,005, n=9).
6. **Propuesta:** un score *compuesto* e interpretable — no un oráculo de despliegue.

Camino a $\mathcal{Q}$: evidencia visual (NB08)





$\mathcal{Q} > 0$ vs. RBF en SKG **no** implica compatibilidad operativa (GB/RF ganan; $\mathcal{Q}_{\text{rob}}$: `classical`).

Conjetura 1 — score $\mathcal{Q}(\mathcal{D})$

$$\mathcal{Q}(\mathcal{D}) = w_1 \Delta A + w_2 \hat{d}_F + w_3 \Delta H, \qquad \sum_i w_i = 1,\ w_i \geq 0 \tag{1}$$

ΔA: señal vs. etiquetas; $\hat{d}_F$: no-aproximabilidad clásica; ΔH: riqueza espectral.

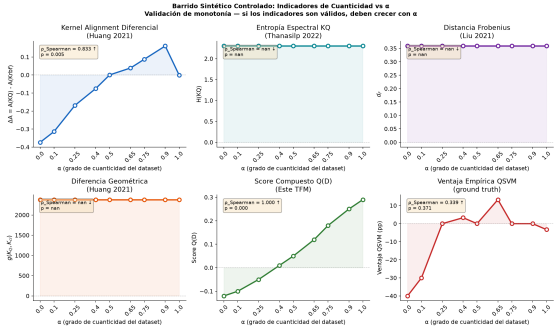
Qué sí

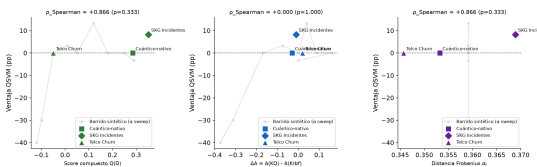
Diagnóstico *a priori* útil en barrido sintético (ρ_S=0,833).

Qué no

$\mathcal{Q} > 0$ vs. RBF $\neq$ "desplegar QSVM" (contraejemplo SKG). Cruzar siempre con GB/RF y $\mathcal{Q}_{\mathrm{rob}}$.

Validación P1 — barrido sintético y correlaciones





Camino a la Conjetura 2 / QCR (antes de la fórmula)

1. Si el diagnóstico dice "clásico", el default es el stack clásico.
2. Pero la pregunta correcta es: ¿falla el **dato** o el **espacio de representación**?
3. Hipótesis: existe $\psi : \mathcal{X} \to \mathcal{Z}$ polinómica que induzca geometría usable por el feature map **sin** destruir la señal.
4. **Notebook 09:** cuatro prototipos — ZZ-compatibles, rotación máx d_F, re-uploading, Q-UMAP/MDS.
5. Resultado: subidas locales de $\mathcal{Q}$ *vs. RBF*; bajo $\mathcal{Q}_{\text{rob}}$ Telco sigue `classical` y SKG solo cambia geometría (`try-ZZ`), **sin** lift de accuracy vs. GB/RF.

Lectura

QCR es un **programa de investigación** formalizado desde la evidencia — no un algoritmo cerrado ni un rescate operativo.

Conjetura 2 — espacio de representación QCR

Si $\mathcal{Q}(\mathcal{D}) \leq 0$, se conjetura $\mathcal{Z}$ y $\psi : \mathcal{X} \to \mathcal{Z}$ **polinómica** tales que

$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^\star} \hat{y} \qquad \text{con} \quad \mathcal{Q}(\psi(\mathcal{D})) > 0 \;\text{ y }\; \varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star). \tag{2}$$

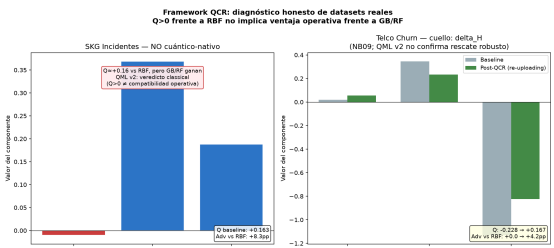
Intuición

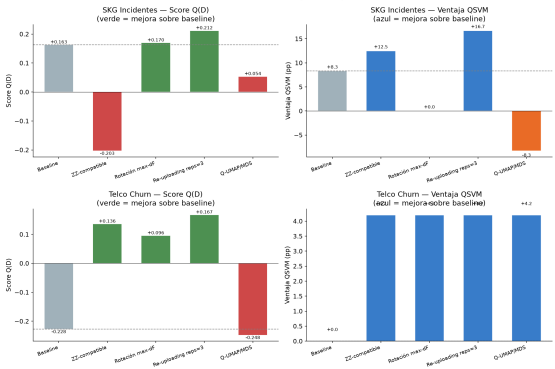
Transformar el dato *antes* del kernel para que el mapa "vea" estructura usable.

Estado

Conjetura **abierta**.
Este TFM la **plantea** + evidencia preliminar — no demostración.

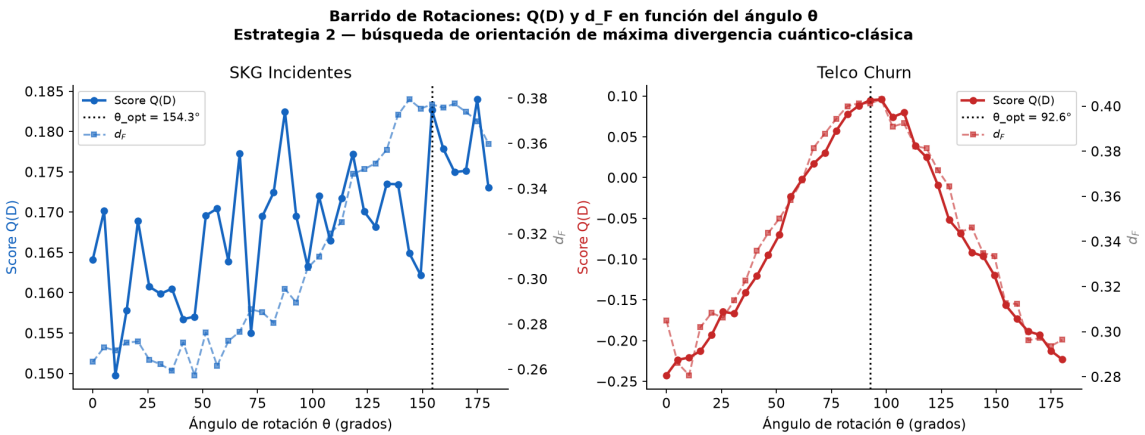
Evidencia P2 — diagnóstico y mapeos (NB09)





SKG/Telco: **no** cuántico-nativos. Lift NB09 vs. RBF $\neq$ ventaja vs. GB/RF; bajo $\mathcal{Q}_{\text{rob}}$ Telco sigue `classical`.

Evidencia P2 — barrido de rotaciones



Conclusiones (I) — ventaja condicionada

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: aparece cuando el feature map coincide con el generador (ZZ medido aquí; Pauli-Y confirma el mismo principio).
3. En **datos reales** SKG/Telco **sin** esa estructura: gana GB/RF (no son cuántico-nativos).
4. Regresión: ventaja acotada (Friedman); en movilidad SKG, árboles dominan.
5. Anomalías / lags: misma regla — solo con target alineado (`zz_phase`, `zz_lag`).

Conclusiones (II) — híbridos y coste

6. QAOA reduce coste de asignación $\approx 30\,\%$ vs. Greedy a escala moderada.
7. VQE competitivo en portafolio pequeño; TSP n=4: empate óptimo (valor de *modelado*, no speedup).
8. MDS: patrón híbrido viable ($P(\mathrm{opt}) \approx 73\,\%$).
9. Coste de simulación del kernel $O(n^2)$: obstáculo práctico actual.
10. Metodologías maduras vs. hardware inmaduro: resultados mixtos son esperables en NISQ.

Conclusiones (III) — conjeturas y adopción

11. $\mathcal{Q}(\mathcal{D})$: diagnóstico útil en barrido sintético (ρ_S=0,833); en reales, n pequeño y matizado por $\mathcal{Q}_{\mathrm{rob}}$.
12. QCR: **planteado formalmente**; evidencia preliminar; no demostración ni rescate operativo.
13. Adopción recomendada: **selectiva e híbrida** — módulo cuántico como herramienta adicional, no sustituto del stack clásico (SKG).

Respuesta a la pregunta del TFM

Ventaja medible hoy cuando hay coincidencia mapa–generador o QUBO híbrido viable; en ausencia de eso, el clásico domina — y eso también es un resultado.

Limitaciones (I)

- **Simulación statevector**: sin ruido NISQ de hardware; ideales $\neq$ shots reales.
- **PCA a** n_q=2: $\sim$68 % de varianza descartada; $\mathcal{Q}$ mide el subespacio proyectado.
- **Muestra** $n\approx$80 en indicadores; correlación en 3 datasets reales es orientativa.
- **Baseline RBF**: $\mathcal{Q} > 0$ vs. RBF $\neq$ ventaja vs. GB/RF (caso SKG).

Limitaciones (II)

- **QCR** sin demostración fuerte; Q-UMAP sin métrica cuántica real (MDS proxy).
- **Un feature map operativo principal** (ZZ), con validación cruzada Pauli-Y limitada.
- **TSP**: empate óptimo $\neq$ speedup asintótico.
- **Escalabilidad**: kernel $O(n^2)$ limita n en simulación; no se evaluó hardware real.
- **Datos SKG**: fraction de la operación; no cierran todos los casos de uso empresariales.

Trabajo futuro (I) — corto plazo y SKG

Corto plazo

- Hardware ruidoso (IBM) + mitigación (ZNE)
- Más qubits / menos PCA agresivo
- Validación fuerte de QCR y $\mathcal{Q}_{\mathrm{rob}}$
- Calibrar pesos (w_i); más feature maps (IQP, Pauli)
- Kernels aleatorizados $O(n)$ / ensembles

Aplicación SKG

- QAOA en asignación real (`agents.csv`)
- VRP-TW / rutas de emergencia
- Multiclase de gravedad de incidentes
- Activación selectiva en pipeline productivo
- A/B testing cuántico–clásico

Trabajo futuro (II) — medio/largo plazo

- Benchmarks con separación formal (Bravyi et al.) para certificar $\mathcal{Q}$
- Certificación estadística de ventaja (Huang et al., 2021)
- Demostración o refutación de la conjetura QCR
- Q-means / autoencoders / aprendizaje no supervisado cuántico
- Análisis de barren plateaus en VQC
- Integración API + monitorización de *data drift* en SKG

Trabajo futuro (III) — roadmap

Corto (1–2 a)	Medio (2–4 a)	Largo (4+ a)
Hardware IBM + ZNE	4–8 qubits, menos PCA	FTQC / corrección errores
API + A/B test SKG	QAOA asignación real	Demostrar / refutar QCR
QAOA $p>1$ / SPSA	Validar $\mathcal{Q}$ en corpus amplio	QCR multi-mapa + publicación

Validación cruzada ZZ vs Pauli-Y (principio general)

Resultado (QML v2, n=120, 5 repeats)

- Generador ZZ $\Rightarrow$ QSVM-ZZ 0,828 vs RBF 0,478
- Generador Pauli-Y $\Rightarrow$ QSVM-PauliY 0,550 vs RBF 0,517
- Kernel ZZ *desalineado* cae a 0,406

Lectura

La ventaja sigue al **emparejamiento** mapa–generador. ZZ es el mapa del corpus principal; **no** el único admisible.

Gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

(Preskill, 2018; Biamonte et al., 2017; Farhi et al., 2014; Schuld, 2021; Huang et al., 2021; Liu et al., 2021; Cerezo et al., 2021)

Referencias (selección) I

Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. et al. (2019). *Machine learning methods in quantum computing theory*. Proc. SPIE.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Referencias (selección) II

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S. et al. (2022). *Exponential concentration and the limits of quantum ML*. arXiv:2208.11060.