Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica · UNIR

Director: Ricardo Rafael Domínguez Reyes

unir LA UNIVERSIDAD EN INTERNET

ÍNDICE

01 – Motivación

02 – Introducción

03 – Contexto y estado de la técnica

04 – Planteamiento y metodología

05 – Resultados: Q vs C

06 – Conjeturas: $\mathcal{Q}$ y QCR

07 – Evidencia de las conjeturas

08 – Conclusiones y limitaciones

09 – Trabajo futuro

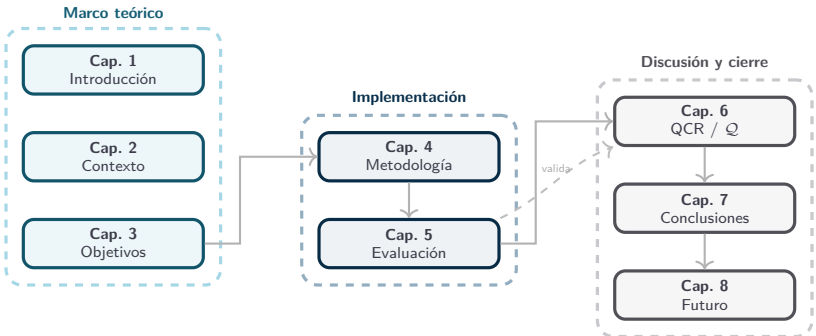
Motivación
La brecha entre promesa y evidencia

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

Pregunta práctica

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

Motivación
Estructura del TFM



Introducción
Planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Hipótesis operativa

La ventaja es **real pero condicionada**:

1. coincidencia **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

Introducción
Alcance

Familias industriales (5)

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Detección de anomalías (OCSVM-ZZ)
- Optimización (QAOA / VQE)
- Series temporales (QK-SVR sobre lags)

Nueve casos de uso con protocolo justo en el documento.

Tres capas de datos

1. Sintéticos con estructura cuántica nativa (diseño propio)
2. Práctica SKG Tecnología
3. Referencia pública

Contexto y estado de la técnica
Era NISQ

NISQ (Preskill, 2018)

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

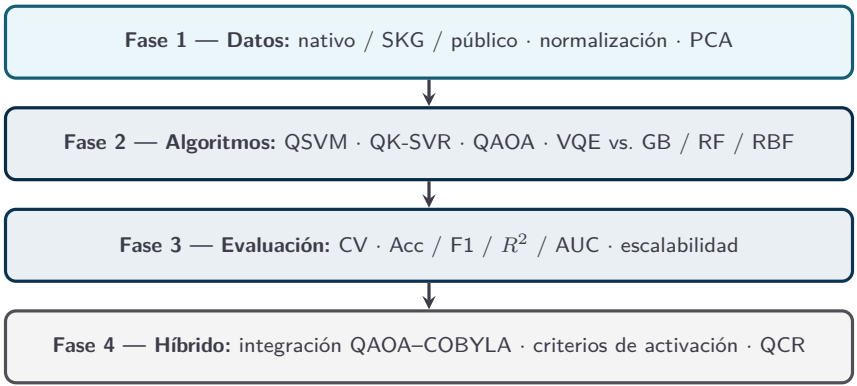
Contexto y estado de la técnica
Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Separación rigurosa para un problema basado en el logaritmo discreto (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2024).
- Gap que aborda este TFM: comparaciones **justas** sobre datos empresariales reales.

Posicionamiento de este TFM

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

Planteamiento y metodología
Metodología en cuatro fases



Planteamiento y metodología

Diseño: 5 familias $\times$ 3 capas de datos

Familia	Cuántico	Clásico de referencia
Clasificación	QSVM (ZZ)	GB, RF, SVM-RBF
Regresión	QK-SVR	RF, XGBoost, SVR-RBF, Ridge
Anomalías	OCSVM-ZZ	IsolationForest, LOF
Optimización	QAOA / VQE	Greedy, ILP, NN+2-opt
Series temporales	QK-SVR (lags)	Ridge, SVR-RBF, GB

Misma pregunta en las cinco: **¿quién gana, Q o C?** en (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia**.

Lectura transversal

Kernels: ventaja si mapa y generador coinciden. Optimización: QUBO + híbrido a escala viable (no speedup asintótico).

Planteamiento y metodología
Criterio de activación del módulo cuántico

Problema	Activar si	Módulo Q	Fallback
Clasif. / Regresión	coincidencia mapa–generador y vence a GB/RF (no basta $\mathcal{Q} > 0$ vs RBF)	QSVM / QK-SVR	GB / RF
Anomalías	novedad alineada al mapa (`zz_phase`)	OCSVM-ZZ	IF / LOF
Forecasting	target alineado (`zz_lag`)	QK-SVR	Ridge / GB
Optimización / TSP	QUBO factible, n viable	QAOA / VQE	Greedy / ILP / 2-opt
Caso general	SKG/Telco sin estructura ZZ o n demasiado grande	**no se activa**	pipeline clásico

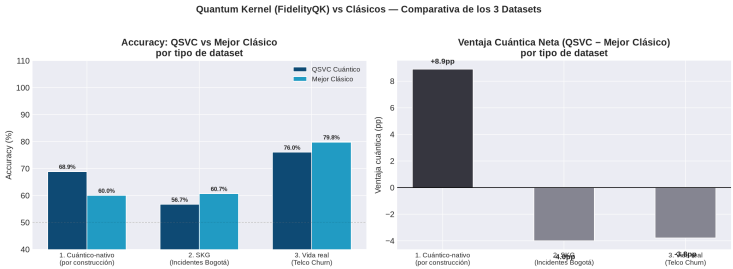
Resultados: Q vs C
Qué comparamos

Familia	Nativo	SKG	Referencia
1. Clasificación (QSVM)	ZZ sintético	Incidentes Bogotá	Telco Churn
2. Regresión (QK-SVR)	target alineado	Movilidad Bogotá	Friedman #1
3. Anomalías (OCSVM-ZZ)	`zz_phase`	outliers inyectados	moons
4. Optimización (QAOA)	asignación QUBO	cobertura MDS	TSP $n{=}4$
5. Series temporales (QK-SVR)	`zz_lag`	velocidad de corredores	`sine`

Formato fijo en las 5 diapositivas siguientes

Plot (o tabla) + misma lectura: **Nativo / SKG / Referencia** → gana Q o gana C. Sin formalismo, sin ejemplos narrativos, sin algoritmos fuera del TFM.

Resultados: Q vs C
1. Clasificación (QSVM vs clásico)

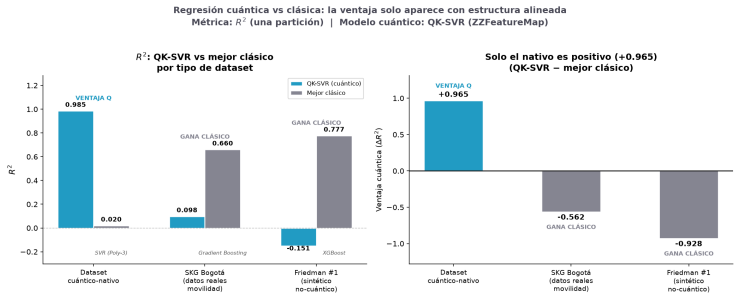


Q vs C

- **Nativo:** gana Q ($+8.9$ pp)
- **SKG:** gana C ($-4{,}0$ pp)
- **Telco:** gana C ($-3{,}8$ pp vs GB; $-23{,}8$ pp en protocolo justo)

Baseline = mejor clásico.
También: Q más lento ($1/t \approx 0$).

Resultados: Q vs C
2. Regresión (QK-SVR vs clásico)

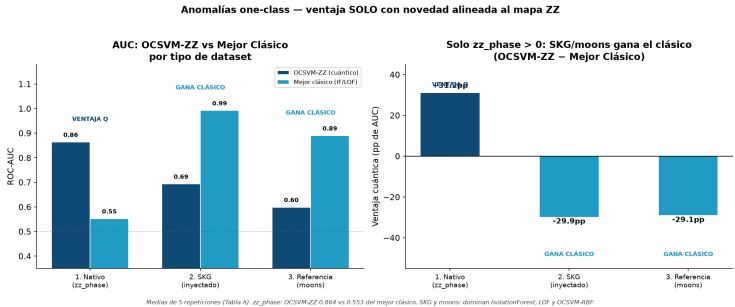


Q vs C

- **Nativo:** gana Q (por construcción) ($\Delta R^2 = +0{,}965$; R^2 de $0{,}985$ vs $0{,}020$)
- **SKG:** gana C ($\Delta R^2 = -0{,}562$)
- **Friedman:** gana C ($\Delta R^2 = -0{,}928$)

Ventaja solo con estructura alineada.

Resultados: Q vs C
3. Anomalías (OCSVM-ZZ vs clásico)



Q vs C

- **Nativo:** gana Q (+31.2 pp AUC)
- **SKG:** gana C ($-29{,}9$ pp)
- **moons:** gana C ($-29{,}1$ pp)

Misma lectura que clasif./regresión: ventaja solo con novedad alineada al mapa.

Resultados: Q vs C
4. Optimización (QAOA/VQE vs clásico)

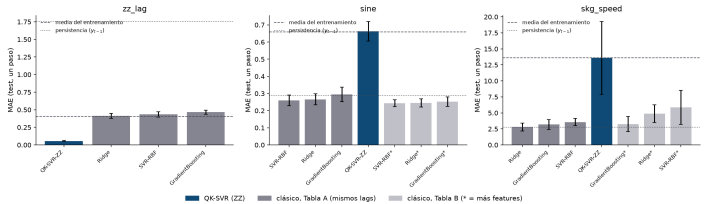
Capa	Problema	Cuántico	Clásico
Sintético	Asignación QUBO	QAOA = óptimo exacto (5/5); sin ventaja	Hungarian / PuLP
Sintético	MDS (cobertura)	6 nodos: óptimo; ER n=6–15: MDS óptimo 2/5	ILP / Greedy: 5/5
Referencia	Portafolio (3 de 6)	Óptimo: QAOA 6/10, VQE 3/10	Greedy: óptimo
Referencia	TSP n=4	empate óptimo	NN+2-opt (gap 0)

Q vs C (misma pregunta)

- **Asignación y portafolio:** sin ventaja; óptimo en 6/10 (QAOA) y 3/10 (VQE) semillas.
- **MDS:** empate en la red de 6 nodos ($P(\text{opt})$ media $5{,}7\,\%$); en grafos ER gana C (-60 pp de instancias con MDS óptimo).
- **TSP:** empate en calidad; **no** hay speedup — modelado QUBO.

Contraste en coste/calidad de solución; estructura QUBO: notebook 11.

Resultados: Q vs C
5. Series temporales (QK-SVR vs clásico)



Un paso adelante, 2 lags; MAE en test, división temporal 70/30, 5 repeticiones.

Q vs C

- **Nativo (`zz_lag`):** gana Q (MAE $0{,}056$ vs $0{,}414$ de Ridge)
- **SKG (corredores):** gana C ($2{,}80$ de Ridge, $\approx$ persistencia, vs $13{,}59$)
- **Referencia (`sine`):** gana C ($0{,}260$ vs $0{,}662$, $=$ media del entrenamiento)

Resultados: Q vs C
Síntesis 5 × 3

Familia	Nativo	SKG	Referencia
Clasificación	**gana Q**	gana C	gana C
Regresión	**gana Q**	gana C	gana C
Anomalías	**gana Q**	gana C	gana C
Optimización	sin ventaja: QAOA empata en asignación y TSP; portafolio, 6/10 semillas		
Series temporales	**gana Q**	gana C	gana C

Mensaje único

Ventaja cuántica **condicionada**: aparece con alineación mapa–generador (en optimización, QUBO viable sin ventaja medida). En datos reales SKG/Telco sin esa estructura: pipeline clásico.

Conjeturas
De la evidencia emergen dos preguntas

Preguntas originales (Cap. 6)

1. **P1 — tests de cuanticidad**

   ¿Se puede diagnosticar *a priori* si un dataset tiene *estructura cuántica* (alineación mapa–dato) y, por tanto, admitirá ventaja?

2. **P2 — mapeos cuántico-compatibles**

   Si no hay estructura nativa, ¿existe un nuevo mapeo ψ y un espacio de representación donde se conserve la estructura e información del dato, adquiera estructura cuántica, y haya mapa de vuelta si hace falta? (analogía: Fourier)

Conjeturas
Camino a la Conjetura 1 (I) — por qué un perfil

Literatura

- Ventaja cuántica de kernel $\Rightarrow$ alineación con etiquetas **y** geometría no reproducible por el clásico (Huang et al., 2021; Liu et al., 2021).
- Un solo indicador no basta: hace falta $A_Q > A_{cl}$ **y** d_F grande (Huang et al., 2021; Schuld, 2021).
- Riesgo: el kernel cuántico puede **concentrarse** y perder señal — vigilar $H(K)$ (Thanasilp et al., 2024).

Hecho empírico

Ventaja si el mapa que estructura el dato = mapa del modelo **cuántico**. Si no: gana el **clásico**.

Idea corregida

No un escalar: un **vector** $\mathcal{Q}(\mathcal{D}) = (\Delta A, \hat{d}_F, \Delta H, \hat{g}, \ldots)$ que se *mira* componente a componente.

Conjeturas
Camino a la Conjetura 1 (II) — componentes y evidencia

Interpretación (cuántico vs clásico)

- ΔA — ¿el cuántico ve mejor las clases?
  > 0: sí, más alineación con las etiquetas que el clásico (Cortes et al., 2012; Huang et al., 2021).
- $\hat{d}_F$ — ¿la geometría es distinta?
  Grande: el cuántico no es un clásico disfrazado (Liu et al., 2021).
- ΔH — ¿el kernel cuántico aporta diversidad o se ha "aplanado"?
  Bajo/negativo: todas las similitudes se parecen (concentración) $\Rightarrow$ poca info útil (Thanasilp et al., 2024).
- $\hat{g}$ — ¿el RBF reproduce la geometría cuántica?
  Cerca de 1: sí; grande: no (necesario, no suficiente) (Huang et al., 2021).

Evidencia (TFM)

Barrido α (n=9, NB08): mezcla de etiquetas, X fijo.

Hallazgo robusto: $\rho_S(\alpha, \Delta A)$=0,833 (p=0,005).

d_F/H constantes por diseño; no confundir con $\rho(\mathcal{Q}, \text{ventaja})$.

Conjeturas
Conjetura 1 — $\mathcal{Q}(\mathcal{D})$ como vector, no escalar

$$\mathcal{Q}(\mathcal{D}) \;=\; \big(\Delta A,\; \hat{d}_F,\; \Delta H,\; \hat{g}\big) \qquad \text{(perfil; sin pesos)} \tag{1}$$

Opcional en el documento: un escalar $w^\top \mathcal{Q}$ se probó y **falla** como ranking operativo — por eso no se usa para decidir.

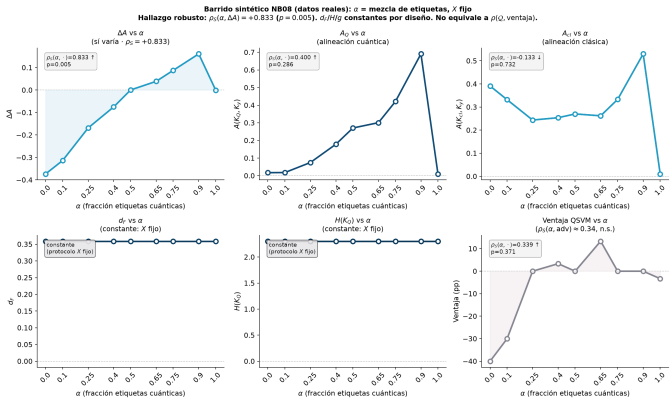
Cómo se lee

- ΔA: ¿mejor alineación que el clásico?
- $\hat{d}_F$: ¿geometría distinta?
- ΔH: ¿diversidad o concentración?
- $\hat{g}$: ¿el RBF reproduce la geometría cuántica?

Límite

El vector describe geometría vs. RBF. La adopción exige ventaja vs. mejor clásico **en la familia** (clasif./reg./anomalías) y alineación mapa–generador.

Conjeturas
Validación P1 — barrido sintético (α)



Qué es (NB08 real)

- α: fracción de etiquetas cuánticas (X fijo).
- ΔA crece con α: ρ_S=0,833 (p=0,005).
- d_F y H **constantes** (kernels no cambian con labels).

Límite

ρ=0,833 es $\rho(\alpha, \Delta A)$, no $\rho(\mathcal{Q}, \text{ventaja})$.

Barrido structure-aware: trabajo futuro.

Conjeturas
P1 — qué comparamos (mismas métricas)

Estructura cuántica = vector $(\Delta A,\ \Delta H,\ d_F,\ g,\ \mathcal{Q})$

- $\Delta A = A(K_Q, yy^\top) - A(K_{\mathrm{RBF}}, yy^\top)$ — alineación de (Cortes et al., 2012)
- $\Delta H = H(K_Q) - H(K_{\mathrm{RBF}})$ — proxy de (Thanasilp et al., 2024)
- $d_F = \|K_Q - K_{\mathrm{RBF}}\|_F / n$ — proxy propio (cf. (Liu et al., 2021))
- g (diferencia geom.) — (Huang et al., 2021); $\mathcal{Q}$ compuesto (este TFM)

Mismo protocolo en clasificación, regresión, anomalías y optimización (ZZ 2q, n=60, 3 repeats, RBF Frobenius-best).
Optimización = **paisaje QUBO** (bitstrings → energía), no QAOA.
Control nulo: ΔA con y permutada. Sin accuracy / R^2 / AUC / coste.

Nota: no hay Δ_{op} aquí

Eso era solo un nombre confuso para "accuracy(QSVM)−accuracy(mejor clásico)" en clasificación. **No** es métrica de estructura. Se retiró de estas figuras.

Conjeturas
P1 — qué mide g (Huang et al., 2021)

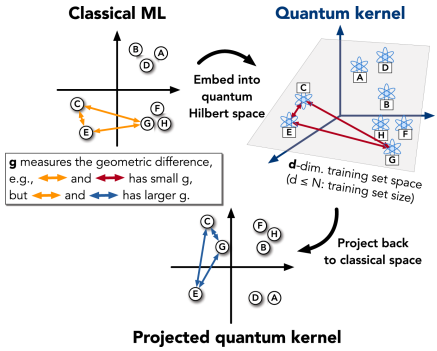


Fig. 2 de Huang et al. (2021), CC BY 4.0

Idea

g compara las **flechas** (similitudes kernel) entre puntos en el espacio clásico y en el cuántico. g pequeño: el kernel clásico ya reproduce la geometría cuántica; g grande: no.

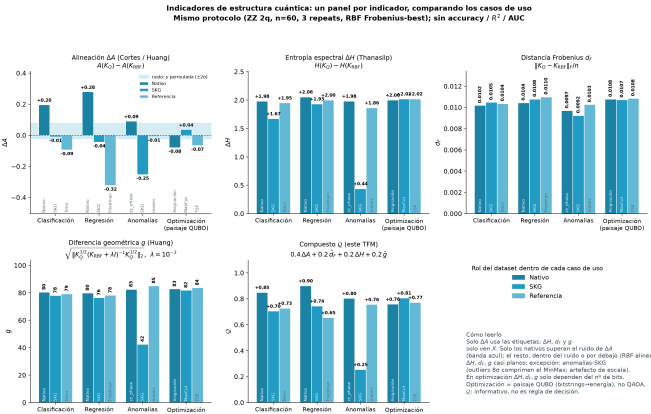
d = dimensión efectiva del dato en Hilbert.

Nuestra medición

g: necesario, no suficiente; no usa y. Huang (λ=10^{-3}): $g \approx 76$–85 en casi todos los casos (42 en anomalías-SKG, artefacto). $g \gg 1$ pero igual para nativos y reales: **no discrimina**. Antes ≈ 3000 (artefacto).

Conjeturas

P1 — los cinco indicadores en los cuatro casos de uso



Cómo leerlo

Un panel por indicador; eje X = caso de uso; 3 barras = Nativo / SKG / Referencia (optimización: asignación / MaxCut / TSP).

- ΔA: solo los nativos superan el ruido (banda azul); el resto, dentro del ruido o por debajo (incluida la optimización)
- ΔH, d_F, g: casi planos; excepción anomalías-SKG = artefacto de escala (outliers 8σ comprimen el MinMax)
- $\mathcal{Q}$: informativo; lo dominan indicadores planos

Conjeturas
P1 — cómo interpretar

¿ΔA negativo + ΔH mínimo = estructura?

No. Los **nativos** tienen $\Delta A > 0$ sobre el ruido (clasif. $+0{,}20$, reg. $+0{,}28$, anom. $+0{,}09$); los datos reales y los paisajes de optimización quedan dentro o por debajo del nulo ($\Delta A < 0 =$ el RBF alinea mejor, no "estructura negativa"). El único ΔH mínimo (anomalías-SKG, $0{,}44$) es un artefacto de escala.

¿d_F discrimina?

Aquí, apenas: $\approx 0{,}01$ en todos los casos; g y ΔH también planos. Solo ΔA usa y; los otros tres solo ven X.

Lectura defendible

Lo que separa estructura es ΔA (alineación mapa–dato (Liu et al., 2021; Huang et al., 2021)), no d_F, g ni ΔH. Optimización: paisaje QUBO con 2 qubits (PCA retiene $\approx 1/3$): **sin evidencia** de estructura; límite del diseño.

Conjeturas
Camino a la Conjetura 2 — la analogía de Fourier

La pregunta natural de un matemático

Un problema difícil en el dominio original se vuelve simple en otro espacio, y se regresa si hace falta. Ejemplo: la transformada de Fourier $\hat{f}(\omega) = \int f(x)\, e^{-i\omega x}\, dx$ convierte convolución en producto.

Tres propiedades la hacen útil: **conserva la información** (invertible); la **estructura se ve** (se vuelve diagonal); tiene **mapa de vuelta**.

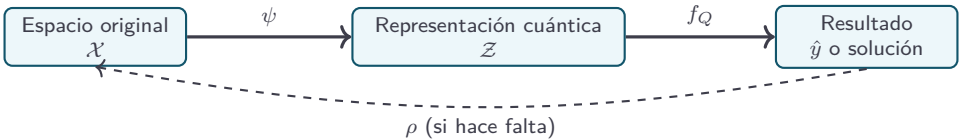
Y no es un mapa arbitrario

Viene de un **núcleo** (kernel) $e^{-i\omega x}$. Por el teorema de Bochner, los kernels invariantes por traslación son transformadas de Fourier de una medida: el mapa de características de un kernel *es* un mapeo de tipo Fourier.

La analogía con el kernel cuántico

Si el dato no tiene estructura cuántica, ¿existe un **nuevo mapeo** ψ **y un espacio de representación** $\mathcal{Z}$ donde se conserve la estructura e información del dato, adquiera estructura cuántica y se pueda sacar partido de los algoritmos cuánticos, con un mapeo de vuelta al espacio original cuando haga falta?

Conjeturas
Conjetura 2 — espacio de representación QCR



Qué se pide de ψ

1. **Conserva estructura e información** de los datos.
2. **Estructura cuántica**: $\mathcal{Q}(\psi(\mathcal{D})) > 0$.
3. **Mapa de vuelta** ρ al espacio original cuando se necesite (p. ej. optimización).
4. Utilidad: $\varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star)$.

Sobre la naturaleza de ψ

ψ **no tiene por qué ser un polinomio**: Fourier usa exponenciales y nace de un kernel. Con ventaja global, el coste de calcular ψ debe contarse.

Estado

Conjetura **abierta**: este TFM la **plantea**. Prototipos (NB 09): sin ventaja frente al clásico fuerte. Sin demostración.

Conclusiones (I) — ventaja condicionada

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: aparece cuando el feature map coincide con el generador (ZZ medido aquí; Pauli-Y confirma el mismo principio).
3. En **datos reales** SKG/Telco **sin** esa estructura: gana el **clásico** (no son cuántico-nativos).
4. Regresión: ventaja solo en el dataset nativo, por construcción ($\Delta R^2 = +0{,}965$); en Friedman y en movilidad SKG, el clásico domina.
5. Anomalías / lags: misma regla — solo con target alineado (`zz_phase`, `zz_lag`).

Conclusiones (II) — híbridos y coste

6. Optimización: QAOA iguala al óptimo exacto en asignación (5/5) y empata en TSP $n{=}4$ (valor de *modelado*, no speedup); en portafolio, QAOA acierta el óptimo en 6 de 10 semillas y VQE en 3 de 10.
7. MDS: empate en 6 nodos; en grafos ER ($n{=}6$–15) QAOA obtiene el MDS óptimo en $2/5$ instancias (ILP y Greedy, 5/5).
8. Coste de simulación del kernel $O(n^2)$: obstáculo práctico actual.
9. Metodologías maduras vs. hardware inmaduro: resultados mixtos son esperables en NISQ.

Conclusiones (III) — conjeturas y adopción

11. $\mathcal{Q}(\mathcal{D})$ como **vector** $(\Delta A, \hat{d}_F, \Delta H, \hat{g})$; el escalar colapsado no se usa; sí $\rho_S(\alpha, \Delta A)$=0,833.
12. QCR: **planteado**; evidencia preliminar vs. RBF; no rescate operativo.
13. Adopción recomendada: **selectiva e híbrida** — módulo cuántico como herramienta adicional, no sustituto del stack clásico (SKG).

Respuesta a la pregunta del TFM

Ventaja medible hoy cuando hay coincidencia mapa–generador o QUBO híbrido viable; en ausencia de eso, el clásico domina — y eso también es un resultado.

Conclusiones
Limitaciones (I)

- **Simulación statevector**: sin ruido NISQ de hardware; ideales $\neq$ shots reales.
- **PCA a** $n_q{=}2$: $\sim$68–69 % de varianza descartada en SKG y Telco (NB08); $\mathcal{Q}$ mide el subespacio proyectado.
- **Muestra** $n{\approx}80$ en indicadores; correlación en 3 datasets reales es orientativa.
- **Baseline**: $\mathcal{Q} > 0$ vs. un clásico débil $\neq$ ventaja vs. el mejor clásico (caso SKG).
- **Protocolos distintos**: Δ_{RBF} (NB08) $\neq$ ventaja vs mejor clásico (clasificación / NB06); no se mezclan en una sola ρ ni en la misma leyenda.

Limitaciones (II) — debilidades expuestas

- **Barrido** α: X fijo $\Rightarrow$ d_F/H constantes; ρ_S=0,833 es $\rho(\alpha, \Delta A)$, no predicción de ventaja.
- **Sin dumps de** K: no se inventan heatmaps ni contrastes a mano.
- **Rotaciones NB09**: series del notebook; no regenerar con curvas proxy.
- **Post-QCR**: solo Q/Adv logueados; no inventar componentes post.
- **QCR** sin demostración fuerte; Q-UMAP = MDS proxy.
- **Escalabilidad**: kernel $O(n^2)$; sin hardware real.

Trabajo futuro (I) — corto plazo y SKG

Corto plazo

- Hardware ruidoso (IBM) + mitigación (ZNE)
- Más qubits / menos PCA agresivo
- Validación fuerte de QCR y $\mathcal{Q}_{\text{rob}}$
- Calibrar pesos (w_i); más feature maps (IQP, Pauli)
- Kernels aleatorizados $O(n)$ / ensembles

Aplicación SKG

- QAOA en asignación real (`agents.csv`)
- VRP-TW / rutas de emergencia
- Multiclase de gravedad de incidentes
- Activación selectiva en pipeline productivo
- A/B testing cuántico–clásico

Trabajo futuro (II) — medio/largo plazo

- Benchmarks con separación formal (Bravyi et al.) para certificar $\mathcal{Q}$
- Diferencia geométrica y cotas de ventaja potencial (Huang et al., 2021)
- Demostración o refutación de la conjetura QCR
- Q-means / autoencoders / aprendizaje no supervisado cuántico
- Análisis de barren plateaus en VQC
- Integración API + monitorización de *data drift* en SKG

Trabajo futuro (III) — roadmap

Corto (1–2 a)	Medio (2–4 a)	Largo (4+ a)
Hardware IBM + ZNE	4–8 qubits, menos PCA	FTQC / corrección errores
API + A/B test SKG	QAOA asignación real	Demostrar / refutar QCR
QAOA $p>1$ / SPSA	Validar $\mathcal{Q}$ en corpus amplio	QCR multi-mapa + publicación

muchas gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

Referencias (selección) I

Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). *Algorithms for learning kernels based on centered alignment*. JMLR, 13, 795–828.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. V. et al. (2019). *Machine learning methods in quantum computing theory*. arXiv:1906.10175.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Referencias (selección) II

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S., Wang, S., Cerezo, M., & Holmes, Z. (2024). *Exponential concentration in quantum kernel methods*. Nat. Commun., 15, 5200.