Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica · UNIR

Director: Ricardo Rafael Domínguez Reyes

unir LA UNIVERSIDAD EN INTERNET

ÍNDICE

01 – Motivación

02 – Introducción

03 – Contexto y estado de la técnica

04 – Planteamiento y metodología

05 – Resultados: Q vs C

06 – Conjeturas: $\mathcal{Q}$ y QCR

07 – Evidencia de las conjeturas

08 – Conclusiones y limitaciones

09 – Trabajo futuro

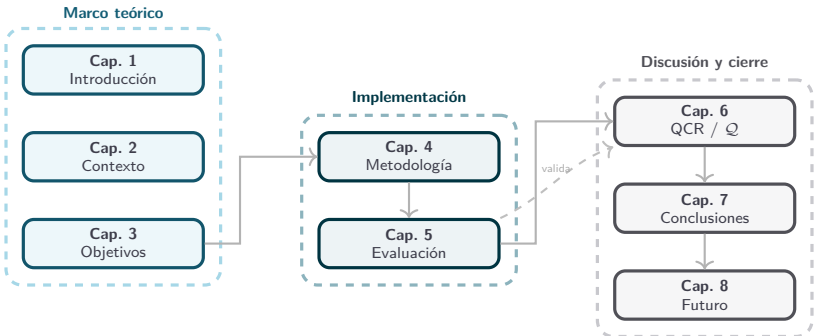
Motivación
La brecha entre promesa y evidencia

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

Pregunta práctica

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

Motivación
Estructura del TFM



Introducción
Planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Hipótesis operativa

La ventaja es **real pero condicionada**:

1. coincidencia **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

Introducción
Alcance

Familias industriales (4)

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Optimización combinatoria (QAOA)
- Optimización / híbrido (VQE + MDS)

Extendidas a 9 protocolos justos en el documento (anomalías, TSP, lags,. . .).

Tres capas de datos

1. Sintéticos con estructura cuántica nativa (Liu et al., 2021)
2. Práctica SKG Tecnología
3. Referencia pública

Contexto y estado de la técnica
Era NISQ

NISQ (Preskill, 2018)

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

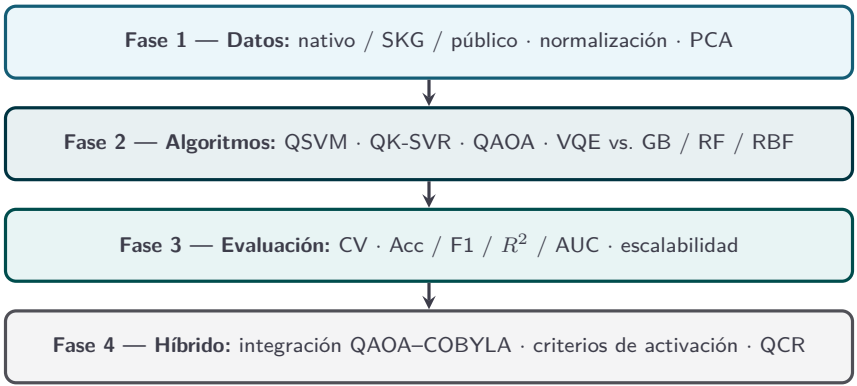
Contexto y estado de la técnica
Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Datasets donde el kernel cuántico es óptimo por construcción (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2022).
- Gap empírico: pocos estudios **justos** sobre datos empresariales reales (Fastovets et al., 2019).

Posicionamiento de este TFM

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

Metodología en cuatro fases



Planteamiento y metodología
Diseño: 4 familias $\times$ 3 capas de datos

Familia	Cuántico	Clásico de referencia
Clasificación	QSVM (ZZ)	GB, RF, SVM-RBF
Regresión	QK-SVR	RF, XGBoost, SVR-RBF, Ridge
Anomalías	OCSVM-ZZ	IsolationForest, LOF
Optimización	QAOA / VQE	Greedy, ILP, NN+2-opt

Misma pregunta en las cuatro: **¿quién gana, Q o C?** en (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia**.

Lectura transversal

Kernels: ventaja si mapa y generador coinciden. Optimización: QUBO + híbrido a escala viable (no speedup asintótico).

Planteamiento y metodología
Criterio de activación del módulo cuántico

Problema	Activar si	Módulo Q	Fallback
Clasif. / Regresión	coincidencia mapa–generador y vence a GB/RF (no basta $\mathcal{Q} > 0$ vs RBF)	QSVM / QK-SVR	GB / RF
Anomalías	novedad alineada al mapa (`zz_phase`)	OCSVM-ZZ	IF / LOF
Forecasting	target alineado (`zz_lag`)	QK-SVR	Ridge / GB
Optimización / TSP	QUBO factible, n viable	QAOA / VQE	Greedy / ILP / 2-opt
Caso general	SKG/Telco sin estructura ZZ o n demasiado grande	**no se activa**	pipeline clásico

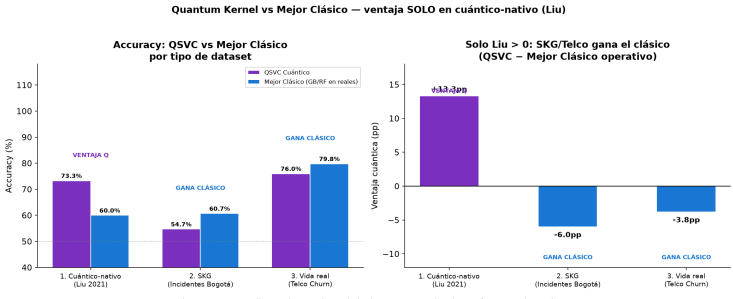
Resultados: Q vs C
Qué comparamos

Familia	Nativo	SKG	Referencia
1. Clasificación (QSVM)	Liu ZZ	Incidentes Bogotá	Telco Churn
2. Regresión (QK-SVR)	target alineado	Movilidad Bogotá	Friedman #1
3. Anomalías (OCSVM-ZZ)	`zz_phase`	outliers inyectados	moons
4. Optimización (QAOA)	asignación QUBO	cobertura MDS	TSP $n{=}4$

Formato fijo en las 4 diapositivas siguientes

Plot (o tabla) + misma lectura: **Nativo / SKG / Referencia** $\rightarrow$ gana Q o gana C. Sin formalismo, sin ejemplos narrativos, sin algoritmos fuera del TFM.

Resultados: Q vs C
1. Clasificación (QSVM vs clásico)

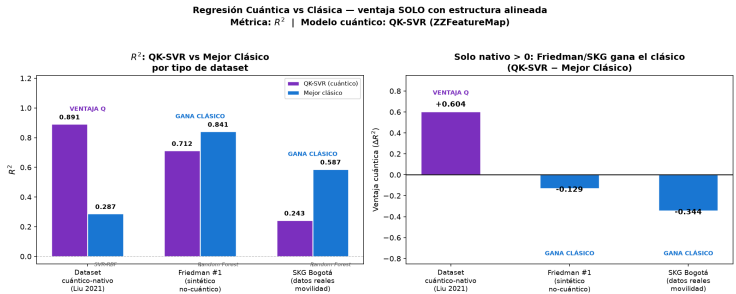


Q vs C

- **Nativo:** gana Q ($+13.3$ pp)
- **SKG:** gana C ($-6{,}0$ pp)
- **Telco:** gana C ($-3{,}8$ pp vs GB)

Baseline = mejor clásico.
También: Q más lento ($1/t \approx 0$).

Resultados: Q vs C
2. Regresión (QK-SVR vs clásico)

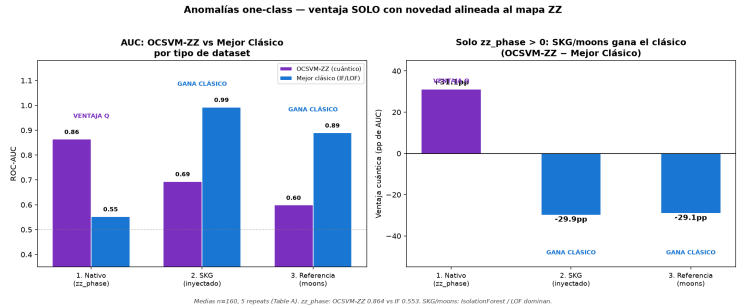


Q vs C

- **Nativo:** gana Q ($\Delta R^2 = +0{,}60$)
- **Friedman:** gana C ($\Delta R^2 = -0{,}13$)
- **SKG:** gana C ($\Delta R^2 = -0{,}34$)

Misma lectura que clasificación: ventaja solo con estructura alineada.

Resultados: Q vs C
3. Anomalías (OCSVM-ZZ vs clásico)



Q vs C

- **Nativo:** gana Q (+31.2 pp AUC)
- **SKG:** gana C ($-29{,}9$ pp)
- **moons:** gana C ($-29{,}1$ pp)

Misma lectura que clasif./regresión: ventaja solo con novedad alineada al mapa.

Resultados: Q vs C
4. Optimización (QAOA/VQE vs clásico)

Capa	Problema	Cuántico	Clásico
Nativo / control	Asignación QUBO	**QAOA $-30.3\,\%$ coste**	Greedy
SKG-like	MDS (cobertura)	**óptimo;** $P \approx 73\,\%$	fuerza bruta / Greedy
Referencia	TSP $n{=}4$	empate óptimo	NN+2-opt (gap 0)

Q vs C (misma pregunta)

- **Asignación:** gana Q en coste a escala moderada.
- **MDS:** Q recupera el óptimo (patrón híbrido viable).
- **TSP:** empate en calidad; **no** hay speedup — modelado QUBO.

Optimización $\neq$ kernels: aquí el contraste es coste/calidad de solución, no accuracy. La estructura del paisaje QUBO se mide aparte (P1, notebook 11).

Resultados: Q vs C
Síntesis 4 × 3

Familia	Nativo	SKG	Referencia
Clasificación	**gana Q**	gana C	gana C
Regresión	**gana Q**	gana C	gana C
Anomalías	**gana Q**	gana C	gana C
Optimización	**gana Q** (coste)	**viable** (óptimo)	empate

Mensaje único

Ventaja cuántica **condicionada**: aparece con alineación mapa–generador (o QUBO viable). En datos reales SKG/Telco sin esa estructura: pipeline clásico.

Conjeturas
De la evidencia emergen dos preguntas

Preguntas originales (Cap. 6)

1. **P1 — tests de cuanticidad**

   ¿Se puede diagnosticar *a priori* si un dataset tiene *estructura cuántica* (alineación mapa–dato) y, por tanto, admitirá ventaja?

2. **P2 — mapeos cuántico-compatibles**

   Si no hay estructura nativa, ¿existe un nuevo mapeo ψ y un espacio de representación donde se conserve la estructura e información del dato, adquiera estructura cuántica, y haya mapa de vuelta si hace falta? (analogía: Fourier)

Conjeturas
Camino a la Conjetura 1 (I) — por qué un perfil

Literatura

- Ventaja cuántica de kernel $\Rightarrow$ alineación con etiquetas **y** geometría no reproducible por el clásico (Huang et al., 2021; Liu et al., 2021).
- Un solo indicador no basta: hace falta $A_Q > A_{cl}$ **y** d_F grande (Huang et al., 2021; Schuld, 2021).
- Riesgo: el kernel cuántico puede **concentrarse** y perder señal — vigilar $H(K)$ (Thanasilp et al., 2022).

Hecho empírico

Ventaja si el mapa que estructura el dato = mapa del modelo **cuántico**. Si no: gana el **clásico**.

Idea corregida

No un escalar: un **vector** $\mathcal{Q}(\mathcal{D}) = (\Delta A, \hat{d}_F, \Delta H, \hat{g}, \ldots)$ que se *mira* componente a componente.

Conjeturas
Camino a la Conjetura 1 (II) — componentes y evidencia

Interpretación (cuántico vs clásico)

- ΔA — ¿el cuántico ve mejor las clases?
  > 0: sí, más alineación con las etiquetas que el clásico (Cortes et al., 2012; Huang et al., 2021).
- $\hat{d}_F$ — ¿la geometría es distinta?
  Grande: el cuántico no es un clásico disfrazado (Liu et al., 2021).
- ΔH — ¿el kernel cuántico aporta diversidad o se ha "aplanado"?
  Bajo/negativo: todas las similitudes se parecen (concentración) $\Rightarrow$ poca info útil (Thanasilp et al., 2022).
- $\hat{g}$ — ¿el RBF reproduce la geometría cuántica?
  Cerca de 1: sí; grande: no (necesario, no suficiente) (Huang et al., 2021).

Evidencia (TFM)

Barrido α (n=9, NB08): mezcla de etiquetas, X fijo.

Hallazgo robusto: $\rho_S(\alpha, \Delta A)$=0,833 (p=0,005).

d_F/H constantes por diseño; no confundir con $\rho(\mathcal{Q}, \text{ventaja})$.

Conjeturas
Conjetura 1 — $\mathcal{Q}(\mathcal{D})$ como vector, no escalar

$$\mathcal{Q}(\mathcal{D}) \;=\; \big(\Delta A,\; \hat{d}_F,\; \Delta H,\; \hat{g}\big) \qquad \text{(perfil; sin pesos)} \tag{1}$$

Opcional en el documento: un escalar $w^\top \mathcal{Q}$ se probó y **falla** como ranking operativo — por eso no se usa para decidir.

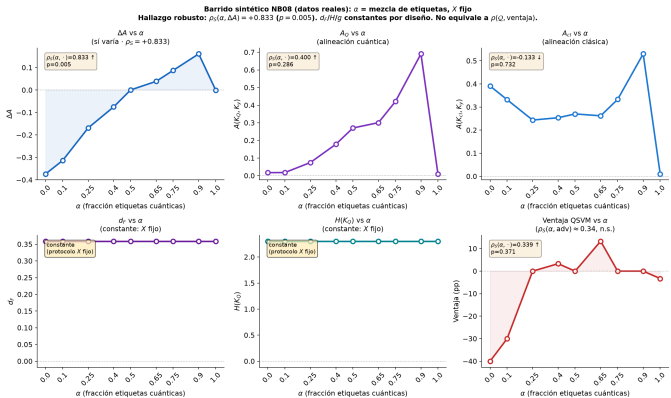
Cómo se lee

- ΔA: ¿mejor alineación que el clásico?
- $\hat{d}_F$: ¿geometría distinta?
- ΔH: ¿diversidad o concentración?
- $\hat{g}$: ¿el RBF reproduce la geometría cuántica?

Límite

El vector describe geometría vs. RBF. La adopción exige ventaja vs. mejor clásico **en la familia** (clasif./reg./anomalías) y alineación mapa–generador.

Conjeturas
Validación P1 — barrido sintético (α)



Qué es (NB08 real)

- α: fracción de etiquetas cuánticas (X fijo).
- ΔA crece con α: ρ_S=0,833 (p=0,005).
- d_F y H **constantes** (kernels no cambian con labels).

Límite

ρ=0,833 es $\rho(\alpha, \Delta A)$, no $\rho(\mathcal{Q}, \text{ventaja})$.

Barrido structure-aware: trabajo futuro.

Conjeturas
P1 — qué comparamos (mismas métricas)

Estructura cuántica = vector $(\Delta A,\ \Delta H,\ d_F,\ g,\ \mathcal{Q})$

- $\Delta A = A(K_Q, yy^\top) - A(K_{\mathrm{RBF}}, yy^\top)$ — (Huang et al., 2021)
- $\Delta H = H(K_Q) - H(K_{\mathrm{RBF}})$ — (Thanasilp et al., 2022)
- $d_F = \|K_Q - K_{\mathrm{RBF}}\|_F / n$ — (Liu et al., 2021)
- g (diferencia geom.) — (Huang et al., 2021); $\mathcal{Q}$ compuesto (este TFM)

Mismo protocolo en clasificación, regresión, anomalías y optimización (ZZ 2q, n=60, 3 repeats, RBF Frobenius-best).
Optimización = **paisaje QUBO** (bitstrings → energía), no QAOA.
Control nulo: ΔA con y permutada. Sin accuracy / R^2 / AUC / coste.

Nota: no hay Δ_{op} aquí

Eso era solo un nombre confuso para "accuracy(QSVM)−accuracy(mejor clásico)" en clasificación. **No** es métrica de estructura. Se retiró de estas figuras.

Conjeturas
P1 — qué mide g (Huang et al., 2021)

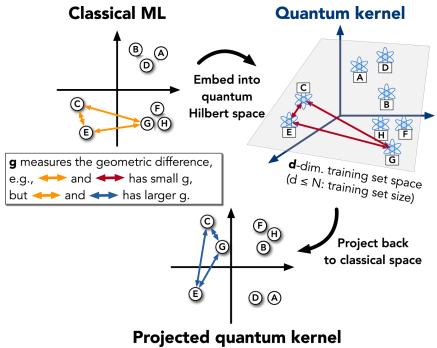


Fig. 2 de Huang et al. (2021), CC BY 4.0

Idea

g compara las **flechas** (similitudes kernel) entre puntos en el espacio clásico y en el cuántico. g pequeño: el kernel clásico ya reproduce la geometría cuántica; g grande: no.

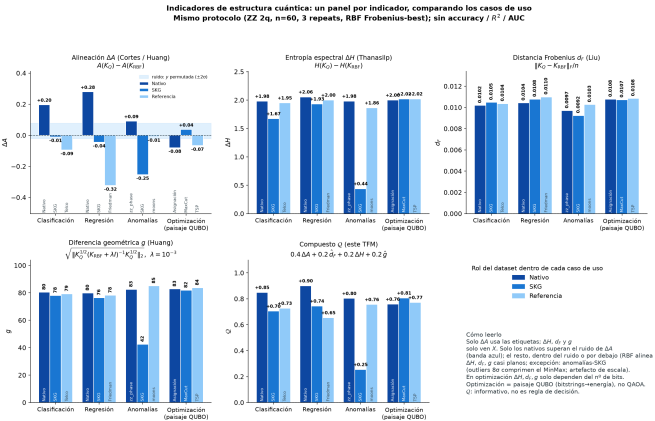
d = dimensión efectiva del dato en Hilbert.

Nuestra medición

g: necesario, no suficiente; no usa y. Huang (λ=10^{-3}): $g \approx 76$–85 en casi todos los casos (42 en anomalías-SKG, artefacto). $g \gg 1$ pero igual para nativos y reales: **no discrimina**. Antes ≈ 3000 (artefacto).

Conjeturas

P1 — los cinco indicadores en los cuatro casos de uso



Cómo leerlo

Un panel por indicador; eje X = caso de uso; 3 barras = Nativo / SKG / Referencia (optimización: asignación / MaxCut / TSP).

- ΔA: solo los nativos superan el ruido (banda azul); el resto, dentro del ruido o por debajo (incluida la optimización)
- ΔH, d_F, g: casi planos; excepción anomalías-SKG = artefacto de escala (outliers 8σ comprimen el MinMax)
- Q: informativo; lo dominan indicadores planos

Conjeturas
P1 — cómo interpretar

¿ΔA negativo + ΔH mínimo = estructura?

No. Los **nativos** tienen $\Delta A > 0$ sobre el ruido (clasif. $+0{,}20$, reg. $+0{,}28$, anom. $+0{,}09$); los datos reales y los paisajes de optimización quedan dentro o por debajo del nulo ($\Delta A < 0 =$ el RBF alinea mejor, no "estructura negativa"). El único ΔH mínimo (anomalías-SKG, $0{,}44$) es un artefacto de escala.

¿d_F discrimina?

Aquí, apenas: $\approx 0{,}01$ en todos los casos; g y ΔH también planos. Solo ΔA usa y; los otros tres solo ven X.

Lectura defendible

Lo que separa estructura es ΔA (alineación mapa–dato (Liu et al., 2021; Huang et al., 2021)), no d_F, g ni ΔH. Optimización: paisaje QUBO con 2 qubits (PCA retiene $\approx 1/3$): **sin evidencia** de estructura; límite del diseño.

Conjeturas
Camino a la Conjetura 2 — la analogía de Fourier

La pregunta natural de un matemático

Un problema difícil en el dominio original se vuelve simple en otro espacio, y se regresa si hace falta. Ejemplo: la transformada de Fourier $\hat{f}(\omega) = \int f(x)\, e^{-i\omega x}\, dx$ convierte convolución en producto.

Tres propiedades la hacen útil: **conserva la información** (invertible); la **estructura se ve** (se vuelve diagonal); tiene **mapa de vuelta**.

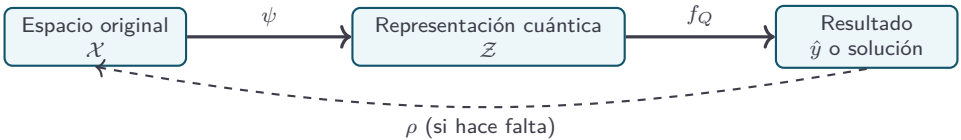
Y no es un mapa arbitrario

Viene de un **núcleo** (kernel) $e^{-i\omega x}$. Por el teorema de Bochner, los kernels invariantes por traslación son transformadas de Fourier de una medida: el mapa de características de un kernel *es* un mapeo de tipo Fourier.

La analogía con el kernel cuántico

Si el dato no tiene estructura cuántica, ¿existe un **nuevo mapeo** ψ **y un espacio de representación** $\mathcal{Z}$ donde se conserve la estructura e información del dato, adquiera estructura cuántica y se pueda sacar partido de los algoritmos cuánticos, con un mapeo de vuelta al espacio original cuando haga falta?

Conjeturas
Conjetura 2 — espacio de representación QCR



Qué se pide de ψ

1. **Conserva estructura e información** de los datos.
2. **Estructura cuántica**: $\mathcal{Q}(\psi(\mathcal{D})) > 0$.
3. **Mapa de vuelta** ρ al espacio original cuando se necesite (p. ej. optimización).
4. Utilidad: $\varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star)$.

Sobre la naturaleza de ψ

ψ **no tiene por qué ser un polinomio**: Fourier usa exponenciales y nace de un kernel. Con ventaja global, el coste de calcular ψ debe contarse.

Estado

Conjetura **abierta**: este TFM la **plantea**. Prototipos (NB 09): sin ventaja frente al clásico fuerte. Sin demostración.

Conclusiones (I) — ventaja condicionada

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: aparece cuando el feature map coincide con el generador (ZZ medido aquí; Pauli-Y confirma el mismo principio).
3. En **datos reales** SKG/Telco **sin** esa estructura: gana el **clásico** (no son cuántico-nativos).
4. Regresión: ventaja acotada (Friedman); en movilidad SKG, el clásico domina.
5. Anomalías / lags: misma regla — solo con target alineado (`zz_phase`, `zz_lag`).

Conclusiones (II) — híbridos y coste

6. QAOA reduce coste de asignación $\approx 30\,\%$ vs. Greedy a escala moderada.
7. VQE competitivo en portafolio pequeño; TSP $n{=}4$: empate óptimo (valor de *modelado*, no speedup).
8. MDS: patrón híbrido viable ($P(\text{opt}) \approx 73\,\%$).
9. Coste de simulación del kernel $O(n^2)$: obstáculo práctico actual.
10. Metodologías maduras vs. hardware inmaduro: resultados mixtos son esperables en NISQ.

Conclusiones (III) — conjeturas y adopción

11. $\mathcal{Q}(\mathcal{D})$ como **vector** $(\Delta A, \hat{d}_F, \Delta H, \hat{g})$; el escalar colapsado no se usa; sí $\rho_S(\alpha, \Delta A)$=0,833.
12. QCR: **planteado**; evidencia preliminar vs. RBF; no rescate operativo.
13. Adopción recomendada: **selectiva e híbrida** — módulo cuántico como herramienta adicional, no sustituto del stack clásico (SKG).

Respuesta a la pregunta del TFM

Ventaja medible hoy cuando hay coincidencia mapa–generador o QUBO híbrido viable; en ausencia de eso, el clásico domina — y eso también es un resultado.

Conclusiones
Limitaciones (I)

- **Simulación statevector**: sin ruido NISQ de hardware; ideales $\neq$ shots reales.
- **PCA a** $n_q{=}2$: $\sim$68 % de varianza descartada; $\mathcal{Q}$ mide el subespacio proyectado.
- **Muestra** $n{\approx}80$ en indicadores; correlación en 3 datasets reales es orientativa.
- **Baseline**: $\mathcal{Q} > 0$ vs. un clásico débil $\neq$ ventaja vs. el mejor clásico (caso SKG).
- **Protocolos distintos**: Δ_{RBF} (NB08) $\neq$ ventaja vs mejor clásico (clasificación / NB06); no se mezclan en una sola ρ ni en la misma leyenda.

Limitaciones (II) — debilidades expuestas

- **Barrido** α: X fijo $\Rightarrow$ d_F/H constantes; ρ_S=0,833 es $\rho(\alpha, \Delta A)$, no predicción de ventaja.
- **Sin dumps de** K: no se inventan heatmaps ni contrastes a mano.
- **Rotaciones NB09**: series del notebook; no regenerar con curvas proxy.
- **Post-QCR**: solo Q/Adv logueados; no inventar componentes post.
- **QCR** sin demostración fuerte; Q-UMAP = MDS proxy.
- **Escalabilidad**: kernel $O(n^2)$; sin hardware real.

Trabajo futuro (I) — corto plazo y SKG

Corto plazo

- Hardware ruidoso (IBM) + mitigación (ZNE)
- Más qubits / menos PCA agresivo
- Validación fuerte de QCR y $\mathcal{Q}_{\text{rob}}$
- Calibrar pesos (w_i); más feature maps (IQP, Pauli)
- Kernels aleatorizados $O(n)$ / ensembles

Aplicación SKG

- QAOA en asignación real (`agents.csv`)
- VRP-TW / rutas de emergencia
- Multiclase de gravedad de incidentes
- Activación selectiva en pipeline productivo
- A/B testing cuántico–clásico

Trabajo futuro (II) — medio/largo plazo

- Benchmarks con separación formal (Bravyi et al.) para certificar $\mathcal{Q}$
- Certificación estadística de ventaja (Huang et al., 2021)
- Demostración o refutación de la conjetura QCR
- Q-means / autoencoders / aprendizaje no supervisado cuántico
- Análisis de barren plateaus en VQC
- Integración API + monitorización de *data drift* en SKG

Trabajo futuro (III) — roadmap

Corto (1–2 a)	Medio (2–4 a)	Largo (4+ a)
Hardware IBM + ZNE	4–8 qubits, menos PCA	FTQC / corrección errores
API + A/B test SKG	QAOA asignación real	Demostrar / refutar QCR
QAOA $p>1$ / SPSA	Validar $\mathcal{Q}$ en corpus amplio	QCR multi-mapa + publicación

muchas gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

unir LA UNIVERSIDAD EN INTERNET

Referencias (selección) I

Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). *Algorithms for learning kernels based on centered alignment*. JMLR.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. et al. (2019). *Machine learning methods in quantum computing theory*. Proc. SPIE.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Referencias (selección) II

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S. et al. (2022). *Exponential concentration and the limits of quantum ML*. arXiv:2208.11060.