Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica ů UNIR
Director: Ricardo Rafael Domínguez Reyes

Documento: `Documento/main.pdf` *Código:* `POCs/qml_v2/`

Agenda (línea cronológica del TFM)

1. Motivación
2. Introducción
3. Contexto y estado de la técnica
4. Planteamiento y metodología
5. Resultados de modelos
6. Conjeturas ($\mathcal{Q}$, QCR)
7. Análisis de las conjeturas
8. Conclusiones
9. Trabajo futuro

Estructura del documento

Marco teórico (Cap. 1–3) $\rightarrow$ Implementación (Cap. 4–5) $\rightarrow$ Discusión y cierre (Cap. 6–8).

Motivación

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

Pregunta práctica

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

Estructura del TFM



Introducción — planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Hipótesis operativa

La ventaja es **real pero condicionada**:

1. coincidencia **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

Introducción — alcance

Familias industriales (4)

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Optimización combinatoria (QAOA)
- Optimización / híbrido (VQE + MDS)

Extendidas a 9 protocolos justos en el documento (anomalías, TSP, lags,...).

Tres capas de datos

1. Sintéticos con estructura cuántica nativa (Liu et al., 2021)
2. Práctica SKG Tecnología
3. Referencia pública

Era NISQ

NISQ (Preskill, 2018)

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

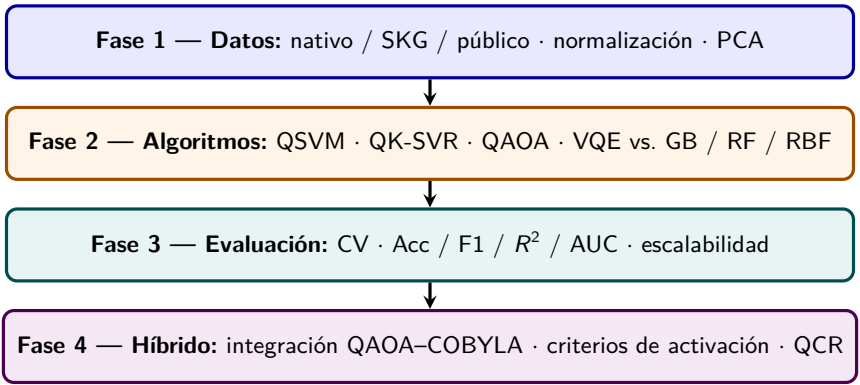
Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Datasets donde el kernel cuántico es óptimo por construcción (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2022).
- Gap empírico: pocos estudios **justos** sobre datos empresariales reales (Fastovets et al., 2019).

Posicionamiento de este TFM

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

Metodología en cuatro fases



Formalismo — kernel cuántico

Mapa de características $\phi : \mathcal{X} \to \mathcal{H}$ (`ZZFeatureMap`) y kernel de fidelidad:

$$\kappa(x_i, x_j) = \left| \langle \phi(x_i) \,|\, \phi(x_j) \rangle \right|^2 \tag{1}$$

Clasificador: SVM / SVR / OCSVM sobre $K_{ij} = \kappa(x_i, x_j)$ frente a baseline RBF bajo el mismo protocolo (Schuld, 2021; Liu et al., 2021).

Condición de ventaja (kernels)

La ventaja aparece cuando el **generador del dato** coincide con el feature map. ZZ es el mapa medido en este corpus; no el único admisible (Pauli, IQP,...).

Formalismo — QAOA / VQE híbridos

Problema combinatorio $\rightarrow$ QUBO $\rightarrow$ Hamiltoniano de Ising:

$$\min_{x\in\{0,1\}^n} x^\top Q x \quad \Longrightarrow \quad H_C = \sum_i h_i Z_i + \sum_{i<j} J_{ij} Z_i Z_j \tag{2}$$

Ansatz QAOA de profundidad p (Farhi et al., 2014):

$$|\psi(\boldsymbol{\gamma},\boldsymbol{\beta})\rangle = e^{-i\beta_p H_B} e^{-i\gamma_p H_C} \cdots e^{-i\beta_1 H_B} e^{-i\gamma_1 H_C} |+\rangle^{\otimes n} \tag{3}$$

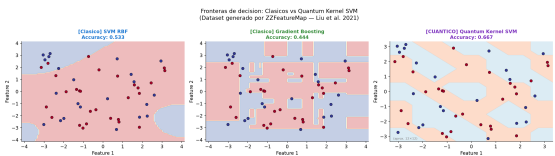
Optimizador clásico (COBYLA) ajusta $(\boldsymbol{\gamma},\boldsymbol{\beta})$; el módulo cuántico propone candidatos.

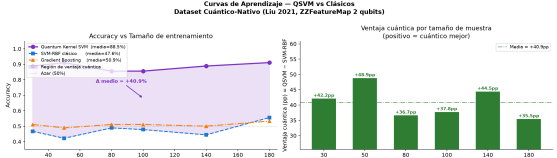
Diseño: 4 familias $\times$ 3 capas de datos

Familia	**Cuántico**	**Clásico de referencia**
Clasificación	QSVM (ZZ)	GB, RF, SVM-RBF
Regresión	QK-SVR	XGBoost, RF, SVR-RBF, Ridge
Optimización (asignación)	QAOA (p=1)	Greedy, búsqueda local, ILP
Portafolio / cobertura	VQE / QAOA-MDS	Markowitz, fuerza bruta

Cada familia se evalúa, cuando aplica, en: (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia pública**.

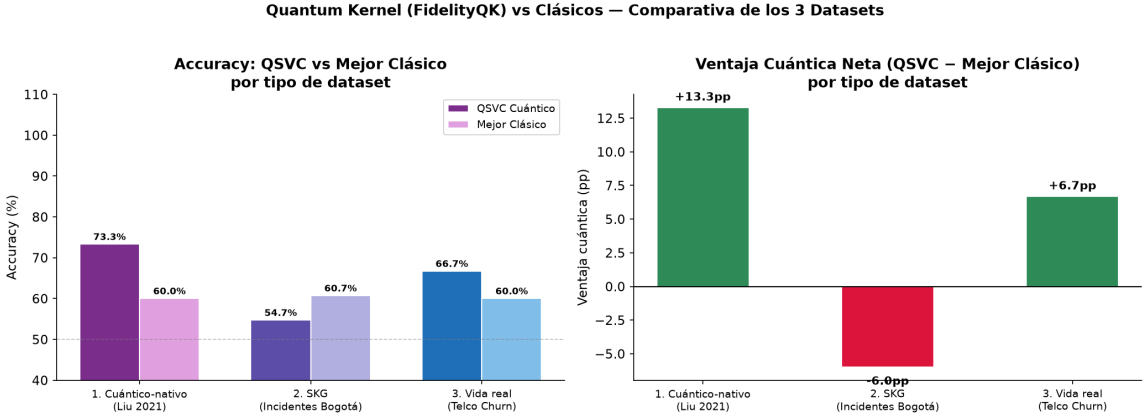
Resultados — datos cuántico-nativos (Liu et al.)





Etiquetas generadas con `ZZFeatureMap`: QSVM recupera la frontera; RBF/GB $\approx$ azar (Δ media $\approx +41$ pp).

Resultados — clasificación en 3 capas de datos



Resultados — clasificación (Telco / sin estructura ZZ)

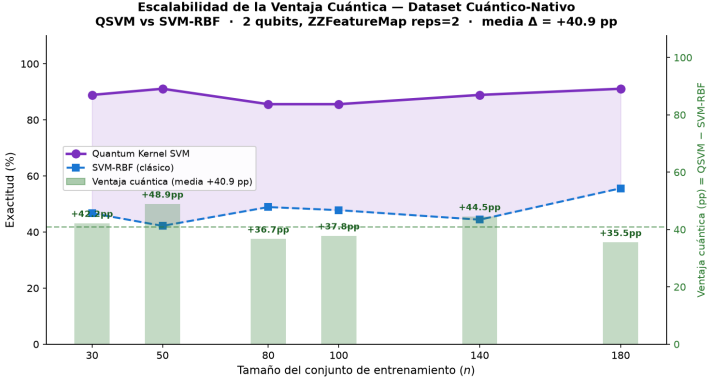


Lectura

- GB/RF/XGBoost: F1 $\approx 0{,}78$–$0{,}79$
- QSVM / VQC: F1 $\approx 0{,}64$–$0{,}66$
- Tiempo: clásico $< 2\,\text{s}$; cuántico $> 15\,\text{s}$

Sin coincidencia mapa–generador, gana el stack clásico.

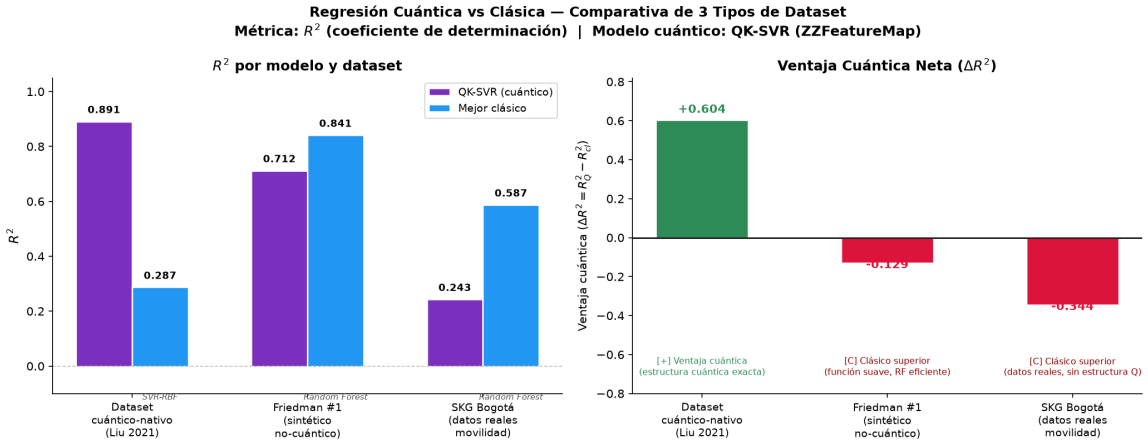
Resultados — escalabilidad del QSVM



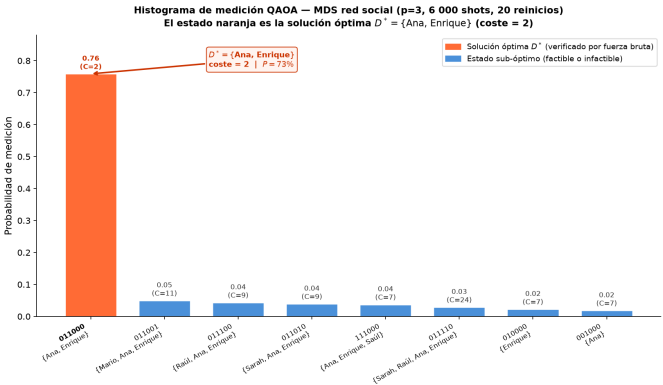
Cifras ancla

- **+38.3 pp** con estructura ZZ
- Media **+40.9 pp** ($n \in [30, 180]$)
- En Telco/SKG: gana el clásico

Resultados — regresión (QK-SVR)



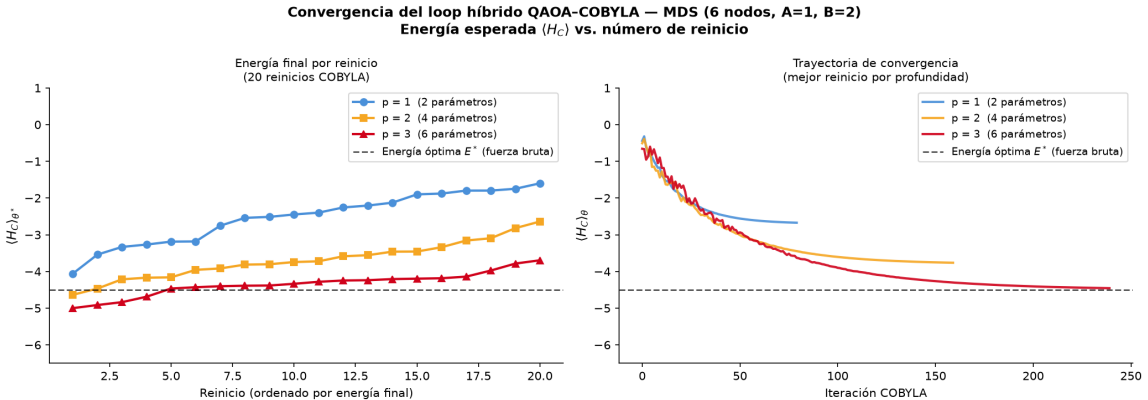
Resultados — QAOA (medición)



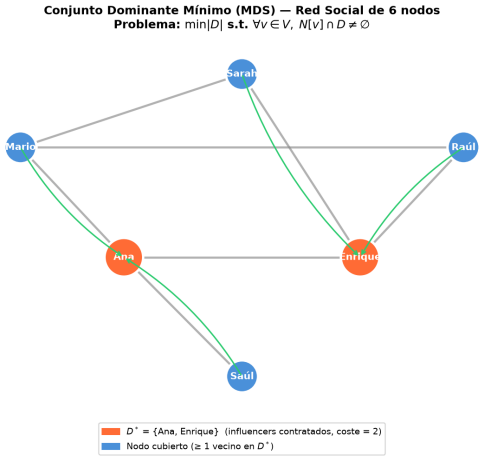
Hallazgos

- QAOA: $-\mathbf{30.3\,\%}$ coste vs. Greedy
- VQE competitivo en portafolio pequeño
- TSP n=4: empate óptimo — valor de *modelado*

Resultados — loop híbrido QAOA–COBYLA



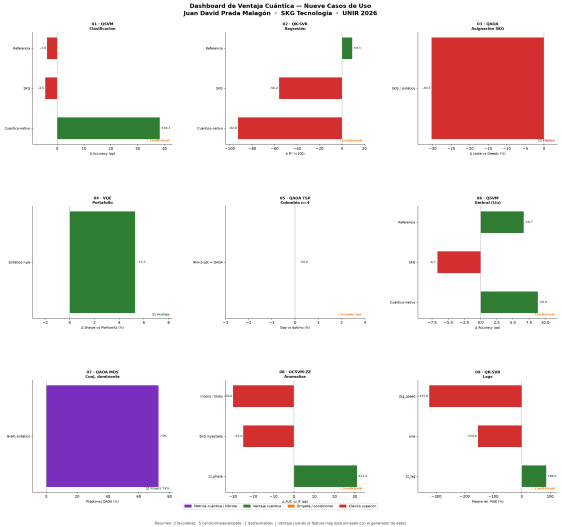
Resultados — MDS (solución en grafo)



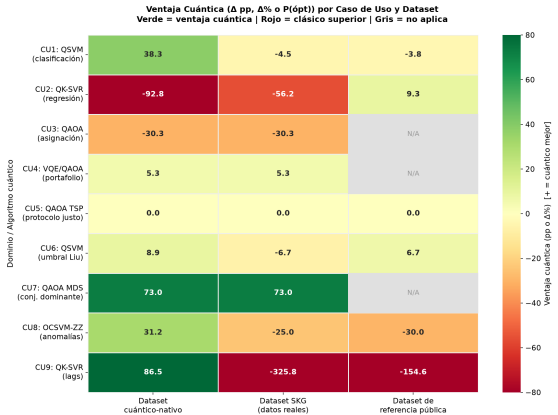
Lectura

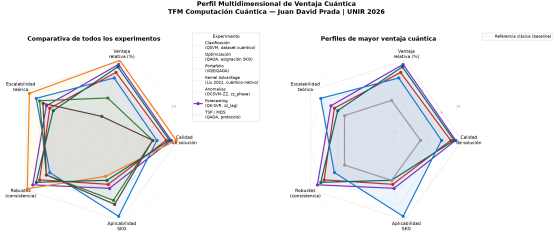
- $D^\star = \{\text{Ana}, \text{Enrique}\}$
- $P(\text{opt}) \approx 73\,\%$ (patrón híbrido)
- Escala moderada; no speedup asintótico

Síntesis — dashboard de 9 casos



Síntesis — heatmap y radar





De la evidencia a dos preguntas

Lo que vimos en los 9 casos

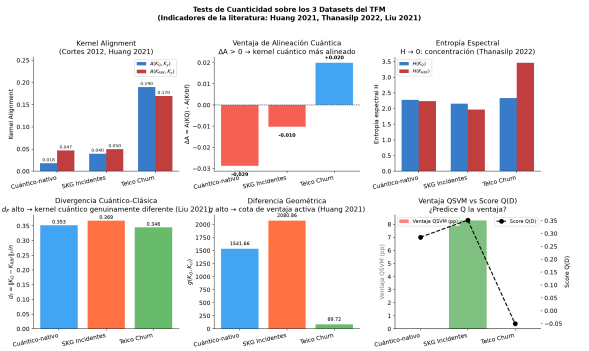
- Ventaja clara **solo** cuando el generador coincide con el feature map (ZZ).
- En SKG/Telco (sin esa estructura): gana el clásico.
- En QUBO híbrido: valor a escala moderada, no speedup universal.

Preguntas que emergen

1. ¿Se puede **diagnosticar a priori** si un dataset admitirá ventaja?
2. Si $\mathcal{Q}(\mathcal{D}) \leq 0$, ¿existe un mapeo ψ que active la ventaja sin destruir la señal?

Cómo llegamos a $\mathcal{Q}(\mathcal{D})$

1. Literatura: un indicador no basta (Huang et al., 2021; Liu et al., 2021; Thanasilp et al., 2022).
2. Notebook 08: ΔA, d_F, $H(K)$ en nativo / SKG / Telco.
3. d_F y g rankean bien; ΔA inestable con PCA a 2 qubits.
4. Barrido en α: $\rho_S(\mathcal{Q}, \text{ventaja}) = 0{,}833$.
5. Propuesta: **score compuesto** interpretable.



Conjetura 1 — score de cuanticidad $\mathcal{Q}(\mathcal{D})$

$$\mathcal{Q}(\mathcal{D}) = w_1 \Delta A + w_2 \hat{d}_F + w_3 \Delta H, \qquad \sum_i w_i = 1,\ w_i \geq 0 \tag{4}$$

$\Delta A = A(K_Q, K_y) - A(K_{\mathrm{RBF}}, K_y)$ (señal vs. etiquetas)

$\hat{d}_F = \|K_Q - K_{\mathrm{cl}}^{\star}\|_F \big/ d_{F,\mathrm{máx}}$ (no-aproximabilidad)

$\Delta H = H(K_Q) - H(K_{\mathrm{RBF}})$ (riqueza espectral)

Interpretación

$\mathcal{Q} > 0$: ventaja estructural esperada.

$\mathcal{Q} < 0$: superioridad clásica.

Coherente con la geometría de Huang et al. (2021).

Cómo llegamos a QCR

1. Si $\mathcal{Q}(\mathcal{D}) \leq 0$, el stack clásico es la opción por defecto.
2. Pero: ¿el fallo es del **dato** o del **espacio de representación**?
3. Hipótesis: existe $\psi : \mathcal{X} \to \mathcal{Z}$ (polinómica) que induzca estructura compatible con el feature map.
4. Notebook 09: prototipos — features ZZ-compatibles, rotación máx d_F, re-uploading.
5. Resultado: subidas locales de $\mathcal{Q}$; **sin** demostración fuerte de ventaja general.

Lectura para el tribunal

QCR no es un algoritmo cerrado: es un **programa de investigación** formalizado a partir de la evidencia del TFM.

Conjetura 2 — espacio de representación QCR

Si $\mathcal{Q}(\mathcal{D}) \leq 0$, se conjetura existencia de $\mathcal{Z}$ y $\psi : \mathcal{X} \to \mathcal{Z}$ **polinómica** tales que

$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^\star} \hat{y} \qquad \text{con} \quad \mathcal{Q}(\psi(\mathcal{D})) > 0 \;\text{ y }\; \varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star). \tag{5}$$

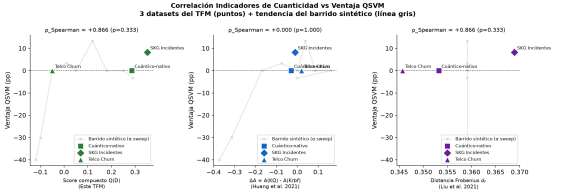
Intuición

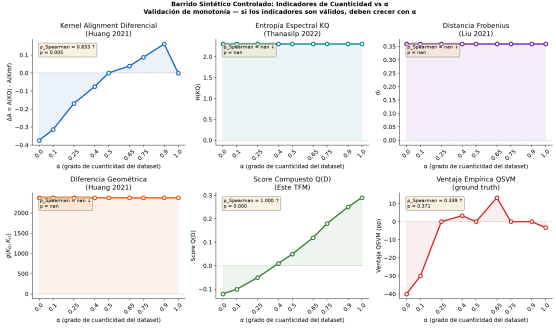
Transformar el dato *antes* del kernel para que el mapa ZZ "vea" estructura usable.

Estado

Conjetura **abierta**.
Este TFM la **plantea** y aporta evidencia preliminar — no una demostración.

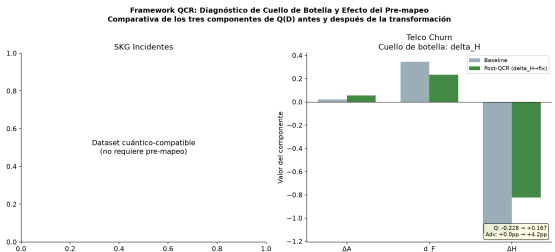
Análisis P1 — tests de cuanticidad

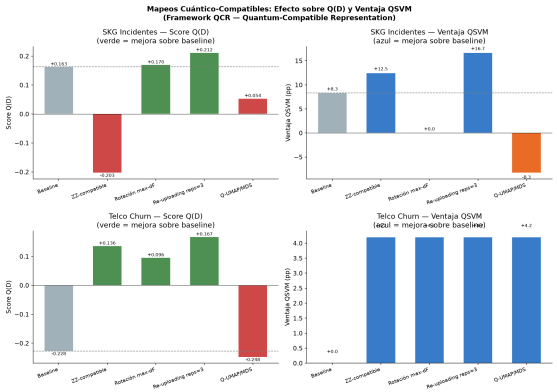




Barrido sintético: $\rho_S(\mathcal{Q}, \text{ventaja}) = 0{,}833$ ($p = 0{,}005$, $n = 9$). Componente más informativo: d_F.

Análisis P2 — mapeos cuántico-compatibles





Protocolo de diagnóstico → transformación candidata (rotación / re-uploading / . . .). Validación fuerte de QCR = línea post-TFM.

Conclusiones

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: coincidencia feature map $\leftrightarrow$ generador; ZZ es el mapa medido aquí.
3. En optimización: QAOA/VQE aportan valor en QUBO de escala moderada (patrón híbrido).
4. $\mathcal{Q}(\mathcal{D})$ es un diagnóstico útil *a priori* ($\rho_S = 0{,}833$ en barrido sintético).
5. QCR queda **formalmente planteado**; no demostrado.
6. Adopción recomendada: **selectiva e híbrida**, no sustitutiva del stack clásico.

Limitaciones (explicitadas)

- Simulación statevector (sin ruido NISQ de hardware).
- PCA a n_q=2 (68 % de varianza descartada).
- Correlación $\mathcal{Q}$ en datos reales con n pequeño (orientativa).
- QCR sin demostración fuerte.
- TSP: empate óptimo $\neq$ speedup.

Trabajo futuro

Corto plazo

- Hardware ruidoso / shots reales
- Más qubits, menos PCA
- Validación fuerte de QCR

Medio–largo plazo

- Benchmarks con separación formal
- Q-means / autoencoders
- Activación selectiva en pipelines productivos

Gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

(Preskill, 2018; Biamonte et al., 2017; Farhi et al., 2014; Schuld, 2021; Huang et al., 2021; Liu et al., 2021; Cerezo et al., 2021)

Referencias (selección) I

Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. et al. (2019). *Machine learning methods in quantum computing theory*. Proc. SPIE.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Referencias (selección) II

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S. et al. (2022). *Exponential concentration and the limits of quantum ML*. arXiv:2208.11060.