unir LA UNIVERSIDAD EN INTERNET

Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica · UNIR
Director: Ricardo Rafael Domínguez Reyes

Documento: `Documento/main.pdf` *Código:* `POCs/qml_v2/`
Práctica: SKG Tecnología

Agenda (línea cronológica del TFM)

1. Motivación
2. Introducción
3. Contexto y estado de la técnica
4. Planteamiento y metodología
5. Resultados: Q vs C (4 familias $\times$ 3 capas)
6. Conjeturas: cómo llegamos a $\mathcal{Q}$ y QCR
7. Evidencia de las conjeturas
8. Conclusiones y limitaciones
9. Trabajo futuro

Estructura del documento

Marco teórico (Cap. 1–3) $\rightarrow$ Implementación (Cap. 4–5) $\rightarrow$ Discusión y cierre (Cap. 6–8).

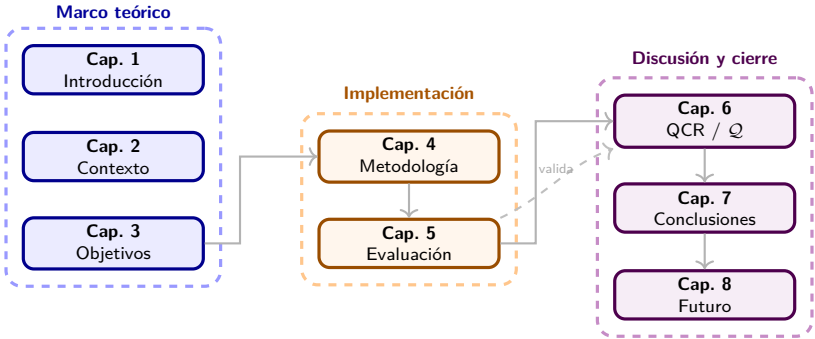
Motivación

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

Pregunta práctica

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

Estructura del TFM



Introducción — planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Hipótesis operativa

La ventaja es **real pero condicionada**:

1. coincidencia **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

Introducción — alcance

Familias industriales (4)

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Optimización combinatoria (QAOA)
- Optimización / híbrido (VQE + MDS)

Extendidas a 9 protocolos justos en el documento (anomalías, TSP, lags,...).

Tres capas de datos

1. Sintéticos con estructura cuántica nativa (Liu et al., 2021)
2. Práctica SKG Tecnología
3. Referencia pública

Era NISQ

NISQ (Preskill, 2018)

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

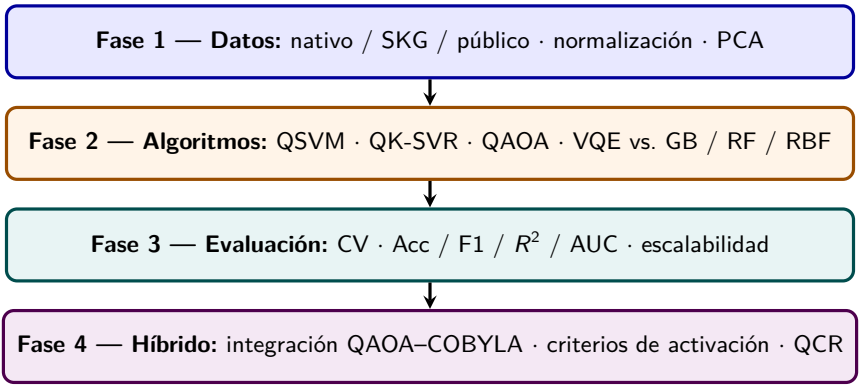
Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Datasets donde el kernel cuántico es óptimo por construcción (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2022).
- Gap empírico: pocos estudios **justos** sobre datos empresariales reales (Fastovets et al., 2019).

Posicionamiento de este TFM

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

Metodología en cuatro fases



Diseño: 4 familias $\times$ 3 capas de datos

Familia	Cuántico	Clásico de referencia
Clasificación	QSVM (ZZ)	GB, RF, SVM-RBF
Regresión	QK-SVR	RF, XGBoost, SVR-RBF, Ridge
Anomalías	OCSVM-ZZ	IsolationForest, LOF
Optimización	QAOA / VQE	Greedy, ILP, NN+2-opt

Misma pregunta en las cuatro: **¿quién gana, Q o C?** en (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia**.

Lectura transversal

Kernels: ventaja si mapa y generador coinciden. Optimización: QUBO + híbrido a escala viable (no speedup asintótico).

Criterio de activación del módulo cuántico

Problema	**Activar si**	**Módulo Q**	**Fallback**
Clasif. / Regresión	coincidencia mapa–generador *y* vence a GB/RF (no basta $\mathcal{Q} > 0$ vs RBF)	QSVM / QK-SVR	GB / RF
Anomalías	novedad alineada al mapa (`zz_phase`)	OCSVM-ZZ	IF / LOF
Forecasting	target alineado (`zz_lag`)	QK-SVR	Ridge / GB
Optimización / TSP	QUBO factible, *n* viable	QAOA / VQE	Greedy / ILP / 2-opt
Caso general	SKG/Telco sin estructura ZZ o *n* demasiado grande	**no se activa**	pipeline clásico

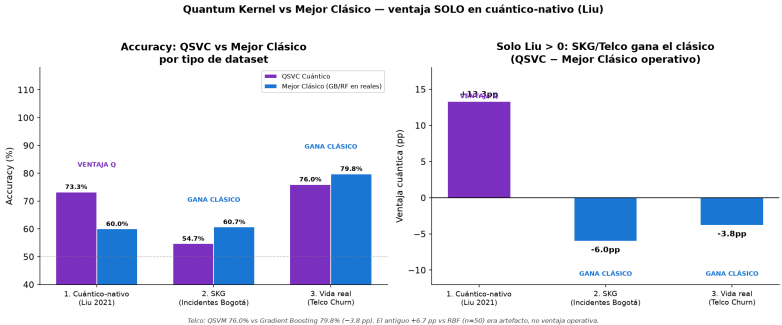
Resultados — qué comparamos

Familia	Nativo	SKG	Referencia
1. Clasificación (QSVM)	Liu ZZ	Incidentes Bogotá	Telco Churn
2. Regresión (QK-SVR)	target alineado	Movilidad Bogotá	Friedman #1
3. Anomalías (OCSVM-ZZ)	zz_phase	outliers inyectados	moons
4. Optimización (QAOA)	asignación QUBO	cobertura MDS	TSP n=4

Formato fijo en las 4 diapositivas siguientes

Plot (o tabla) + misma lectura: **Nativo / SKG / Referencia** → gana Q o gana C. Sin formalismo, sin ejemplos narrativos, sin algoritmos fuera del TFM.

Resultados — 1. Clasificación (QSVM vs clásico)



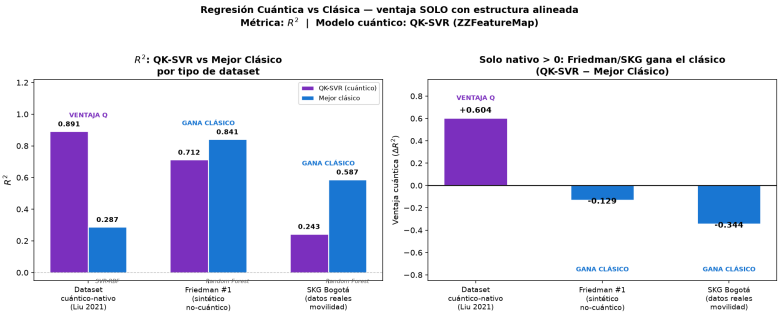
Q vs C

- **Nativo:** gana Q ($+13.3$ pp)
- **SKG:** gana C ($-6{,}0$ pp)
- **Telco:** gana C ($-3{,}8$ pp vs GB)

Baseline = mejor clásico.

También: Q más lento ($1/t \approx 0$).

Resultados — 2. Regresión (QK-SVR vs clásico)

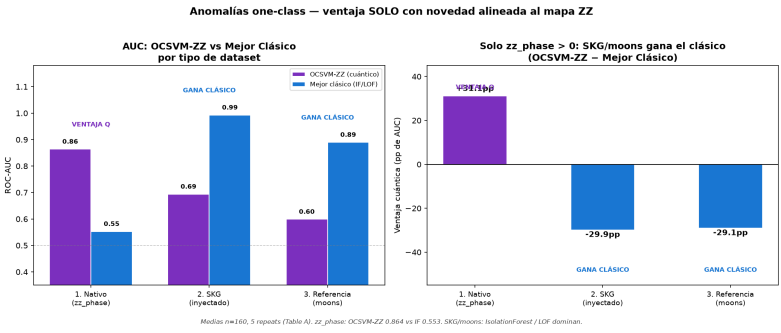


Q vs C

- **Nativo:** gana Q ($\Delta R^2 = +0{,}60$)
- **Friedman:** gana C ($\Delta R^2 = -0{,}13$)
- **SKG:** gana C ($\Delta R^2 = -0{,}34$)

Misma lectura que clasificación: ventaja solo con estructura alineada.

Resultados — 3. Anomalías (OCSVM-ZZ vs clásico)



Q vs C

- **Nativo:** gana Q (+31.2 pp AUC)
- **SKG:** gana C (−29,9 pp)
- **moons:** gana C (−29,1 pp)

Misma lectura que clasif./regresión: ventaja solo con novedad alineada al mapa.

Resultados — 4. Optimización (QAOA/VQE vs clásico)

Capa	Problema	Cuántico	Clásico
Nativo / control	Asignación QUBO	**QAOA −30.3 % coste**	Greedy
SKG-like	MDS (cobertura)	**óptimo;** $P \approx 73\,\%$	fuerza bruta / Greedy
Referencia	TSP n=4	empate óptimo	NN+2-opt (gap 0)

Q vs C (misma pregunta)

- **Asignación:** gana Q en coste a escala moderada.
- **MDS:** Q recupera el óptimo (patrón híbrido viable).
- **TSP:** empate en calidad; **no** hay speedup — modelado QUBO.

Optimización $\neq$ kernels: aquí el contraste es coste/calidad de solución, no accuracy.

Resultados — síntesis 4 × 3

Familia	Nativo	SKG	Referencia
Clasificación	**gana Q**	gana C	gana C
Regresión	**gana Q**	gana C	gana C
Anomalías	**gana Q**	gana C	gana C
Optimización	**gana Q** (coste)	**viable** (óptimo)	empate

Mensaje único

Ventaja cuántica **condicionada**: aparece con alineación mapa–generador (o QUBO viable). En datos reales SKG/Telco sin esa estructura: pipeline clásico.

De la evidencia emergen dos preguntas

Preguntas originales (Cap. 6)

1. **P1 — tests de cuanticidad**

   ¿Se puede diagnosticar *a priori* si un dataset tiene *estructura cuántica* (alineación mapa–dato) y, por tanto, admitirá ventaja?

2. **P2 — mapeos cuántico-compatibles**

   Si no hay estructura nativa, ¿existe un mapeo ψ a un espacio de representación que induzca esa estructura **sin pérdida de información** (en lo posible)?

Camino a la Conjetura 1 (I) — por qué un perfil

Literatura

- Ventaja cuántica de kernel $\Rightarrow$ alineación con etiquetas **y** geometría no reproducible por el clásico (Huang et al., 2021; Liu et al., 2021).
- Un solo indicador no basta: hace falta $A_Q > A_{cl}$ **y** d_F grande (Huang et al., 2021; Schuld, 2021).
- Riesgo: el kernel cuántico puede **concentrarse** y perder señal — vigilar $H(K)$ (Thanasilp et al., 2022).

Hecho empírico

Ventaja si el mapa que estructura el dato = mapa del modelo **cuántico**. Si no: gana el **clásico**.

Idea corregida

No un escalar: un **vector** $\mathcal{Q}(\mathcal{D}) = (\Delta A, \hat{d}_F, \Delta H, \ldots)$ que se *mira* componente a componente.

Camino a la Conjetura 1 (II) — componentes y evidencia

Interpretación (cuántico vs clásico)

- ΔA — ¿el cuántico ve mejor las clases?
  > 0: sí, más alineación con las etiquetas que el clásico (Cortes et al., 2012; Huang et al., 2021).
- $\hat{d}_F$ — ¿la geometría es distinta?
  Grande: el cuántico no es un clásico disfrazado (Liu et al., 2021).
- ΔH — ¿el kernel cuántico aporta diversidad o se ha "aplanado"?
  Bajo/negativo: todas las similitudes se parecen (concentración) $\Rightarrow$ poca info útil (Thanasilp et al., 2022).

Evidencia (TFM)

Barrido α (n=9, NB08): mezcla de etiquetas, X fijo.

Hallazgo robusto: $\rho_S(\alpha, \Delta A)$=0,833 (p=0,005).

d_F/H constantes por diseño; no confundir con $\rho(\mathcal{Q}, \text{ventaja})$.

Propuesta (vector)

$\mathcal{Q}(\mathcal{D}) = (\Delta A, \hat{d}_F, \Delta H)$.

Perfil geométrico vs. RBF — la decisión mira la ventaja vs. mejor clásico **por familia** (clasif./reg./anomalías)

Conjetura 1 — $\mathcal{Q}(\mathcal{D})$ como vector, no escalar

$$\mathcal{Q}(\mathcal{D}) \;=\; (\Delta A,\ \hat{d}_F,\ \Delta H) \qquad \text{(perfil; sin pesos)} \tag{1}$$

Opcional en el documento: un escalar $w^\top \mathcal{Q}$ se probó y **falla** como ranking operativo — por eso no se usa para decidir.

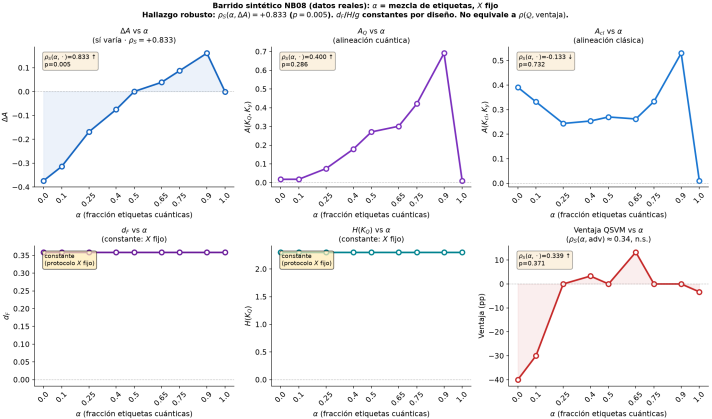
Cómo se lee

- ΔA: ¿mejor alineación que el clásico?
- $\hat{d}_F$: ¿geometría distinta?
- ΔH: ¿diversidad o concentración?

Límite

El vector describe geometría vs. RBF. La adopción exige ventaja vs. mejor clásico **en la familia** (clasif./reg./anomalías) y alineación mapa–generador.

Validación P1 — barrido sintético (α)



Qué es (NB08 real)

- α: fracción de etiquetas cuánticas (X fijo).
- ΔA crece con α: ρ_S=0,833 (p=0,005).
- d_F y H **constantes** (kernels no cambian con labels).
- La ventaja supervisada es ruidosa ($\rho_S \approx$0,34).

Límite

No afirmar que $\mathcal{Q}$ predice ventaja con ρ=0,833: ese número es $\rho(\alpha, \Delta A)$. Un barrido structure-aware queda como trabajo futuro.

P1 — qué comparamos (mismas métricas)

Estructura cuántica = $(\Delta A,\ d_F,\ \Delta H)$

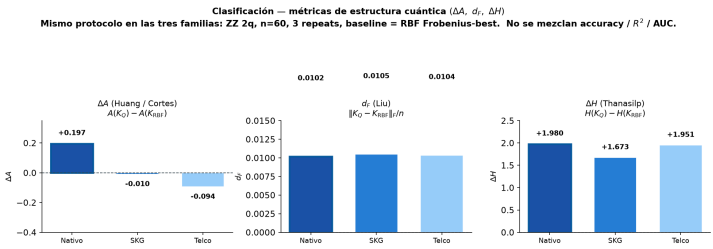
- $\Delta A = A(K_Q, yy^\top) - A(K_{\mathrm{RBF}}, yy^\top)$ — (Huang et al., 2021)
- $d_F = \|K_Q - K_{\mathrm{RBF}}\|_F / n$ — (Liu et al., 2021)
- $\Delta H = H(K_Q) - H(K_{\mathrm{RBF}})$ — (Thanasilp et al., 2022)

Mismo protocolo en clasificación, regresión y anomalías (ZZ 2q, n=60, 3 repeats, RBF Frobenius-best).
No se mezcla accuracy / R^2 / AUC en estos plots.

Nota: no hay Δ_{op} aquí

Eso era solo un nombre confuso para "accuracy(QSVM)−accuracy(mejor clásico)" en clasificación. **No** es métrica de estructura. Se retiró de estas figuras.

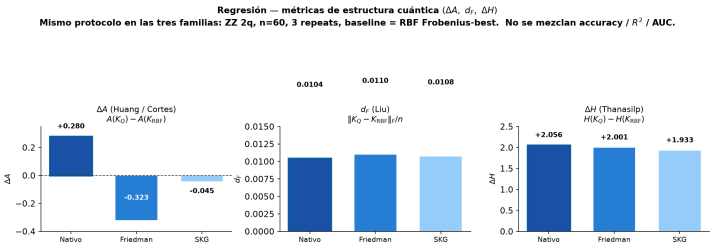
P1 — Clasificación: $(\Delta A,\ d_F,\ \Delta H)$



Lectura

- Nativo: $\Delta A{+}0{,}20$
- SKG: $\Delta A{\approx}0$
- Telco: $\Delta A{-}0{,}09$
- $d_F{\approx}0{,}01$ en los tres (casi no discrimina)

P1 — Regresión: las mismas métricas

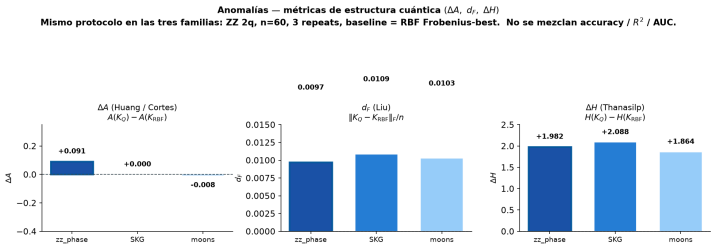


Lectura

- Nativo: $\Delta A{+}0{,}28$
- Friedman: $\Delta A{-}0{,}32$
- SKG: $\Delta A{-}0{,}04$
- d_F otra vez $\approx 0{,}01$

Misma escala que clasificación.

P1 — Anomalías: las mismas métricas

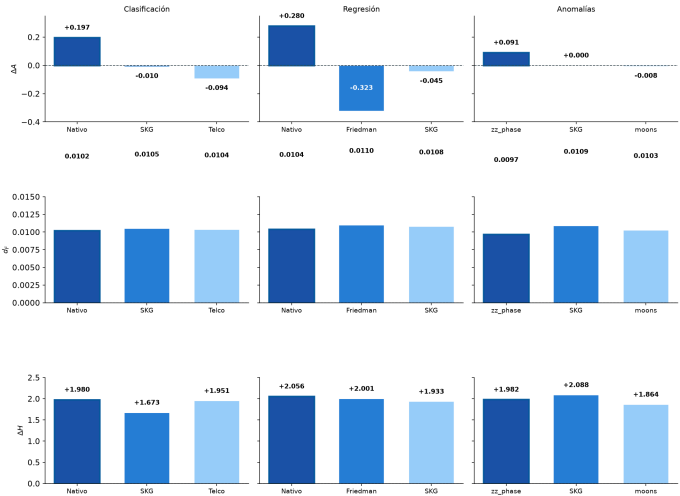


Lectura

- zz_phase: ΔA+0,09
- SKG / moons: $\Delta A \approx 0$
- d_F otra vez $\approx$ 0,01

Misma escala que clasif./reg.

P1 — las tres familias juntas



P1 — cómo interpretar

¿ΔA negativo + ΔH mínimo = estructura?

No. El control nativo tiene $\Delta A > 0$ en las tres familias. Friedman (regresión) tiene el ΔA más negativo ($-0{,}32$): sin alineación mapa–dato.

¿d_F discrimina entre datasets?

Aquí, apenas ($\approx 0{,}01$ en todos). El kernel ZZ es distinto del RBF, pero d_F no ordena nativo vs SKG/Telco/Friedman.

Lectura defendible

Comparar **las mismas** métricas entre casos de uso. Patrón: $\Delta A > 0$ en el control nativo (clasif./reg./anomalías); $\Delta A \leq 0$ en datos sin estructura ZZ. Alineación mapa–generador (Liu et al., 2021).

Camino a la Conjetura 2 / QCR (antes de la fórmula)

1. Si el diagnóstico dice "clásico", el default es el stack clásico.
2. Pero la pregunta correcta es: ¿falla el **dato** o el **espacio de representación**?
3. Hipótesis: existe $\psi : \mathcal{X} \to \mathcal{Z}$ polinómica que induzca geometría usable por el feature map **sin** destruir la señal.
4. **Notebook 09:** cuatro prototipos — ZZ-compatibles, rotación máx d_F, re-uploading, Q-UMAP/MDS.
5. Resultado: subidas locales de $\mathcal{Q}$ vs. baseline clásico débil; bajo $\mathcal{Q}_{\text{rob}}$ Telco sigue `classical` y SKG solo cambia geometría (`try-ZZ`), **sin** lift vs. el clásico fuerte.

Lectura

QCR es un **programa de investigación** formalizado desde la evidencia — no un algoritmo cerrado ni un rescate operativo.

Conjetura 2 — espacio de representación QCR

Si $\mathcal{Q}(\mathcal{D}) \leq 0$, se conjetura $\mathcal{Z}$ y $\psi : \mathcal{X} \to \mathcal{Z}$ **polinómica** tales que

$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^\star} \hat{y} \qquad \text{con} \quad \mathcal{Q}(\psi(\mathcal{D})) > 0 \ \text{ y } \ \varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star). \tag{2}$$

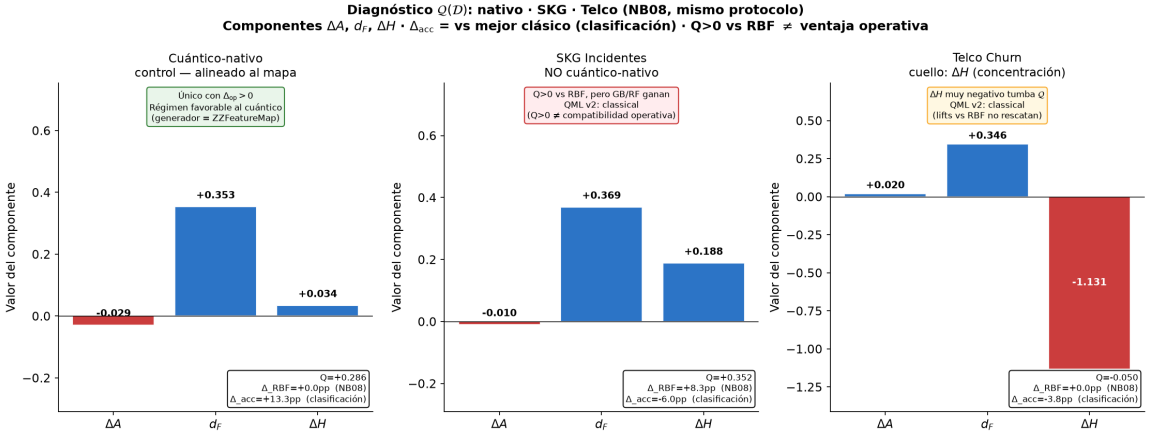
Intuición

Transformar el dato *antes* del kernel para que el mapa "vea" estructura usable.

Estado

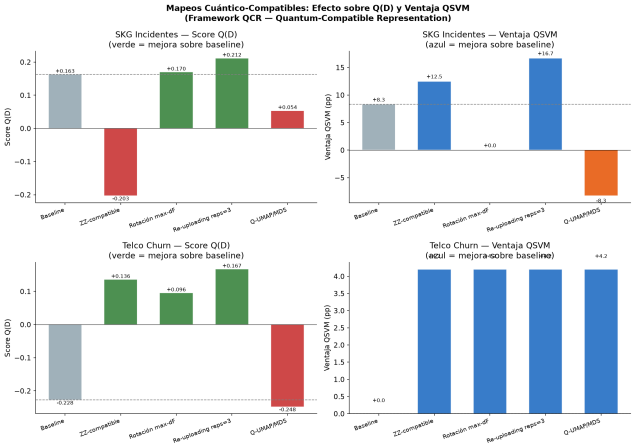
Conjetura **abierta**.
Este TFM la **plantea** + evidencia preliminar — no demostración.

Evidencia P2 — diagnóstico nativo / SKG / Telco



Solo el **nativo** gana vs mejor clásico (clasificación $+13{,}3$ pp). SKG: $\mathcal{Q} > 0$ vs RBF pero gana GB/RF. Telco: cuello ΔH. Misma lectura en regresión / anomalías.

Evidencia P2 — mapeos QCR (SKG y Telco)



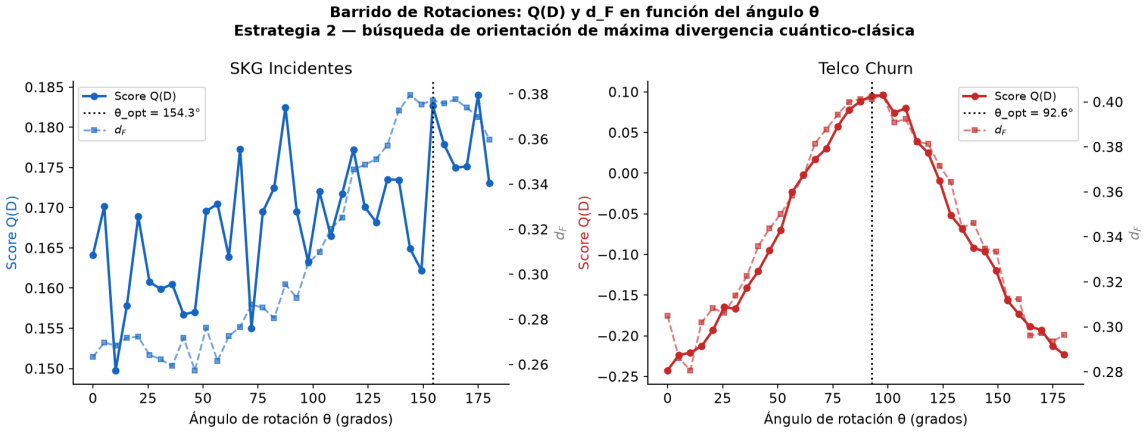
Por qué no el nativo

El dataset cuántico-nativo **ya** tiene ventaja operativa (+13,3 pp). QCR se plantea para datos **sin** esa alineación.

Lectura

Lifts vs. RBF en SKG/Telco $\neq$ rescate operativo. Bajo $\mathcal{Q}_{\mathrm{rob}}$ Telco sigue `classical`; SKG no es nativo.

Evidencia P2 — barrido de rotaciones (SKG / Telco)



NB09 solo sobre datasets reales (nativo no requiere rotación). Series del notebook; sin proxy.

Conclusiones (I) — ventaja condicionada

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: aparece cuando el feature map coincide con el generador (ZZ medido aquí; Pauli-Y confirma el mismo principio).
3. En **datos reales** SKG/Telco **sin** esa estructura: gana el **clásico** (no son cuántico-nativos).
4. Regresión: ventaja acotada (Friedman); en movilidad SKG, el clásico domina.
5. Anomalías / lags: misma regla — solo con target alineado (`zz_phase`, `zz_lag`).

Conclusiones (II) — híbridos y coste

6. QAOA reduce coste de asignación $\approx 30\,\%$ vs. Greedy a escala moderada.
7. VQE competitivo en portafolio pequeño; TSP n=4: empate óptimo (valor de *modelado*, no speedup).
8. MDS: patrón híbrido viable ($P(\mathrm{opt}) \approx 73\,\%$).
9. Coste de simulación del kernel $O(n^2)$: obstáculo práctico actual.
10. Metodologías maduras vs. hardware inmaduro: resultados mixtos son esperables en NISQ.

Conclusiones (III) — conjeturas y adopción

11. $\mathcal{Q}(\mathcal{D})$ como **vector** $(\Delta A, \hat{d}_F, \Delta H)$; el escalar colapsado no se usa; sí $\rho_S(\alpha, \Delta A)$=0,833.
12. QCR: **planteado**; evidencia preliminar vs. RBF; no rescate operativo.
13. Adopción recomendada: **selectiva e híbrida** — módulo cuántico como herramienta adicional, no sustituto del stack clásico (SKG).

Respuesta a la pregunta del TFM

Ventaja medible hoy cuando hay coincidencia mapa–generador o QUBO híbrido viable; en ausencia de eso, el clásico domina — y eso también es un resultado.

Limitaciones (I)

- **Simulación statevector**: sin ruido NISQ de hardware; ideales $\neq$ shots reales.
- **PCA a** n_q=2: $\sim$68 % de varianza descartada; $\mathcal{Q}$ mide el subespacio proyectado.
- **Muestra** $n\approx$80 en indicadores; correlación en 3 datasets reales es orientativa.
- **Baseline**: $\mathcal{Q} > 0$ vs. un clásico débil $\neq$ ventaja vs. el mejor clásico (caso SKG).
- **Protocolos distintos**: Δ_{RBF} (NB08) $\neq$ ventaja vs mejor clásico (clasificación / NB06); no se mezclan en una sola ρ ni en la misma leyenda.

Limitaciones (II) — debilidades expuestas

- **Barrido** α: X fijo $\Rightarrow$ d_F/H constantes; ρ_S=0,833 es $\rho(\alpha, \Delta A)$, no predicción de ventaja.
- **Sin dumps de** K: no se inventan heatmaps ni contrastes a mano.
- **Rotaciones NB09**: series del notebook; no regenerar con curvas proxy.
- **Post-QCR**: solo Q/Adv logueados; no inventar componentes post.
- **QCR** sin demostración fuerte; Q-UMAP = MDS proxy.
- **Escalabilidad**: kernel $O(n^2)$; sin hardware real.

Criterio de integridad

Qué es un buen resultado en este TFM

Argumentar y discutir desde lo **medido**: ventaja condicionada, resultados negativos, potencia baja (n=3), protocolos distintos.

Qué no se hace

Alterar datos, embellecer series, mezclar Δ_{RBF} con la ventaja operativa de clasificación, ni fabricar artefactos ausentes. Si falta la medición, se omite o se declara el límite.

Trabajo futuro (I) — corto plazo y SKG

Corto plazo

- Hardware ruidoso (IBM) + mitigación (ZNE)
- Más qubits / menos PCA agresivo
- Validación fuerte de QCR y $\mathcal{Q}_{\mathrm{rob}}$
- Calibrar pesos (w_i); más feature maps (IQP, Pauli)
- Kernels aleatorizados $O(n)$ / ensembles

Aplicación SKG

- QAOA en asignación real (`agents.csv`)
- VRP-TW / rutas de emergencia
- Multiclase de gravedad de incidentes
- Activación selectiva en pipeline productivo
- A/B testing cuántico–clásico

Trabajo futuro (II) — medio/largo plazo

- Benchmarks con separación formal (Bravyi et al.) para certificar $\mathcal{Q}$
- Certificación estadística de ventaja (Huang et al., 2021)
- Demostración o refutación de la conjetura QCR
- Q-means / autoencoders / aprendizaje no supervisado cuántico
- Análisis de barren plateaus en VQC
- Integración API + monitorización de *data drift* en SKG

Trabajo futuro (III) — roadmap

Corto (1–2 a)

- Hardware IBM + ZNE
- API + A/B test SKG
- QAOA $p>1$ / SPSA

Medio (2–4 a)

- 4–8 qubits, menos PCA
- QAOA asignación real
- Validar $\mathcal{Q}$ en corpus amplio

Largo (4+ a)

- FTQC / corrección errores
- Demostrar / refutar QCR
- QCR multi-mapa + publicación

Validación cruzada ZZ vs Pauli-Y (principio general)

Resultado (QML v2, n=120, 5 repeats)

- Generador ZZ $\Rightarrow$ QSVM-ZZ 0,828 vs RBF 0,478
- Generador Pauli-Y $\Rightarrow$ QSVM-PauliY 0,550 vs RBF 0,517
- Kernel ZZ *desalineado* cae a 0,406

Lectura

La ventaja sigue al **emparejamiento** mapa–generador. ZZ es el mapa del corpus principal; **no** el único admisible.

Gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

(Preskill, 2018; Biamonte et al., 2017; Farhi et al., 2014; Schuld, 2021; Huang et al., 2021; Liu et al., 2021; Cerezo et al., 2021)

Referencias (selección) I

Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). *Algorithms for learning kernels based on centered alignment*. JMLR.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. et al. (2019). *Machine learning methods in quantum computing theory*. Proc. SPIE.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Referencias (selección) II

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S. et al. (2022). *Exponential concentration and the limits of quantum ML*. arXiv:2208.11060.