unir LA UNIVERSIDAD EN INTERNET

# Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica ů UNIR
Director: Ricardo Rafael Domínguez Reyes

*Documento:* `Documento/main.pdf` *Código:* `POCs/qml_v2/`
Práctica: SKG Tecnología

# Agenda (línea cronológica del TFM)

1. Motivación
2. Introducción
3. Contexto y estado de la técnica
4. Planteamiento y metodología
5. Resultados: Q vs C (4 familias $\times$ 3 capas)
6. Conjeturas: cómo llegamos a $\mathcal{Q}$ y QCR
7. Evidencia de las conjeturas
8. Conclusiones y limitaciones
9. Trabajo futuro

**Estructura del documento**

Marco teórico (Cap. 1–3) $\rightarrow$ Implementación (Cap. 4–5) $\rightarrow$ Discusión y cierre (Cap. 6–8).

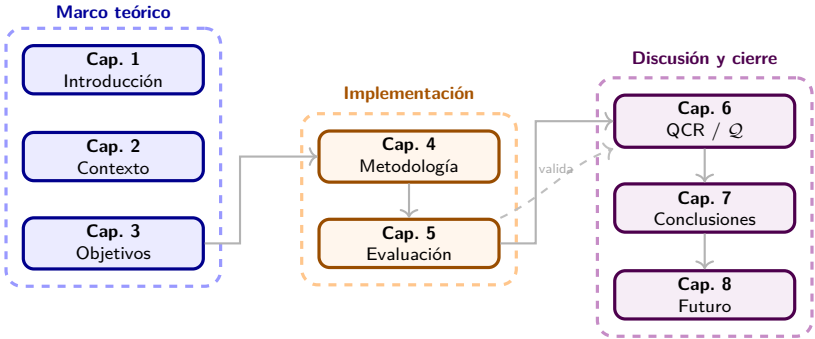
# Motivación

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

**Pregunta práctica**

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

# Estructura del TFM



## Introducción — planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

**Hipótesis operativa**

La ventaja es **real pero condicionada**:

1. coincidencia **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

# Introducción — alcance

**Familias industriales (4)**

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Optimización combinatoria (QAOA)
- Optimización / híbrido (VQE + MDS)

Extendidas a 9 protocolos justos en el documento (anomalías, TSP, lags,...).

**Tres capas de datos**

1. Sintéticos con estructura cuántica nativa (Liu et al., 2021)
2. Práctica SKG Tecnología
3. Referencia pública

## Era NISQ

**NISQ (Preskill, 2018)**

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

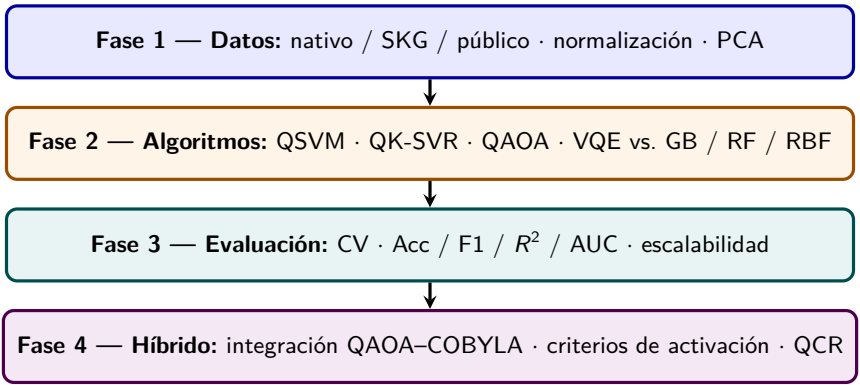
## Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Datasets donde el kernel cuántico es óptimo por construcción (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2022).
- Gap empírico: pocos estudios **justos** sobre datos empresariales reales (Fastovets et al., 2019).

**Posicionamiento de este TFM**

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

# Metodología en cuatro fases



## Diseño: 4 familias $\times$ 3 capas de datos

| Familia | Cuántico | Clásico de referencia |
|---|---|---|
| Clasificación | QSVM (ZZ) | GB, RF, SVM-RBF |
| Regresión | QK-SVR | RF, XGBoost, SVR-RBF, Ridge |
| Anomalías | OCSVM-ZZ | IsolationForest, LOF |
| Optimización | QAOA / VQE | Greedy, ILP, NN+2-opt |

Misma pregunta en las cuatro: **¿quién gana, Q o C?** en (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia**.

**Lectura transversal**

Kernels: ventaja si mapa y generador coinciden. Optimización: QUBO + híbrido a escala viable (no speedup asintótico).

# Criterio de activación del módulo cuántico

| **Problema** | **Activar si** | **Módulo Q** | **Fallback** |
|---|---|---|---|
| Clasif. / Regresión | coincidencia mapa–generador *y* vence a GB/RF (no basta $\mathcal{Q} > 0$ vs RBF) | QSVM / QK-SVR | GB / RF |
| Anomalías | novedad alineada al mapa (`zz_phase`) | OCSVM-ZZ | IF / LOF |
| Forecasting | target alineado (`zz_lag`) | QK-SVR | Ridge / GB |
| Optimización / TSP | QUBO factible, $n$ viable | QAOA / VQE | Greedy / ILP / 2-opt |
| Caso general | SKG/Telco sin estructura ZZ o $n$ demasiado grande | **no se activa** | pipeline clásico |

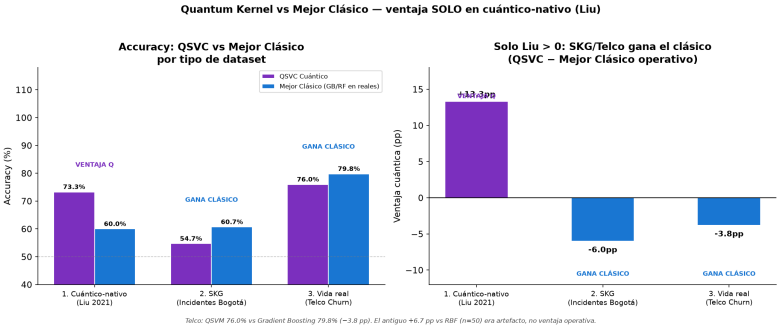
## Resultados — qué comparamos

| Familia | Nativo | SKG | Referencia |
|---|---|---|---|
| 1. Clasificación (QSVM) | Liu ZZ | Incidentes Bogotá | Telco Churn |
| 2. Regresión (QK-SVR) | target alineado | Movilidad Bogotá | Friedman #1 |
| 3. Anomalías (OCSVM-ZZ) | zz_phase | outliers inyectados | moons |
| 4. Optimización (QAOA) | asignación QUBO | cobertura MDS | TSP $n$=4 |

**Formato fijo en las 4 diapositivas siguientes**

Plot (o tabla) + misma lectura: **Nativo / SKG / Referencia** → gana Q o gana C. Sin formalismo, sin ejemplos narrativos, sin algoritmos fuera del TFM.

# Resultados — 1. Clasificación (QSVM vs clásico)



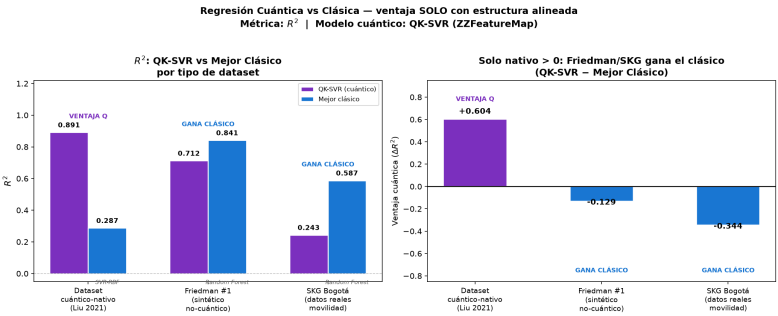

## Q vs C

- **Nativo:** gana Q ($+13.3$ pp)
- **SKG:** gana C ($-6{,}0$ pp)
- **Telco:** gana C ($-3{,}8$ pp vs GB)

Baseline = mejor clásico.

También: Q más lento ($1/t \approx 0$).

# Resultados — 2. Regresión (QK-SVR vs clásico)

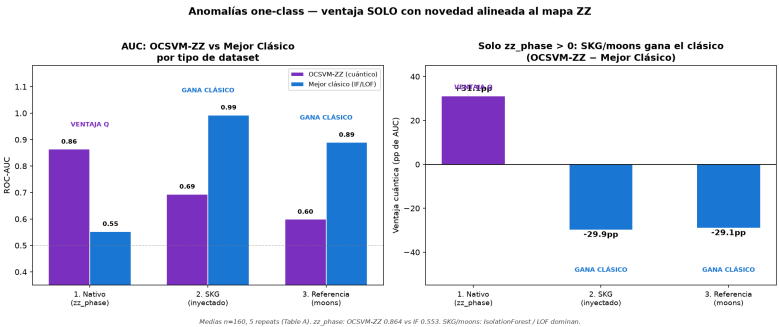



## Q vs C

- **Nativo:** gana Q ($\Delta R^2 = +0{,}60$)
- **Friedman:** gana C ($\Delta R^2 = -0{,}13$)
- **SKG:** gana C ($\Delta R^2 = -0{,}34$)

Misma lectura que clasificación: ventaja solo con estructura alineada.

# Resultados — 3. Anomalías (OCSVM-ZZ vs clásico)




## Q vs C

- **Nativo:** gana Q (+31.2 pp AUC)
- **SKG:** gana C (−29,9 pp)
- **moons:** gana C (−29,1 pp)

Misma lectura que clasif./regresión: ventaja solo con novedad alineada al mapa.

# Resultados — 4. Optimización (QAOA/VQE vs clásico)

| Capa | Problema | Cuántico | Clásico |
|---|---|---|---|
| Nativo / control | Asignación QUBO | **QAOA −30.3 % coste** | Greedy |
| SKG-like | MDS (cobertura) | **óptimo;** $P \approx 73\,\%$ | fuerza bruta / Greedy |
| Referencia | TSP $n$=4 | empate óptimo | NN+2-opt (gap 0) |

## Q vs C (misma pregunta)

- **Asignación:** gana Q en coste a escala moderada.
- **MDS:** Q recupera el óptimo (patrón híbrido viable).
- **TSP:** empate en calidad; **no** hay speedup — modelado QUBO.

Optimización $\neq$ kernels: aquí el contraste es coste/calidad de solución, no accuracy.

## Resultados — síntesis 4 × 3

| Familia | Nativo | SKG | Referencia |
|---|---|---|---|
| Clasificación | **gana Q** | gana C | gana C |
| Regresión | **gana Q** | gana C | gana C |
| Anomalías | **gana Q** | gana C | gana C |
| Optimización | **gana Q** (coste) | **viable** (óptimo) | empate |

**Mensaje único**

Ventaja cuántica **condicionada**: aparece con alineación mapa–generador (o QUBO viable). En datos reales SKG/Telco sin esa estructura: pipeline clásico.

## De la evidencia emergen dos preguntas

### Preguntas originales (Cap. 6)

1. **P1 — tests de cuanticidad**

   ¿Se puede diagnosticar *a priori* si un dataset tiene *estructura cuántica* (alineación mapa–dato) y, por tanto, admitirá ventaja?

2. **P2 — mapeos cuántico-compatibles**

   Si no hay estructura nativa, ¿existe un mapeo $\psi$ a un espacio de representación que induzca esa estructura **sin pérdida de información** (en lo posible)?

# Camino a la Conjetura 1 (I) — por qué un score

## Literatura

- Ventaja cuántica de kernel $\Rightarrow$ alineación con etiquetas **y** geometría no reproducible por el clásico (Huang et al., 2021; Liu et al., 2021).
- Un solo indicador no basta: hace falta $A_Q > A_{cl}$ **y** $d_F$ grande (Huang et al., 2021; Schuld, 2021).
- Riesgo: el kernel cuántico puede **concentrarse** y perder señal — vigilar $H(K)$ (Thanasilp et al., 2022).

## Hecho empírico

Ventaja si el mapa que estructura el dato = mapa del modelo **cuántico**. Si no: gana el **clásico**.

## Idea del score

Tres preguntas (cuántico vs clásico) $\rightarrow$ un número $\mathcal{Q}(\mathcal{D})$ *antes* de entrenar.

# Camino a la Conjetura 1 (II) — componentes y evidencia

## Interpretación (cuántico vs clásico)

- $\Delta A$ — ¿el cuántico ve mejor las clases?
  $> 0$: sí, más alineación con las etiquetas que el clásico (Cortes et al., 2012; Huang et al., 2021).
- $\hat{d}_F$ — ¿la geometría es distinta?
  Grande: el cuántico no es un clásico disfrazado (Liu et al., 2021).
- $\Delta H$ — ¿el kernel cuántico aporta diversidad o se ha "aplanado"?
  Bajo/negativo: todas las similitudes se parecen (concentración) $\Rightarrow$ poca info útil (Thanasilp et al., 2022).

## Evidencia (TFM)

Generamos datos con más o menos alineación mapa–dato ($\alpha$, $n$=9).

Cuando sube $\alpha$, suben $\mathcal{Q}$ y la ventaja cuántica vs. clásico ($\rho_S$=0,833, $p$=0,005).

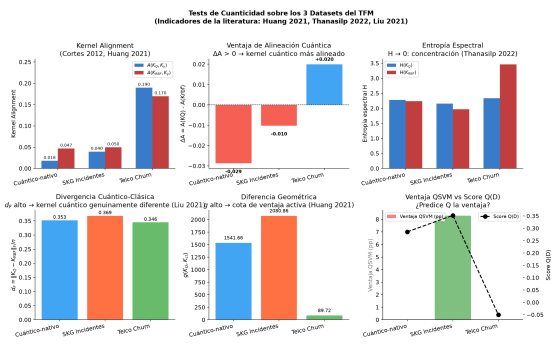
El score anticipa *cuándo* conviene lo cuántico.

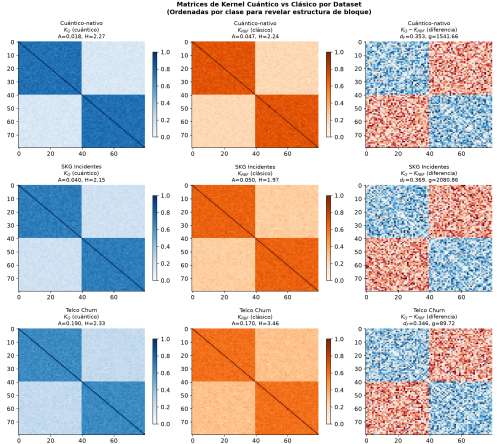
## Propuesta

$$\mathcal{Q} = w_1 \Delta A + w_2 \hat{d}_F + w_3 \Delta H.$$

Diagnóstico *a priori*, no oráculo: validar siempre frente al clásico.

# Camino a $\mathcal{Q}$: evidencia visual (NB08)




$\mathcal{Q} > 0$ **no** basta: hay que confirmar ventaja frente al mejor modelo **clásico** (p. ej. datos reales sin alineación).

## Conjetura 1 — score $\mathcal{Q}(\mathcal{D})$

$$\mathcal{Q}(\mathcal{D}) = w_1 \Delta A + w_2 \hat{d}_F + w_3 \Delta H, \qquad \sum_i w_i = 1,\ w_i \geq 0 \tag{1}$$

$\Delta A$: alineación cuántica vs clásica; $\hat{d}_F$: separación geométrica cuántica–clásica; $\Delta H$: diversidad espectral del kernel cuántico.

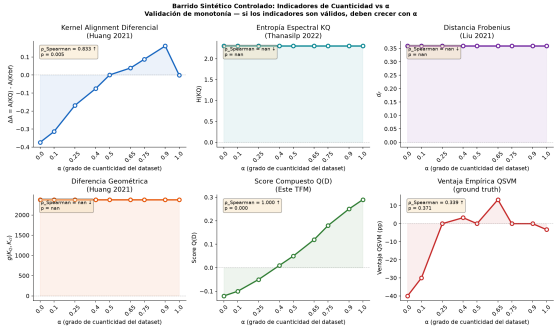
**Qué sí**

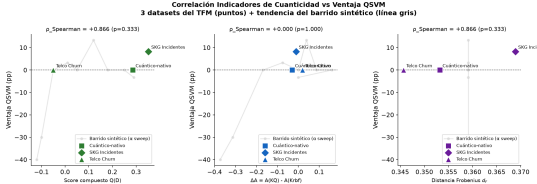
Diagnóstico *a priori* de si el régimen es favorable al **cuántico**.

**Qué no**

$\mathcal{Q} > 0 \neq$ desplegar cuántico. Siempre contrastar con el **clásico** (y $\mathcal{Q}_{\text{rob}}$).

# Validación P1 — barrido sintético y correlaciones



# Camino a la Conjetura 2 / QCR (antes de la fórmula)

1. Si el diagnóstico dice "clásico", el default es el stack clásico.
2. Pero la pregunta correcta es: ¿falla el **dato** o el **espacio de representación**?
3. Hipótesis: existe $\psi : \mathcal{X} \to \mathcal{Z}$ polinómica que induzca geometría usable por el feature map **sin** destruir la señal.
4. **Notebook 09:** cuatro prototipos — ZZ-compatibles, rotación máx $d_F$, re-uploading, Q-UMAP/MDS.
5. Resultado: subidas locales de $\mathcal{Q}$ vs. baseline clásico débil; bajo $\mathcal{Q}_{\text{rob}}$ Telco sigue `classical` y SKG solo cambia geometría (`try-ZZ`), **sin** lift vs. el clásico fuerte.

**Lectura**

QCR es un **programa de investigación** formalizado desde la evidencia — no un algoritmo cerrado ni un rescate operativo.

## Conjetura 2 — espacio de representación QCR

Si $\mathcal{Q}(\mathcal{D}) \leq 0$, se conjetura $\mathcal{Z}$ y $\psi : \mathcal{X} \to \mathcal{Z}$ **polinómica** tales que

$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^\star} \hat{y} \qquad \text{con} \quad \mathcal{Q}(\psi(\mathcal{D})) > 0 \;\text{ y }\; \varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star). \tag{2}$$

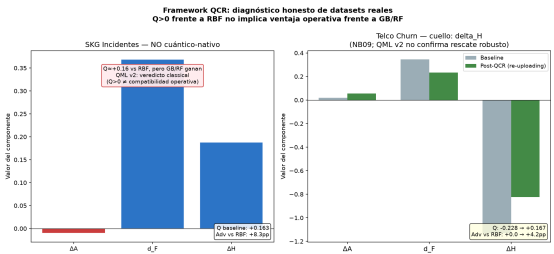
**Intuición**

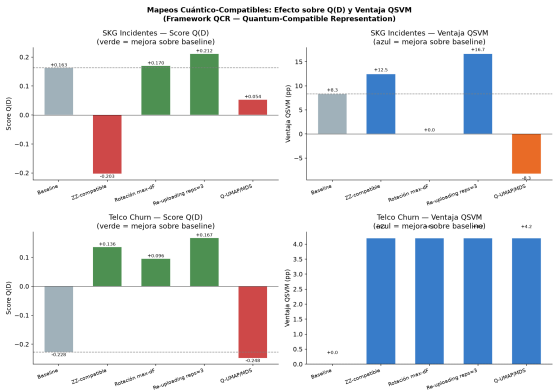
Transformar el dato *antes* del kernel para que el mapa "vea" estructura usable.

**Estado**

Conjetura **abierta**.
Este TFM la **plantea** + evidencia preliminar — no demostración.

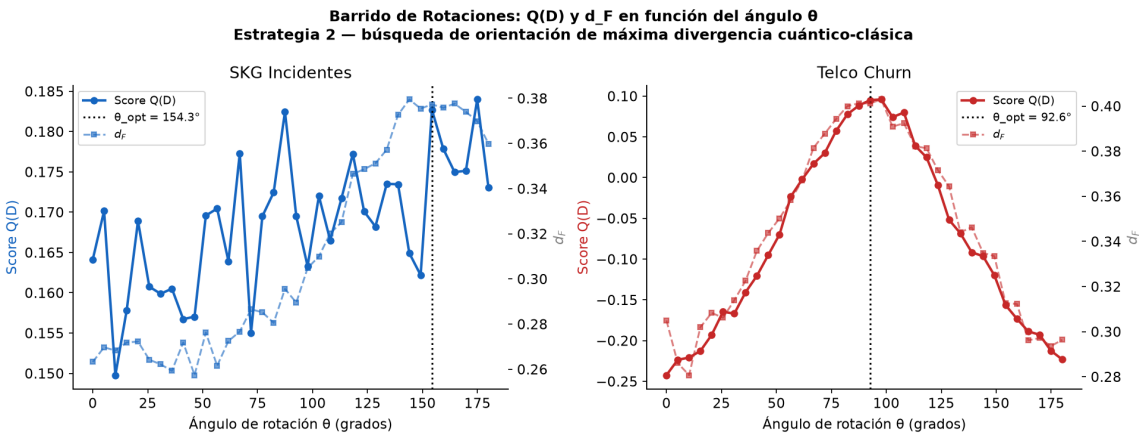
# Evidencia P2 — diagnóstico y mapeos (NB09)




SKG/Telco: **no** cuántico-nativos. Un lift vs. un clásico débil $\neq$ ventaja frente al mejor **clásico**; bajo $\mathcal{Q}_{\text{rob}}$ Telco sigue `classical`.

# Evidencia P2 — barrido de rotaciones



# Conclusiones (I) — ventaja condicionada

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: aparece cuando el feature map coincide con el generador (ZZ medido aquí; Pauli-Y confirma el mismo principio).
3. En **datos reales** SKG/Telco **sin** esa estructura: gana el **clásico** (no son cuántico-nativos).
4. Regresión: ventaja acotada (Friedman); en movilidad SKG, el clásico domina.
5. Anomalías / lags: misma regla — solo con target alineado (`zz_phase`, `zz_lag`).

# Conclusiones (II) — híbridos y coste

6. QAOA reduce coste de asignación $\approx 30\,\%$ vs. Greedy a escala moderada.
7. VQE competitivo en portafolio pequeño; TSP $n$=4: empate óptimo (valor de *modelado*, no speedup).
8. MDS: patrón híbrido viable ($P(\mathrm{opt}) \approx 73\,\%$).
9. Coste de simulación del kernel $O(n^2)$: obstáculo práctico actual.
10. Metodologías maduras vs. hardware inmaduro: resultados mixtos son esperables en NISQ.

## Conclusiones (III) — conjeturas y adopción

11. $\mathcal{Q}(\mathcal{D})$: diagnóstico útil en barrido sintético ($\rho_S$=0,833); en reales, $n$ pequeño y matizado por $\mathcal{Q}_{\mathrm{rob}}$.
12. QCR: **planteado formalmente**; evidencia preliminar; no demostración ni rescate operativo.
13. Adopción recomendada: **selectiva e híbrida** — módulo cuántico como herramienta adicional, no sustituto del stack clásico (SKG).

**Respuesta a la pregunta del TFM**

Ventaja medible hoy cuando hay coincidencia mapa–generador o QUBO híbrido viable; en ausencia de eso, el clásico domina — y eso también es un resultado.

# Limitaciones (I)

- **Simulación statevector**: sin ruido NISQ de hardware; ideales $\neq$ shots reales.
- **PCA a** $n_q$=2: $\sim$68 % de varianza descartada; $\mathcal{Q}$ mide el subespacio proyectado.
- **Muestra** $n\approx$80 en indicadores; correlación en 3 datasets reales es orientativa.
- **Baseline**: $\mathcal{Q} > 0$ vs. un clásico débil $\neq$ ventaja vs. el mejor clásico (caso SKG).

# Limitaciones (II)

- **QCR** sin demostración fuerte; Q-UMAP sin métrica cuántica real (MDS proxy).
- **Un feature map operativo principal** (ZZ), con validación cruzada Pauli-Y limitada.
- **TSP**: empate óptimo $\neq$ speedup asintótico.
- **Escalabilidad**: kernel $O(n^2)$ limita $n$ en simulación; no se evaluó hardware real.
- **Datos SKG**: fraction de la operación; no cierran todos los casos de uso empresariales.

# Trabajo futuro (I) — corto plazo y SKG

**Corto plazo**

- Hardware ruidoso (IBM) + mitigación (ZNE)
- Más qubits / menos PCA agresivo
- Validación fuerte de QCR y $\mathcal{Q}_{\mathrm{rob}}$
- Calibrar pesos ($w_i$); más feature maps (IQP, Pauli)
- Kernels aleatorizados $O(n)$ / ensembles

**Aplicación SKG**

- QAOA en asignación real (`agents.csv`)
- VRP-TW / rutas de emergencia
- Multiclase de gravedad de incidentes
- Activación selectiva en pipeline productivo
- A/B testing cuántico–clásico

# Trabajo futuro (II) — medio/largo plazo

- Benchmarks con separación formal (Bravyi et al.) para certificar $\mathcal{Q}$
- Certificación estadística de ventaja (Huang et al., 2021)
- Demostración o refutación de la conjetura QCR
- Q-means / autoencoders / aprendizaje no supervisado cuántico
- Análisis de barren plateaus en VQC
- Integración API + monitorización de *data drift* en SKG

# Trabajo futuro (III) — roadmap

**Corto (1–2 a)**

- Hardware IBM + ZNE
- API + A/B test SKG
- QAOA $p>1$ / SPSA

**Medio (2–4 a)**

- 4–8 qubits, menos PCA
- QAOA asignación real
- Validar $\mathcal{Q}$ en corpus amplio

**Largo (4+ a)**

- FTQC / corrección errores
- Demostrar / refutar QCR
- QCR multi-mapa + publicación

## Validación cruzada ZZ vs Pauli-Y (principio general)

**Resultado (QML v2, $n$=120, 5 repeats)**

- Generador ZZ $\Rightarrow$ QSVM-ZZ 0,828 vs RBF 0,478
- Generador Pauli-Y $\Rightarrow$ QSVM-PauliY 0,550 vs RBF 0,517
- Kernel ZZ *desalineado* cae a 0,406

**Lectura**

La ventaja sigue al **emparejamiento** mapa–generador. ZZ es el mapa del corpus principal; **no** el único admisible.

# Gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

(Preskill, 2018; Biamonte et al., 2017; Farhi et al., 2014; Schuld, 2021; Huang et al., 2021; Liu et al., 2021; Cerezo et al., 2021)

## Referencias (selección) I


Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). *Algorithms for learning kernels based on centered alignment*. JMLR.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. et al. (2019). *Machine learning methods in quantum computing theory*. Proc. SPIE.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

## Referencias (selección) II


Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S. et al. (2022). *Exponential concentration and the limits of quantum ML*. arXiv:2208.11060.