unir LA UNIVERSIDAD EN INTERNET

# Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica ů UNIR
Director: Ricardo Rafael Domínguez Reyes

*Documento:* `Documento/main.pdf` *Código:* `POCs/qml_v2/`
Práctica: SKG Tecnología

# Agenda (línea cronológica del TFM)

1. Motivación
2. Introducción
3. Contexto y estado de la técnica
4. Planteamiento y metodología
5. Resultados de modelos (plots)
6. Conjeturas: cómo llegamos a $\mathcal{Q}$ y QCR
7. Evidencia de las conjeturas
8. Conclusiones y limitaciones
9. Trabajo futuro

**Estructura del documento**

Marco teórico (Cap. 1–3) $\rightarrow$ Implementación (Cap. 4–5) $\rightarrow$ Discusión y cierre (Cap. 6–8).

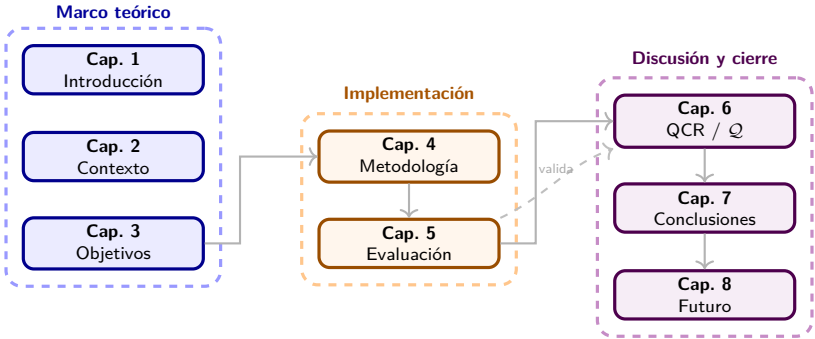
## Motivación

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

**Pregunta práctica**

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

# Estructura del TFM



## Introducción — planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

**Hipótesis operativa**

La ventaja es **real pero condicionada**:

1. coincidencia **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

# Introducción — alcance

**Familias industriales (4)**

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Optimización combinatoria (QAOA)
- Optimización / híbrido (VQE + MDS)

Extendidas a 9 protocolos justos en el documento (anomalías, TSP, lags,...).

**Tres capas de datos**

1. Sintéticos con estructura cuántica nativa (Liu et al., 2021)
2. Práctica SKG Tecnología
3. Referencia pública

## Era NISQ

**NISQ (Preskill, 2018)**

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

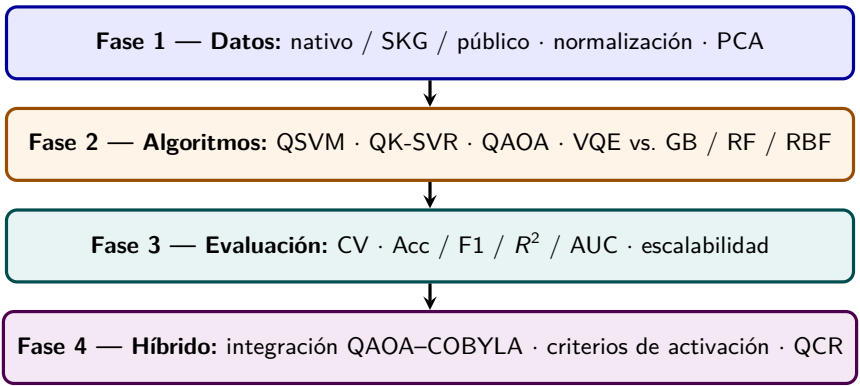
## Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Datasets donde el kernel cuántico es óptimo por construcción (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2022).
- Gap empírico: pocos estudios **justos** sobre datos empresariales reales (Fastovets et al., 2019).

**Posicionamiento de este TFM**

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

# Metodología en cuatro fases



## Diseño: 4 familias $\times$ 3 capas de datos

| Familia | Cuántico | Clásico de referencia |
|---|---|---|
| Clasificación | QSVM (ZZ) | GB, RF, SVM-RBF |
| Regresión | QK-SVR | XGBoost, RF, SVR-RBF, Ridge |
| Optimización (asignación) | QAOA ($p$=1) | Greedy, búsqueda local, ILP |
| Portafolio / cobertura | VQE / QAOA-MDS | Markowitz, fuerza bruta |
| Anomalías / lags | OCSVM-ZZ / QK-SVR | IF, LOF, Ridge, GB |

Cada familia se evalúa, cuando aplica, en: (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia pública**.

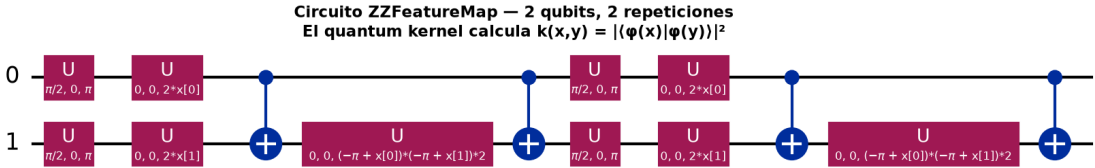
**Condición operativa (sin detenerse en formalismo)**

Kernels: ventaja si el **generador** coincide con el feature map (ZZ medido aquí). Optimización: QUBO + loop híbrido (QAOA/VQE + COBYLA) a escala viable.

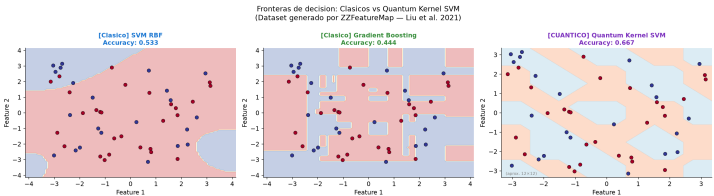
# Criterio de activación del módulo cuántico

| **Problema** | **Activar si** | **Módulo Q** | **Fallback** |
|---|---|---|---|
| Clasif. / Regresión | coincidencia mapa–generador *y* vence a GB/RF (no basta $\mathcal{Q} > 0$ vs RBF) | QSVM / QK-SVR | GB / RF |
| Anomalías | novedad alineada al mapa (`zz_phase`) | OCSVM-ZZ | IF / LOF |
| Forecasting | target alineado (`zz_lag`) | QK-SVR | Ridge / GB |
| Optimización / TSP | QUBO factible, *n* viable | QAOA / VQE | Greedy / ILP / 2-opt |
| Caso general | SKG/Telco sin estructura ZZ o *n* demasiado grande | **no se activa** | pipeline clásico |

# Resultados — circuito ZZFeatureMap (mapa usado)



# Resultados — nativo ZZ: el QSVM ve la frontera



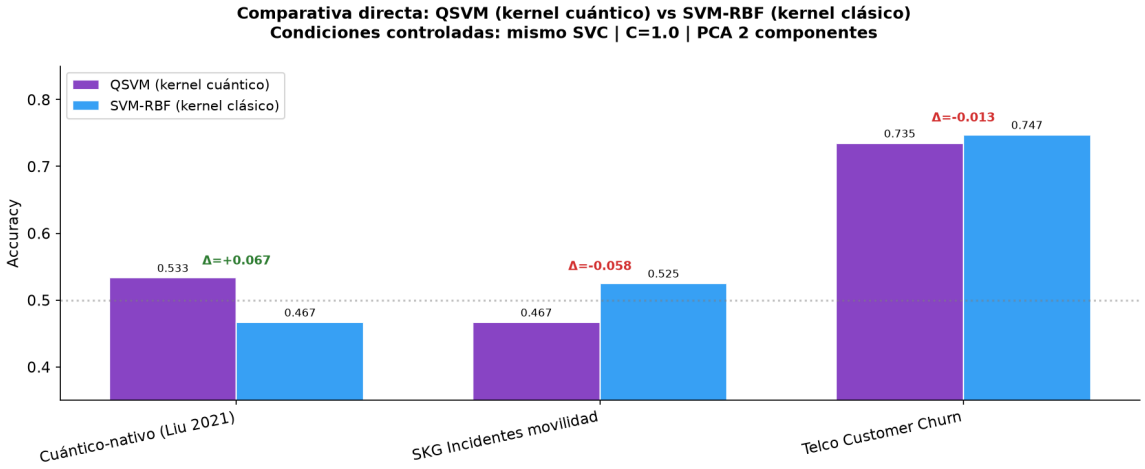

## Qué muestra

Etiquetas generadas con el mismo `ZZFeatureMap`.

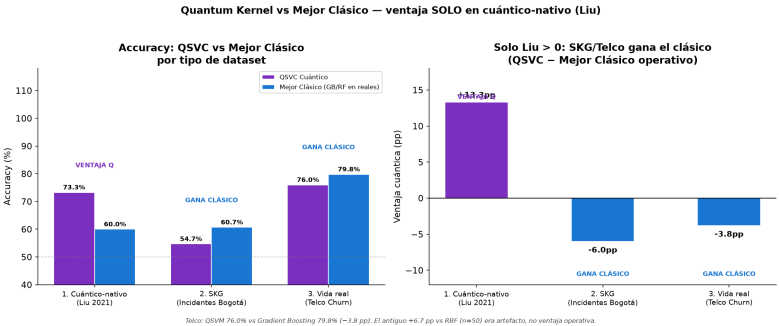
- QSVM recupera la frontera
- RBF / GB $\approx$ azar

Régimen controlado (Liu): no es un dataset empresarial. El punto es la coincidencia mapa–generador, no el tamaño de muestra.

# Resultados — QSVM vs SVM (directo)



# Resultados — clasificación en 3 capas de datos

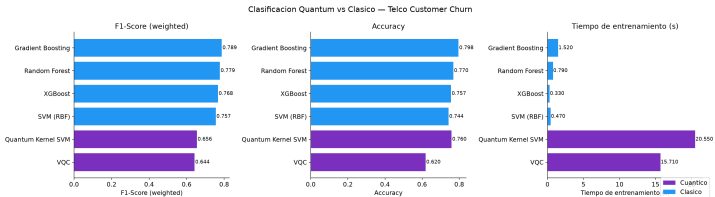



## Lectura (única)

- **Liu:** ventaja Q ($+13.3$ pp)
- **SKG:** gana clásico ($-6{,}0$ pp)
- **Telco:** gana clásico ($-3{,}8$ pp vs GB)

Telco $+6{,}7$ pp vs RBF ($n$=50) era artefacto —**no** ventaja operativa.

# Resultados — Telco: sin estructura ZZ (gana el clásico)

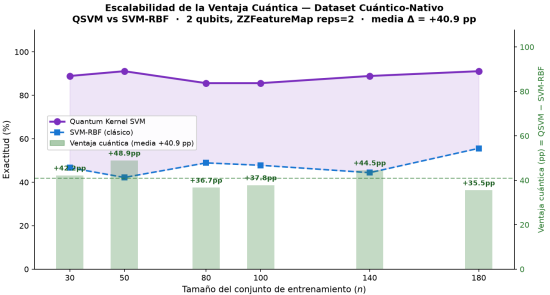


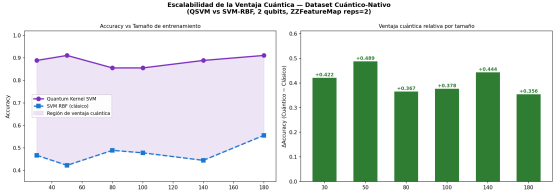

## Lectura

- GB/RF/XGBoost: F1 $\approx 0{,}78$–$0{,}79$
- QSVM / VQC: F1 $\approx 0{,}64$–$0{,}66$
- Tiempo: clásico $< 2\,\text{s}$; cuántico $> 15\,\text{s}$

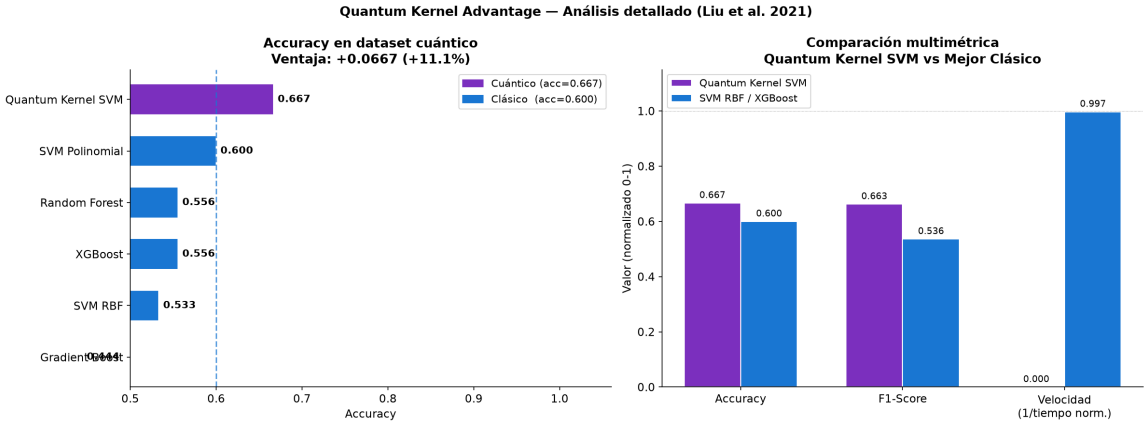
SKG/Telco no son cuántico-nativos.

# Resultados — escalabilidad del QSVM

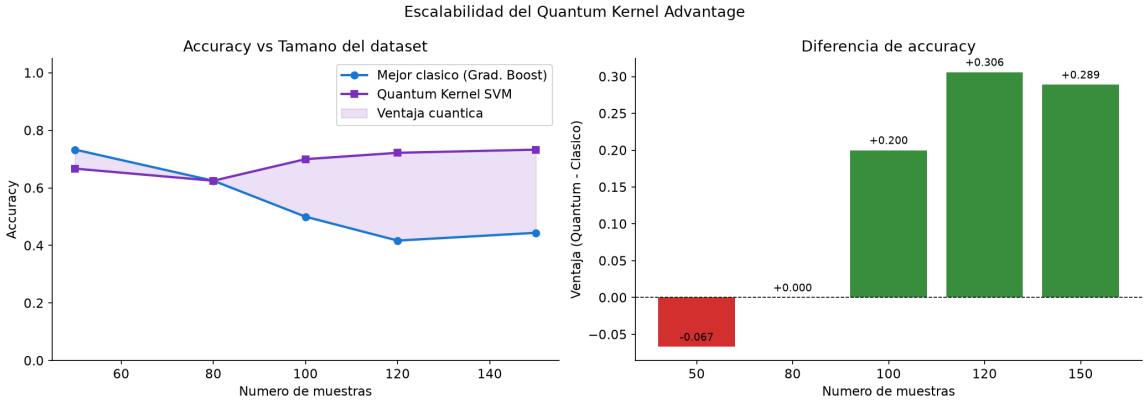


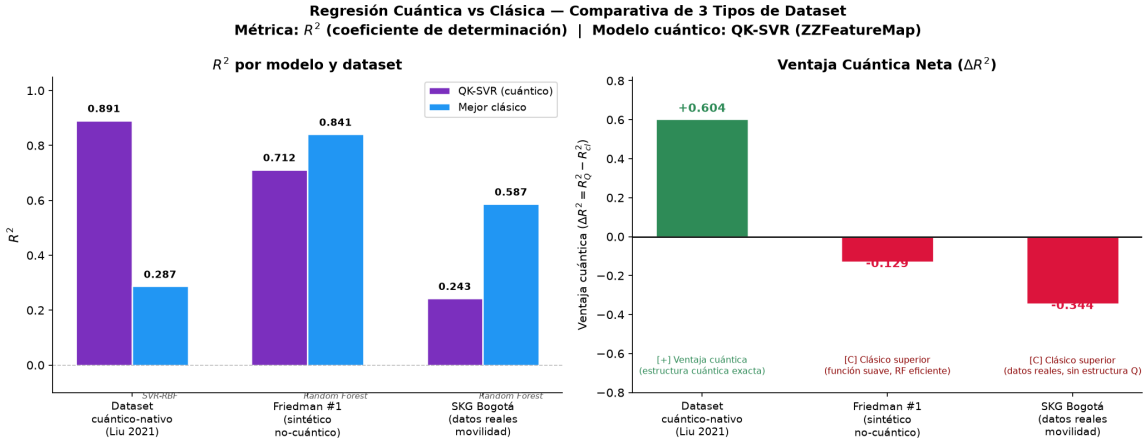
# Resultados — detalle del umbral de ventaja



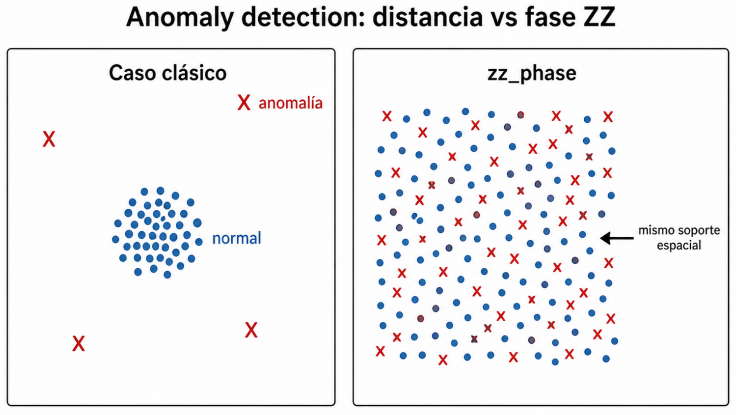
# Resultados — coste del kernel cuántico



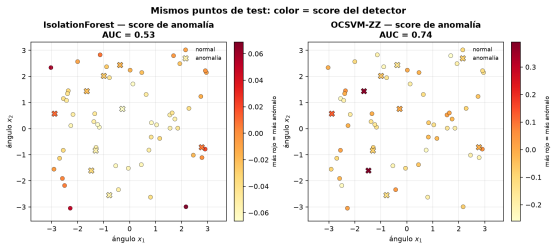
# Resultados — regresión (QK-SVR, 3 datasets)

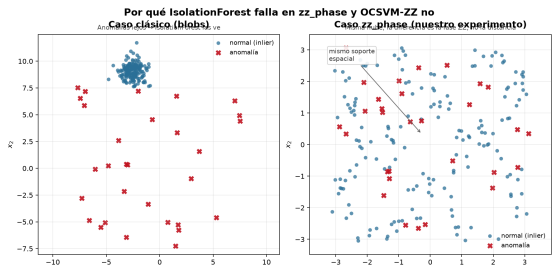


# Resultados — anomalías: idea (distancia vs fase ZZ)



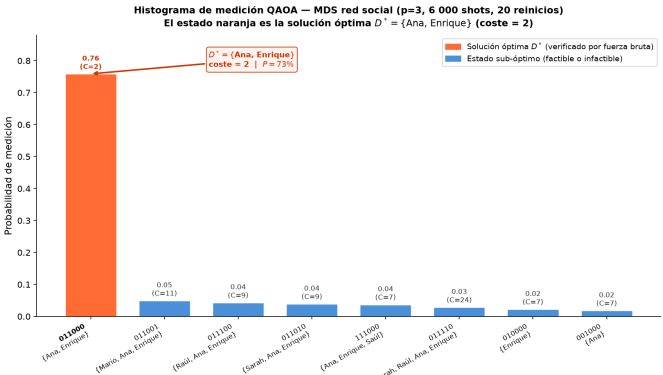
# Resultados — anomalías (OCSVM-ZZ)




Ventaja solo en `zz_phase`; en moons/blobs/SKG inyectado gana IsolationForest.

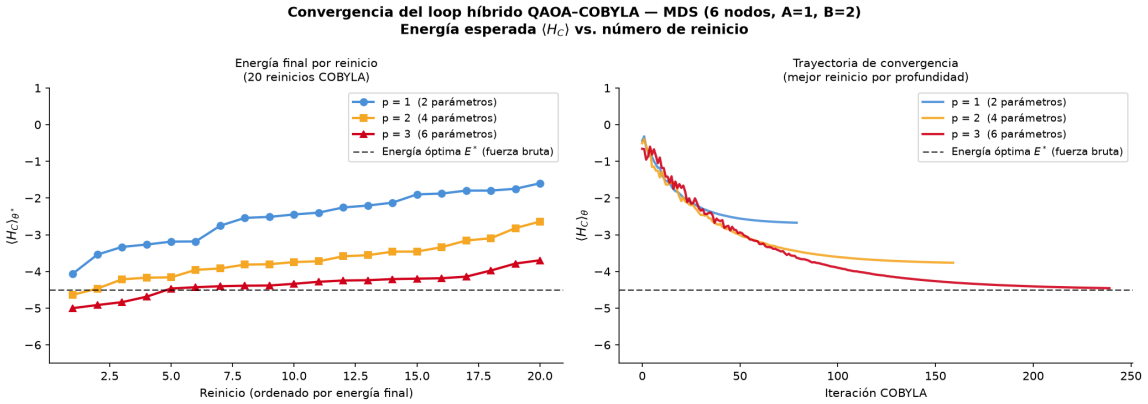
# Resultados — QAOA (histograma de medición)



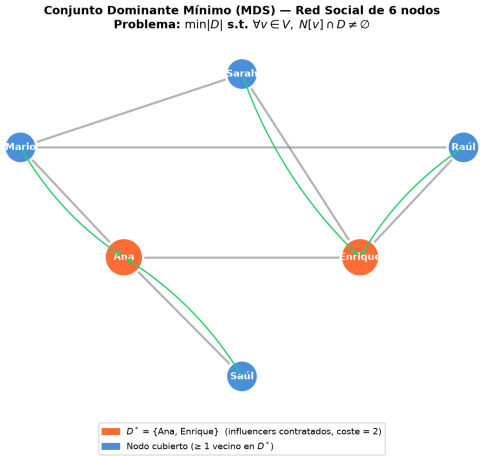

## Hallazgos

- QAOA: $-\mathbf{30.3\,\%}$ coste vs. Greedy
- VQE competitivo en portafolio pequeño
- TSP $n$=4: empate óptimo (modelado, no speedup)

# Resultados — loop híbrido QAOA–COBYLA



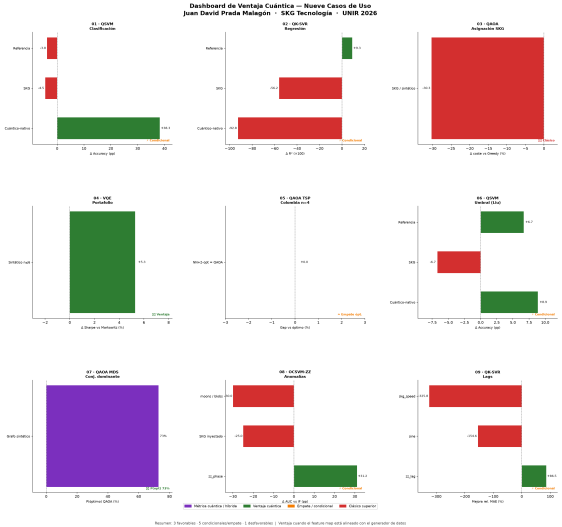
# Resultados — MDS (solución en grafo)




## Lectura

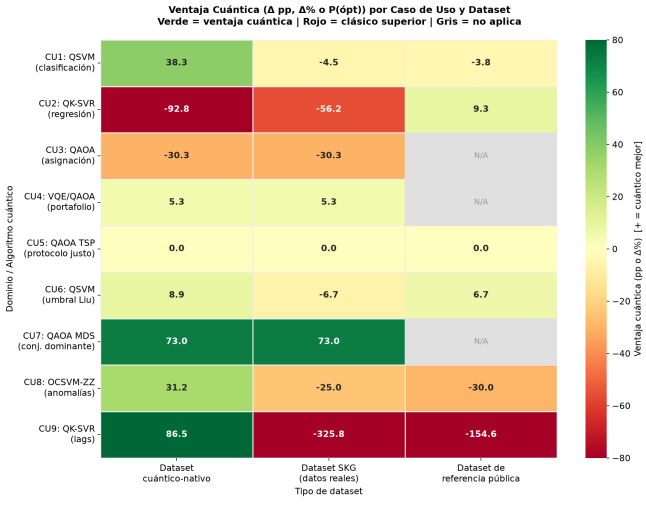
- $D^\star = \{\text{Ana}, \text{Enrique}\}$
- $P(\text{opt}) \approx 73\,\%$ (patrón híbrido)
- Escala moderada; no speedup asintótico

# Síntesis — dashboard de 9 casos

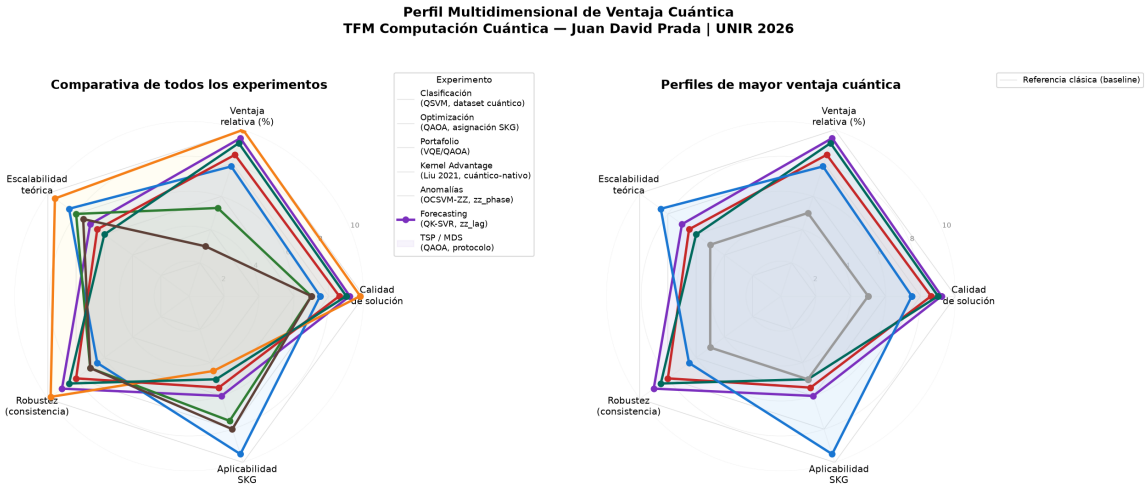



Resumen: 3 favorables · 5 condicionalesEmpate · 1 desfavorables | Ventaja cuántica el feature map está alineado con el generador de datos

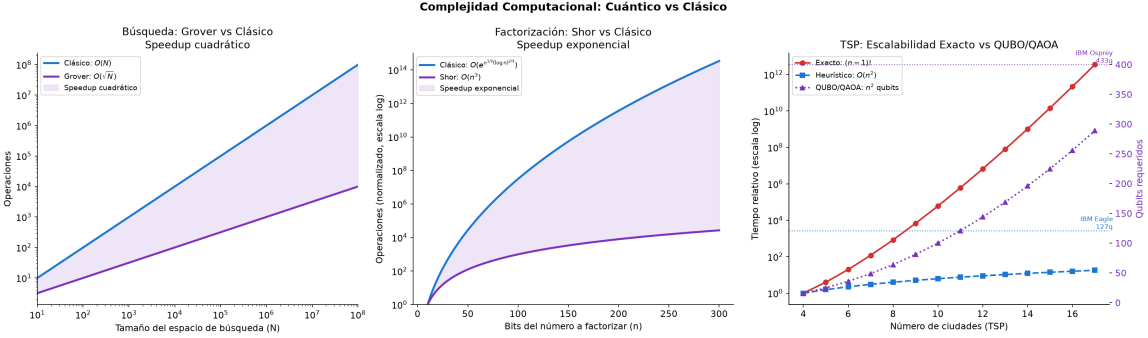
# Síntesis — heatmap por dominio



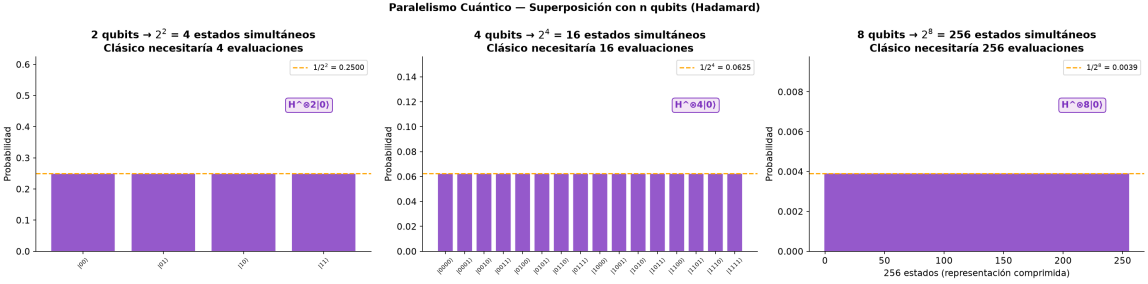
# Síntesis — radar multidimensional



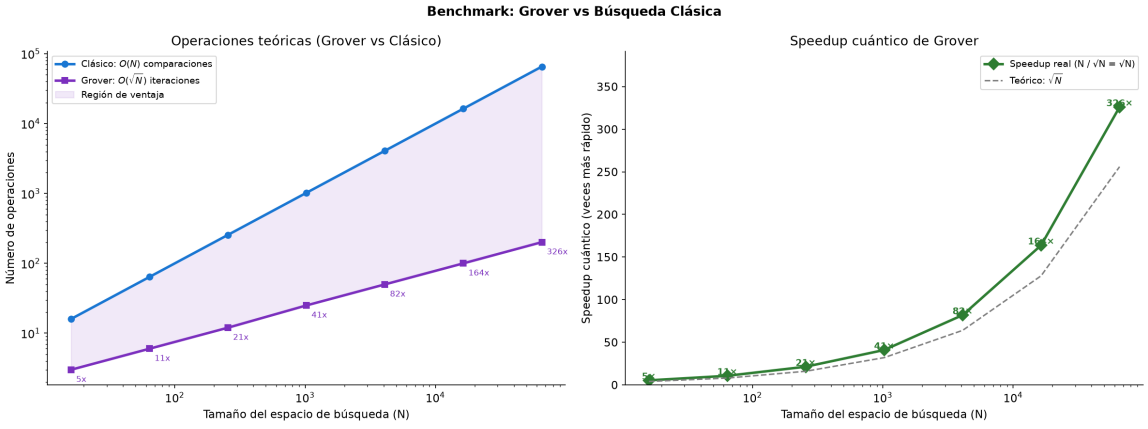
# Síntesis — complejidad cuántico vs clásico



# Síntesis — paralelismo / superposición ($2^n$)



# Síntesis — benchmark Grover vs búsqueda clásica

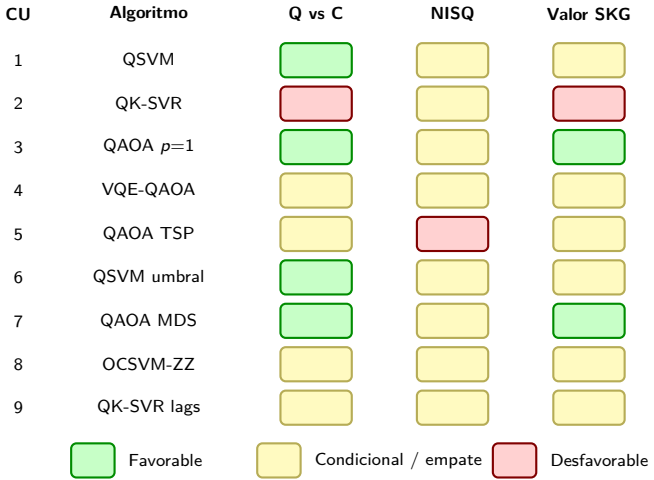


# Síntesis — tabla de 9 casos (cifras ancla)

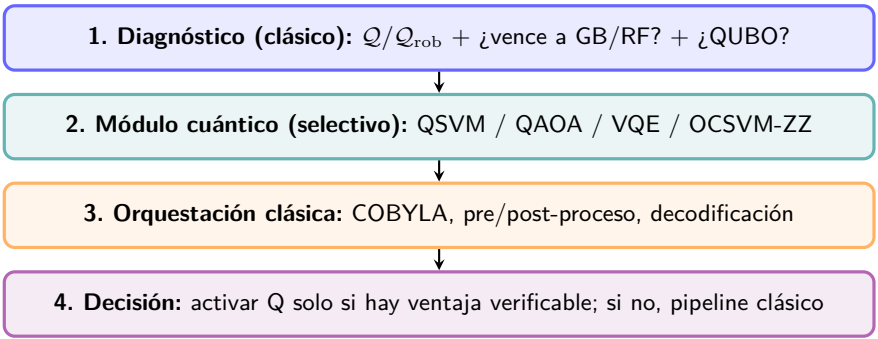
| CU | Algoritmo | Nativo | SKG | Referencia |
|---|---|---|---|---|
| 1 | QSVM | **+38.3 pp** | −4.5 pp | −3.8 pp |
| 2 | QK-SVR | $-0{,}93\,\Delta R^2$ | $-0{,}56\,\Delta R^2$ | $+0{,}09\,\Delta R^2$ |
| 3 | QAOA ($p$=1) | **−30.3 % vs Greedy** | | — |
| 4 | VQE/QAOA | Óptimo ($n \leq 6$) | | — |
| 5 | QAOA TSP | empate óptimo ($n$=4) | | gap 0 |
| 6 | QSVM umbral | **+8.9 pp** | −6,7 pp | +6,7 vs RBF‡ |
| 7 | QAOA MDS | $P(\mathrm{opt}) \approx 73\,\%$ | | NP-hard |
| 8 | OCSVM-ZZ | **+31 pp AUC** (`zz_phase`) | clásico | clásico |
| 9 | QK-SVR lags | **ΔMAE** −0,36 (`zz_lag`) | clásico | clásico |

‡vs RBF en $n$=50 — no ventaja operativa vs GB/RF. SKG/Telco en kernels: clásico.

# Síntesis — semáforo por caso de uso



# Arquitectura híbrida — 4 capas (prototipo)




Para SKG: herramienta **adicional**, no sustituto del stack actual.

## De la evidencia emergen dos preguntas

Tras los 9 casos **no** partimos de $\mathcal{Q}$ ni de QCR: partimos de hechos.

1. Ventaja de kernel **clara** solo cuando el generador coincide con el feature map (ZZ-nativo; también `zz_phase`, `zz_lag`).
2. En SKG/Telco (sin esa estructura) gana GB/RF: **no** son cuántico-nativos.
3. En QUBO híbrido hay valor a escala moderada; TSP $n$=4 empata al óptimo (modelado $\neq$ speedup).

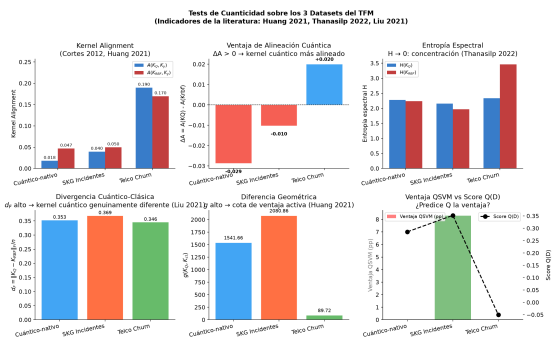
### Preguntas originales (Cap. 6)

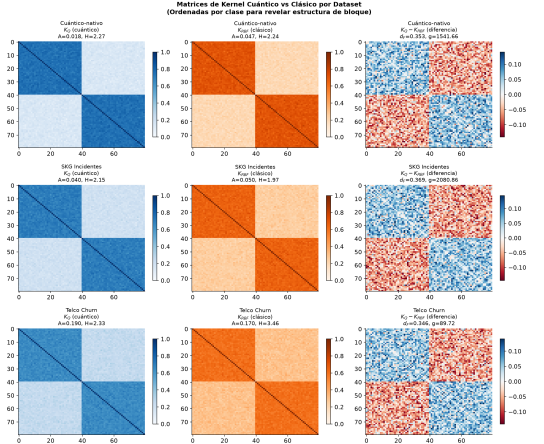
1. **P1 — tests de cuanticidad:** ¿Se puede diagnosticar *a priori* si un dataset admitirá ventaja?
2. **P2 — mapeos cuántico-compatibles:** Si no hay estructura nativa, ¿existe un $\psi$ que la induzca sin destruir la señal?

# Camino a la Conjetura 1 (antes de la fórmula)

1. **Literatura:** un solo indicador no basta (Huang et al., 2021; Liu et al., 2021; Thanasilp et al., 2022).
2. **Hecho empírico:** en nativo hay ventaja; en SKG/Telco no (vs. GB/RF).
3. **Notebook 08:** medimos $\Delta A$, $d_F$, $H(K)$ sobre los tres datasets.
4. **Hallazgo:** $d_F$ rankea mejor; $\Delta A$ se degrada con PCA a 2 qubits.
5. **Barrido sintético** en $\alpha$ (fracción de estructura ZZ): $\rho_S(\mathcal{Q}, \text{ventaja}) = 0{,}833$ ($p$=0,005, $n$=9).
6. **Propuesta:** un score *compuesto* e interpretable — no un oráculo de despliegue.

# Camino a $\mathcal{Q}$: evidencia visual (NB08)




$\mathcal{Q} > 0$ vs. RBF en SKG **no** implica compatibilidad operativa (GB/RF ganan; $\mathcal{Q}_{\text{rob}}$: `classical`).

## Conjetura 1 — score $\mathcal{Q}(\mathcal{D})$

$$\mathcal{Q}(\mathcal{D}) = w_1 \Delta A + w_2 \hat{d}_F + w_3 \Delta H, \qquad \sum_i w_i = 1,\ w_i \geq 0 \tag{1}$$

$\Delta A$: señal vs. etiquetas; $\hat{d}_F$: no-aproximabilidad clásica; $\Delta H$: riqueza espectral.

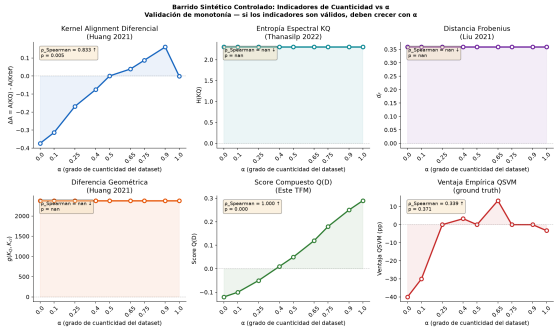
**Qué sí**

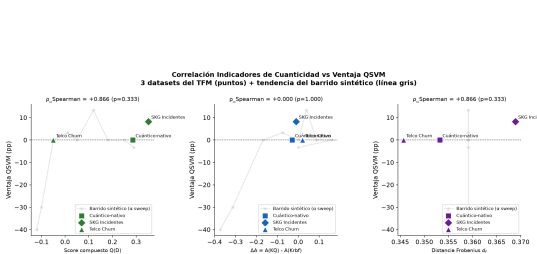
Diagnóstico *a priori* útil en barrido sintético ($\rho_S$=0,833).

**Qué no**

$\mathcal{Q} > 0$ vs. RBF $\neq$ "desplegar QSVM" (contraejemplo SKG). Cruzar siempre con GB/RF y $\mathcal{Q}_{\mathrm{rob}}$.

# Validación P1 — barrido sintético y correlaciones



## Camino a la Conjetura 2 / QCR (antes de la fórmula)

1. Si el diagnóstico dice "clásico", el default es el stack clásico.
2. Pero la pregunta correcta es: ¿falla el **dato** o el **espacio de representación**?
3. Hipótesis: existe $\psi : \mathcal{X} \to \mathcal{Z}$ polinómica que induzca geometría usable por el feature map **sin** destruir la señal.
4. **Notebook 09:** cuatro prototipos — ZZ-compatibles, rotación máx $d_F$, re-uploading, Q-UMAP/MDS.
5. Resultado: subidas locales de $\mathcal{Q}$ *vs. RBF*; bajo $\mathcal{Q}_{\text{rob}}$ Telco sigue `classical` y SKG solo cambia geometría (`try-ZZ`), **sin** lift de accuracy vs. GB/RF.

**Lectura**

QCR es un **programa de investigación** formalizado desde la evidencia — no un algoritmo cerrado ni un rescate operativo.

## Conjetura 2 — espacio de representación QCR

Si $\mathcal{Q}(\mathcal{D}) \leq 0$, se conjetura $\mathcal{Z}$ y $\psi : \mathcal{X} \to \mathcal{Z}$ **polinómica** tales que

$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^\star} \hat{y} \qquad \text{con} \quad \mathcal{Q}(\psi(\mathcal{D})) > 0 \;\text{ y }\; \varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star). \tag{2}$$

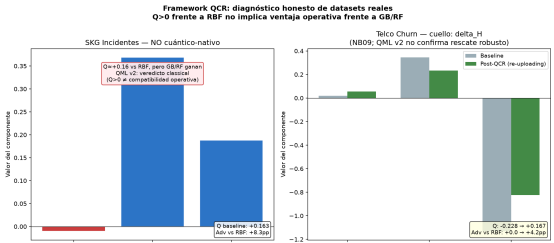
**Intuición**

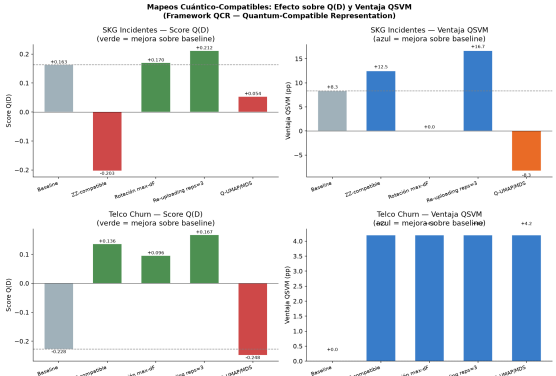
Transformar el dato *antes* del kernel para que el mapa "vea" estructura usable.

**Estado**

Conjetura **abierta**.
Este TFM la **plantea** + evidencia preliminar — no demostración.

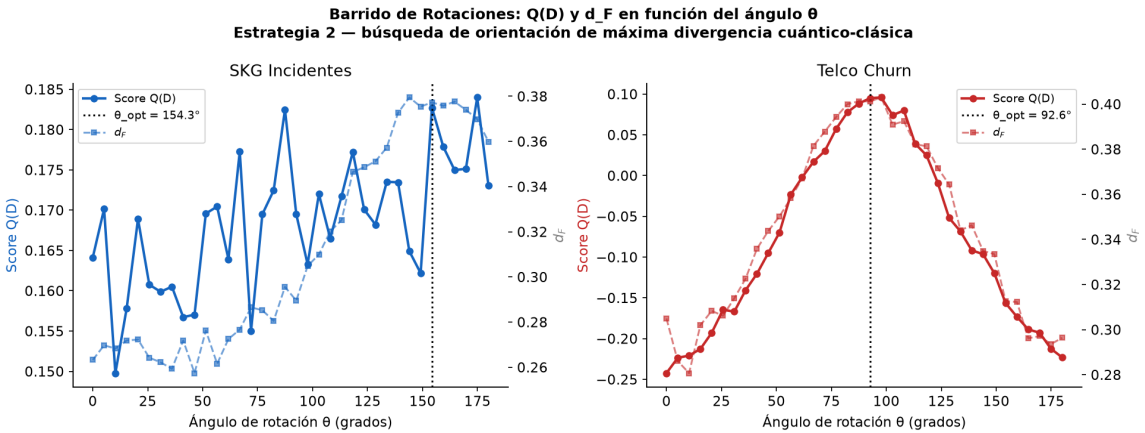
# Evidencia P2 — diagnóstico y mapeos (NB09)




SKG: NO cuántico-nativo. Telco: lift NB09 vs. RBF; $\mathcal{Q}_{\mathrm{rob}}$ no confirma rescate.

# Evidencia P2 — barrido de rotaciones



# Conclusiones (I) — ventaja condicionada

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: aparece cuando el feature map coincide con el generador (ZZ medido aquí; Pauli-Y confirma el mismo principio).
3. En **datos reales** SKG/Telco **sin** esa estructura: gana GB/RF (no son cuántico-nativos).
4. Regresión: ventaja acotada (Friedman); en movilidad SKG, árboles dominan.
5. Anomalías / lags: misma regla — solo con target alineado (`zz_phase`, `zz_lag`).

# Conclusiones (II) — híbridos y coste

6. QAOA reduce coste de asignación $\approx 30\,\%$ vs. Greedy a escala moderada.
7. VQE competitivo en portafolio pequeño; TSP $n$=4: empate óptimo (valor de *modelado*, no speedup).
8. MDS: patrón híbrido viable ($P(\mathrm{opt}) \approx 73\,\%$).
9. Coste de simulación del kernel $O(n^2)$: obstáculo práctico actual.
10. Metodologías maduras vs. hardware inmaduro: resultados mixtos son esperables en NISQ.

## Conclusiones (III) — conjeturas y adopción

11. $\mathcal{Q}(\mathcal{D})$: diagnóstico útil en barrido sintético ($\rho_S$=0,833); en reales, $n$ pequeño y matizado por $\mathcal{Q}_{\mathrm{rob}}$.
12. QCR: **planteado formalmente**; evidencia preliminar; no demostración ni rescate operativo.
13. Adopción recomendada: **selectiva e híbrida** — módulo cuántico como herramienta adicional, no sustituto del stack clásico (SKG).

**Respuesta a la pregunta del TFM**

Ventaja medible hoy cuando hay coincidencia mapa–generador o QUBO híbrido viable; en ausencia de eso, el clásico domina — y eso también es un resultado.

# Limitaciones (I)

- **Simulación statevector**: sin ruido NISQ de hardware; ideales $\neq$ shots reales.
- **PCA a** $n_q$=2: $\sim$68 % de varianza descartada; $\mathcal{Q}$ mide el subespacio proyectado.
- **Muestra** $n\approx$80 en indicadores; correlación en 3 datasets reales es orientativa.
- **Baseline RBF**: $\mathcal{Q} > 0$ vs. RBF $\neq$ ventaja vs. GB/RF (caso SKG).

# Limitaciones (II)

- **QCR** sin demostración fuerte; Q-UMAP sin métrica cuántica real (MDS proxy).
- **Un feature map operativo principal** (ZZ), con validación cruzada Pauli-Y limitada.
- **TSP**: empate óptimo $\neq$ speedup asintótico.
- **Escalabilidad**: kernel $O(n^2)$ limita $n$ en simulación; no se evaluó hardware real.
- **Datos SKG**: fraction de la operación; no cierran todos los casos de uso empresariales.

# Trabajo futuro (I) — corto plazo y SKG

**Corto plazo**

- Hardware ruidoso (IBM) + mitigación (ZNE)
- Más qubits / menos PCA agresivo
- Validación fuerte de QCR y $\mathcal{Q}_{\mathrm{rob}}$
- Calibrar pesos ($w_i$); más feature maps (IQP, Pauli)
- Kernels aleatorizados $O(n)$ / ensembles

**Aplicación SKG**

- QAOA en asignación real (`agents.csv`)
- VRP-TW / rutas de emergencia
- Multiclase de gravedad de incidentes
- Activación selectiva en pipeline productivo
- A/B testing cuántico–clásico

## Trabajo futuro (II) — medio/largo plazo

- Benchmarks con separación formal (Bravyi et al.) para certificar $\mathcal{Q}$
- Certificación estadística de ventaja (Huang et al., 2021)
- Demostración o refutación de la conjetura QCR
- Q-means / autoencoders / aprendizaje no supervisado cuántico
- Análisis de barren plateaus en VQC
- Integración API + monitorización de *data drift* en SKG

# Trabajo futuro (III) — roadmap

| Corto (1–2 a) | Medio (2–4 a) | Largo (4+ a) |
|---|---|---|
| Hardware IBM + ZNE | 4–8 qubits, menos PCA | FTQC / corrección errores |
| API + A/B test SKG | QAOA asignación real | Demostrar / refutar QCR |
| QAOA $p>1$ / SPSA | Validar $\mathcal{Q}$ en corpus amplio | QCR multi-mapa + publicación |

## Validación cruzada ZZ vs Pauli-Y (principio general)

**Resultado (QML v2, $n$=120, 5 repeats)**

- Generador ZZ $\Rightarrow$ QSVM-ZZ 0,828 vs RBF 0,478
- Generador Pauli-Y $\Rightarrow$ QSVM-PauliY 0,550 vs RBF 0,517
- Kernel ZZ *desalineado* cae a 0,406

**Lectura**

La ventaja sigue al **emparejamiento** mapa–generador. ZZ es el mapa del corpus principal; **no** el único admisible.

# Gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

(Preskill, 2018; Biamonte et al., 2017; Farhi et al., 2014; Schuld, 2021; Huang et al., 2021; Liu et al., 2021; Cerezo et al., 2021)

## Referencias (selección) I


Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. et al. (2019). *Machine learning methods in quantum computing theory*. Proc. SPIE.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

## Referencias (selección) II

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S. et al. (2022). *Exponential concentration and the limits of quantum ML*. arXiv:2208.11060.