Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica · UNIR

Director: Ricardo Rafael Domínguez Reyes

unir LA UNIVERSIDAD EN INTERNET

ÍNDICE

01 – Motivación

02 – Introducción

03 – Contexto y estado de la técnica

04 – Planteamiento y metodología

05 – Resultados: Q vs C

06 – Conjeturas: $\mathcal{Q}$ y QCR

07 – Evidencia de las conjeturas

08 – Conclusiones y limitaciones

09 – Trabajo futuro

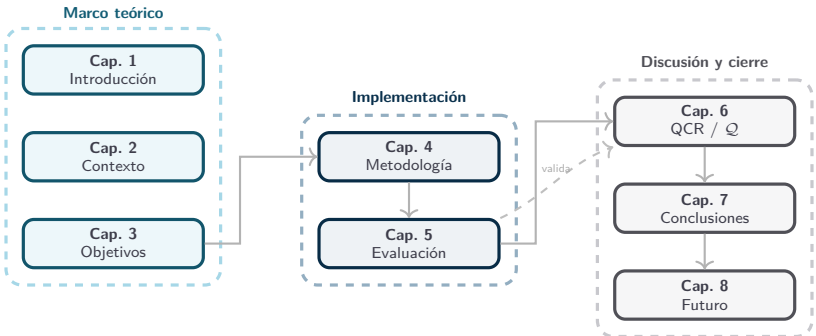
Motivación
La brecha entre promesa y evidencia

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

Pregunta práctica

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

Motivación
Estructura del TFM



Introducción
Planteamiento del problema

Pregunta de investigación

¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?

Qué se compara	Dónde	Qué se obtiene
algoritmos cuánticos frente al mejor clásico, en igualdad de condiciones	cinco casos de uso comunes, con datos de SKG y de referencia pública	si el cuántico gana en datos reales y un criterio para activarlo

Introducción
Alcance

Casos de uso comunes (5)

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Detección de anomalías (OCSVM-ZZ)
- Optimización (QAOA / VQE)
- Series temporales (QK-SVR sobre lags)

Nueve casos de uso con protocolo justo en el documento.

Dos clases de datos

1. **Práctica**: datos reales de SKG Tecnología
2. **Referencia pública**

No se generan datos etiquetados con el propio kernel cuántico: la ventaja sería circular y no informaría sobre problemas reales.

Contexto y estado de la técnica
Era NISQ

NISQ (Preskill, 2018)

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

Planteamiento y metodología

Metodología en cuatro fases

1. Datos

- Dos clases: práctica SKG y referencia pública
- Preprocesado: estandarizar, PCA a 2 componentes y escalar a $[-\pi, \pi]$
- Particiones aleatorias repetidas; en series, 70/30 en orden temporal

2. Modelos

- **Cuánticos:** QSVM, QK-SVR y OCSVM con kernel ZZ de 2 qubits; QAOA y VQE
- **Clásicos:** SVM, regresión logística, Ridge, RF, GB, Isolation Forest, LOF; Hungarian, ILP, Greedy, NN+2-opt, SA-QUBO

3. Evaluación

- **Protocolo justo:** tabla A (mismas 2 variables para todos) y tabla B (el clásico, con todas)
- **Métricas:** exactitud, R^2, AUC, P(óptimo)
- 5–10 repeticiones; simulación exacta del vector de estado

4. Híbrido y diagnóstico

- Diagnóstico $\mathcal{Q}(\mathcal{D})$: indicadores previos a ejecutar el algoritmo
- Criterios de activación del módulo cuántico
- QCR: mapeo hacia una representación cuántica (conjetura)

Salida: para cada caso de uso y conjunto de datos, ¿gana Q o gana C?

Planteamiento y metodología
Modelos comparados

Caso de uso	Modelo cuántico	Modelos clásicos de referencia
Clasificación	**QSVM-ZZ**: kernel de fidelidad con `ZZFeatureMap` (2 qubits, 2 repeticiones, entrelazamiento completo) y SVM con matriz de Gram precalculada	Gradient Boosting, SVM-RBF, SVM lineal, regresión logística
Regresión	**QK-SVR-ZZ**: el mismo kernel con SVR (C=10, ε=0,1)	Ridge, SVR-RBF, Random Forest, Gradient Boosting
Anomalías	**OCSVM-ZZ**: SVM de una clase con el mismo kernel (ν=0,05)	OCSVM-RBF, Isolation Forest, LOF
Optimización	**QAOA** (COBYLA; p=1 en asignación y TSP, p=3 en MDS y portafolio) y **VQE** (`TwoLocal` Ry–CZ, 3 repeticiones)	Hungarian / ILP (PuLP-CBC), Greedy, fuerza bruta, vecino más cercano + 2-opt, recocido simulado sobre el QUBO (SA-QUBO)
Series temporales	**QK-SVR-ZZ** sobre los 2 últimos valores (lags)	Ridge, SVR-RBF, Gradient Boosting

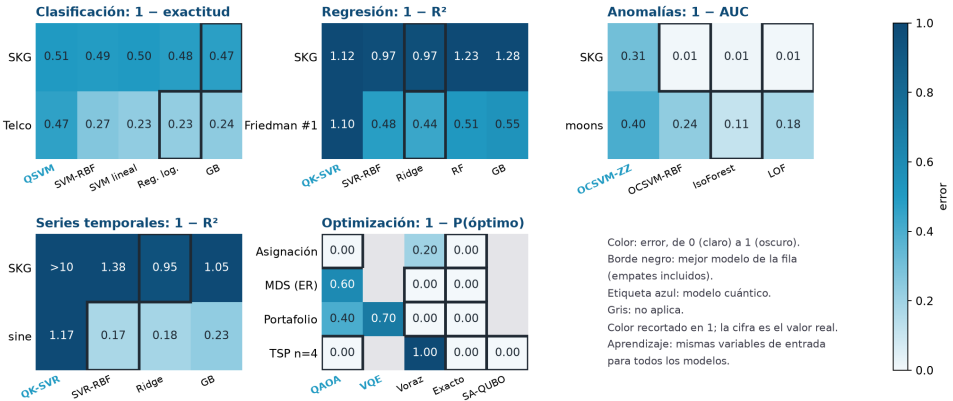
Todos los modelos cuánticos se simulan con el vector de estado exacto (sin ruido de hardware).

Planteamiento y metodología
Datasets utilizados

Caso de uso	Práctica SKG	Referencia pública
Clasificación	**Incidentes NUSE (Bogotá)**: gravedad binaria del incidente	**Telco Churn**: abandono de clientes (IBM / Kaggle)
Regresión	**Tiempos de viaje**: velocidad media a partir de lecturas y hora	**Friedman #1**: función no lineal sintética con ruido
Anomalías	**Incidentes** con atípicos inyectados	`moons`: dos lunas con atípicos uniformes en su caja
Series temporales	**Velocidad de 5 corredores**: lecturas cada 5 minutos	`sine`: senoide con dos estacionalidades y ruido
Optimización	Sin datos SKG (asignación real: trabajo futuro)	**Asignación** agente–tarea (QUBO), **MDS** (red de 6 nodos y grafos Erdős–Rényi), **portafolio** de 6 activos (Yahoo Finance) y **TSP** con 4 capitales de Colombia

Resultados: Q vs C

Mapa de errores: cuántico frente a clásico



El cuántico no es el mejor en ninguna celda; en optimización, QAOA iguala al exacto, no lo supera.

Resultados: Q vs C
Síntesis: caso de uso × conjunto de datos

Caso de uso	Clase de datos	Conjunto de datos	Resultado
Clasificación	SKG	Incidentes NUSE	Empate
	Referencia	Telco Churn	**Gana C**
Regresión	SKG	Tiempos de viaje	**Gana C**
	Referencia	Friedman #1	**Gana C**
Anomalías	SKG	Incidentes inyectados	**Gana C**
	Referencia	`moons`	**Gana C**
Series temporales	SKG	Corredores	**Gana C**
	Referencia	`sine`	**Gana C**
Optimización	Referencia	Asignación QUBO	Empate
	Referencia	MDS (grafos ER)	**Gana C**
	Referencia	Portafolio	**Gana C**
	Referencia	TSP $n{=}4$	Empate

Empate: diferencia dentro de una desviación estándar de las repeticiones, o mismo valor óptimo. En ningún caso gana el cuántico.

Resultados: Q vs C
Criterio de activación del módulo cuántico

Problema	Activar si	Módulo Q	Fallback
Clasif. / Regresión	vence a GB/RF en comparación justa (no basta $\mathcal{Q} > 0$ vs RBF)	QSVM / QK-SVR	GB / RF
Anomalías	vence a IF / LOF en comparación justa	OCSVM-ZZ	IF / LOF
Forecasting	vence a Ridge / GB	QK-SVR	Ridge / GB
Optimización / TSP	QUBO factible, n viable	QAOA / VQE	Greedy / ILP / 2-opt
Caso general	no vence al clásico o n demasiado grande	**no se activa**	pipeline clásico

Conjeturas
De la evidencia emergen dos preguntas

Preguntas originales (Cap. 6)

1. **P1 — tests de cuanticidad**

   ¿Se puede diagnosticar *a priori* si un dataset tiene *estructura cuántica* (alineación kernel–dato) y, por tanto, admitirá ventaja?

2. **P2 — mapeos cuántico-compatibles**

   Si el dato no tiene estructura cuántica, ¿existe un nuevo mapeo ψ y un espacio de representación donde se conserve la estructura e información del dato, adquiera estructura cuántica, y haya mapa de vuelta si hace falta? (analogía con la transformada de Fourier)

Conjeturas
Camino a la Conjetura 1 (I) — por qué un perfil

Literatura

- Ventaja cuántica de kernel $\Rightarrow$ alineación con etiquetas **y** geometría no reproducible por el clásico (Huang et al., 2021; Liu et al., 2021).
- Un solo indicador no basta: hace falta $A_Q > A_{cl}$ **y** d_F grande (Huang et al., 2021; Schuld, 2021).
- Riesgo: el kernel cuántico puede **concentrarse** y perder señal — vigilar $H(K)$ (Thanasilp et al., 2024).

Hecho empírico

En datos reales y de referencia no se mide alineación kernel–dato y gana el **clásico**.

Idea corregida

No un escalar: un **vector** $\mathcal{Q}(\mathcal{D}) = (\Delta A, \hat{d}_F, \Delta H, \hat{g}, \ldots)$ que se *mira* componente a componente.

Conjeturas
Camino a la Conjetura 1 (II) — componentes y evidencia

Interpretación (cuántico vs clásico)

- ΔA — ¿el cuántico ve mejor las clases?
  > 0: sí, más alineación con las etiquetas que el clásico (Cortes et al., 2012; Huang et al., 2021).
- $\hat{d}_F$ — ¿la geometría es distinta?
  Grande: el cuántico no es un clásico disfrazado (Liu et al., 2021).
- ΔH — ¿el kernel cuántico aporta diversidad o se ha "aplanado"?
  Bajo/negativo: todas las similitudes se parecen (concentración) $\Rightarrow$ poca info útil (Thanasilp et al., 2024).
- $\hat{g}$ — ¿el RBF reproduce la geometría cuántica?
  Cerca de 1: sí; grande: no (necesario, no suficiente) (Huang et al., 2021).

Evidencia (TFM)

Barrido α (n=9, NB08): mezcla de etiquetas, X fijo.

Hallazgo robusto: $\rho_S(\alpha, \Delta A)$=0,833 (p=0,005).

d_F/H constantes por diseño; no confundir con $\rho(\mathcal{Q}, \text{ventaja})$.

Conjeturas
Conjetura 1 — $\mathcal{Q}(\mathcal{D})$ como vector, no escalar

$$\mathcal{Q}(\mathcal{D}) \;=\; \big(\Delta A,\; \hat{d}_F,\; \Delta H,\; \hat{g}\big) \qquad \text{(perfil; sin pesos)} \tag{1}$$

Opcional en el documento: un escalar $w^\top \mathcal{Q}$ se probó y **falla** como ranking operativo — por eso no se usa para decidir.

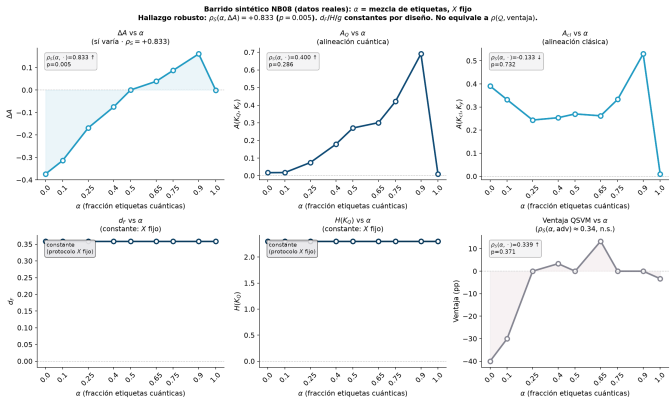
Cómo se lee

- ΔA: ¿mejor alineación que el clásico?
- $\hat{d}_F$: ¿geometría distinta?
- ΔH: ¿diversidad o concentración?
- $\hat{g}$: ¿el RBF reproduce la geometría cuántica?

Límite

El vector describe geometría vs. RBF. La adopción exige ventaja vs. mejor clásico **en el caso de uso** (clasif./reg./anomalías).

Conjeturas
Calibración de P1 — barrido sintético (α)



Qué es (NB08 real)

- α: fracción de etiquetas cuánticas (X fijo).
- Calibración del indicador: ΔA crece con α: ρ_S=0,833 (p=0,005).
- d_F y H **constantes** (kernels no cambian con labels).

Límite

ρ=0,833 es $\rho(\alpha, \Delta A)$, no $\rho(\mathcal{Q}, \text{ventaja})$.

Barrido structure-aware: trabajo futuro.

Conjeturas
P1 — qué comparamos (mismas métricas)

Estructura cuántica = vector $(\Delta A,\ \Delta H,\ d_F,\ g,\ \mathcal{Q})$

- $\Delta A = A(K_Q, yy^\top) - A(K_{\mathrm{RBF}}, yy^\top)$ — alineación de (Cortes et al., 2012)
- $\Delta H = H(K_Q) - H(K_{\mathrm{RBF}})$ — proxy de (Thanasilp et al., 2024)
- $d_F = \|K_Q - K_{\mathrm{RBF}}\|_F / n$ — proxy propio (cf. (Liu et al., 2021))
- g (diferencia geom.) — (Huang et al., 2021); $\mathcal{Q}$ compuesto (este TFM)

Mismo protocolo en clasificación, regresión, anomalías y optimización (ZZ 2q, n=60, 3 repeats, RBF Frobenius-best).
Optimización = **paisaje QUBO** (bitstrings → energía), no QAOA.
Control nulo: ΔA con y permutada. Sin accuracy / R^2 / AUC / coste.

Nota: no hay Δ_{op} aquí

Eso era solo un nombre confuso para "accuracy(QSVM)−accuracy(mejor clásico)" en clasificación. **No** es métrica de estructura. Se retiró de estas figuras.

Conjeturas
P1 — qué mide g (Huang et al., 2021)

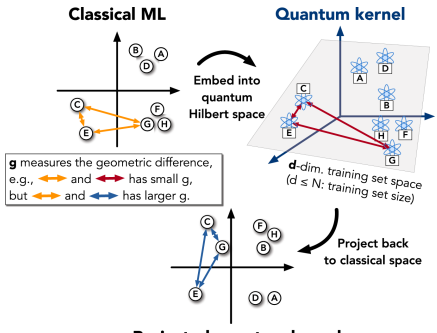


Fig. 2 de Huang et al. (2021), CC BY 4.0

Idea

g compara las **flechas** (similitudes kernel) entre puntos en el espacio clásico y en el cuántico. g pequeño: el kernel clásico ya reproduce la geometría cuántica; g grande: no.

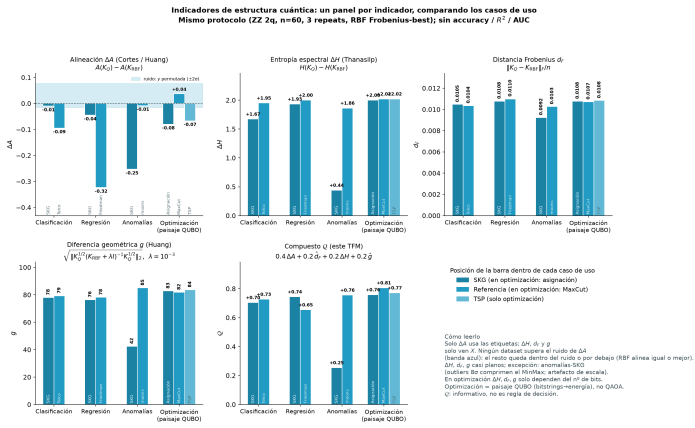
d = dimensión efectiva del dato en Hilbert.

Nuestra medición

g: necesario, no suficiente; no usa y. Huang (λ=10^{-3}): $g \approx 76$–85 en casi todos los casos (42 en anomalías-SKG, artefacto). $g \gg 1$ en todos los casos: **no discrimina**. Antes ≈ 3000 (artefacto).

Conjeturas

P1 — los cinco indicadores en los cuatro casos de uso



Cómo leerlo

Un panel por indicador; eje X = caso de uso; Barras por caso: SKG y referencia (optimización: asignación / MaxCut / TSP).

- ΔA: ningún dato real ni paisaje de optimización supera el ruido (banda azul), salvo MaxCut dentro de él
- ΔH, d_F, g: casi planos; excepción anomalías-SKG = artefacto de escala (outliers 8σ comprimen el MinMax)
- Q: informativo; lo dominan indicadores planos

Conjeturas
P1 — cómo interpretar

¿ΔA negativo + ΔH mínimo = estructura?

No. Los datos reales, los de referencia y los paisajes de optimización quedan dentro o por debajo del nulo ($\approx +0{,}03 \pm 0{,}02$); $\Delta A < 0$ = el RBF alinea mejor, no "estructura negativa". El único ΔH mínimo (anomalías-SKG, $0{,}44$) es un artefacto de escala.

¿d_F discrimina?

Aquí, apenas: $\approx 0{,}01$ en todos los casos; g y ΔH también planos. Solo ΔA usa y; los otros tres solo ven X.

Lectura defendible

El único indicador con señal potencial es ΔA (alineación kernel–dato (Liu et al., 2021; Huang et al., 2021)); d_F, g y ΔH no discriminan. Con $n = 2$ conjuntos comparables, $\mathcal{Q}$ es diagnóstico a priori, no predictor validado. Optimización: paisaje QUBO con 2 qubits (PCA retiene $\approx 1/3$): **sin evidencia** de estructura; límite del diseño.

Camino a la Conjetura 2 — analogía con Fourier

La idea, por analogía con la transformada de Fourier

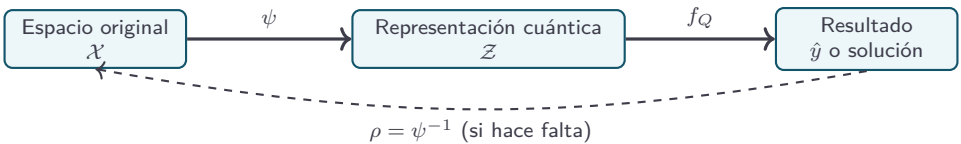
Un problema difícil en un espacio puede volverse más simple en otro; allí se resuelve y, si hace falta, se regresa. Eso funciona gracias a tres propiedades:

1. **conserva la información** (es invertible),
2. **hace visible la estructura** del problema,
3. tiene un **mapa de vuelta**.

La analogía con el kernel cuántico

Si el dato no tiene estructura cuántica, ¿existe un **mapeo** ψ **y un espacio de representación** $\mathcal{Z}$ donde se conserve la información del dato, adquiera estructura cuántica y se pueda sacar partido de los algoritmos cuánticos, con un mapeo de vuelta al espacio original cuando haga falta?

Conjeturas
Conjetura 2 — espacio de representación QCR



Qué se pide de ψ

1. $\psi : \mathcal{X} \to \mathcal{Z}$ es un **isomorfismo**: conserva estructura e información.
2. La **imagen** de ψ tiene **estructura cuántica**.
3. El mapa de vuelta es su inversa, $\rho = \psi^{-1}$.

Comentarios

- No sabemos con certeza la forma de ψ.
- El coste de calcular ψ debe tenerse en cuenta en las aplicaciones.
- Queda como **conjetura abierta**.

Conclusiones
Mensajes clave

1. Sin ventaja en datos reales

En SKG y en los benchmarks públicos gana el clásico o empatan. No se generan datos a la medida del kernel: sería circular.

2. Optimización: valor de modelado

QAOA iguala al óptimo exacto en problemas pequeños, pero no lo supera.

3. Diagnosticar antes de invertir

$\mathcal{Q}(\mathcal{D})$, como vector de indicadores, es un diagnóstico a priori sin validar; QCR queda planteada como conjetura.

4. Adopción selectiva e híbrida

Se activa solo si vence al clásico en comparación justa; hoy, ninguno.

Respuesta a la pregunta del TFM

No hay ventaja cuántica medible en los casos evaluados con datos reales y de referencia; el clásico domina, y eso también es un resultado.

Limitaciones del estudio

Simulación ideal

Statevector sin ruido de hardware; el coste del kernel crece como $O(n^2)$.

Alcance de los datos

SKG se usó como práctica (series: 5 corredores, un paso, sin ARIMA ni Prophet).

Escala reducida

2 qubits tras PCA y muestras pequeñas: los resultados son orientativos.

Base teórica abierta

$\mathcal{Q}(\mathcal{D})$ es empírico, sin validar con ventaja demostrada, y QCR carece de demostración.

Trabajo futuro
Hoja de ruta

Corto plazo

- Hardware real con mitigación de errores
- Más qubits y menos reducción por PCA
- Más *feature maps*

Medio plazo

- Validar $\mathcal{Q}(\mathcal{D})$ en un corpus amplio
- QAOA sobre asignación y rutas reales de SKG
- Pruebas A/B cuántico–clásico

Largo plazo

- Demostrar o refutar QCR
- Problemas con estructura cuántica natural
- Hardware tolerante a fallos

muchas gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

Referencias
Selección I

Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). *Algorithms for learning kernels based on centered alignment*. JMLR, 13, 795–828.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. V. et al. (2019). *Machine learning methods in quantum computing theory*. arXiv:1906.10175.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Referencias
Selección II

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S., Wang, S., Cerezo, M., & Holmes, Z. (2024). *Exponential concentration in quantum kernel methods*. Nat. Commun., 15, 5200.