Ventaja cuántica en ciencia de datos: condiciones empíricas, métodos híbridos y criterios de activación selectiva

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica ů UNIR
Director: Ricardo Rafael Domínguez Reyes

Documento: `Documento/main.pdf` *Código:* `POCs/qml_v2/`

Agenda (línea cronológica del TFM)

1. Motivación
2. Introducción
3. Contexto y estado de la técnica
4. Planteamiento y metodología
5. Resultados de modelos
6. Conjeturas ($\mathcal{Q}$, QCR)
7. Análisis de las conjeturas
8. Conclusiones
9. Trabajo futuro

Estructura del documento

Marco teórico (Cap. 1–3) $\rightarrow$ Implementación (Cap. 4–5) $\rightarrow$ Discusión y cierre (Cap. 6–8).

Motivación

- La ciencia de datos escala en dimensionalidad y complejidad combinatoria (Jordan & Mitchell, 2015; Biamonte et al., 2017).
- Los algoritmos variacionales y de kernel prometen ventaja en la era NISQ (Preskill, 2018; Farhi et al., 2014; Schuld, 2021).
- Persiste una **brecha** entre promesas teóricas y evidencia reproducible sobre datos reales.

Pregunta práctica

¿Cuándo activar un módulo cuántico y cuándo quedarse con el stack clásico?

Estructura del TFM



Introducción — planteamiento del problema

El problema central del trabajo (Preskill, 2018; Biamonte et al., 2017):

> *¿En qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Hipótesis operativa

La ventaja es **real pero condicionada**:

1. alineación **feature map** $\leftrightarrow$ **generador de datos**, o
2. problema formulable como QUBO con arquitectura **híbrida** a escala viable.

Introducción — alcance

Familias industriales (4)

- Clasificación supervisada (QSVM)
- Regresión (QK-SVR)
- Optimización combinatoria (QAOA)
- Optimización / híbrido (VQE + MDS)

Extendidas a 9 protocolos justos en el documento (anomalías, TSP, lags,...).

Tres capas de datos

1. Sintéticos con estructura cuántica nativa (Liu et al., 2021)
2. Práctica SKG Tecnología
3. Referencia pública

Era NISQ

NISQ (Preskill, 2018)

Dispositivos de escala intermedia **ruidosos**: qubits limitados, decoherencia, sin corrección de errores a gran escala.

- Algoritmos viables hoy: **variacionales** (QAOA, VQE) e híbridos (Farhi et al., 2014; Cerezo et al., 2021).
- Kernels cuánticos: acceso a espacios de Hilbert de alta dimensión (Schuld, 2021; Huang et al., 2021).
- Distinción clave: **metodologías** maduras vs. **hardware** aún inmaduro.

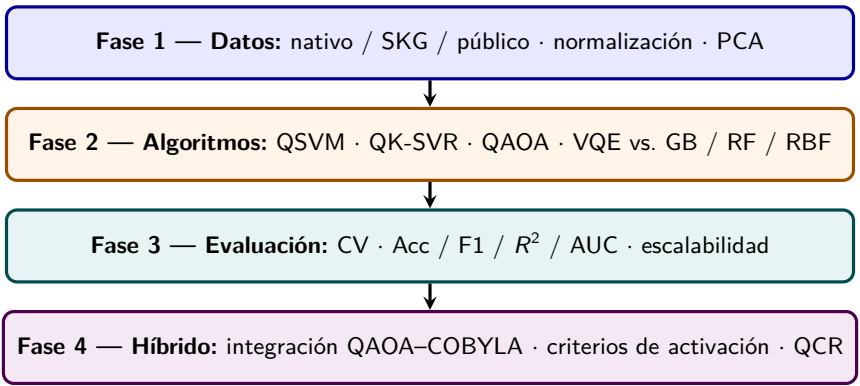
Comparaciones cuántico–clásico en la literatura

- Condiciones teóricas de ventaja de kernel: geometría de datos crítica (Huang et al., 2021).
- Datasets donde el kernel cuántico es óptimo por construcción (Liu et al., 2021).
- Concentración de kernels y límites prácticos (Thanasilp et al., 2022).
- Gap empírico: pocos estudios **justos** sobre datos empresariales reales (Fastovets et al., 2019).

Posicionamiento de este TFM

Evidencia empírica + protocolos justos + diagnóstico $\mathcal{Q}(\mathcal{D})$ + QCR formalmente planteado.

Metodología en cuatro fases



Formalismo — kernel cuántico

Mapa de características $\phi : \mathcal{X} \to \mathcal{H}$ (`ZZFeatureMap`) y kernel de fidelidad:

$$\kappa(x_i, x_j) = \left| \langle \phi(x_i) \,|\, \phi(x_j) \rangle \right|^2 \tag{1}$$

Clasificador: SVM / SVR / OCSVM sobre $K_{ij} = \kappa(x_i, x_j)$ frente a baseline RBF bajo el mismo protocolo (Schuld, 2021; Liu et al., 2021).

Principio de alineación

La ventaja aparece cuando el **generador del dato** está alineado con el feature map. ZZ es el mapa validado en este corpus; no el único admisible (Pauli, IQP,...).

Formalismo — QAOA / VQE híbridos

Problema combinatorio $\rightarrow$ QUBO $\rightarrow$ Hamiltoniano de Ising:

$$\min_{x\in\{0,1\}^n} x^\top Q x \quad \Longrightarrow \quad H_C = \sum_i h_i Z_i + \sum_{i<j} J_{ij} Z_i Z_j \tag{2}$$

Ansatz QAOA de profundidad p (Farhi et al., 2014):

$$|\psi(\boldsymbol{\gamma},\boldsymbol{\beta})\rangle = e^{-i\beta_p H_B} e^{-i\gamma_p H_C} \cdots e^{-i\beta_1 H_B} e^{-i\gamma_1 H_C} |+\rangle^{\otimes n} \tag{3}$$

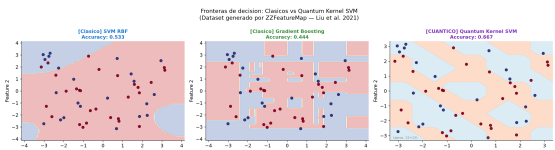
Optimizador clásico (COBYLA) ajusta $(\boldsymbol{\gamma},\boldsymbol{\beta})$; el módulo cuántico propone candidatos.

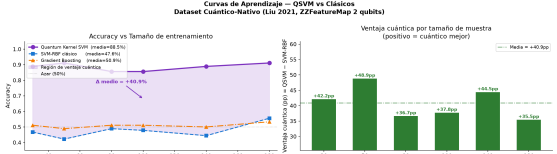
Diseño: 4 familias $\times$ 3 capas de datos

Familia	**Cuántico**	**Clásico de referencia**
Clasificación	QSVM (ZZ)	GB, RF, SVM-RBF
Regresión	QK-SVR	XGBoost, RF, SVR-RBF, Ridge
Optimización (asignación)	QAOA (p=1)	Greedy, búsqueda local, ILP
Portafolio / cobertura	VQE / QAOA-MDS	Markowitz, fuerza bruta

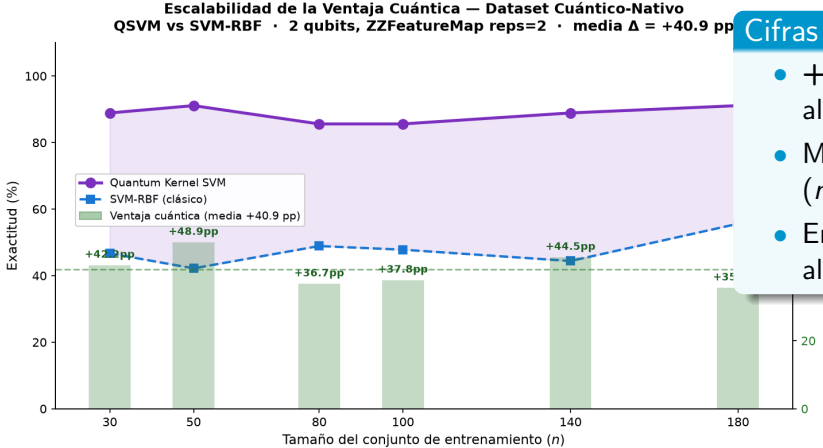
Cada familia se evalúa, cuando aplica, en: (i) **cuántico-nativo**, (ii) **SKG**, (iii) **referencia pública**.

Resultados — principio de alineación





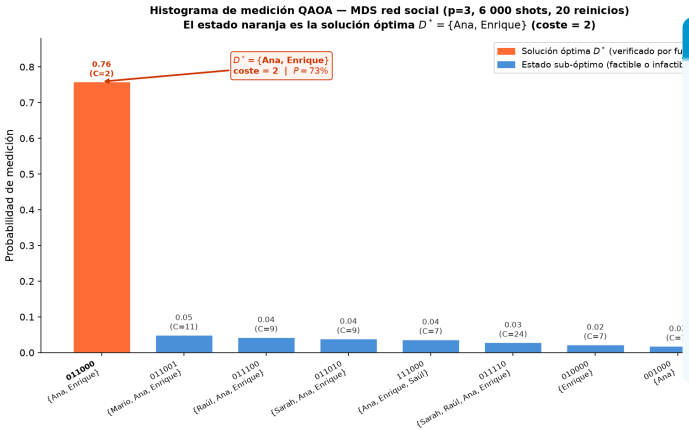
Resultados — clasificación



Cifras ancla

- **+38.3 pp** en datos alineados al mapa
- Media **+40.9 pp** ($n \in [30, 180]$)
- En Telco/SKG **sin** alineación: gana el clásico

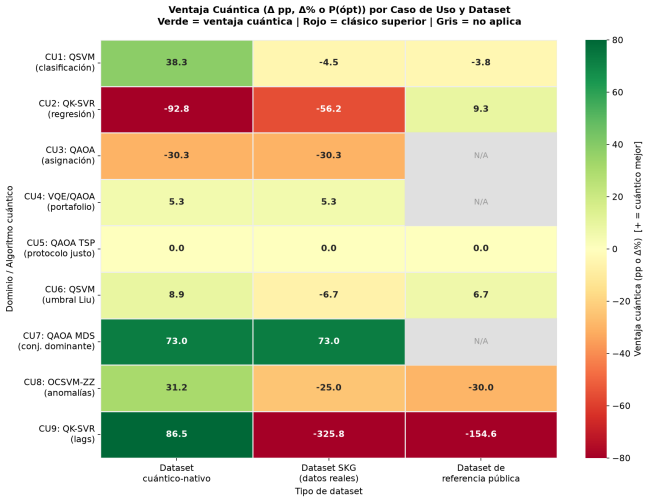
Resultados — optimización híbrida



Hallazgos

- QAOA: $-\mathbf{30.3\,\%}$ coste vs. Greedy
- VQE competitivo en portafolio pequeño
- MDS: $P(\mathrm{opt}) \approx 73\,\%$ (patrón híbrido)
- TSP n=4: empate óptimo — valor de *modelado*, no speedup

Síntesis visual de ventaja



De la evidencia a las preguntas originales

Tras observar ventaja **solo** con alineación mapa–generador:

1. **Tests de cuanticidad:** ¿Existe algún indicador calculable *a priori* sobre un dataset que permita predecir si un algoritmo cuántico mostrará ventaja sobre los clásicos?
2. **Mapeos cuántico-compatibles:** Si un dataset no tiene estructura cuántica nativa, ¿puede transformarse a un espacio de representación donde la tenga, sin alterar la información discriminativa?

Conjetura 1 — score de cuanticidad $\mathcal{Q}(\mathcal{D})$

$$\mathcal{Q}(\mathcal{D}) = w_1 \Delta A + w_2 \hat{d}_F + w_3 \Delta H, \qquad \sum_i w_i = 1,\ w_i \geq 0 \tag{4}$$

donde

$$\begin{aligned} \Delta A &= A(K_Q, K_y) - A(K_{\mathrm{RBF}}, K_y), \\ \hat{d}_F &= \|K_Q - K_{\mathrm{cl}}^{\star}\|_F / d_{F,\mathrm{máx}}, \\ \Delta H &= H(K_Q) - H(K_{\mathrm{RBF}}). \end{aligned}$$

Interpretación

$\mathcal{Q}(\mathcal{D}) > 0$ predice ventaja estructural del kernel cuántico; $\mathcal{Q}(\mathcal{D}) < 0$ predice superioridad clásica. Coherente con la geometría de Huang et al. (2021).

Conjetura 2 — espacio de representación QCR

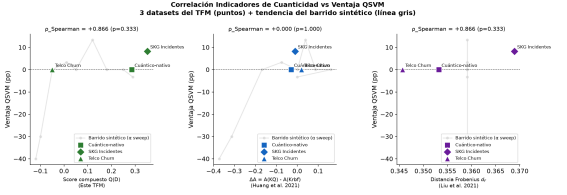
Si $\mathcal{Q}(\mathcal{D}) \leq 0$, la conjetura afirma existencia de $\mathcal{Z}$ y $\psi : \mathcal{X} \to \mathcal{Z}$ **polinómica** tales que

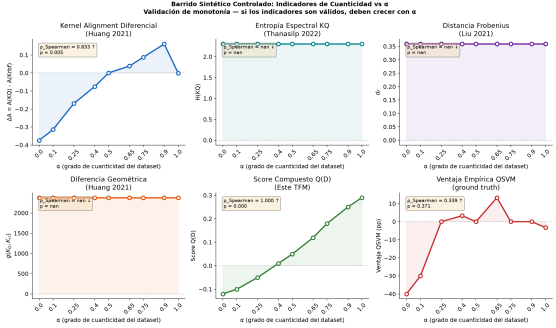
$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^\star} \hat{y} \qquad \text{con} \quad \mathcal{Q}(\psi(\mathcal{D})) > 0 \;\text{ y }\; \varepsilon(f_Q^\star \circ \psi) \leq \varepsilon(f_C^\star). \tag{5}$$

Estado

Conjetura **abierta**. Este TFM la **plantea formalmente** y aporta evidencia preliminar — no una demostración.

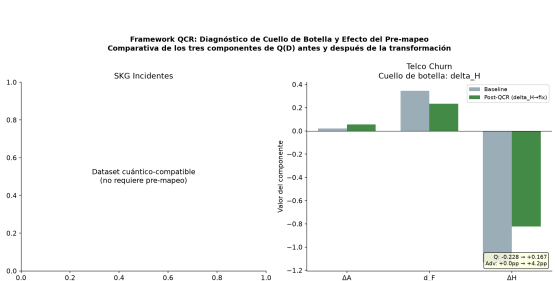
Análisis P1 — tests de cuanticidad

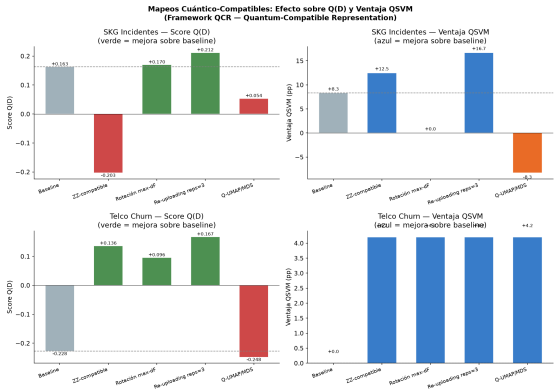




Barrido sintético: $\rho_S(\mathcal{Q}, \text{ventaja}) = 0{,}833$ ($p = 0{,}005$, $n = 9$). Componente más informativo: d_F.

Análisis P2 — mapeos cuántico-compatibles





Protocolo de diagnóstico → transformación candidata (rotación / re-uploading / . . .). Validación fuerte de QCR = línea post-TFM.

Conclusiones

1. La ventaja cuántica en ciencia de datos es **real pero condicionada**.
2. En kernels: alineación feature map $\leftrightarrow$ generador; ZZ es el mapa medido aquí.
3. En optimización: QAOA/VQE aportan valor en QUBO de escala moderada (patrón híbrido).
4. $\mathcal{Q}(\mathcal{D})$ es un diagnóstico útil *a priori* ($\rho_S = 0{,}833$ en barrido sintético).
5. QCR queda **formalmente planteado**; no demostrado.
6. Adopción recomendada: **selectiva e híbrida**, no sustitutiva del stack clásico.

Limitaciones (explicitadas)

- Simulación statevector (sin ruido NISQ de hardware).
- PCA a n_q=2 (68 % de varianza descartada).
- Correlación $\mathcal{Q}$ en datos reales con n pequeño (orientativa).
- QCR sin demostración fuerte.
- TSP: empate óptimo $\neq$ speedup.

Trabajo futuro

Corto plazo

- Hardware ruidoso / shots reales
- Más qubits, menos PCA
- Validación fuerte de QCR

Medio–largo plazo

- Benchmarks con separación formal
- Q-means / autoencoders
- Activación selectiva en pipelines productivos

Gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

(Preskill, 2018; Biamonte et al., 2017; Farhi et al., 2014; Schuld, 2021; Huang et al., 2021; Liu et al., 2021; Cerezo et al., 2021)

Referencias (selección) I

Biamonte, J. et al. (2017). *Quantum machine learning*. Nature, 549, 195–202.

Cerezo, M. et al. (2021). *Variational quantum algorithms*. Nat. Rev. Phys., 3, 625–644.

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv:1411.4028.

Fastovets, D. et al. (2019). *Machine learning methods in quantum computing theory*. Proc. SPIE.

Huang, H.-Y. et al. (2021). *Power of data in quantum machine learning*. Nat. Commun., 12, 2631.

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260.

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nat. Phys., 17, 1013–1017.

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.

Referencias (selección) II

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv:2101.11020.

Thanasilp, S. et al. (2022). *Exponential concentration and the limits of quantum ML*. arXiv:2208.11060.