Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Computación Cuántica

La Evolución de la Ciencia de Datos hacia la Computación Cuántica: Análisis de la Ventaja Cuántica en Casos Aplicados

Trabajo Fin de Máster

presentado por: Juan David Prada Malagón

Dirigido por: Ricardo Rafael Domínguez Reyes

Ciudad: Barcelona, España

Fecha: April 22, 2026

Índice general

Índice de figuras III

Índice de cuadros IV

Resumen V

Abstract VI

1. Introducción 1

1.1. Motivación y justificación del tema 1

1.2. Planteamiento del problema 2

1.3. Estructura del trabajo 3

2. Contexto y revisión de la técnica 4

2.1. Antecedentes históricos 4

2.2. Computación cuántica en la era NISQ 4

2.3. Aprendizaje automático cuántico 5

2.4. Optimización cuántica aplicada 6

2.5. Análisis crítico de los trabajos previos 6

3. Objetivos 8

3.1. Objetivo general 8

3.2. Objetivos específicos 8

4. Metodología 10

4.1. Fase 1: Selección y preparación de datos 10

4.2. Fase 2: Implementación de algoritmos 10

4.3. Fase 3: Diseño experimental y evaluación 10

4.4. Fase 4: Diseño del prototipo híbrido 11

5. Desarrollo del Trabajo 12

6. Resultados / Análisis / Comparativa / Discusión de resultados 13

7. Conclusiones 14

8. Trabajo futuro **15**

Bibliografía **16**

Apéndices **19**

Índice de figuras

Índice de cuadros

Resumen

La computación cuántica representa un paradigma emergente con potencial transformador para la ciencia de datos. Sin embargo, persiste una brecha significativa entre las promesas teóricas de los algoritmos cuánticos y su aplicabilidad práctica en entornos empresariales reales. Este trabajo propone un estudio comparativo riguroso entre algoritmos cuánticos —concretamente métodos de kernel cuántico y el algoritmo QAOA— y sus equivalentes clásicos —SVM, Random Forests y heurísticas de optimización— aplicados a problemas reales de clasificación supervisada y optimización combinatoria, utilizando datos procedentes de una empresa privada. Se evalúa el rendimiento mediante métricas de precisión, eficiencia computacional y escalabilidad. Adicionalmente, se diseña un prototipo conceptual de flujo de trabajo híbrido cuántico-clásico orientado a la integración práctica en pipelines productivos. Los resultados buscan aportar evidencia empírica sobre las condiciones reales de ventaja cuántica en ciencia de datos aplicada.

Palabras clave: computación cuántica, ciencia de datos, ventaja cuántica, aprendizaje automático cuántico, QAOA

Abstract

Quantum computing represents an emerging paradigm with transformative potential for data science. However, a significant gap persists between the theoretical promises of quantum algorithms and their practical applicability in real business environments. This work proposes a rigorous comparative study between quantum algorithms —specifically quantum kernel methods and the QAOA— and their classical counterparts —SVM, Random Forests and optimization heuristics— applied to real-world supervised classification and combinatorial optimization problems, using data from a private company. Performance is evaluated through accuracy, computational efficiency and scalability metrics. Additionally, a conceptual hybrid quantum-classical workflow prototype is designed, oriented towards practical integration into production pipelines. The results aim to provide empirical evidence on the real conditions of quantum advantage in applied data science.

Keywords: quantum computing, data science, quantum advantage, quantum machine learning, QAOA

1. Introducción

La computación cuántica representa uno de los paradigmas tecnológicos con mayor potencial transformador de las próximas décadas. Su capacidad para explotar fenómenos mecano-cuánticos como la superposición y el entrelazamiento abre la posibilidad de resolver problemas que resultan intratables para los computadores clásicos actuales (Preskill, 2018). En paralelo, la ciencia de datos ha consolidado su posición como disciplina central en la toma de decisiones empresariales, apoyándose en algoritmos de aprendizaje automático, optimización combinatoria y análisis estadístico a gran escala (Jordan & Mitchell, 2015). La convergencia de ambas disciplinas da lugar a un campo emergente con implicaciones profundas tanto para la investigación académica como para la práctica profesional.

Sin embargo, a pesar del creciente interés y del avance de los dispositivos cuánticos de escala intermedia ruidosa (NISQ, por sus siglas en inglés), persiste una brecha significativa entre las promesas teóricas de la computación cuántica y su aplicabilidad práctica en entornos reales de ciencia de datos (Preskill, 2018). Los algoritmos variacionales cuánticos, como el Quantum Approximate Optimization Algorithm (QAOA) (Farhi et al., 2014) o los circuitos cuánticos variacionales (VQC) (Cerezo et al., 2021), han emergido como las principales estrategias para aprovechar los dispositivos NISQ actuales, pero su ventaja frente a los métodos clásicos no está aún suficientemente demostrada en casos de uso empresariales reales.

Este trabajo aborda precisamente esa brecha, proponiendo un análisis comparativo riguroso y aplicado entre algoritmos cuánticos y clásicos en problemas representativos de la ciencia de datos.

1.1. Motivación y justificación del tema

La ciencia de datos, sustentada en técnicas de aprendizaje automático clásico, enfrenta limitaciones inherentes al paradigma de computación binaria cuando los problemas escalan en dimensionalidad o complejidad combinatoria (Biamonte et al., 2017). Tareas como la clasificación de patrones en espacios de alta dimensión, la optimización de carteras de activos o la segmentación de clientes en grandes volúmenes de datos presentan costes computacionales que crecen de forma exponencial o polinómica con el tamaño del problema, lo que limita la capacidad de respuesta en entornos productivos con restricciones de

tiempo.

La computación cuántica ofrece, en teoría, aceleraciones sustanciales para ciertos tipos de problemas. El algoritmo de Grover proporciona una aceleración cuadrática en búsquedas no estructuradas (Grover, 1996), mientras que el algoritmo de Shor permite factorización en tiempo polinómico (Shor, 1994). Más recientemente, los métodos de aprendizaje automático cuántico, en particular los basados en kernels cuánticos, han demostrado que los computadores cuánticos pueden acceder a espacios de características exponencialmente grandes, lo que podría suponer una ventaja real en tareas de clasificación (Haug et al., 2023).

No obstante, el consenso científico actual es cauteloso. Preskill (2018) acuñó el término NISQ para describir la era actual de la computación cuántica, caracterizada por dispositivos con un número limitado de qubits y alta tasa de error, que aún no permiten implementar corrección de errores cuánticos a gran escala. En este contexto, resulta imprescindible evaluar de forma empírica y sistemática si los algoritmos cuánticos disponibles hoy en día pueden ofrecer ventajas medibles frente a sus equivalentes clásicos en problemas de ciencia de datos de relevancia empresarial.

La motivación de este trabajo surge precisamente de la necesidad de cubrir este vacío: no existen suficientes estudios comparativos que contrasten el rendimiento de algoritmos cuánticos con técnicas clásicas consolidadas sobre datos reales de negocio, evaluando no solo la precisión sino también la escalabilidad, el coste computacional y la viabilidad de integración en pipelines productivos.

1.2. Planteamiento del problema

El problema central que aborda este trabajo puede formularse de la siguiente manera: *¿en qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Para responder a esta pregunta, se plantea un estudio comparativo estructurado en torno a dos familias de problemas representativos: (1) problemas de **clasificación supervisada**, donde se comparará el rendimiento de clasificadores basados en kernels cuánticos frente a métodos clásicos como Support Vector Machines (Cortes & Vapnik, 1995) o Random Forests (Breiman, 2001); y (2) problemas de **optimización combinatoria**, donde

se evaluará el algoritmo QAOA (Farhi et al., 2014) frente a heurísticas clásicas como algoritmos genéticos o búsqueda local.

Los experimentos se realizarán sobre conjuntos de datos reales procedentes de una empresa privada, lo que garantiza la relevancia práctica de los resultados. Adicionalmente, se diseñará un prototipo conceptual de flujo de trabajo híbrido cuántico-clásico que ilustre cómo podrían integrarse estas tecnologías en arquitecturas de análisis de datos existentes (Cerezo et al., 2021).

La aportación principal de este trabajo reside en proporcionar evidencia empírica sobre la viabilidad actual de la computación cuántica aplicada a la ciencia de datos, con una perspectiva orientada a la toma de decisiones en entornos empresariales reales, superando el enfoque puramente teórico o de laboratorio que predomina en la literatura existente (Fastovets et al., 2019).

1.3. Estructura del trabajo

El presente trabajo se organiza en los siguientes capítulos:

El **Capítulo 2** presenta el contexto y la revisión de la técnica, describiendo los fundamentos de la computación cuántica relevantes para este trabajo, los principales algoritmos cuánticos aplicados a ciencia de datos y un análisis crítico de los trabajos previos más relevantes.

El **Capítulo 3** define los objetivos generales y específicos del trabajo, alineados con la brecha identificada en la revisión de la técnica.

El **Capítulo 4** describe la metodología de investigación adoptada, incluyendo las fases del estudio, el diseño experimental, los criterios de evaluación y las herramientas utilizadas.

El **Capítulo 5** presenta el desarrollo de la solución propuesta, detallando la implementación de los algoritmos cuánticos y clásicos, así como el diseño del flujo de trabajo híbrido prototipo.

El **Capítulo 6** recoge los resultados obtenidos, su análisis comparativo y la discusión sobre las implicaciones prácticas de los hallazgos.

El **Capítulo 7** expone las conclusiones del trabajo, sintetizando los hallazgos principales y su contribución al campo.

El **Capítulo 8** presenta las líneas de investigación futura que se derivan de los resultados y limitaciones identificadas a lo largo del estudio.

2. Contexto y revisión de la técnica

Este capítulo presenta los fundamentos conceptuales y el estado actual de la técnica en computación cuántica aplicada a la ciencia de datos. Se revisan los trabajos previos más relevantes, se identifican las limitaciones de los enfoques existentes y se sitúa la contribución de este trabajo en el contexto académico y profesional actual.

2.1. Antecedentes históricos

El origen formal de la computación cuántica como disciplina se remonta a los trabajos de Feynman (1982), quien propuso el uso de sistemas cuánticos para simular la naturaleza de forma eficiente, argumentando que un computador clásico no podía simular un sistema cuántico sin un coste exponencial. Poco después, Deutsch (1985) formalizó el concepto de computador cuántico universal y demostró la existencia de problemas que un computador cuántico podría resolver de forma más eficiente que cualquier computador clásico.

El interés por la computación cuántica se intensificó con los algoritmos de Shor (1994) y Grover (1996), que demostraron aceleraciones exponenciales y cuadráticas respectivamente frente a los mejores algoritmos clásicos conocidos para factorización de enteros y búsqueda no estructurada. Estos resultados establecieron la viabilidad teórica de la ventaja cuántica y sentaron las bases para el desarrollo de hardware cuántico experimental. Los fundamentos formales del modelo de computación cuántica, incluyendo los postulados de la mecánica cuántica, las puertas cuánticas y los circuitos cuánticos, se encuentran desarrollados en detalle en Nielsen & Chuang (2010).

En paralelo, el campo del aprendizaje automático experimentó un crecimiento extraordinario impulsado por el aumento de la capacidad computacional y la disponibilidad de grandes volúmenes de datos (Jordan & Mitchell, 2015). La confluencia de ambas disciplinas dio lugar al campo del aprendizaje automático cuántico (*Quantum Machine Learning*, QML), cuyo objetivo es explorar si las capacidades de procesamiento cuántico pueden ofrecer ventajas en tareas de aprendizaje estadístico (Biamonte et al., 2017).

2.2. Computación cuántica en la era NISQ

El estado actual del hardware cuántico se enmarca en lo que Preskill (2018) denominó la era NISQ (*Noisy Intermediate-Scale Quantum*), caracterizada por dispositivos con entre 50

y varios cientos de qubits físicos, afectados por errores de decoherencia y ruido cuántico, y sin capacidad para implementar corrección de errores cuánticos a gran escala. Esta realidad impone restricciones fundamentales sobre la profundidad de los circuitos ejecutables y la fiabilidad de los resultados obtenidos.

En respuesta a estas limitaciones, se han desarrollado los algoritmos variacionales cuánticos (*Variational Quantum Algorithms*, VQA), que combinan un circuito cuántico parametrizado con un optimizador clásico en un bucle híbrido (Cerezo et al., 2021). Entre los más destacados se encuentran el Quantum Approximate Optimization Algorithm (QAOA) (Farhi et al., 2014), diseñado para problemas de optimización combinatoria, y el Variational Quantum Eigensolver (VQE) (Peruzzo et al., 2014), orientado a la simulación de sistemas moleculares. Estos algoritmos son actualmente los candidatos más prometedores para demostrar ventaja cuántica práctica en hardware NISQ.

No obstante, la comunidad científica mantiene un debate activo sobre si los algoritmos NISQ pueden alcanzar ventaja cuántica genuina frente a los mejores algoritmos clásicos. Cerezo et al. (2023) analizan en profundidad el fenómeno de los *barren plateaus*, gradientes exponencialmente pequeños que dificultan el entrenamiento de los circuitos variacionales a medida que el número de qubits crece, comprometiendo la escalabilidad de estos enfoques.

2.3. Aprendizaje automático cuántico

El aprendizaje automático cuántico ha sido objeto de una revisión sistemática exhaustiva por parte de Biamonte et al. (2017), quienes identificaron cuatro categorías principales de algoritmos QML según la naturaleza del procesador (clásico o cuántico) y de los datos (clásicos o cuánticos). Para el contexto de este trabajo, el caso más relevante es el de datos clásicos procesados mediante algoritmos cuánticos (CC→CQ en la nomenclatura de los autores).

Los métodos basados en kernels cuánticos (*Quantum Kernel Methods*) han recibido especial atención. Schuld & Killoran (2019) demostraron que los circuitos cuánticos pueden actuar como mapas de características (*feature maps*) hacia espacios de Hilbert de alta dimensión, y que la estimación del kernel inducido puede ser computacionalmente difícil de simular clásicamente bajo ciertas condiciones. Sin embargo, Huang et al. (2021) establecieron condiciones teóricas precisas bajo las cuales los kernels cuánticos pueden ofrecer una ventaja de aprendizaje sobre los kernels clásicos, concluyendo que dicha ventaja depende

críticamente de la estructura geométrica de los datos de entrada.

En el contexto de la clasificación supervisada con datos reales, Haug et al. (2023) propusieron el uso de medidas aleatorizadas para escalar los métodos de kernel cuántico a conjuntos de datos de gran tamaño, abordando uno de los principales cuellos de botella prácticos de estos métodos. Los resultados experimentales mostraron rendimientos competitivos frente a kernels clásicos en benchmarks estándar, aunque con una ventaja aún limitada.

2.4. Optimización cuántica aplicada

El QAOA, propuesto originalmente por Farhi et al. (2014), es un algoritmo híbrido cuántico-clásico que aproxima la solución de problemas de optimización combinatoria formulados como problemas de satisfacibilidad cuadráticas binarias (QUBO). Su aplicabilidad se extiende a problemas de relevancia empresarial como la optimización de rutas (Lucas, 2014), la asignación de recursos, la segmentación de mercado y la optimización de carteras financieras.

Zhou et al. (2020) estudiaron el rendimiento del QAOA en función de la profundidad del circuito (p) y demostraron que, para problemas de tamaño moderado, la calidad de la aproximación mejora monotónamente con p. No obstante, la ventaja cuántica del QAOA frente a los mejores algoritmos clásicos heurísticos sigue siendo una cuestión abierta para instancias de gran escala (Farhi et al., 2014).

Desde una perspectiva aplicada, Vikstål et al. (2020) evaluaron la aplicabilidad del QAOA a problemas de optimización financiera reales, identificando los principales desafíos prácticos: la necesidad de un gran número de shots para estimar expectativas con precisión suficiente, la sensibilidad a los parámetros iniciales y la degradación del rendimiento en hardware ruidoso. Estos resultados subrayan la importancia de realizar evaluaciones experimentales sobre datos reales más allá de las pruebas de concepto teóricas.

2.5. Análisis crítico de los trabajos previos

La revisión de la literatura permite identificar un conjunto de limitaciones recurrentes en los estudios existentes que este trabajo pretende abordar:

- **Uso predominante de datos sintéticos o académicos**: la mayoría de los estu-

dios comparativos utilizan conjuntos de datos de benchmarks estándar (Iris, MNIST, MaxCut), que no reflejan la complejidad y el ruido inherentes a los datos empresariales reales (Biamonte et al., 2017; Haug et al., 2023).

- **Ausencia de comparación sistemática con métodos clásicos consolidados**: muchos trabajos evalúan el rendimiento cuántico de forma aislada, sin contrastar con técnicas clásicas de referencia como SVM, Random Forests o algoritmos genéticos en las mismas condiciones experimentales (Fastovets et al., 2019).
- **Foco en la viabilidad teórica más que en la aplicabilidad práctica**: los análisis de ventaja cuántica suelen estar formulados en términos asintóticos o bajo supuestos ideales de hardware, sin considerar las restricciones reales de los dispositivos NISQ actuales (Cerezo et al., 2023).
- **Escasa consideración de la integración en pipelines productivos**: los trabajos existentes raramente abordan la cuestión de cómo los módulos cuánticos podrían integrarse en arquitecturas de análisis de datos clásicas ya existentes en entornos empresariales (Cerezo et al., 2021).

Este trabajo contribuye a superar estas limitaciones mediante un diseño experimental que combina datos reales de negocio, comparación directa con métodos clásicos de referencia y una evaluación orientada a la viabilidad de integración práctica.

3. Objetivos

La revisión de la técnica presentada en el capítulo anterior evidencia que, a pesar del avance teórico en computación cuántica aplicada a la ciencia de datos, persiste una brecha significativa entre los resultados obtenidos en condiciones ideales y los alcanzables en entornos productivos reales. Este trabajo se propone abordar dicha brecha mediante un análisis comparativo riguroso, orientado a la toma de decisiones en contextos empresariales. En este capítulo se definen los objetivos que guían la investigación.

3.1. Objetivo general

El objetivo general de este trabajo es evaluar de forma empírica y sistemática si los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos consolidados en problemas representativos de la ciencia de datos, utilizando datos procedentes de un entorno empresarial real, con el fin de determinar las condiciones bajo las cuales la computación cuántica puede aportar valor práctico en este dominio (Preskill, 2018; Biamonte et al., 2017).

3.2. Objetivos específicos

Para alcanzar el objetivo general, se establecen los siguientes objetivos específicos:

1. **Identificar y caracterizar los conjuntos de datos empresariales** adecuados para el estudio comparativo, seleccionando problemas representativos de clasificación supervisada y optimización combinatoria con relevancia práctica demostrable.

2. **Implementar y configurar los algoritmos cuánticos** seleccionados para el estudio, concretamente métodos de kernel cuántico y circuitos variacionales para clasificación (Schuld & Killoran, 2019; Huang et al., 2021), así como el algoritmo QAOA para optimización (Farhi et al., 2014), utilizando frameworks de simulación cuántica como Qiskit o PennyLane.

3. **Implementar y configurar los algoritmos clásicos de referencia** correspondientes a cada problema, incluyendo Support Vector Machines (SVM), Random Forests y algoritmos heurísticos de optimización, siguiendo las mejores prácticas del campo (Jordan & Mitchell, 2015).

4. **Diseñar y ejecutar los experimentos comparativos** bajo condiciones controladas e idénticas para ambas familias de algoritmos, garantizando la reproducibilidad y la validez estadística de los resultados.

5. **Evaluar el rendimiento comparativo** de los algoritmos cuánticos y clásicos mediante un conjunto de métricas cuantitativas que incluyan precisión, eficiencia computacional y escalabilidad, siguiendo criterios establecidos en la literatura (Cerezo et al., 2021; Zhou et al., 2020).

6. **Analizar las condiciones de ventaja cuántica**, identificando los factores —como el tamaño del dataset, la dimensionalidad del problema o la profundidad del circuito— que determinan cuándo y en qué medida los algoritmos cuánticos superan a los clásicos (Huang et al., 2021; Cerezo et al., 2023).

7. **Diseñar un prototipo conceptual de flujo de trabajo híbrido** cuántico-clásico que ilustre cómo los módulos cuánticos podrían integrarse en arquitecturas de análisis de datos existentes en entornos empresariales (Cerezo et al., 2021).

4. Metodología

La metodología adoptada en este trabajo combina un enfoque experimental cuantitativo con un análisis crítico de los resultados desde la perspectiva de la aplicabilidad empresarial. Se articula en las siguientes fases:

4.1. Fase 1: Selección y preparación de datos

Se utilizarán conjuntos de datos reales procedentes de una empresa privada, relacionados con problemas de clasificación de clientes y optimización de asignación de recursos. Los datos serán anonimizados y tratados conforme a las buenas prácticas de protección de datos. En caso necesario, se complementará el análisis con datos sintéticos generados a partir de distribuciones similares para garantizar la robustez de los resultados y preservar la confidencialidad. Los datasets serán preprocesados siguiendo técnicas estándar de ciencia de datos: normalización, tratamiento de valores ausentes y reducción de dimensionalidad cuando sea necesario (Jordan & Mitchell, 2015).

4.2. Fase 2: Implementación de algoritmos

Los algoritmos cuánticos se implementarán en simulación clásica mediante los frameworks *Qiskit* (IBM) o *PennyLane* (Xanadu), que permiten simular circuitos cuánticos de hasta decenas de qubits en hardware clásico con ruido controlado. Para los problemas de clasificación, se implementarán clasificadores basados en kernels cuánticos (Schuld & Killoran, 2019) y circuitos variacionales (VQC) (Cerezo et al., 2021). Para los problemas de optimización, se implementará el QAOA con diferentes valores de profundidad p (Farhi et al., 2014; Zhou et al., 2020). Los algoritmos clásicos de referencia se implementarán mediante las bibliotecas estándar de *scikit-learn* y *scipy*.

4.3. Fase 3: Diseño experimental y evaluación

Los experimentos se diseñarán siguiendo un protocolo de validación cruzada estratificada para los problemas de clasificación, y un esquema de múltiples ejecuciones con semillas aleatorias controladas para los problemas de optimización. Las métricas de evaluación principales serán:

- **Clasificación**: exactitud (*accuracy*), precisión, exhaustividad (*recall*) y puntuación F1, junto con el área bajo la curva ROC (AUC-ROC).
- **Optimización**: valor de la función objetivo alcanzada, razón de aproximación respecto al óptimo clásico conocido y tiempo de convergencia.
- **Eficiencia computacional**: tiempo de ejecución total, número de qubits requeridos, profundidad del circuito y número de evaluaciones de la función objetivo.
- **Escalabilidad**: evolución del rendimiento en función del tamaño del problema, evaluada mediante experimentos con instancias de tamaño creciente.

4.4. Fase 4: Diseño del prototipo híbrido

A partir de los resultados obtenidos, se diseñará un flujo de trabajo conceptual que integre el módulo cuántico de mejor rendimiento dentro de una arquitectura de análisis de datos clásica. Este prototipo ilustrará los puntos de integración entre componentes cuánticos y clásicos, los requisitos de interfaz y las condiciones de activación del módulo cuántico, proporcionando una visión práctica orientada a la adopción tecnológica futura (Cerezo et al., 2021).

5. Desarrollo del Trabajo

Este es el grueso del TFM. Por supuesto, la estructura de este Capítulo dependerá de la temática específica que se desarrolle.

Por favor, revisa en el repositorio de ReUNIR para ver ejemplos de desarrollos de esta Sección.

6. Resultados / Análisis / Comparativa / Discusión de resultados

Es muy importante presentar los resultados de forma clara y detallada. Analizar estos resultados, presentar comparaciones con otros trabajos y/o entre las distintas soluciones que aportemos. También es muy importante analizar cuidadosamente todos estos resultados.

Incluye las figuras pertinentes y pon atención a su formato.

Sé excrupuloso con la forma de plantear las comparaciones y resalta lo novedoso de tu TFM.

7. Conclusiones

Las consclusiones NO pueden limitarse a hacer un repaso del Trabajo, sino que deben aportar una visión clara y sintética de lo que se extrae de todo el trabajo realizado.

Puedes hacer una narrativa y puedes complementarla con una itemización, para que las cosas puedan verse de forma sintética e inmediata.

De nuevo, mira ejemplos de trabajos bien evaluados en el repositorio ReUNIR (los que están han sido bien evaluados).

8. Trabajo futuro

En un análisis autocrítico, podemos plantear todas las limitaciones del trabajo y explicar de qué manera puede mejorarse o cómo puede llegarse a los lugares que no se hayan podido alcanzar. Hay que explicar todo esto detalladamente, NO basta con un par de párrafos generales.

Bibliografía

Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., & Lloyd, S. (2017). *Quantum machine learning*. Nature, 549(7671), 195–202. https://doi.org/10.1038/nature23474

Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., ... Coles, P. J. (2021). *Variational quantum algorithms*. Nature Reviews Physics, 3(9), 625–644. https://doi.org/10.1038/s42254-021-00348-9

Cerezo, M., Larocca, M., García-Martín, D., Coles, P. J., Zoufal, C., & Babbush, R. (2023). *Does provable absence of barren plateaus imply classical simulability? Or, why we need to rethink variational quantum computing*. arXiv preprint arXiv:2312.09121. https://doi.org/10.48550/arXiv.2312.09121

Cortes, C., & Vapnik, V. (1995). *Support-vector networks*. Machine Learning, 20(3), 273–297. https://doi.org/10.1007/BF00994018

Deutsch, D. (1985). *Quantum theory, the Church–Turing principle and the universal quantum computer*. Proceedings of the Royal Society of London A, 400(1818), 97–117. https://doi.org/10.1098/rspa.1985.0070

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv preprint arXiv:1411.4028. https://doi.org/10.48550/arXiv.1411.4028

Fastovets, D. V., Bogdanov, Yu. I., Bantysh, B. I., & Lukichev, V. F. (2019). *Machine learning methods in quantum computing theory*. arXiv preprint arXiv:1906.10175. https://doi.org/10.48550/arXiv.1906.10175

Feynman, R. P. (1982). *Simulating physics with computers*. International Journal of Theoretical Physics, 21(6–7), 467–488. https://doi.org/10.1007/BF02650179

Grover, L. K. (1996). *A fast quantum mechanical algorithm for database search*. Proceedings of the 28th Annual ACM Symposium on Theory of Computing, 212–219. https://doi.org/10.1145/237814.237866

Haug, T., Self, C. N., & Kim, M. S. (2023). *Quantum machine learning of large datasets using randomized measurements*. Machine Learning: Science and Technology, 4(1), 015005. https://doi.org/10.1088/2632-2153/acb0b4

Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). *Power of data in quantum machine learning*. Nature Communications, 12(1), 2631. https://doi.org/10.1038/s41467-021-22539-9

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260. https://doi.org/10.1126/science.aaa8415

Lucas, A. (2014). *Ising formulations of many NP problems*. Frontiers in Physics, 2, 5. https://doi.org/10.3389/fphy.2014.00005

Nielsen, M. A., & Chuang, I. L. (2010). *Quantum computation and quantum information* (10th anniversary ed.). Cambridge University Press. https://doi.org/10.1017/CBO9780511976667

Peruzzo, A., McClean, J., Shadbolt, P., Yung, M.-H., Zhou, X.-Q., Love, P. J., ... O'Brien, J. L. (2014). *A variational eigenvalue solver on a photonic quantum processor*. Nature Communications, 5(1), 4213. https://doi.org/10.1038/ncomms5213

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79. https://doi.org/10.22331/q-2018-08-06-79

Schuld, M., & Killoran, N. (2019). *Quantum machine learning in feature Hilbert spaces*. Physical Review Letters, 122(4), 040504. https://doi.org/10.1103/PhysRevLett.122.040504

Shor, P. W. (1994). *Algorithms for quantum computation: Discrete logarithms and factoring*. Proceedings of the 35th Annual Symposium on Foundations of Computer Science, 124–134. https://doi.org/10.1109/SFCS.1994.365700

Vikstål, P., Grönkvist, M., Svensson, M., Andersson, M., Johansson, G., & Ferrini, G. (2020). *Applying the quantum approximate optimization algorithm to the tail-assignment problem*. Physical Review Applied, 14(3), 034009. https://doi.org/10.1103/PhysRevApplied.14.034009

Zhou, L., Wang, S.-T., Choi, S., Pichler, H., & Lukin, M. D. (2020). *Quantum approximate optimization algorithm: Performance, mechanism, and implementation on near-term devices.* Physical Review X, 10(2), 021067. https://doi.org/10.1103/PhysRevX.10.021067

Apéndices

Pueden incluirse tantos apéndices como sean necesarios.