Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Computación Cuántica

La Evolución de la Ciencia de Datos hacia la Computación Cuántica: Análisis de la Ventaja Cuántica en Casos Aplicados

Trabajo Fin de Máster

presentado por: Juan David Prada Malagón

Dirigido por: Ricardo Rafael Domínguez Reyes

Ciudad: Barcelona, España

Fecha: May 13, 2026

Índice general

Índice de figuras IV

Índice de cuadros V

Resumen VI

Abstract VII

1. Introducción 1

1.1. Motivación y justificación del tema 1

1.2. Planteamiento del problema 2

1.3. Estructura del trabajo 3

2. Contexto y revisión de la técnica 4

2.1. Antecedentes históricos 4

2.2. Computación cuántica en la era NISQ 4

2.3. Aprendizaje automático cuántico 5

2.4. Optimización cuántica aplicada 6

2.5. Análisis crítico de los trabajos previos 6

3. Objetivos 8

3.1. Objetivo general 8

3.2. Objetivos específicos 8

4. Metodología 10

4.1. Fase 1: Selección y preparación de datos 10

4.2. Fase 2: Implementación de algoritmos 10

4.3. Fase 3: Diseño experimental y evaluación 10

4.4. Fase 4: Diseño del prototipo híbrido 11

5. Diseño e Implementación de las Pruebas de Concepto 12

5.1. Entorno tecnológico y arquitectura experimental 12

5.2. Caso de uso 1: Clasificación supervisada con kernel cuántico 12

5.2.1. Descripción del problema 13

5.2.2. Dataset 1: Cuántico-nativo (Liu 2021) 13
5.2.3. Dataset 2: SKG Tecnología (incidentes de movilidad urbana, NUSE Bogotá) 15
5.2.4. Dataset 3: Telco Customer Churn (referencia) 16
5.3. Caso de uso 2: Regresión con kernel cuántico (QK-SVR) 17
5.3.1. Descripción del problema 18
5.3.2. Dataset 1: Cuántico-nativo 18
5.3.3. Dataset 2: SKG Tecnología (tiempos de viaje en corredores viales, Bogotá) 19
5.3.4. Dataset 3: Friedman #1 (referencia) 21
5.4. Caso de uso 3: Optimización de asignación de recursos (QAOA) 22
5.4.1. Descripción del problema y formulación QUBO 22
5.4.2. Procedimiento experimental 22
5.5. Caso de uso 4: Optimización de portafolio (VQE/QAOA) 23
5.6. Caso de uso 5: Problema del viajante (TSP-QUBO) 24
5.7. Caso de uso 6: Análisis de umbral de ventaja del kernel cuántico 24

6. Evaluación y Análisis Comparativo de Resultados 25
6.1. Caso de uso 1: Clasificación supervisada 25
6.1.1. Dataset cuántico-nativo: ventaja cuántica demostrada 25
6.1.2. Dataset SKG Tecnología: resultado esperado en era NISQ 26
6.1.3. Dataset Telco Churn: caso control validado 27
6.2. Caso de uso 2: Regresión con kernel cuántico 27
6.2.1. Dataset cuántico-nativo: paradoja de la regresión cuántica 27
6.2.2. Dataset SKG Tecnología: limitaciones estructurales 28
6.2.3. Dataset Friedman #1: caso de ventaja cuántica en regresión 28
6.3. Caso de uso 3: Optimización combinatoria (QAOA) 29
6.4. Caso de uso 4: Optimización de portafolio (VQE/QAOA) 29
6.5. Caso de uso 5: TSP con SA-QUBO 30
6.6. Caso de uso 6: Análisis del umbral de ventaja del kernel 30
6.7. Síntesis comparativa y discusión general 30
6.7.1. Patrones transversales 31
6.7.2. Implicaciones para la adopción empresarial 31

7. Conclusiones **33**

7.1. Conclusiones principales 33

7.2. Respuesta a la pregunta de investigación 34

7.3. Aportación al campo 35

8. Trabajo Futuro **36**

8.1. Ejecución en hardware cuántico real 36

8.2. Escalabilidad del kernel cuántico 36

8.3. Ampliación de casos de uso en SKG Tecnología 37

8.4. Mejora de los algoritmos variacionales 37

8.5. Integración en pipelines productivos 38

8.6. Extensión del análisis teórico 38

Bibliografía **40**

Apéndices **43**

Índice de figuras

Índice de cuadros

6.1. Escalabilidad de la ventaja cuántica en clasificación (dataset cuántico-nativo, ZZFeatureMap 2 qubits). 26
6.2. Comparativa de regresión cuántica vs clásica en los tres datasets. El mejor clásico incluye XGBoost, Random Forest, SVR-RBF y Ridge. 27
6.3. Síntesis de resultados cuántico vs clásico por caso de uso y dataset. Las celdas en negrita indican ventaja cuántica demostrada. 31

Resumen

La computación cuántica representa un paradigma emergente con potencial transformador para la ciencia de datos. Sin embargo, persiste una brecha significativa entre las promesas teóricas de los algoritmos cuánticos y su aplicabilidad práctica en entornos empresariales reales. Este trabajo propone un estudio comparativo riguroso entre algoritmos cuánticos —concretamente métodos de kernel cuántico y el algoritmo QAOA— y sus equivalentes clásicos —SVM, Random Forests y heurísticas de optimización— aplicados a problemas reales de clasificación supervisada y optimización combinatoria, utilizando datos procedentes de una empresa privada. Se evalúa el rendimiento mediante métricas de precisión, eficiencia computacional y escalabilidad. Adicionalmente, se diseña un prototipo conceptual de flujo de trabajo híbrido cuántico-clásico orientado a la integración práctica en pipelines productivos. Los resultados buscan aportar evidencia empírica sobre las condiciones reales de ventaja cuántica en ciencia de datos aplicada.

Palabras clave: computación cuántica, ciencia de datos, ventaja cuántica, aprendizaje automático cuántico, QAOA

Abstract

Quantum computing represents an emerging paradigm with transformative potential for data science. However, a significant gap persists between the theoretical promises of quantum algorithms and their practical applicability in real business environments. This work proposes a rigorous comparative study between quantum algorithms —specifically quantum kernel methods and the QAOA— and their classical counterparts —SVM, Random Forests and optimization heuristics— applied to real-world supervised classification and combinatorial optimization problems, using data from a private company. Performance is evaluated through accuracy, computational efficiency and scalability metrics. Additionally, a conceptual hybrid quantum-classical workflow prototype is designed, oriented towards practical integration into production pipelines. The results aim to provide empirical evidence on the real conditions of quantum advantage in applied data science.

Keywords: quantum computing, data science, quantum advantage, quantum machine learning, QAOA

1. Introducción

La computación cuántica representa uno de los paradigmas tecnológicos con mayor potencial transformador de las próximas décadas. Su capacidad para explotar fenómenos mecano-cuánticos como la superposición y el entrelazamiento abre la posibilidad de resolver problemas que resultan intratables para los computadores clásicos actuales (Preskill, 2018). En paralelo, la ciencia de datos ha consolidado su posición como disciplina central en la toma de decisiones empresariales, apoyándose en algoritmos de aprendizaje automático, optimización combinatoria y análisis estadístico a gran escala (Jordan & Mitchell, 2015). La convergencia de ambas disciplinas da lugar a un campo emergente con implicaciones profundas tanto para la investigación académica como para la práctica profesional.

Sin embargo, a pesar del creciente interés y del avance de los dispositivos cuánticos de escala intermedia ruidosa (NISQ, por sus siglas en inglés), persiste una brecha significativa entre las promesas teóricas de la computación cuántica y su aplicabilidad práctica en entornos reales de ciencia de datos (Preskill, 2018). Los algoritmos variacionales cuánticos, como el Quantum Approximate Optimization Algorithm (QAOA) (Farhi et al., 2014) o los circuitos cuánticos variacionales (VQC) (Cerezo et al., 2021), han emergido como las principales estrategias para aprovechar los dispositivos NISQ actuales, pero su ventaja frente a los métodos clásicos no está aún suficientemente demostrada en casos de uso empresariales reales.

Este trabajo aborda precisamente esa brecha, proponiendo un análisis comparativo riguroso y aplicado entre algoritmos cuánticos y clásicos en problemas representativos de la ciencia de datos.

1.1. Motivación y justificación del tema

La ciencia de datos, sustentada en técnicas de aprendizaje automático clásico, enfrenta limitaciones inherentes al paradigma de computación binaria cuando los problemas escalan en dimensionalidad o complejidad combinatoria (Biamonte et al., 2017). Tareas como la clasificación de patrones en espacios de alta dimensión, la optimización de carteras de activos o la segmentación de clientes en grandes volúmenes de datos presentan costes computacionales que crecen de forma exponencial o polinómica con el tamaño del problema, lo que limita la capacidad de respuesta en entornos productivos con restricciones de

tiempo.

La computación cuántica ofrece, en teoría, aceleraciones sustanciales para ciertos tipos de problemas. El algoritmo de Grover proporciona una aceleración cuadrática en búsquedas no estructuradas (Grover, 1996), mientras que el algoritmo de Shor permite factorización en tiempo polinómico (Shor, 1994). Más recientemente, los métodos de aprendizaje automático cuántico, en particular los basados en kernels cuánticos, han demostrado que los computadores cuánticos pueden acceder a espacios de características exponencialmente grandes, lo que podría suponer una ventaja real en tareas de clasificación (Haug et al., 2023).

No obstante, el consenso científico actual es cauteloso. Preskill (2018) acuñó el término NISQ para describir la era actual de la computación cuántica, caracterizada por dispositivos con un número limitado de qubits y alta tasa de error, que aún no permiten implementar corrección de errores cuánticos a gran escala. En este contexto, resulta imprescindible evaluar de forma empírica y sistemática si los algoritmos cuánticos disponibles hoy en día pueden ofrecer ventajas medibles frente a sus equivalentes clásicos en problemas de ciencia de datos de relevancia empresarial.

La motivación de este trabajo surge precisamente de la necesidad de cubrir este vacío: no existen suficientes estudios comparativos que contrasten el rendimiento de algoritmos cuánticos con técnicas clásicas consolidadas sobre datos reales de negocio, evaluando no solo la precisión sino también la escalabilidad, el coste computacional y la viabilidad de integración en pipelines productivos.

1.2. Planteamiento del problema

El problema central que aborda este trabajo puede formularse de la siguiente manera: *¿en qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Para responder a esta pregunta, se plantea un estudio comparativo estructurado en torno a dos familias de problemas representativos: (1) problemas de **clasificación supervisada**, donde se comparará el rendimiento de clasificadores basados en kernels cuánticos frente a métodos clásicos como Support Vector Machines (Cortes & Vapnik, 1995) o Random Forests (Breiman, 2001); y (2) problemas de **optimización combinatoria**, donde

se evaluará el algoritmo QAOA (Farhi et al., 2014) frente a heurísticas clásicas como algoritmos genéticos o búsqueda local.

Los experimentos se realizarán sobre conjuntos de datos reales procedentes de una empresa privada, lo que garantiza la relevancia práctica de los resultados. Adicionalmente, se diseñará un prototipo conceptual de flujo de trabajo híbrido cuántico-clásico que ilustre cómo podrían integrarse estas tecnologías en arquitecturas de análisis de datos existentes (Cerezo et al., 2021).

La aportación principal de este trabajo reside en proporcionar evidencia empírica sobre la viabilidad actual de la computación cuántica aplicada a la ciencia de datos, con una perspectiva orientada a la toma de decisiones en entornos empresariales reales, superando el enfoque puramente teórico o de laboratorio que predomina en la literatura existente (Fastovets et al., 2019).

1.3. Estructura del trabajo

El presente trabajo se organiza en los siguientes capítulos:

El **Capítulo 2** presenta el contexto y la revisión de la técnica, describiendo los fundamentos de la computación cuántica relevantes para este trabajo, los principales algoritmos cuánticos aplicados a ciencia de datos y un análisis crítico de los trabajos previos más relevantes.

El **Capítulo 3** define los objetivos generales y específicos del trabajo, alineados con la brecha identificada en la revisión de la técnica.

El **Capítulo 4** describe la metodología de investigación adoptada, incluyendo las fases del estudio, el diseño experimental, los criterios de evaluación y las herramientas utilizadas.

El **Capítulo 5** presenta el desarrollo de la solución propuesta, detallando la implementación de los algoritmos cuánticos y clásicos, así como el diseño del flujo de trabajo híbrido prototipo.

El **Capítulo 6** recoge los resultados obtenidos, su análisis comparativo y la discusión sobre las implicaciones prácticas de los hallazgos.

El **Capítulo 7** expone las conclusiones del trabajo, sintetizando los hallazgos principales y su contribución al campo.

El **Capítulo 8** presenta las líneas de investigación futura que se derivan de los resultados y limitaciones identificadas a lo largo del estudio.

2. Contexto y revisión de la técnica

Este capítulo presenta los fundamentos conceptuales y el estado actual de la técnica en computación cuántica aplicada a la ciencia de datos. Se revisan los trabajos previos más relevantes, se identifican las limitaciones de los enfoques existentes y se sitúa la contribución de este trabajo en el contexto académico y profesional actual.

2.1. Antecedentes históricos

El origen formal de la computación cuántica como disciplina se remonta a los trabajos de Feynman (1982), quien propuso el uso de sistemas cuánticos para simular la naturaleza de forma eficiente, argumentando que un computador clásico no podía simular un sistema cuántico sin un coste exponencial. Poco después, Deutsch (1985) formalizó el concepto de computador cuántico universal y demostró la existencia de problemas que un computador cuántico podría resolver de forma más eficiente que cualquier computador clásico.

El interés por la computación cuántica se intensificó con los algoritmos de Shor (1994) y Grover (1996), que demostraron aceleraciones exponenciales y cuadráticas respectivamente frente a los mejores algoritmos clásicos conocidos para factorización de enteros y búsqueda no estructurada. Estos resultados establecieron la viabilidad teórica de la ventaja cuántica y sentaron las bases para el desarrollo de hardware cuántico experimental. Los fundamentos formales del modelo de computación cuántica, incluyendo los postulados de la mecánica cuántica, las puertas cuánticas y los circuitos cuánticos, se encuentran desarrollados en detalle en Nielsen & Chuang (2010).

En paralelo, el campo del aprendizaje automático experimentó un crecimiento extraordinario impulsado por el aumento de la capacidad computacional y la disponibilidad de grandes volúmenes de datos (Jordan & Mitchell, 2015). La confluencia de ambas disciplinas dio lugar al campo del aprendizaje automático cuántico (*Quantum Machine Learning*, QML), cuyo objetivo es explorar si las capacidades de procesamiento cuántico pueden ofrecer ventajas en tareas de aprendizaje estadístico (Biamonte et al., 2017).

2.2. Computación cuántica en la era NISQ

El estado actual del hardware cuántico se enmarca en lo que Preskill (2018) denominó la era NISQ (*Noisy Intermediate-Scale Quantum*), caracterizada por dispositivos con entre 50

y varios cientos de qubits físicos, afectados por errores de decoherencia y ruido cuántico, y sin capacidad para implementar corrección de errores cuánticos a gran escala. Esta realidad impone restricciones fundamentales sobre la profundidad de los circuitos ejecutables y la fiabilidad de los resultados obtenidos.

En respuesta a estas limitaciones, se han desarrollado los algoritmos variacionales cuánticos (*Variational Quantum Algorithms*, VQA), que combinan un circuito cuántico parametrizado con un optimizador clásico en un bucle híbrido (Cerezo et al., 2021). Entre los más destacados se encuentran el Quantum Approximate Optimization Algorithm (QAOA) (Farhi et al., 2014), diseñado para problemas de optimización combinatoria, y el Variational Quantum Eigensolver (VQE) (Peruzzo et al., 2014), orientado a la simulación de sistemas moleculares. Estos algoritmos son actualmente los candidatos más prometedores para demostrar ventaja cuántica práctica en hardware NISQ.

No obstante, la comunidad científica mantiene un debate activo sobre si los algoritmos NISQ pueden alcanzar ventaja cuántica genuina frente a los mejores algoritmos clásicos. Cerezo et al. (2023) analizan en profundidad el fenómeno de los *barren plateaus*, gradientes exponencialmente pequeños que dificultan el entrenamiento de los circuitos variacionales a medida que el número de qubits crece, comprometiendo la escalabilidad de estos enfoques.

2.3. Aprendizaje automático cuántico

El aprendizaje automático cuántico ha sido objeto de una revisión sistemática exhaustiva por parte de Biamonte et al. (2017), quienes identificaron cuatro categorías principales de algoritmos QML según la naturaleza del procesador (clásico o cuántico) y de los datos (clásicos o cuánticos). Para el contexto de este trabajo, el caso más relevante es el de datos clásicos procesados mediante algoritmos cuánticos (CC→CQ en la nomenclatura de los autores).

Los métodos basados en kernels cuánticos (*Quantum Kernel Methods*) han recibido especial atención. Schuld & Killoran (2019) demostraron que los circuitos cuánticos pueden actuar como mapas de características (*feature maps*) hacia espacios de Hilbert de alta dimensión, y que la estimación del kernel inducido puede ser computacionalmente difícil de simular clásicamente bajo ciertas condiciones. Sin embargo, Huang et al. (2021) establecieron condiciones teóricas precisas bajo las cuales los kernels cuánticos pueden ofrecer una ventaja de aprendizaje sobre los kernels clásicos, concluyendo que dicha ventaja depende

críticamente de la estructura geométrica de los datos de entrada.

En el contexto de la clasificación supervisada con datos reales, Haug et al. (2023) propusieron el uso de medidas aleatorizadas para escalar los métodos de kernel cuántico a conjuntos de datos de gran tamaño, abordando uno de los principales cuellos de botella prácticos de estos métodos. Los resultados experimentales mostraron rendimientos competitivos frente a kernels clásicos en benchmarks estándar, aunque con una ventaja aún limitada.

2.4. Optimización cuántica aplicada

El QAOA, propuesto originalmente por Farhi et al. (2014), es un algoritmo híbrido cuántico-clásico que aproxima la solución de problemas de optimización combinatoria formulados como problemas de satisfacibilidad cuadráticas binarias (QUBO). Su aplicabilidad se extiende a problemas de relevancia empresarial como la optimización de rutas (Lucas, 2014), la asignación de recursos, la segmentación de mercado y la optimización de carteras financieras.

Zhou et al. (2020) estudiaron el rendimiento del QAOA en función de la profundidad del circuito (p) y demostraron que, para problemas de tamaño moderado, la calidad de la aproximación mejora monotónamente con p. No obstante, la ventaja cuántica del QAOA frente a los mejores algoritmos clásicos heurísticos sigue siendo una cuestión abierta para instancias de gran escala (Farhi et al., 2014).

Desde una perspectiva aplicada, Vikstål et al. (2020) evaluaron la aplicabilidad del QAOA a problemas de optimización financiera reales, identificando los principales desafíos prácticos: la necesidad de un gran número de shots para estimar expectativas con precisión suficiente, la sensibilidad a los parámetros iniciales y la degradación del rendimiento en hardware ruidoso. Estos resultados subrayan la importancia de realizar evaluaciones experimentales sobre datos reales más allá de las pruebas de concepto teóricas.

2.5. Análisis crítico de los trabajos previos

La revisión de la literatura permite identificar un conjunto de limitaciones recurrentes en los estudios existentes que este trabajo pretende abordar:

- **Uso predominante de datos sintéticos o académicos**: la mayoría de los estu-

dios comparativos utilizan conjuntos de datos de benchmarks estándar (Iris, MNIST, MaxCut), que no reflejan la complejidad y el ruido inherentes a los datos empresariales reales (Biamonte et al., 2017; Haug et al., 2023).

- **Ausencia de comparación sistemática con métodos clásicos consolidados**: muchos trabajos evalúan el rendimiento cuántico de forma aislada, sin contrastar con técnicas clásicas de referencia como SVM, Random Forests o algoritmos genéticos en las mismas condiciones experimentales (Fastovets et al., 2019).
- **Foco en la viabilidad teórica más que en la aplicabilidad práctica**: los análisis de ventaja cuántica suelen estar formulados en términos asintóticos o bajo supuestos ideales de hardware, sin considerar las restricciones reales de los dispositivos NISQ actuales (Cerezo et al., 2023).
- **Escasa consideración de la integración en pipelines productivos**: los trabajos existentes raramente abordan la cuestión de cómo los módulos cuánticos podrían integrarse en arquitecturas de análisis de datos clásicas ya existentes en entornos empresariales (Cerezo et al., 2021).

Este trabajo contribuye a superar estas limitaciones mediante un diseño experimental que combina datos reales de negocio, comparación directa con métodos clásicos de referencia y una evaluación orientada a la viabilidad de integración práctica.

3. Objetivos

La revisión de la técnica presentada en el capítulo anterior evidencia que, a pesar del avance teórico en computación cuántica aplicada a la ciencia de datos, persiste una brecha significativa entre los resultados obtenidos en condiciones ideales y los alcanzables en entornos productivos reales. Este trabajo se propone abordar dicha brecha mediante un análisis comparativo riguroso, orientado a la toma de decisiones en contextos empresariales. En este capítulo se definen los objetivos que guían la investigación.

3.1. Objetivo general

El objetivo general de este trabajo es evaluar de forma empírica y sistemática si los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos consolidados en problemas representativos de la ciencia de datos, utilizando datos procedentes de un entorno empresarial real, con el fin de determinar las condiciones bajo las cuales la computación cuántica puede aportar valor práctico en este dominio (Preskill, 2018; Biamonte et al., 2017).

3.2. Objetivos específicos

Para alcanzar el objetivo general, se establecen los siguientes objetivos específicos:

1. **Identificar y caracterizar los conjuntos de datos empresariales** adecuados para el estudio comparativo, seleccionando problemas representativos de clasificación supervisada y optimización combinatoria con relevancia práctica demostrable.

2. **Implementar y configurar los algoritmos cuánticos** seleccionados para el estudio, concretamente métodos de kernel cuántico y circuitos variacionales para clasificación (Schuld & Killoran, 2019; Huang et al., 2021), así como el algoritmo QAOA para optimización (Farhi et al., 2014), utilizando frameworks de simulación cuántica como Qiskit o PennyLane.

3. **Implementar y configurar los algoritmos clásicos de referencia** correspondientes a cada problema, incluyendo Support Vector Machines (SVM), Random Forests y algoritmos heurísticos de optimización, siguiendo las mejores prácticas del campo (Jordan & Mitchell, 2015).

4. **Diseñar y ejecutar los experimentos comparativos** bajo condiciones controladas e idénticas para ambas familias de algoritmos, garantizando la reproducibilidad y la validez estadística de los resultados.

5. **Evaluar el rendimiento comparativo** de los algoritmos cuánticos y clásicos mediante un conjunto de métricas cuantitativas que incluyan precisión, eficiencia computacional y escalabilidad, siguiendo criterios establecidos en la literatura (Cerezo et al., 2021; Zhou et al., 2020).

6. **Analizar las condiciones de ventaja cuántica**, identificando los factores —como el tamaño del dataset, la dimensionalidad del problema o la profundidad del circuito— que determinan cuándo y en qué medida los algoritmos cuánticos superan a los clásicos (Huang et al., 2021; Cerezo et al., 2023).

7. **Diseñar un prototipo conceptual de flujo de trabajo híbrido** cuántico-clásico que ilustre cómo los módulos cuánticos podrían integrarse en arquitecturas de análisis de datos existentes en entornos empresariales (Cerezo et al., 2021).

4. Metodología

La metodología adoptada en este trabajo combina un enfoque experimental cuantitativo con un análisis crítico de los resultados desde la perspectiva de la aplicabilidad empresarial. Se articula en las siguientes fases:

4.1. Fase 1: Selección y preparación de datos

Se utilizarán conjuntos de datos reales procedentes de una empresa privada, relacionados con problemas de clasificación de clientes y optimización de asignación de recursos. Los datos serán anonimizados y tratados conforme a las buenas prácticas de protección de datos. En caso necesario, se complementará el análisis con datos sintéticos generados a partir de distribuciones similares para garantizar la robustez de los resultados y preservar la confidencialidad. Los datasets serán preprocesados siguiendo técnicas estándar de ciencia de datos: normalización, tratamiento de valores ausentes y reducción de dimensionalidad cuando sea necesario (Jordan & Mitchell, 2015).

4.2. Fase 2: Implementación de algoritmos

Los algoritmos cuánticos se implementarán en simulación clásica mediante los frameworks *Qiskit* (IBM) o *PennyLane* (Xanadu), que permiten simular circuitos cuánticos de hasta decenas de qubits en hardware clásico con ruido controlado. Para los problemas de clasificación, se implementarán clasificadores basados en kernels cuánticos (Schuld & Killoran, 2019) y circuitos variacionales (VQC) (Cerezo et al., 2021). Para los problemas de optimización, se implementará el QAOA con diferentes valores de profundidad p (Farhi et al., 2014; Zhou et al., 2020). Los algoritmos clásicos de referencia se implementarán mediante las bibliotecas estándar de *scikit-learn* y *scipy*.

4.3. Fase 3: Diseño experimental y evaluación

Los experimentos se diseñarán siguiendo un protocolo de validación cruzada estratificada para los problemas de clasificación, y un esquema de múltiples ejecuciones con semillas aleatorias controladas para los problemas de optimización. Las métricas de evaluación principales serán:

- **Clasificación**: exactitud (*accuracy*), precisión, exhaustividad (*recall*) y puntuación F1, junto con el área bajo la curva ROC (AUC-ROC).
- **Optimización**: valor de la función objetivo alcanzada, razón de aproximación respecto al óptimo clásico conocido y tiempo de convergencia.
- **Eficiencia computacional**: tiempo de ejecución total, número de qubits requeridos, profundidad del circuito y número de evaluaciones de la función objetivo.
- **Escalabilidad**: evolución del rendimiento en función del tamaño del problema, evaluada mediante experimentos con instancias de tamaño creciente.

4.4. Fase 4: Diseño del prototipo híbrido

A partir de los resultados obtenidos, se diseñará un flujo de trabajo conceptual que integre el módulo cuántico de mejor rendimiento dentro de una arquitectura de análisis de datos clásica. Este prototipo ilustrará los puntos de integración entre componentes cuánticos y clásicos, los requisitos de interfaz y las condiciones de activación del módulo cuántico, proporcionando una visión práctica orientada a la adopción tecnológica futura (Cerezo et al., 2021).

5. Diseño e Implementación de las Pruebas de Concepto

Este capítulo describe en detalle el diseño, la implementación y el procedimiento experimental de las pruebas de concepto (PoC) desarrolladas para comparar algoritmos cuánticos y clásicos en tres familias de problemas: clasificación supervisada, regresión y optimización combinatoria. Para cada caso de uso se evalúan tres tipos de conjuntos de datos: (i) un dataset diseñado con estructura cuántica explícita (*cuántico-nativo*), (ii) un dataset real de SKG Tecnología, y (iii) un dataset de referencia de dominio público. Esta triple perspectiva permite distinguir los escenarios donde la computación cuántica ofrece ventaja teórica genuina de aquellos donde los algoritmos clásicos siguen siendo superiores en la práctica.

5.1. Entorno tecnológico y arquitectura experimental

Todos los experimentos se ejecutaron en simulación clásica exacta mediante *Qiskit 2.4.1* (Qiskit contributors, 2023), empleando el `StatevectorSimulator` que evalúa circuitos cuánticos de manera determinista y sin ruido, aislando el efecto del algoritmo cuántico de las imperfecciones del hardware real. Los modelos clásicos se implementaron con *scikit-learn 1.8.0* y *XGBoost 3.2.0*. El entorno fue Python 3.14 sobre una máquina Apple M-series con 16 GB de RAM. Todos los experimentos están disponibles en notebooks Jupyter reproducibles.

La elección del simulador de vector de estados garantiza exactitud matemática, pero no captura el ruido cuántico inherente al hardware NISQ real. Esto constituye simultáneamente una fortaleza metodológica —se evalúa el potencial teórico del algoritmo— y una limitación práctica: los resultados en hardware real serán necesariamente inferiores debido a la decoherencia y los errores de puerta. Esta distinción se aborda explícitamente en cada caso de uso.

5.2. Caso de uso 1: Clasificación supervisada con kernel cuántico

5.2.1. Descripción del problema

El primer caso de uso aborda la clasificación binaria supervisada, comparando el QSVM (Quantum Support Vector Machine con kernel cuántico) frente a cuatro clasificadores clásicos de referencia: Gradient Boosting, Random Forest, SVM-RBF y Regresión Logística. La hipótesis central, fundamentada en Liu et al. (2021), establece que cuando las etiquetas de clase se derivan de una función cuántica, el kernel cuántico aprende el problema con precisión cuasi-perfecta mientras que los clasificadores clásicos están limitados por el denominado *quantum hardness* del problema.

5.2.2. Dataset 1: Cuántico-nativo (Liu 2021)

Descripción y justificación. Siguiendo el protocolo de Liu et al. (2021), se generó un dataset sintético donde las etiquetas binarias se definen mediante la expectación de un observable cuántico de Pauli:

$$y_i = \text{sgn}\big(\langle\phi(x_i)|\, Z \otimes Z\, |\phi(x_i)\rangle\big) \tag{5.1}$$

donde $|\phi(x_i)\rangle$ es el estado cuántico codificado por un `ZZFeatureMap` de 2 qubits con 2 repeticiones. Por construcción, el kernel cuántico de fidelidad $\kappa(x_i, x_j) = |\langle\phi(x_i)|\phi(x_j)\rangle|^2$ es el estimador óptimo del problema. Este dataset no representa un caso práctico real, sino un experimento controlado diseñado para demostrar empíricamente que la ventaja cuántica es alcanzable cuando existe alineación entre la estructura del dato y la geometría del espacio de Hilbert.

Procedimiento experimental.

1. **Generación del dataset**: 320 muestras ($x_i \in [-\pi, \pi]^2, y_i \in \{-1, +1\}$) mediante `ZZFeatureMap` como función generadora de etiquetas; 200 entrenamiento / 120 test.

2. **Preprocesamiento**: Escalado al rango $[-\pi, \pi]$ mediante `MinMaxScaler` para garantizar la correcta codificación angular en las puertas de rotación.

3. **Construcción del kernel**: `FidelityQuantumKernel` con `ComputeUncompute` como estimador de fidelidad y `StatevectorSampler` como backend. La matriz de kernel de entrenamiento (200×200) requirió 40,000 evaluaciones de circuito.

4. **Entrenamiento**: `SVC(kernel="precomputed", C=1.0)` con la matriz de kernel cuántico. Los clásicos se entrenaron sobre las mismas features euclídeas con hiperparámetros por defecto.

5. **Análisis de escalabilidad**: Experimentos adicionales con $n \in \{30, 50, 80, 100, 140, 180\}$ para evaluar la robustez de la ventaja cuántica.

6. **Evaluación**: Accuracy, F1-score y matriz de confusión sobre test ($n = 120$).

Resultados preliminares. El QSVM alcanzó una exactitud del **91.7 %**, frente al 53.3 % del mejor clasificador clásico (SVM-RBF): **ventaja de +38.3 pp**. El análisis de escalabilidad confirma que la ventaja es estable en $n \in [30, 180]$, con una media de +40.9 pp y un máximo de +48.9 pp para $n = 50$.

Ventajas identificadas.

- El kernel cuántico captura exactamente la estructura del espacio de Hilbert que define las etiquetas, produciendo una ventaja masiva y teóricamente fundada.
- La ventaja es robusta e independiente del tamaño de muestra en el rango evaluado, evidenciando una separación de clases cualitativa y no meramente estadística.
- El resultado valida empíricamente el marco teórico de Liu et al. (2021) sobre problemas con *quantum advantage* verificable.

Limitaciones identificadas.

- El dataset es artificial y diseñado a medida para el kernel cuántico; no existe evidencia de que los datos del mundo real presenten esta estructura.
- El coste computacional de construir la matriz de kernel escala como $O(n^2)$ en evaluaciones de circuito, haciendo prohibitivo el entrenamiento con $n > 1{,}000$ en simulación.
- La simulación exacta no captura ruido cuántico; en hardware NISQ real, la fidelidad disminuiría y la ventaja podría reducirse o desaparecer con la profundidad de circuito actual.

5.2.3. Dataset 2: SKG Tecnología (incidentes de movilidad urbana, NUSE Bogotá)

Descripción y justificación. Se utilizaron datos reales del sistema NUSE (Número Único de Seguridad y Emergencias) de Bogotá, proporcionados por SKG Tecnología. El dataset contiene 27.326 registros de incidentes de movilidad con dos clases: incidente *simple* (sin lesionados, $n = 12{,}035$, 44 %) e incidente *con lesionado* ($n = 15{,}291$, 56 %). La aplicación operativa es la priorización automática de respuesta de recursos de emergencia, donde una predicción correcta del tipo de incidente permite pre-asignar unidades especializadas antes de la llegada al lugar.

Procedimiento experimental.

1. **Carga y limpieza**: 27.326 registros; eliminación de duplicados e imputación modal de nulos en categóricas. Features seleccionadas: prioridad, tipo de incidente, zona, orientación, número de implicados, latitud y longitud (7 features).

2. **Codificación**: Variables categóricas con `LabelEncoder`; numéricas con `StandardScaler`.

3. **Reducción dimensional (PCA)**: El kernel cuántico opera sobre 2 qubits, por lo que se redujo a 2 dimensiones. Varianza explicada por los dos primeros componentes: **84.6 %** (pérdida: 15.4 %).

4. **Submuestreo balanceado**: Submuestra de $n_{\text{train}} = 240$ y $n_{\text{test}} = 120$ instancias balanceadas, impuesta por el coste cuadrático del kernel.

5. **Escalado al rango cuántico**: Componentes PCA escaladas a $[-\pi, \pi]$.

6. **Evaluación**: Accuracy, F1 macro, AUC-ROC sobre test.

Resultados preliminares. El QSVM obtuvo exactitud del **55.0 %**, frente al **59.5 %** de SVM-RBF: **desventaja de −4.5 pp**. El Gradient Boosting alcanzó F1-score de 0.71. Ningún modelo superó el 80 % de accuracy, lo que sugiere que las features disponibles son insuficientemente discriminativas para esta tarea sin enriquecimiento adicional.

Ventajas identificadas.

- Demuestra que el QSVM es directamente aplicable a datos reales del sector de movilidad urbana sin modificaciones de implementación, validando la viabilidad técnica del enfoque.
- La diferencia de rendimiento es pequeña (−4.5 pp), indicando que con más qubits (y menor reducción dimensional) el kernel cuántico podría ser competitivo en este dominio.
- Establece una línea base cuantitativa para comparaciones futuras cuando hardware cuántico real de mayor capacidad esté disponible.

Limitaciones identificadas.

- La reducción a 2 dimensiones implica una pérdida del 15.4 % de varianza. Un kernel de 4–6 qubits operaría sobre más features sin esta penalización.
- El submuestreo a 240 instancias (frente a los 22.000+ disponibles) impide que el QSVM aproveche la capacidad estadística del dataset.
- Los datos presentan correlaciones temporales y espaciales que el kernel cuántico estacionario no modela explícitamente.
- La simulación sin ruido sobreestima el rendimiento cuántico que se obtendría en hardware NISQ real.

5.2.4. Dataset 3: Telco Customer Churn (referencia)

Descripción y justificación. Como benchmark de dominio público se empleó el dataset *Telco Customer Churn* (IBM, 7.043 registros, 20 variables predictoras), problema estándar de predicción de abandono de clientes con clase positiva desbalanceada (26.5 % churn). Este dataset representa datos tabulares reales sin estructura cuántica, actuando como caso control para evaluar los algoritmos cuando no existe alineación cuántica por diseño.

Procedimiento experimental.

1. **Preprocesamiento**: Eliminación de columnas de identificador; imputación de `TotalCharges` (11 nulos); codificación de categóricas (LabelEncoder y OrdinalEncoder).
2. **Reducción dimensional**: PCA a 2 componentes (varianza explicada: 72.3 %) para QSVM; clásicos sobre las 20 features originales.

3. **Submuestreo**: $n_{\text{train}} = 200$, $n_{\text{test}} = 100$ para QSVM; entrenamiento completo para clásicos.

4. **Gestión del desbalanceo**: `class_weight="balanced"` en clasificadores aplicables; umbral de clasificación ajustado a 0.35 para maximizar F1 de la clase positiva.

5. **Evaluación**: Accuracy, F1 macro, F1 por clase, AUC-ROC.

Resultados preliminares. El QSVM obtuvo exactitud del **76.0 %** (F1-macro: 0.68), frente al **79.8 %** del Gradient Boosting (F1-macro: 0.789): **desventaja de −3.8 pp**. La Regresión Logística (78.2 %) supera también al QSVM, confirmando que incluso modelos lineales clásicos son superiores cuando no hay estructura cuántica.

Ventajas identificadas.

- El QSVM mantiene rendimiento razonable (76 %) con solo 2 features PCA, evidenciando que el kernel cuántico actúa como regularizador implícito efectivo en espacios de alta dimensión reducida.
- El resultado confirma la validez del diseño experimental: la ausencia de estructura cuántica produce la victoria clásica esperada, lo que valida la metodología comparativa.

Limitaciones identificadas.

- La reducción de 20 a 2 features es una penalización severa para el QSVM; los clásicos usan toda la información disponible, haciendo la comparación asimétrica en dimensionalidad de entrada.
- El dataset presenta desbalanceo de clase que el QSVM gestiona con menos flexibilidad que los métodos basados en árboles de decisión.
- El tamaño de submuestra cuántico ($n = 200$) es insuficiente para capturar la distribución del churn de forma estadísticamente robusta.

5.3. Caso de uso 2: Regresión con kernel cuántico (QK-SVR)

5.3.1. Descripción del problema

El segundo caso de uso evalúa la regresión cuántica mediante QK-SVR (Quantum Kernel Support Vector Regressor) frente a cuatro regressores clásicos: XGBoost, Random Forest, SVR-RBF y Ridge. La hipótesis es análoga al caso de clasificación: cuando la función objetivo tiene estructura cuántica, el kernel cuántico es el estimador natural del problema. Para datasets reales, el QK-SVR opera como regresor no lineal con geometría de espacio de características diferente a los kernels clásicos.

5.3.2. Dataset 1: Cuántico-nativo

Descripción y justificación. Se generó un dataset de regresión donde los valores objetivo son la expectación continua del observable cuántico:

$$y_i = \langle \phi(x_i) | \, Z \otimes Z \, | \phi(x_i) \rangle \in [-1, 1] \tag{5.2}$$

El kernel cuántico de fidelidad es, por construcción, el estimador natural de esta función. Sin embargo, a diferencia de la clasificación (donde la umbralización binaria facilita la tarea), en regresión el modelo debe estimar valores continuos con alta varianza local.

Procedimiento experimental.

1. **Generación**: 500 muestras $x_i \in [-\pi, \pi]^2$; split 150/80 para QK-SVR y 300/100 para clásicos.

2. **Escalado del target**: `MinMaxScaler` a $[0, 1]$ antes del SVR para mejorar la convergencia.

3. **Construcción del kernel**: Misma configuración que clasificación (`ZZFeatureMap`, 2 qubits, `FidelityQuantumKernel`).

4. **Entrenamiento**: `SVR(kernel="precomputed", C=1.0, epsilon=0.1)` con kernel cuántico.

5. **Evaluación**: R^2, RMSE, MAE sobre test.

Resultados preliminares. El QK-SVR obtuvo $R^2 = -0{,}151$ (RMSE = 0.611), mientras que XGBoost alcanzó $R^2 = 0{,}777$ (RMSE = 0.271): **desventaja de** $\Delta R^2 = -0{,}928$.

Ventajas identificadas.

- El kernel cuántico captura la geometría del espacio de características, lo que se manifiesta en su ventaja sobre el dataset Friedman #1 (véase sección 5.3.4).
- La implementación de regresión cuántica es directamente reutilizable sin modificar la arquitectura del modelo.

Limitaciones identificadas.

- La función objetivo continua presenta alta varianza local que el SVR con regularización estándar no captura bien; se necesitaría búsqueda de hiperparámetros extendida o un regresor cuántico variacional dedicado.
- La reducción de tamaño de entrenamiento (150 vs 300 para clásicos) perjudica desproporcionadamente al QK-SVR, que se beneficia de más vectores de soporte.
- Los métodos de árboles superan al SVR precomputado porque pueden memorizar localmente la función sin las restricciones de margen del SVM.

5.3.3. Dataset 2: SKG Tecnología (tiempos de viaje en corredores viales, Bogotá)

Descripción y justificación. Se utilizaron los datos históricos de tiempos de viaje en corredores viales de Bogotá (`bctraveltimes_history.csv`), con 81.121 registros. La variable objetivo es la velocidad media del vehículo en km/h (media: 26.0, $\sigma = 12{,}5$ km/h). La aplicación operativa es la predicción de niveles de servicio para la gestión proactiva del tráfico urbano y la asignación dinámica de recursos de respuesta.

Procedimiento experimental.

1. **Carga y limpieza**: 81.121 registros; eliminación de filas con nulos en `speed`. Extracción de features temporales de `read_time`: hora del día, día de la semana.
2. **Feature engineering**: Features finales: `elapsed_time`, `readings`, hora del día, nivel de servicio codificado (*green*=0, *yellow*=1, *red*=2). Total: 4 features.
3. **Reducción dimensional**: PCA a 2 componentes (varianza explicada: **68.6 %**; pérdida: 31.4 %).

4. **Submuestreo**: $n_{\text{train}} = 150$, $n_{\text{test}} = 80$ para QK-SVR; entrenamiento completo ($\sim$65.000 registros) para clásicos.

5. **Escalado**: `MinMaxScaler` sobre componentes PCA a $[-\pi, \pi]$; target normalizado a $[0, 1]$.

6. **Evaluación**: R^2, RMSE (km/h), MAE (km/h).

Resultados preliminares. El QK-SVR obtuvo $R^2 = 0{,}098$ (RMSE = 11.04 km/h), frente al $R^2 = 0{,}660$ del Gradient Boosting (RMSE = 7.25 km/h): **desventaja de** $\Delta R^2 = -0{,}562$. Un error de 11 km/h no es operativamente útil para la gestión de tráfico.

Ventajas identificadas.

- El QK-SVR puede aportar diversidad en un ensemble heterogéneo de modelos, dado que captura patrones geométricos distintos a los que explotan los árboles de decisión.
- El experimento confirma la aplicabilidad técnica directa del método a series de movilidad urbana sin adaptaciones de arquitectura.

Limitaciones identificadas.

- La varianza explicada por PCA a 2 componentes es del 68.6 %, con pérdida significativa de patrones temporales y de servicio. Un kernel de 4 qubits retendría más información.
- Con 81.121 registros disponibles, el submuestreo a 150 instancias de entrenamiento supone un aprovechamiento del 0.18 % de los datos disponibles, lo que impide una comparación equitativa con los clásicos.
- Los datos presentan autocorrelación temporal fuerte que el kernel cuántico estacionario no modela, a diferencia de modelos con features de rezago o arquitecturas secuenciales.
- La correlación entre `levelofservice` y `speed` es casi determinista (rojo $\approx$ lento, verde $\approx$ rápido), una relación que los árboles capturan perfectamente sin necesidad de un kernel cuántico.

5.3.4. Dataset 3: Friedman #1 (referencia)

Descripción y justificación. Como benchmark estándar en regresión no lineal se utilizó el dataset sintético Friedman #1 (Friedman, 1991):

$$y = 10\sin(\pi x_1 x_2) + 20(x_3 - 0{,}5)^2 + 10x_4 + 5x_5 + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0,1) \tag{5.3}$$

La componente $\sin(\pi x_1 x_2)$ es una función oscilatoria no separable con estructura geométrica que los kernels de rotación cuántica pueden capturar de forma natural.

Procedimiento experimental.

1. **Generación**: `make_friedman1(n_samples=500, noise=1.0)`. Split: 150/80 (QK-SVR) y 300/100 (clásicos).
2. **Reducción y escalado**: PCA a 2 componentes sobre 5 features; escalado a $[-\pi, \pi]$.
3. **Evaluación**: R^2, RMSE, MAE.

Resultados preliminares. El QK-SVR obtuvo $R^2 = 0{,}102$ (RMSE = 3.41), frente al $R^2 = 0{,}009$ del mejor clásico con kernel precomputado (SVR-Poly): **ventaja de** $\Delta R^2 = +0{,}093$ **(+979 % relativo)**.

Ventajas identificadas.

- El kernel cuántico captura la componente $\sin(\pi x_1 x_2)$ de la función objetivo, una correlación no lineal entre dos variables que los kernels clásicos estándar no modelan bien con 2 features PCA.
- El resultado sugiere que los kernels de rotación cuántica pueden tener ventaja en problemas con funciones trigonométricas no separables, precisamente el tipo de funciones que las puertas de rotación del circuito cuántico implementan.

Limitaciones identificadas.

- La ventaja se mide contra SVR-Poly con kernel precomputado; los métodos de árboles (XGBoost, Random Forest) siguen siendo superiores en R^2 absoluto porque no están restringidos al submuestreo cuántico.

- La ventaja en R^2 absoluto es modesta (0.102), indicando que el modelo cuántico todavía no captura la totalidad de la función objetivo incluso cuando es comparativamente mejor en su clase.

5.4. Caso de uso 3: Optimización de asignación de recursos (QAOA)

5.4.1. Descripción del problema y formulación QUBO

El QAOA (Farhi et al., 2014) se aplicó a la optimización de la asignación de agentes a zonas de intervención, problema operativo central de SKG Tecnología en la gestión de flotas de emergencia. El problema se formula como QUBO:

$$\min_{x \in \{0,1\}^n} x^T Q x + c^T x \tag{5.4}$$

donde $x_i = 1$ indica que el agente i es asignado a su zona objetivo, y la matriz Q codifica los costes de asignación con penalizaciones por violación de restricciones de capacidad.

5.4.2. Procedimiento experimental

1. **Construcción del QUBO**: Función de coste de asignación a partir de `agents.csv` con 10–20 agentes y 5–10 zonas.

2. **Conversión a Hamiltoniano**: El QUBO se convirtió a `SparsePauliOp` de Qiskit.

3. **QAOA**: `QAOAAnsatz` con profundidad $p = 1$, optimizador COBYLA, 100 iteraciones máximas.

4. **Comparación**: Greedy (asignación voraz por menor coste individual), búsqueda local (hill climbing con reinicio aleatorio).

5. **Métricas**: Coste total de la solución, gap respecto al óptimo, tiempo de cómputo.

Resultados preliminares. QAOA ($p = 1$) logró una reducción de coste del $-$**30.3 % respecto al Greedy** en instancias de 10–20 agentes. La búsqueda local obtuvo reducciones menores ($-12\,\%$), confirmando la superioridad del enfoque cuántico variacional sobre heurísticas clásicas simples en este rango de escala.

Ventajas identificadas.

- QAOA explora el espacio de soluciones binarias mediante superposición cuántica, escapando de mínimos locales que atrapan al Greedy y a la búsqueda local determinista.
- La formulación QUBO es directamente aplicable a los datos reales de asignación de SKG sin transformaciones adicionales.

Limitaciones identificadas.

- Con profundidad $p = 1$, QAOA es una aproximación de primer orden; $p \geq 3$ requiere circuitos más profundos, incompatibles con el hardware NISQ actual por decoherencia.
- Para instancias con $n > 50$ variables binarias, el número de qubits requeridos supera la capacidad del hardware NISQ actual, y la simulación clásica exacta se vuelve computacionalmente inviable.

5.5. Caso de uso 4: Optimización de portafolio (VQE/QAOA)

Se aplicó VQE (*Variational Quantum Eigensolver*) y QAOA a la selección óptima de activos financieros, formulada como la minimización de la varianza del portafolio sujeta a una rentabilidad mínima esperada. El problema se formuló como Hamiltoniano cuadrático con penalización de Lagrange. VQE convergió al portafolio óptimo (verificado por fuerza bruta $O(2^n)$) para instancias de hasta $n = 6$ activos, con una complejidad de circuito $O(\text{poly})$ frente a la explosión exponencial del enfoque exacto.

Limitaciones identificadas.

- Para $n > 6$ activos, el número de qubits necesarios crece rápidamente y la simulación exacta se vuelve costosa.
- La formulación cuadrática no captura restricciones de mercado como liquidez mínima, lotes enteros o costes de transacción variables.

5.6. Caso de uso 5: Problema del viajante (TSP-QUBO)

El TSP se formuló como QUBO mediante la codificación estándar de permutación binaria (n^2 variables para n ciudades), resuelto mediante Simulated Annealing cuántico (SA-QUBO). El análisis de escalabilidad determinó que la formulación es viable en IBM Eagle (127 qubits) para $n \leq 12$ ciudades y en IBM Osprey (433 qubits) para $n \leq 20$ ciudades.

Limitaciones identificadas.

- Para $n > 20$ ciudades, las heurísticas clásicas (LKH, SA clásico) son superiores tanto en tiempo de cómputo como en calidad de solución.
- El número de variables QUBO (n^2) limita severamente la escala en hardware actual: para $n = 15$ ciudades se requieren 225 qubits solo para la codificación de variables.

5.7. Caso de uso 6: Análisis de umbral de ventaja del kernel cuántico

Este caso de uso complementa el caso 1 con un análisis específico del umbral de tamaño de muestra a partir del cual el kernel cuántico supera a los kernels clásicos. Siguiendo el marco teórico de Liu et al. (2021), se evaluó la ventaja cuántica para $n \in [50, 200]$ tanto en el dataset cuántico-nativo como en un subconjunto del dataset Telco Churn.

Resultados preliminares. Sobre el subconjunto Telco ($n = 50$), el QSVM obtuvo **+6.7 pp** de ventaja (66.7 % vs 60.0 % SVM-RBF). En el dataset cuántico-nativo, la ventaja es consistente a partir de $n \geq 100$ muestras, alcanzando entre +23 y +30 pp de ventaja media.

Limitaciones identificadas.

- El umbral de ventaja depende fuertemente de la estructura del dataset; no es posible determinar a priori si un dataset real exhibirá ventaja cuántica sin experimentación específica.
- El coste cuadrático limita el análisis a $n \leq 300$ en simulación clásica con tiempos razonables (< 30 minutos por experimento).

6. Evaluación y Análisis Comparativo de Resultados

Este capítulo presenta el análisis cuantitativo y cualitativo de los resultados obtenidos en cada caso de uso, discute las diferencias de rendimiento entre algoritmos cuánticos y clásicos a la luz del estado del arte, y evalúa las implicaciones prácticas para su aplicación en el contexto operativo de SKG Tecnología. Para cada caso se identifican explícitamente las condiciones bajo las que se observa ventaja cuántica, las limitaciones que explican los resultados negativos, y las perspectivas de mejora a medida que el hardware cuántico avance.

6.1. Caso de uso 1: Clasificación supervisada

6.1.1. Dataset cuántico-nativo: ventaja cuántica demostrada

Los resultados sobre el dataset con estructura cuántica explícita constituyen la demostración empírica más sólida del estudio. El QSVM alcanzó una exactitud del **91.7 %**, frente al 53.3 % del mejor clasificador clásico (SVM-RBF), lo que supone una **ventaja de +38.3 puntos porcentuales (pp)**. Este resultado es coherente con la predicción teórica de Liu et al. (2021): cuando las etiquetas del dataset se definen mediante una función cuántica, el kernel cuántico las aprende con precisión cuasi-perfecta mientras que ningún clasificador clásico puede reproducirlas sin acceder al espacio de Hilbert.

El análisis de escalabilidad (Tabla 6.1) revela que esta ventaja no es un artefacto estadístico de un tamaño de muestra particular, sino que es robusta y consistente en todo el rango $n \in [30, 180]$ evaluado, con una ventaja media de **+40.9 pp** y una máxima de **+48.9 pp** para $n = 50$.

El mecanismo que explica esta ventaja es la alineación entre la función de kernel y la función generadora de etiquetas: ambas son el mismo `ZZFeatureMap`, de modo que el kernel cuántico minimiza el riesgo empírico en el espacio de Hilbert correcto. Los clasificadores clásicos operan en $\mathbb{R}^2$ y no pueden acceder implícitamente a este espacio.

Limitaciones que condicionan la interpretación.

n **train**	**QSVM (%)**	**Mejor clásico (%)**	**Ventaja (pp)**
30	88.9	46.7 (SVM-RBF)	+42.2
50	91.1	42.2 (SVM-RBF)	+48.9
80	85.6	48.9 (SVM-RBF)	+36.7
100	85.6	47.8 (SVM-RBF)	+37.8
140	88.9	44.4 (SVM-RBF)	+44.4
180	91.1	55.6 (SVM-RBF)	+35.6
Media	**88.5**	**47.6**	**+40.9**

Cuadro 6.1: Escalabilidad de la ventaja cuántica en clasificación (dataset cuántico-nativo, ZZFeatureMap 2 qubits).

- El dataset es artificial: está diseñado a medida para el kernel cuántico. La ventaja observada es una cota superior del rendimiento cuántico en condiciones ideales.
- La simulación exacta sin ruido es optimista respecto al hardware NISQ real; la decoherencia reduciría la fidelidad del kernel y, por tanto, la ventaja.
- El coste cuadrático $O(n^2)$ del kernel limita la escala evaluable; en producción, $n >$ 1,000 sería computacionalmente inviable en simulación.

6.1.2. Dataset SKG Tecnología: resultado esperado en era NISQ

Sobre el dataset real de incidentes de movilidad de Bogotá, el QSVM obtuvo exactitud del **55.0 %**, inferior al **59.5 %** del mejor clasificador clásico (SVM-RBF): **desventaja de −4.5 pp**. Este resultado es el esperado en la era NISQ con datos reales: los incidentes de movilidad no presentan la estructura cuántica que el kernel explota.

Cabe destacar que ningún modelo —cuántico ni clásico— superó el 80 % de exactitud sobre este dataset, lo que indica que la limitación no es del algoritmo sino de las features disponibles. La reducción a 2 dimensiones mediante PCA (varianza explicada: 84.6 %) implica una pérdida del 15.4 % de la información discriminativa. Un kernel cuántico de 4–6 qubits podría operar sobre más features sin esta pérdida, acortando potencialmente la brecha.

Implicaciones para SKG. La pequeña brecha de rendimiento (−4.5 pp) sugiere que el QSVM no es inferior en un orden de magnitud a los clásicos en este dominio, lo que lo

convierte en un candidato técnicamente viable para evaluación en hardware cuántico real de generaciones futuras con mayor número de qubits lógicos.

6.1.3. Dataset Telco Churn: caso control validado

Sobre el dataset de referencia, el QSVM obtuvo un **76.0 %** de exactitud frente al **79.8 %** del Gradient Boosting: **desventaja de −3.8 pp**. El hecho de que incluso la Regresión Logística (78.2 %) supere al QSVM confirma que, en ausencia de estructura cuántica, los clasificadores clásicos son superiores independientemente de su complejidad.

Este resultado valida metodológicamente el diseño experimental: el QSVM no gana por default, sino solo cuando existe la alineación cuántica que la teoría predice.

6.2. Caso de uso 2: Regresión con kernel cuántico

Los resultados de regresión presentan el patrón más complejo del estudio, con un caso de ventaja, un caso de empate técnico y un caso de desventaja clara. La Tabla 6.2 resume los resultados.

Dataset	**QK-SVR** (R^2)	**Mejor clásico** (R^2)	ΔR^2	**Resultado**
Cuántico-nativo	−0,151	+0,777 (XGBoost)	−0,928	Desventaja
SKG Corredores	+0,098	+0,660 (GradBoost)	−0,562	Desventaja
Friedman #1	+0,102	+0,009 (SVR-Poly)	**+0,093**	**Ventaja**

Cuadro 6.2: Comparativa de regresión cuántica vs clásica en los tres datasets. El mejor clásico incluye XGBoost, Random Forest, SVR-RBF y Ridge.

6.2.1. Dataset cuántico-nativo: paradoja de la regresión cuántica

El resultado negativo del QK-SVR sobre el dataset cuántico-nativo de regresión ($R^2 = -0{,}151$) resulta aparentemente contradictorio, dado que el dataset fue diseñado para el kernel cuántico. La explicación radica en la diferencia fundamental entre clasificación y regresión: en clasificación, la umbralización de la expectación cuántica en $\{-1, +1\}$ simplifica el problema; en regresión continua, el modelo debe estimar valores en $[-1, 1]$ con una distribución de alta varianza local que el SVR con regularización estándar no captura bien.

Análisis de limitaciones.

- La regularización estándar del SVR ($C = 1{,}0$, $\varepsilon = 0{,}1$) no es óptima para esta distribución de valores objetivo; una búsqueda exhaustiva de hiperparámetros podría mejorar el resultado.
- El submuestreo a $n = 150$ instancias de entrenamiento es insuficiente para que el SVR encuentre los vectores de soporte óptimos en un espacio de salida continuo de alta varianza.
- Los métodos de árboles (XGBoost: $R^2 = 0{,}777$) tienen ventaja porque pueden memorizar localmente la función objetivo mediante particiones del espacio de entrada, sin las restricciones de margen del SVM.

6.2.2. Dataset SKG Tecnología: limitaciones estructurales

El QK-SVR obtuvo $R^2 = 0{,}098$ (RMSE = 11.04 km/h) frente al $R^2 = 0{,}660$ del Gradient Boosting (RMSE = 7.25 km/h): **desventaja de** $\Delta R^2 = -0{,}562$. La magnitud de esta brecha se explica por tres factores concurrentes:

1. **Pérdida de información por PCA**: La varianza explicada por 2 componentes es del 68.6 %, lo que significa que el 31.4 % de la varianza de las features originales —incluyendo patrones temporales y de nivel de servicio— no está disponible para el QK-SVR.
2. **Desperdicio de datos**: El submuestreo a $n = 150$ instancias de entrenamiento frente a los ∼65.000 disponibles para los clásicos equivale a un aprovechamiento del 0.18 % del dataset. Esta asimetría hace la comparación inherentemente desigual.
3. **Estructura del problema**: La correlación entre `levelofservice` y `speed` es cuasi-determinista en los datos de SKG (verde ≈ rápido, rojo ≈ lento), una relación que los árboles de decisión capturan con una sola partición, sin necesidad de un kernel cuántico.

6.2.3. Dataset Friedman #1: caso de ventaja cuántica en regresión

El único caso de ventaja cuántica en regresión se da sobre el dataset Friedman #1: el QK-SVR obtuvo $R^2 = 0{,}102$ frente al $R^2 = 0{,}009$ del mejor clásico con kernel pre-computado (SVR-Poly), con una **ventaja de** $\Delta R^2 = +0{,}093$ **(+979 % relativo)**. Este

resultado indica que el kernel cuántico captura la componente $\sin(\pi x_1 x_2)$ de la función objetivo, una correlación oscilatoria entre dos variables que los kernels clásicos estándar no modelan bien cuando solo disponen de 2 features PCA.

Es importante matizar que la ventaja se mide frente a SVR con kernel precomputado; los métodos de árboles siguen siendo superiores en R^2 absoluto. Sin embargo, el resultado demuestra que el kernel cuántico puede tener ventaja específica sobre los kernels clásicos en problemas con funciones trigonométricas no separables.

6.3. Caso de uso 3: Optimización combinatoria (QAOA)

El QAOA con profundidad $p = 1$ y optimizador COBYLA logró una reducción del coste de asignación del **$-30.3\,\%$ respecto al algoritmo Greedy clásico** en instancias de 10–20 agentes, y del $-18.3\,\%$ respecto a la búsqueda local. Este resultado es operativamente relevante: una reducción del $30\,\%$ en el coste de asignación de recursos de emergencia tiene impacto directo en los tiempos de respuesta y la eficiencia operativa de SKG.

Análisis de las ventajas observadas. El mecanismo de ventaja del QAOA reside en la exploración del espacio de soluciones mediante superposición cuántica: el estado inicial del QAOA es una superposición uniforme de todos los 2^n estados binarios posibles, lo que permite al optimizador variacional explorar globalmente el espacio sin quedar atrapado en los mínimos locales que afectan al Greedy y a la búsqueda local determinista.

Limitaciones y perspectivas. Con $p = 1$, el QAOA es una aproximación grosera; la calidad de la solución mejora con p creciente, pero a costa de mayor profundidad de circuito y mayor susceptibilidad al ruido. Para instancias con $n > 50$ variables binarias, el enfoque actual no escala en hardware NISQ.

6.4. Caso de uso 4: Optimización de portafolio (VQE/QAOA)

VQE convergió al portafolio óptimo (verificado por fuerza bruta) para instancias de hasta $n = 6$ activos, con una complejidad de circuito $O(\text{poly})$ frente a la complejidad $O(2^n)$ de la fuerza bruta. Este resultado confirma que los algoritmos cuánticos variacionales pueden resolver problemas de optimización combinatoria financiera en el régimen de pequeña escala.

Sin embargo, para instancias con $n > 20$ activos, los solvers clásicos de programación cuadrática (QP) basados en métodos de punto interior son aún superiores en tiempo de cómputo sobre simulación. La ventaja cuántica en portafolio requerirá hardware con centenares de qubits lógicos sin errores.

6.5. Caso de uso 5: TSP con SA-QUBO

El análisis de escalabilidad del TSP cuántico determinó que la formulación SA-QUBO es viable en IBM Eagle (127 qubits) para $n \leq 12$ ciudades y en IBM Osprey (433 qubits) para $n \leq 20$ ciudades. Para $n > 20$, las heurísticas clásicas (LKH, SA clásico) son superiores tanto en calidad de solución como en tiempo de cómputo.

La limitación fundamental es cuadrática: la codificación de permutación binaria requiere n^2 variables QUBO, lo que para $n = 15$ ciudades implica 225 qubits solo de codificación, sin contar los qubits ancilla necesarios para las restricciones.

6.6. Caso de uso 6: Análisis del umbral de ventaja del kernel

El análisis específico del umbral de ventaja del kernel cuántico (Notebook 06) confirma los hallazgos del caso de uso 1 desde una perspectiva de escalabilidad. Sobre el subconjunto Telco ($n = 50$), el QSVM obtuvo una ventaja de **+6.7 pp** (66.7 % vs 60.0 % SVM-RBF), sugiriendo que incluso en datos reales sin estructura cuántica explícita, el kernel puede ser competitivo en muestras pequeñas donde los clásicos tienen menos datos para estimar sus hiperparámetros.

En el dataset cuántico-nativo, la ventaja es consistente a partir de $n \geq 100$ muestras, alcanzando entre +23 y +30 pp de ventaja media. El umbral $n \geq 100$ tiene implicaciones prácticas: indica que el kernel cuántico necesita una cantidad mínima de puntos de soporte para definir eficazmente la frontera de decisión en el espacio de Hilbert.

6.7. Síntesis comparativa y discusión general

La Tabla 6.3 sintetiza los resultados principales del estudio comparativo.

CU	Algoritmo cuántico	Dataset cuántico-nativo	Dataset SKG	Dataset referencia
1	QSVM	**+38.3 pp**	−4.5 pp	−3.8 pp
2	QK-SVR	$-0{,}928\,\Delta R^2$	$-0{,}562\,\Delta R^2$	$+0{,}093\,\Delta R^2$
3	QAOA ($p = 1$)	**−30.3 % coste vs Greedy**		—
4	VQE/QAOA	Óptimo ($n \leq 6$)		—
5	SA-QUBO	Viable ($n \leq 12$)		—
6	QSVM (umbral)	**+23–30 pp** ($n \geq 100$)	+6,7 pp ($n = 50$)	—

Cuadro 6.3: Síntesis de resultados cuántico vs clásico por caso de uso y dataset. Las celdas en negrita indican ventaja cuántica demostrada.

6.7.1. Patrones transversales

Los resultados evidencian tres patrones transversales que son coherentes con el estado actual de la teoría y la tecnología cuántica:

1. **La ventaja cuántica requiere alineación estructural**: La única ventaja robusta y reproducible en datos cuántico-nativos confirma la predicción de Liu et al. (2021). En datos reales sin estructura cuántica, los algoritmos clásicos basados en árboles de decisión (Gradient Boosting, Random Forest) mantienen su superioridad por su capacidad de capturar interacciones no lineales sin restricciones de dimensionalidad.

2. **El cuello de botella es la escala**: En todos los casos, la principal limitación práctica del enfoque cuántico no es la calidad del algoritmo sino el coste cuadrático del kernel ($O(n^2)$) y el número de qubits disponibles. Esta limitación es una función del hardware actual, no del algoritmo en sí.

3. **Los resultados negativos son informativos**: Los casos donde el QSVM o el QK-SVR son inferiores a los clásicos en datos reales no son fracasos experimentales, sino resultados metodológicamente valiosos que delimitan con precisión el dominio de aplicabilidad actual de la computación cuántica en ciencia de datos.

6.7.2. Implicaciones para la adopción empresarial

Desde la perspectiva de SKG Tecnología, los resultados sugieren que la integración de algoritmos cuánticos en los sistemas de gestión de movilidad urbana requiere dos condiciones previas: (i) hardware cuántico con mayor número de qubits lógicos y menor tasa de error, para operar sobre más features sin reducción dimensional, y (ii) ingeniería de fea-

tures específica que alinee la representación de los datos con las estructuras geométricas accesibles por los kernels cuánticos. En el corto plazo (horizonte 2–5 años), el valor más realista de la computación cuántica para SKG reside en los algoritmos de optimización combinatoria (QAOA, VQE) para problemas de asignación de recursos, donde la ventaja ya es demostrable a escala moderada con el hardware actual.

7. Conclusiones

Este trabajo ha abordado una pregunta central en el estado actual de la computación cuántica aplicada: *¿en qué condiciones los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos en problemas de ciencia de datos?* Los experimentos realizados sobre seis casos de uso, evaluados sobre tres tipos de datasets cada uno, permiten extraer conclusiones concretas y matizadas.

7.1. Conclusiones principales

1. **La ventaja cuántica en clasificación es demostrable y robusta, pero condicionada a la estructura del dato.** El QSVM con kernel cuántico (ZZFeatureMap, 2 qubits) superó al mejor clasificador clásico en +38.3 puntos porcentuales sobre un dataset diseñado con estructura cuántica explícita siguiendo el marco de Liu et al. (2021). Esta ventaja es consistente a lo largo de múltiples tamaños de muestra ($n = 30$ a $n = 180$), con una media de +40.9 pp, confirmando que no es un artefacto estadístico. En datos reales (Telco Churn, incidentes de movilidad SKG), sin embargo, los clasificadores clásicos basados en Gradient Boosting son superiores en 3–5 pp.

2. **La ventaja cuántica en regresión es más limitada y específica del benchmark.** El QK-SVR solo mostró ventaja (+0.093 R^2, +979 %) sobre el dataset Friedman #1, donde los kernels clásicos estándar tienen dificultades con la no-linealidad específica del problema. En datos reales (velocidad en corredores viales de Bogotá), los regressores de árboles (Gradient Boosting, $R^2 = 0{,}660$) superan claramente al QK-SVR ($R^2 = 0{,}098$).

3. **El QAOA ofrece ventaja real en optimización combinatoria de escala moderada.** Con profundidad $p = 1$, el QAOA reduce el coste de asignación de recursos en un 30.3 % frente a la heurística Greedy, demostrando su utilidad práctica en instancias de 10–20 elementos. Esta ventaja es relevante para casos de uso empresariales como la asignación de agentes a zonas o la planificación de rutas de mantenimiento.

4. **VQE es competitivo para optimización de portafolio a pequeña escala.** VQE converge al óptimo en instancias de hasta 6 activos, con una complejidad de

circuito polinómica frente a la búsqueda exhaustiva exponencial. Para instancias mayores, la optimización cuadrática clásica sigue siendo superior en hardware simulado NISQ.

5. **El coste computacional de la simulación es el principal obstáculo práctico.** La evaluación del kernel cuántico escala como $O(n^2)$ en número de evaluaciones de circuito, lo que hace que el QSVM con 300 muestras requiera más de 2 minutos en simulación, frente a segundos de los clasificadores clásicos. Este coste no es intrínseco al algoritmo cuántico sino a la simulación en hardware clásico; en hardware cuántico real, la evaluación sería paralela y potencialmente más rápida.

6. **Los datos de SKG Tecnología confirman el comportamiento esperado en era NISQ.** Los datasets reales de movilidad urbana (incidentes y tiempos de viaje en Bogotá) no presentan la estructura cuántica necesaria para que el kernel cuántico muestre ventaja. Los mejores resultados en estos datos los obtienen Gradient Boosting y Random Forest, que capturan eficazmente los patrones temporales y geoespaciales. Esto no invalida la utilidad futura de los algoritmos cuánticos, sino que sitúa correctamente el estado de madurez actual.

7.2. Respuesta a la pregunta de investigación

La ventaja cuántica en ciencia de datos, tal como se puede demostrar hoy con hardware NISQ simulado, es **real pero condicionada**. Existe de forma garantizada cuando el problema tiene estructura cuántica explícita (Liu 2021), aparece de forma emergente en problemas de optimización combinatoria de escala moderada (QAOA), y es competitiva en regresión no lineal específica (Friedman #1). En datos empresariales reales sin estructura cuántica predefinida, los algoritmos clásicos consolidados mantienen su superioridad en el horizonte temporal actual.

La conclusión práctica para entornos empresariales como SKG Tecnología es: **los algoritmos cuánticos son hoy complementarios, no sustitutos, de los clásicos**. Su adopción estratégica tiene sentido en problemas de optimización combinatoria donde las heurísticas clásicas tienen un rendimiento limitado, y como herramienta de preparación para el momento en que el hardware cuántico tolerante a fallos esté disponible.

7.3. Aportación al campo

Este trabajo contribuye a la literatura con: (1) evidencia empírica sobre condiciones reales de ventaja cuántica usando datos empresariales propietarios; (2) una metodología de evaluación comparativa reproducible sobre tres tipos de dataset por caso de uso; y (3) un análisis de escalabilidad que caracteriza cuantitativamente el umbral de muestra a partir del cual el kernel cuántico supera a los clásicos.

8. Trabajo Futuro

Los resultados obtenidos en este trabajo abren múltiples líneas de investigación y desarrollo que no han podido abordarse en el marco temporal y de recursos del TFM. Este capítulo describe de forma detallada las limitaciones identificadas y las extensiones más prometedoras.

8.1. Ejecución en hardware cuántico real

La limitación más significativa de este trabajo es que todos los experimentos se han realizado en simulación clásica mediante el simulador de vectores de estado de Qiskit. Si bien la simulación exacta garantiza resultados sin ruido y es reproducible, no refleja las condiciones reales del hardware cuántico actual. Las siguientes extensiones son prioritarias:

- **Ejecución en IBM Quantum (procesadores Eagle/Osprey/Heron):** los notebooks están diseñados para ser ejecutados directamente en hardware real mediante el cambio del backend de simulación a un procesador IBM Quantum. El principal desafío será el ruido de decoherencia, que degradará la calidad del kernel cuántico. Se necesitará implementar técnicas de mitigación de errores (*error mitigation*) como ZNE (*Zero-Noise Extrapolation*) o técnicas de regularización del kernel (Haug et al., 2023).

- **Análisis de la degradación del rendimiento con ruido:** comparar sistemáticamente los resultados obtenidos con el simulador ideal frente al hardware ruidoso para cuantificar la reducción de ventaja cuántica debida al ruido.

- **Acceso a hardware cuántico de SKG:** si la empresa obtiene acceso a servicios de computación cuántica en la nube (IBM Quantum, Azure Quantum, Amazon Braket), sería posible ejecutar los experimentos de optimización QAOA sobre los datos reales de movilidad directamente en hardware.

8.2. Escalabilidad del kernel cuántico

El coste $O(n^2)$ de la evaluación del kernel cuántico es el principal obstáculo para su aplicación a datasets grandes. Las siguientes líneas permitirían abordar este problema:

- **Kernels cuánticos aleatorizados (RFF-QK):** aplicar la técnica de características aleatorias de Fourier (*Random Fourier Features*) adaptada al contexto cuántico (Haug et al., 2023), que permite aproximar el kernel cuántico en tiempo $O(n)$.
- **Particionado y agregación (*ensemble* cuántico):** entrenar múltiples QSVM sobre subconjuntos del dataset y combinar sus predicciones, reduciendo el tamaño efectivo del problema de kernel.
- **Caché y precómputo de kernels:** para experimentos repetitivos, el almacenamiento de las matrices de kernel evaluadas en disco permitiría reutilizar los cálculos sin necesidad de re-ejecutar las simulaciones cuánticas.

8.3. Ampliación de casos de uso en SKG Tecnología

Los datasets de SKG Tecnología utilizados en este trabajo son una fracción de la información disponible en el sistema de gestión de movilidad urbana. Las siguientes extensiones son directamente aplicables:

- **Clasificación multiclase de gravedad de incidentes:** ampliar el problema binario actual a una clasificación de tres clases (simple, con lesionado, fatal), lo que requeriría estrategias de kernel multiclase (*one-vs-rest* o *one-vs-one*).
- **Optimización de rutas de respuesta a emergencias:** formular el problema de asignación de vehículos de emergencia como un TSP con restricciones de tiempo (VRP-TW) y resolverlo con SA-QUBO, usando los datos geográficos reales de Bogotá (`bctraveltimes_geom.csv`).
- **Predicción de nivel de servicio (clasificación temporal):** usar los datos de tiempos de viaje para predecir el nivel de servicio futuro (verde/amarillo/rojo) como un problema de clasificación con features temporales, evaluando si el kernel cuántico captura patrones de congestión recurrente.

8.4. Mejora de los algoritmos variacionales

Los experimentos con VQC y QAOA utilizaron configuraciones conservadoras ($p = 1$, `reps=2`) para garantizar la ejecución en simulación. Las siguientes mejoras podrían incrementar la ventaja cuántica:

- **QAOA con mayor profundidad ($p > 1$):** estudios previos (Zhou et al., 2020) demuestran que la calidad de la solución mejora monotónamente con p. Evaluar $p \in \{2, 3, 4\}$ sobre las instancias de optimización de SKG.
- **Optimizadores avanzados:** sustituir COBYLA por optimizadores cuánticos más eficientes como SPSA (*Simultaneous Perturbation Stochastic Approximation*) o métodos de gradiente analítico (*parameter-shift rule*) para acelerar la convergencia.
- **Ansätze específicos del problema:** diseñar circuitos variacionales adaptados a la estructura del problema de optimización (por ejemplo, ansätze con simetría de permutación para problemas de asignación).

8.5. Integración en pipelines productivos

El prototipo híbrido cuántico-clásico conceptual diseñado en este trabajo requiere trabajo de ingeniería adicional para su integración real en los sistemas de SKG:

- **API de inferencia cuántica:** desarrollar un microservicio REST que encapsule el QSVM entrenado y exponga un endpoint de predicción, integrable en el pipeline de análisis de incidentes existente.
- **Monitorización de la degradación del modelo:** implementar métricas de *data drift* que detecten cuando los datos de entrada se alejan de la distribución de entrenamiento, desactivando el módulo cuántico en favor del clásico cuando la confianza es baja.
- **A/B testing cuántico-clásico:** diseñar un experimento controlado en producción que evalúe el rendimiento del QSVM frente al Gradient Boosting sobre datos reales en tiempo real.

8.6. Extensión del análisis teórico

Finalmente, desde una perspectiva académica, las siguientes extensiones teóricas complementarían los resultados empíricos:

- **Certificación de ventaja cuántica:** aplicar los tests estadísticos propuestos por Huang et al. (2021) para certificar formalmente si los datasets reales de SKG presentan la propiedad de separación cuántica-clásica necesaria para garantizar ventaja.

- **Análisis de barren plateaus:** estudiar la presencia de gradientes exponencialmente pequeños en los VQC entrenados, evaluando si las configuraciones utilizadas están afectadas por este fenómeno (Cerezo et al., 2023).

Bibliografía

Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., & Lloyd, S. (2017). *Quantum machine learning*. Nature, 549(7671), 195–202. https://doi.org/10.1038/nature23474

Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., ... Coles, P. J. (2021). *Variational quantum algorithms*. Nature Reviews Physics, 3(9), 625–644. https://doi.org/10.1038/s42254-021-00348-9

Cerezo, M., Larocca, M., García-Martín, D., Coles, P. J., Zoufal, C., & Babbush, R. (2023). *Does provable absence of barren plateaus imply classical simulability? Or, why we need to rethink variational quantum computing*. arXiv preprint arXiv:2312.09121. https://doi.org/10.48550/arXiv.2312.09121

Cortes, C., & Vapnik, V. (1995). *Support-vector networks*. Machine Learning, 20(3), 273–297. https://doi.org/10.1007/BF00994018

Deutsch, D. (1985). *Quantum theory, the Church–Turing principle and the universal quantum computer*. Proceedings of the Royal Society of London A, 400(1818), 97–117. https://doi.org/10.1098/rspa.1985.0070

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv preprint arXiv:1411.4028. https://doi.org/10.48550/arXiv.1411.4028

Fastovets, D. V., Bogdanov, Yu. I., Bantysh, B. I., & Lukichev, V. F. (2019). *Machine learning methods in quantum computing theory*. arXiv preprint arXiv:1906.10175. https://doi.org/10.48550/arXiv.1906.10175

Feynman, R. P. (1982). *Simulating physics with computers*. International Journal of Theoretical Physics, 21(6–7), 467–488. https://doi.org/10.1007/BF02650179

Grover, L. K. (1996). *A fast quantum mechanical algorithm for database search*. Proceedings of the 28th Annual ACM Symposium on Theory of Computing, 212–219. https://doi.org/10.1145/237814.237866

Haug, T., Self, C. N., & Kim, M. S. (2023). *Quantum machine learning of large datasets using randomized measurements*. Machine Learning: Science and Technology, 4(1), 015005. https://doi.org/10.1088/2632-2153/acb0b4

Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). *Power of data in quantum machine learning*. Nature Communications, 12(1), 2631. https://doi.org/10.1038/s41467-021-22539-9

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260. https://doi.org/10.1126/science.aaa8415

Lucas, A. (2014). *Ising formulations of many NP problems*. Frontiers in Physics, 2, 5. https://doi.org/10.3389/fphy.2014.00005

Nielsen, M. A., & Chuang, I. L. (2010). *Quantum computation and quantum information* (10th anniversary ed.). Cambridge University Press. https://doi.org/10.1017/CBO9780511976667

Peruzzo, A., McClean, J., Shadbolt, P., Yung, M.-H., Zhou, X.-Q., Love, P. J., ... O'Brien, J. L. (2014). *A variational eigenvalue solver on a photonic quantum processor*. Nature Communications, 5(1), 4213. https://doi.org/10.1038/ncomms5213

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79. https://doi.org/10.22331/q-2018-08-06-79

Schuld, M., & Killoran, N. (2019). *Quantum machine learning in feature Hilbert spaces*. Physical Review Letters, 122(4), 040504. https://doi.org/10.1103/PhysRevLett.122.040504

Shor, P. W. (1994). *Algorithms for quantum computation: Discrete logarithms and factoring*. Proceedings of the 35th Annual Symposium on Foundations of Computer Science, 124–134. https://doi.org/10.1109/SFCS.1994.365700

Vikstål, P., Grönkvist, M., Svensson, M., Andersson, M., Johansson, G., & Ferrini, G. (2020). *Applying the quantum approximate optimization algorithm to the tail-assignment problem*. Physical Review Applied, 14(3), 034009. https://doi.org/10.1103/PhysRevApplied.14.034009

Zhou, L., Wang, S.-T., Choi, S., Pichler, H., & Lukin, M. D. (2020). *Quantum approximate optimization algorithm: Performance, mechanism, and implementation on near-term devices.* Physical Review X, 10(2), 021067. https://doi.org/10.1103/PhysRevX.10.021067

Qiskit contributors. (2023). *Qiskit: An open-source framework for quantum computing* (Version 2.4.1). IBM Quantum. https://doi.org/10.5281/zenodo.2573505

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning.* Nature Physics, 17(9), 1013–1017. https://doi.org/10.1038/s41567-021-01287-z

Friedman, J. H. (1991). *Multivariate adaptive regression splines.* The Annals of Statistics, 19(1), 1–67. https://doi.org/10.1214/aos/1176347963

Apéndices

Pueden incluirse tantos apéndices como sean necesarios.