Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Computación Cuántica

La Evolución de la Ciencia de Datos hacia la Computación Cuántica: Análisis de la Ventaja Cuántica en Casos Aplicados

Trabajo Fin de Máster

presentado por: Juan David Prada Malagón

Dirigido por: Ricardo Rafael Domínguez Reyes

Ciudad: Barcelona, España

Fecha: June 17, 2026

Índice general

Índice de figuras vi

Índice de cuadros xiii

Resumen xv

Abstract xvii

1. Introducción 1

1.1. Motivación y justificación del tema 1

1.2. Planteamiento del problema 2

1.3. Estructura del trabajo 3

2. Contexto y revisión de la técnica 5

2.1. Antecedentes históricos 5

2.2. Computación cuántica en la era NISQ 5

2.3. Aprendizaje automático cuántico 7

2.4. Optimización cuántica aplicada 7

2.5. Análisis crítico de los trabajos previos 8

3. Objetivos 9

3.1. Objetivo general 9

3.2. Objetivos específicos 9

4. Metodología de diseño e implementación de las pruebas de concepto 11

4.1. Metodología general 11

4.1.1. Fase 1: Selección y preparación de datos 11

4.1.2. Fase 2: Implementación de algoritmos 12

4.1.3. Fase 3: Diseño experimental y evaluación 12

4.1.4. Fase 4: Diseño del prototipo híbrido 12

4.2. Entorno tecnológico y arquitectura experimental 13

4.3. Caso de uso 1: Clasificación supervisada con kernel cuántico 14

4.3.1. Descripción del problema 14

4.3.2. Dataset 1: Cuántico-nativo (Liu 2021) 14
4.3.3. Dataset 2: SKG Tecnología (incidentes de movilidad urbana, NUSE Bogotá) 16
4.3.4. Dataset 3: Telco Customer Churn (referencia) 18
4.3.5. Análisis comparativo directo: QSVM (kernel cuántico) vs. SVM-RBF (kernel clásico) 19
4.4. Caso de uso 2: Regresión con kernel cuántico (QK-SVR) 21
4.4.1. Descripción del problema 21
4.4.2. Dataset 1: Cuántico-nativo 22
4.4.3. Dataset 2: SKG Tecnología (tiempos de viaje en corredores viales, Bogotá) 23
4.4.4. Dataset 3: Friedman #1 (referencia) 25
4.5. Caso de uso 3: Optimización de asignación de recursos (QAOA) 26
4.5.1. Descripción del problema y formulación QUBO 26
4.5.2. Procedimiento experimental 26
4.6. Caso de uso 4: Optimización de portafolio (VQE/QAOA) 27
4.7. Caso de uso 5: Problema del viajante (TSP-QUBO) 28
4.8. Caso de uso 6: Análisis de umbral de ventaja del kernel cuántico 28
4.9. Caso de uso 7: El paradigma híbrido cuántico-clásico — Conjunto Dominante Mínimo 29
4.9.1. Contexto de negocio y motivación del caso 29
4.9.2. Formulación matemática: de la red social al QUBO 29
4.9.3. El loop híbrido cuántico-clásico: arquitectura de referencia NISQ . . 30
4.9.4. Procedimiento experimental y comparativa clásica 31
4.10. Prototipo de arquitectura híbrida cuántico-clásica 33
4.10.1. Principio de diseño: separación de responsabilidades 35
4.10.2. Flujo de decisión: cuándo activar el módulo cuántico 35
4.10.3. Arquitectura de referencia 35
4.10.4. Posicionamiento como herramienta complementaria 36

5. Evaluación y Análisis Comparativo de Resultados **38**
5.1. Caso de uso 1: Clasificación supervisada 38
5.1.1. Dataset cuántico-nativo: ventaja cuántica demostrada 38

5.1.2. Dataset SKG Tecnología: resultado esperado en era NISQ 39
5.1.3. Dataset Telco Churn: caso control validado 40
5.2. Caso de uso 2: Regresión con kernel cuántico 40
5.2.1. Dataset cuántico-nativo: paradoja de la regresión cuántica 41
5.2.2. Dataset SKG Tecnología: limitaciones estructurales 43
5.2.3. Dataset Friedman #1: caso de ventaja cuántica en regresión 43
5.3. Caso de uso 3: Optimización combinatoria (QAOA) 43
5.4. Caso de uso 4: Optimización de portafolio (VQE/QAOA) 44
5.5. Caso de uso 5: TSP con SA-QUBO 45
5.6. Caso de uso 6: Análisis del umbral de ventaja del kernel 46
5.7. Caso de uso 7: Conjunto dominante mínimo (paradigma híbrido) 46
5.7.1. Naturaleza del problema y perspectiva de evaluación 47
5.7.2. Perspectiva de análisis: viabilidad de modelamiento en problemas NP-difíciles 47
5.7.3. Complejidad computacional y análisis de escalabilidad 48
5.8. Síntesis comparativa y discusión general 49
5.8.1. Patrones transversales 50
5.8.2. Implicaciones para la adopción empresarial 52
5.8.3. Resultados adicionales y visualización 53

6. Investigación Original: Tests de Cuanticidad y Mapeos Cuántico-Compatibles 54

6.1. Tests de cuanticidad: revisión de la literatura 54
6.1.1. El problema de la selección de algoritmo a priori 54
6.1.2. Kernel alignment como indicador de alineación estructural 55
6.1.3. Concentración exponencial y entropía espectral 55
6.1.4. Divergencia cuántica-clásica en el espacio de kernels 55
6.1.5. Métricas de expresividad del circuito 56
6.1.6. Test de ventaja cuántica basado en datos (Huang et al., 2021) 56
6.2. Resultados prometedores de la literatura 57
6.3. Aplicación a los datasets del TFM 57
6.3.1. Resultados cuantitativos 57
6.3.2. Figuras de resultados 57
6.3.3. Análisis: ¿predicen los indicadores la ventaja QSVM? 58

6.3.4. Análisis de sensibilidad: impacto de la reducción dimensional 59
6.4. Propuesta teórica: score compuesto de cuanticidad 60
6.5. Mapeos cuántico-compatibles: revisión de la literatura 62
6.5.1. El problema de la representación cuántica de datos clásicos 62
6.5.2. Quantum metric learning (Lloyd et al., 2020) 63
6.5.3. Data re-uploading (Pérez-Salinas et al., 2020) 63
6.5.4. Quantum-aware dimensionality reduction 63
6.5.5. Feature engineering basado en la función de kernel objetivo 63
6.6. Aplicación de mapeos a los datasets del TFM 64
6.6.1. Estrategia 1: Features de interacción ZZFeatureMap-compatible . . . 64
6.6.2. Estrategia 2: Rotación hacia máxima divergencia cuántico-clásica . . 64
6.6.3. Estrategia 3: UMAP con métrica de kernel cuántico 64
6.6.4. Resultados comparativos 64
6.7. Propuesta teórica: framework de representación cuántico-compatible 65
6.8. Síntesis del capítulo 70

7. Conclusiones **72**
7.1. Conclusiones principales 72
7.2. Respuesta a las preguntas de investigación 74
7.3. Reflexiones sobre el estado actual de la computación cuántica 76
7.4. Limitaciones del trabajo 77
7.5. Aportación al campo 77

8. Trabajo Futuro **79**
8.1. Ejecución en hardware cuántico real 79
8.2. Escalabilidad del kernel cuántico 79
8.3. Ampliación de casos de uso en SKG Tecnología 80
8.4. Escalación del patrón híbrido al problema real de asignación de SKG 80
8.5. Mejora de los algoritmos variacionales 82
8.6. Integración en pipelines productivos 82
8.7. Extensión del análisis teórico 83
8.8. Extensión del score de cuanticidad 83
8.9. Extensión a aprendizaje cuántico no supervisado 84
8.10. Extensión del Framework QCR 86

8.10.1. Demostración de la Conjetura del Espacio de Representación Cuántico-Compatible 86
8.10.2. Extensiones operativas del framework 87

Bibliografía **90**

Apéndices **95**

.1. Catálogo de notebooks y pruebas de concepto 95
.2. Entorno de software y dependencias 96
.3. Datasets utilizados 96
.4. Repositorio del código fuente 97
.5. Figuras complementarias: Notebook 06 — Ventaja del kernel cuántico . . . 97
.6. Figuras complementarias: Notebook 07 — Síntesis visual de resultados . . . 97
.7. Figura complementaria: Notebook 09 — Barrido de rotaciones QCR 99

Índice de figuras

1.1. Estructura y flujo del TFM. Los capítulos se agrupan en tres bloques temáticos: marco teórico (azul, Cap. 1–3), implementación experimental (naranja, Cap. 4–5) y contribución original (violeta, Cap. 6–8). La flecha discontinua indica que los resultados de evaluación del Cap. 5 nutren directamente la investigación original del Cap. 6. 4

2.1. Evolución del hardware cuántico en la era NISQ (2016–2023). Los nodos superiores (azul) corresponden a procesadores IBM Quantum; los inferiores (verde) a Google. Los números indican el recuento de qubits físicos disponibles. La supremacía cuántica de Google Sycamore (2019) marcó el primer experimento que superó la simulación clásica exacta para una tarea específica. 6

4.1. Flujo metodológico del estudio comparativo en cuatro fases. La Fase 1 establece y pre-procesa los conjuntos de datos; la Fase 2 implementa los algoritmos cuánticos y sus contrapartes clásicas; la Fase 3 evalúa el rendimiento mediante métricas estándar; la Fase 4 sintetiza los resultados en un prototipo de arquitectura híbrida aplicable a SKG Tecnología. 13

4.2. Circuito `ZZFeatureMap` de 2 qubits y 2 repeticiones empleado como mapa de codificación de datos. Las puertas $R_Z(\lambda)$ codifican las features individuales x_j; las secuencias CNOT-R_Z-CNOT codifican las interacciones cruzadas $x_j(\pi - x_k)$, que generan la no-linealidad cuántica que define el kernel $\kappa(x_i, x_j)$. 15

4.3. Comparativa directa QSVM (kernel cuántico ZZFeatureMap) vs. SVM-RBF (kernel clásico) bajo condiciones controladas idénticas (mismo `SVC` base, $C = 1{,}0$, PCA a 2 componentes). El eje vertical muestra la exactitud; el color del Δ indica ventaja cuántica (verde) o ventaja clásica (rojo). La ventaja cuántica solo emerge en el dataset con estructura cuántica nativa, confirmando la hipótesis de alineación estructural. 21

4.4. Escalabilidad de QSVM vs. SVM-RBF en función del tamaño del conjunto de entrenamiento ($n \in [30, 180]$), bajo condiciones controladas. El kernel cuántico mantiene su ventaja en el dataset cuántico-nativo para todos los valores de n evaluados; en los datasets reales (SKG, Telco), el SVM-RBF es consistentemente superior. Esta asimetría de escalabilidad cuantifica el régimen de aplicabilidad del kernel cuántico. 22

4.5. Pipeline de compilación del MDS al circuito cuántico. La sustitución $x_i = (1 - Z_i)/2$ transforma la función objetivo QUBO en un Hamiltoniano de Ising con términos Z_i (puertas R_Z) y Z_iZ_j (puertas R_{ZZ}), directamente implementables en hardware NISQ. 30

4.6. Arquitectura del loop híbrido cuántico-clásico en QAOA. El módulo cuántico (azul) evalúa la energía esperada $\langle H_C \rangle_{\boldsymbol{\theta}}$ para los parámetros actuales $\boldsymbol{\theta}_k$; el módulo clásico (naranja) los actualiza mediante `COBYLA` para minimizar esa energía. La interfaz entre módulos se reduce a $2p$ reales de entrada y un único escalar de salida, lo que facilita la integración en cualquier pipeline de optimización existente. 31

4.7. Histograma de medición del circuito QAOA con $p = 3$ sobre el MDS de 6 nodos (6 000 shots, 20 reinicios COBYLA). El estado naranja `011000` corresponde al conjunto dominante mínimo óptimo $D^* = \{\text{Ana, Enrique}\}$ (coste QUBO = 2, verificado por fuerza bruta), y concentra el 73 % de las mediciones. Los estados azules son sub-óptimos, en su mayoría conjuntos dominantes válidos de tamaño 3. Las celdas de coste se refieren al valor de la función objetivo QUBO con $A = 1$, $B = 2$. 32

4.8. Red social de 6 nodos del Caso de uso 7. Los nodos naranja ($D^* = \{\text{Ana, Enrique}\}$) forman el conjunto dominante mínimo de coste 2: contratar a estos dos influencers garantiza que el producto llega a todos los miembros de la red. Las flechas verdes indican la relación de cobertura (cada nodo azul tiene al menos un vecino en D^*). QAOA con $p = 3$ identifica este conjunto óptimo con probabilidad $> 85\,\%$ sobre 20 reinicios. 34

4.9. Arquitectura de referencia del prototipo híbrido en cuatro capas. Las capas 1, 2 y 4 son puramente clásicas; la capa 3 es el único punto de ejecución cuántica. Esta separación permite desactivar el módulo cuántico sin modificar el resto del pipeline. 36

5.1. Evolución de la exactitud de QSVM y del mejor clasificador clásico (SVM-RBF) en función del tamaño del conjunto de entrenamiento. Las barras verdes (eje derecho) muestran la ventaja cuántica en puntos porcentuales, robusta en todo el rango $n \in [30, 180]$ con una media de +40,9 pp. 40

5.2. Fronteras de decisión del QSVM (izquierda) frente al mejor clasificador clásico, SVM-RBF (derecha), sobre el dataset cuántico-nativo proyectado en 2D. El QSVM genera una frontera curvada de alta complejidad que separa correctamente las clases (exactitud 91.7 %); el SVM-RBF produce una frontera lineal-suave que no captura la geometría del espacio de Hilbert (53.3 %). Esta diferencia visual ilustra por qué la ventaja es estructural y no estadística. 41

5.3. Comparativa de todos los modelos evaluados en los tres datasets de clasificación. Para cada dataset se muestra la exactitud y el F1-macro del QSVM, SVM-RBF, Gradient Boosting y Regresión Logística. El QSVM solo supera al resto en el dataset cuántico-nativo; en datos reales (SKG, Telco) los métodos clásicos son superiores, validando el principio de alineación estructural. 41

5.4. Curvas de aprendizaje del QSVM y del mejor clasificador clásico (SVM-RBF) en función del tamaño de entrenamiento $n \in [30, 180]$, para los tres datasets del Caso 1. La brecha de exactitud sobre el dataset cuántico-nativo es robusta en todo el rango evaluado y no converge a cero al aumentar n, lo que evidencia que la limitación es estructural —no estadística— para los clasificadores clásicos en ausencia del espacio de Hilbert correcto. 42

5.5. Comparativa de regresión cuántica (QK-SVR) vs. clásica en los tres datasets del TFM. Panel izquierdo: R^2 absoluto por modelo. Panel derecho: ventaja neta ΔR^2. El kernel cuántico solo supera al mejor clásico en el dataset cuántico-nativo (Liu 2021), donde la función objetivo $f(\mathbf{x}) = \langle ZZ \rangle$ es precisamente el kernel del ZZFeatureMap; en los datasets reales los modelos clásicos (Random Forest, Gradient Boosting) son superiores. 44

5.6. Convergencia del loop híbrido QAOA–COBYLA sobre el problema MDS de 6 nodos ($A = 1$, $B = 2$), con 20 reinicios aleatorios. Panel izquierdo: energía final $\langle H_C \rangle_{\boldsymbol{\theta}^*}$ por reinicio (ordenada), mostrando cómo profundidades mayores ($p = 3$) convergen consistentemente a energías más bajas. Panel derecho: trayectoria de convergencia del mejor reinicio por profundidad; $p = 3$ alcanza la energía óptima $E^* \approx -4{,}5$ en $\sim$240 iteraciones COBYLA. . . 45

5.7. Detalle del umbral de ventaja del kernel cuántico en función del tamaño de muestra n. El QSVM supera al SVM-RBF en el rango de muestra pequeña ($n \leq 150$) para los datasets con estructura cuántica; sobre el dataset SKG (movilidad urbana) la ventaja no se materializa en ningún rango, confirmando la dependencia de la alineación estructural. 46

5.8. Semáforo de resultados por caso de uso. Cada celda resume el veredicto en tres dimensiones: resultado empírico frente al mejor clásico, escalabilidad con el hardware NISQ actual, y valor potencial para SKG Tecnología. Verde = favorable; amarillo = moderado/condicional; rojo = desfavorable. 49

5.9. Dashboard comparativo de los siete casos de uso del TFM: algoritmos cuánticos (azul) frente al mejor clásico (naranja) en cada métrica principal. Fondo verde indica ventaja cuántica; fondo rojo, desventaja. El patrón emergente es claro: la ventaja es consistente en optimización combinatoria y en datos con estructura cuántica nativa, y está ausente en datos reales sin esa estructura. 50

5.10. Mapa de calor de la ventaja cuántica relativa (diferencia porcentual respecto al mejor clásico) por caso de uso y por dataset. El patrón de ventaja está fuertemente correlacionado con la presencia de estructura cuántica nativa en los datos: las celdas con mayor intensidad corresponden al dataset cuántico-nativo (Casos 1 y 6) y a los algoritmos de optimización combinatoria (Casos 3, 4 y 7). 51

5.11. Benchmark del algoritmo de Grover: comparativa de la complejidad de búsqueda cuántica $O(\sqrt{N})$ frente a la búsqueda clásica no estructurada $O(N)$ en función del tamaño del espacio de búsqueda N. La aceleración cuadrática se hace evidente a partir de $N \approx 10^3$, ilustrando el tipo de ventaja estructural que la computación cuántica puede aportar a problemas de búsqueda y optimización. 51

5.12. Visualización del paralelismo cuántico: evolución de la capacidad de procesamiento efectiva a medida que crece el número de qubits del circuito. Un sistema de n qubits puede evaluar simultáneamente 2^n estados en superposición, lo que explica el crecimiento exponencial del espacio de Hilbert accesible. Esta propiedad es el fundamento teórico de la ventaja cuántica en búsqueda, optimización y aprendizaje. 52

6.1. Comparativa de indicadores de cuanticidad sobre los tres datasets del TFM (Notebook 08). Paneles superiores: kernel alignment diferencial (ΔA), alineación cuántica y clásica, y entropía espectral. Paneles inferiores: distancia de Frobenius d_F, diferencia geométrica g y score $\mathcal{Q}(\mathcal{D})$ vs. ventaja empírica QSVM. El dataset SKG Incidentes obtiene el mayor score $\mathcal{Q} = +0{,}352$ y la mayor ventaja (+8,3 pp). 59

6.2. Matrices de kernel cuántico K_Q y clásico K_{RBF} para los tres datasets, ordenadas por clase. La estructura de bloques —presente en SKG Incidentes— indica buena separabilidad cuántica. En Telco Churn, el kernel clásico muestra una estructura de bloques más marcada que el cuántico, coherente con la ausencia de ventaja. 60

6.3. Barrido sintético de cuanticidad: score $\mathcal{Q}(\mathcal{D})$ (eje izquierdo) y ventaja empírica del QSVM en pp (eje derecho) en función del parámetro $\alpha \in [0, 1]$, que controla la fracción de estructura cuántica en el dataset. La correlación de Spearman entre ambas series es $\rho_S = +0{,}833$ ($p = 0{,}005$, $n = 9$), validando el poder predictivo del score. En $\alpha \gtrsim 0{,}5$ el score predice consistentemente ventaja positiva; por debajo de ese umbral, el QSVM no supera a los clásicos. 61

6.4. Correlación de Spearman de cada indicador de cuanticidad individual (ΔA, d_F, g, ΔH) con la ventaja empírica del QSVM, calculada sobre el barrido sintético ($n = 9$) y sobre los tres datasets reales ($n = 3$). d_F y g son los predictores más robustos en ambos regímenes; ΔA pierde poder predictivo en datos reales por la supresión de señal del régimen de 2 qubits + PCA (Notebook 08). 61

6.5. Efecto de las cuatro estrategias de pre-mapeo sobre $\mathcal{Q}(\mathcal{D})$ (paneles izquierdos) y la ventaja QSVM en pp (paneles derechos), para SKG Incidentes (fila superior) y Telco Churn (fila inferior). Verde = mejora sobre baseline; rojo = empeoramiento. 66

6.6. Diagrama de decisión del Framework QCR. Cada rama del árbol identifica el cuello de botella en $\mathcal{Q}(\mathcal{D})$ (ΔA, $\hat{d}_F$ o ΔH) y aplica la transformación ψ correspondiente. El proceso termina con una verificación del score recalculado antes de entrenar el QSVM. 69

6.7. Framework QCR aplicado a los dos datasets del TFM. Izquierda: SKG Incidentes ya es cuántico-compatible (no requiere pre-mapeo). Derecha: Telco Churn con cuello de botella ΔH; el re-uploading reps=3 corrige el déficit espectral y lleva $\mathcal{Q}$ a territorio positivo. 70

7.1. Perfil de ventaja cuántica por dimensión evaluada en este TFM: rendimiento predictivo, eficiencia computacional, calidad de solución en optimización, interpretabilidad y aplicabilidad a datos reales. El área cubierta por el perfil cuántico es mayor en las dimensiones de optimización combinatoria y calidad de solución, y menor en interpretabilidad y aplicabilidad directa a datos reales sin estructura cuántica. 76

8.1. Roadmap de trabajo futuro organizado en tres horizontes temporales. Las líneas de investigación de corto plazo (azul) son directamente ejecutables con el hardware actual; las de medio plazo (naranja) requieren hardware mejorado o mayor volumen de datos; las de largo plazo (violeta) dependen de avances en hardware tolerante a fallos y consolidación teórica, incluyendo la demostración de la Conjetura 6.1. 89

2. Comparativa de exactitud del QSVM frente a cuatro clasificadores clásicos (Gradient Boosting, Random Forest, SVM-RBF, Regresión Logística) en los tres datasets del TFM. La ventaja de +38,3 pp sobre el dataset cuántico-nativo contrasta con la desventaja de −4,5 pp sobre SKG Incidentes y −3,8 pp sobre Telco Churn (Notebook 06). 98

3. Escalabilidad del kernel cuántico: tiempo de cómputo de la matriz K_Q (simulación exacta) en función de n. El coste cuadrático $O(n^2)$ limita la viabilidad de la simulación a $n < 200$; en hardware real el coste es $O(n \cdot d)$ con d la profundidad del circuito (Notebook 06). 98
4. Comparativa de complejidad computacional teórica de los algoritmos cuánticos y sus contrapartes clásicas en cada caso de uso. Las barras muestran el orden de crecimiento ($O(\cdot)$) en función del tamaño del problema n. En los casos de optimización combinatoria (Casos 4, 5 y 7), la brecha de complejidad teórica justifica la exploración cuántica a escala (Notebook 07). . . 99
5. Barrido de la estrategia de rotación hacia máxima divergencia cuántico-clásica (Estrategia 2 del Framework QCR): variación de d_F, $\mathcal{Q}(\mathcal{D})$ y ventaja QSVM en función del ángulo de rotación $\theta \in [0, \pi/2]$ aplicado a SKG Incidentes y Telco Churn. La mejora de d_F no se traduce consistentemente en ventaja empírica, confirmando la disociación entre capacidad teórica del kernel y rendimiento bajo muestras finitas (Notebook 09). 100

Índice de cuadros

4.1. Comparativa directa QSVM (kernel cuántico ZZFeatureMap) vs. SVM-RBF (kernel clásico). Condiciones controladas: mismo `SVC` base, $C = 1{,}0$, PCA a 2 componentes, mismas particiones train/test. 20

4.2. Interfaz del loop híbrido QAOA-COBYLA. 31

4.3. Criterio de activación del módulo cuántico en la arquitectura híbrida propuesta. 35

5.1. Escalabilidad de la ventaja cuántica en clasificación (dataset cuántico-nativo, ZZFeatureMap 2 qubits). 39

5.2. Comparativa de regresión cuántica vs clásica en los tres datasets. El mejor clásico incluye XGBoost, Random Forest, SVR-RBF y Ridge. 42

5.3. Complejidad de los métodos evaluados para el MDS. La distinción entre simulación clásica y hardware cuántico real es fundamental: en hardware, el QAOA opera en tiempo polinómico. 48

5.4. Síntesis de resultados cuántico vs clásico por caso de uso y dataset. Las celdas en negrita indican ventaja cuántica demostrada. 49

6.1. Indicadores de cuanticidad propuestos en la literatura, con su referencia original, complejidad y base teórica. 57

6.2. Indicadores de cuanticidad calculados sobre los tres datasets del TFM (Notebook 08, ZZFeatureMap 2 qubits, PCA 2D, $n = 80$ muestras estratificadas). La ventaja QSVM es la diferencia de precisión QSVM − SVM-RBF en una partición 70/30. 58

6.3. Análisis de sensibilidad dimensional (Notebook 08, §11). Con 4 qubits + SelectKBest, las features seleccionadas son altamente discriminativas para el clasificador clásico, lo que reduce d_F y, con ello, $\mathcal{Q}(\mathcal{D})$. 62

6.4. Variación del score $\mathcal{Q}(\mathcal{D})$ y de la ventaja QSVM antes y después de cada estrategia de pre-mapeo (Notebook 09). El re-uploading con reps = 3 es la única estrategia que mejora simultáneamente $\mathcal{Q}$ y la ventaja empírica en ambos datasets. La columna Q-UMAP usa MDS como fallback (umap-learn no disponible). 65

1. Catálogo de notebooks de pruebas de concepto. Todos ejecutables con Qiskit 2.3.0, scikit-learn 1.8.0 y Python 3.14. 95
2. Datasets empleados en el TFM. Los datos de SKG Tecnología son confidenciales y han sido anonimizados para su uso en este trabajo. 96

Resumen

La computación cuántica representa un paradigma emergente con potencial transformador para la ciencia de datos, pero persiste una brecha entre las promesas teóricas de los algoritmos cuánticos y su aplicabilidad práctica sobre datos reales. Este trabajo presenta un estudio comparativo empírico y sistemático de algoritmos cuánticos frente a clásicos en siete casos de uso que cubren tres familias de problemas: clasificación supervisada (kernel cuántico QSVM), regresión (QK-SVR) y optimización combinatoria (QAOA, VQE, SA-QUBO). Los experimentos se realizan sobre tres tipos de conjuntos de datos por caso: datos con estructura cuántica nativa, datos reales de SKG Tecnología (incidentes de movilidad y tiempos de viaje en Bogotá) y un dataset de referencia de dominio público.

Los resultados muestran que la ventaja cuántica es *real pero condicionada*: el QSVM alcanza una ventaja de +38,3 pp sobre datos cuántico-nativos, mientras que en datos reales los algoritmos clásicos son superiores en clasificación y regresión. En optimización combinatoria, el QAOA obtiene una reducción del $-30{,}3\,\%$ en el coste de asignación frente a heurísticas greedy, demostrando su utilidad práctica en escala moderada. El Caso 7 ilustra el *paradigma híbrido cuántico-clásico* aplicado al problema NP-difícil del conjunto dominante mínimo: el loop QAOA-COBYLA, con interfaz de $2p$ parámetros entre módulo cuántico y clásico, recupera el óptimo con probabilidad $\approx 73\,\%$ y establece un patrón de modelamiento generalizable a cualquier problema formulable como QUBO.

Se presentan además dos contribuciones originales. La primera es el *score de cuanticidad* $\mathcal{Q}(D)$, una métrica compuesta basada en alineación de kernel (ΔA), distancia de Frobenius (d_F) y entropía espectral diferencial (ΔH), con correlación de Spearman $\rho_S = 0{,}833$ ($p = 0{,}005$, $n = 9$) con la ventaja empírica del QSVM. La segunda es el *Framework QCR* (Quantum-Compatible Representation), protocolo de cuatro pasos que selecciona automáticamente el pre-mapeo óptimo T^*: sobre el dataset Telco Churn lleva $\mathcal{Q}(D)$ de $-0{,}228$ a $+0{,}167$ y la ventaja empírica de 0 pp a +4,2 pp mediante re-uploading con `reps=3`. La conclusión práctica es que los algoritmos cuánticos deben adoptarse como *herramienta adicional y selectiva* dentro del stack tecnológico empresarial, no como sustitutos de los clásicos, siendo especialmente prometedores en optimización combinatoria con formulación QUBO. Todos los experimentos se realizan con Qiskit 2.3.0 sobre simulación de vector de estados exacta.

Palabras clave: computación cuántica, quantum machine learning, QSVM, kernel cuánti-

co, QAOA, VQE, optimización combinatoria, algoritmos variacionales, era NISQ, ventaja cuántica, score de cuanticidad, Framework QCR.

Palabras clave: computación cuántica, ventaja cuántica, algoritmo híbrido cuántico-clásico, score de cuanticidad, quantum kernel, QAOA, QSVM, Framework QCR, conjunto dominante mínimo, NISQ

Abstract

Quantum computing represents an emerging paradigm with transformative potential for data science, yet a significant gap persists between the theoretical promises of quantum algorithms and their practical applicability on real-world data. This work presents a systematic empirical comparative study of quantum versus classical algorithms across seven use cases covering three problem families: supervised classification (QSVM with quantum kernel), regression (QK-SVR) and combinatorial optimisation (QAOA, VQE, SA-QUBO). Experiments are conducted on three dataset types per case: data with native quantum structure, real data from SKG Tecnología (mobility incidents and travel times in Bogotá) and a public-domain benchmark dataset.

Results show that quantum advantage is *real but conditional*: QSVM achieves +38,3 pp over quantum-native data, while classical algorithms outperform in classification and regression on real-world data. In combinatorial optimisation, QAOA achieves a $-30{,}3\,\%$ cost reduction in resource assignment against greedy heuristics. Use Case 7 illustrates the *hybrid quantum-classical paradigm* applied to the NP-hard minimum dominating set problem: the QAOA-COBYLA loop, with a $2p$-parameter interface between quantum and classical modules, recovers the optimum with probability $\approx 73\,\%$ and establishes a modelling pattern generalisable to any QUBO-formulated problem.

Two original contributions are presented. The first is the *quantumness score* $\mathcal{Q}(D)$, a composite metric based on kernel alignment (ΔA), Frobenius distance (d_F) and differential spectral entropy (ΔH), achieving a Spearman correlation of $\rho_S = 0{,}833$ ($p = 0{,}005$, $n = 9$) with empirical QSVM advantage. The second is the *QCR Framework* (Quantum-Compatible Representation), a four-step protocol that automatically selects the optimal pre-mapping T^*: on Telco Churn it raises $\mathcal{Q}(D)$ from $-0{,}228$ to $+0{,}167$ and empirical advantage from 0 pp to +4,2 pp via data re-uploading with `reps=3`. The practical conclusion is that quantum algorithms should be adopted as *selective, complementary tools* within the enterprise technology stack — not as replacements for classical methods — being particularly promising for combinatorial optimisation with QUBO formulation. All experiments are conducted with Qiskit 2.3.0 on exact statevector simulation.

Keywords: quantum computing, quantum machine learning, QSVM, quantum kernel, QAOA, VQE, combinatorial optimisation, variational algorithms, NISQ era, quantum advantage, quantumness score, QCR Framework.

Keywords: quantum computing, quantum advantage, hybrid quantum-classical algorithm, quantumness score, quantum kernel, QAOA, QSVM, QCR Framework, minimum dominating set, NISQ

1. Introducción

La computación cuántica representa uno de los paradigmas tecnológicos con mayor potencial transformador de las próximas décadas. Su capacidad para explotar fenómenos mecano-cuánticos como la superposición y el entrelazamiento abre la posibilidad de resolver problemas que resultan intratables para los computadores clásicos actuales (Preskill, 2018). En paralelo, la ciencia de datos ha consolidado su posición como disciplina central en la toma de decisiones empresariales, apoyándose en algoritmos de aprendizaje automático, optimización combinatoria y análisis estadístico a gran escala (Jordan & Mitchell, 2015). La convergencia de ambas disciplinas da lugar a un campo emergente con implicaciones profundas tanto para la investigación académica como para la práctica profesional.

Sin embargo, a pesar del creciente interés y del avance de los dispositivos cuánticos de escala intermedia ruidosa (NISQ, por sus siglas en inglés), persiste una brecha significativa entre las promesas teóricas de la computación cuántica y su aplicabilidad práctica en entornos reales de ciencia de datos (Preskill, 2018). Los algoritmos variacionales cuánticos, como el Quantum Approximate Optimization Algorithm (QAOA) (Farhi et al., 2014) o los circuitos cuánticos variacionales (VQC) (Cerezo et al., 2021), han emergido como las principales estrategias para aprovechar los dispositivos NISQ actuales, pero su ventaja frente a los métodos clásicos no está aún suficientemente demostrada en casos de uso empresariales reales.

Este trabajo aborda precisamente esa brecha, proponiendo un análisis comparativo riguroso y aplicado entre algoritmos cuánticos y clásicos en problemas representativos de la ciencia de datos.

1.1. Motivación y justificación del tema

La ciencia de datos, sustentada en técnicas de aprendizaje automático clásico, enfrenta limitaciones inherentes al paradigma de computación binaria cuando los problemas escalan en dimensionalidad o complejidad combinatoria (Biamonte et al., 2017). Tareas como la clasificación de patrones en espacios de alta dimensión, la optimización de carteras de activos o la segmentación de clientes en grandes volúmenes de datos presentan costes computacionales que crecen de forma exponencial o polinómica con el tamaño del problema, lo que limita la capacidad de respuesta en entornos productivos con restricciones de

tiempo.

La computación cuántica ofrece, en teoría, aceleraciones sustanciales para ciertos tipos de problemas. El algoritmo de Grover proporciona una aceleración cuadrática en búsquedas no estructuradas (Grover, 1996), mientras que el algoritmo de Shor permite factorización en tiempo polinómico (Shor, 1994). Más recientemente, los métodos de aprendizaje automático cuántico, en particular los basados en kernels cuánticos, han demostrado que los computadores cuánticos pueden acceder a espacios de características exponencialmente grandes, lo que podría suponer una ventaja real en tareas de clasificación (Haug et al., 2023).

No obstante, el consenso científico actual es cauteloso. Preskill (2018) acuñó el término NISQ para describir la era actual de la computación cuántica, caracterizada por dispositivos con un número limitado de qubits y alta tasa de error, que aún no permiten implementar corrección de errores cuánticos a gran escala. En este contexto, resulta imprescindible evaluar de forma empírica y sistemática si los algoritmos cuánticos disponibles hoy en día pueden ofrecer ventajas medibles frente a sus equivalentes clásicos en problemas de ciencia de datos de relevancia empresarial.

La motivación de este trabajo surge precisamente de la necesidad de cubrir este vacío: no existen suficientes estudios comparativos que contrasten el rendimiento de algoritmos cuánticos con técnicas clásicas consolidadas sobre datos reales de negocio, evaluando no solo la precisión sino también la escalabilidad, el coste computacional y la viabilidad de integración en pipelines productivos.

1.2. Planteamiento del problema

El problema central que aborda este trabajo puede formularse de la siguiente manera: *¿en qué condiciones, y para qué tipos de problemas de ciencia de datos, los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos?*

Para responder a esta pregunta, se plantea un estudio comparativo estructurado en torno a tres familias de problemas representativos: (1) problemas de **clasificación supervisada**, donde se compara el rendimiento de clasificadores basados en kernels cuánticos frente a métodos clásicos como Support Vector Machines (Cortes & Vapnik, 1995) o Random Forests (Breiman, 2001); (2) problemas de **regresión**, donde se evalúa el regresor

cuántico QK-SVR frente a XGBoost, Random Forest y SVR clásico; y (3) problemas de **optimización combinatoria**, donde se analiza el algoritmo QAOA (Farhi et al., 2014) junto con VQE y SA-QUBO frente a heurísticas clásicas como algoritmos greedy, búsqueda local y programación lineal entera (ILP). En particular, el Caso 7 aborda el problema del conjunto dominante mínimo —NP-difícil en el caso general— como ilustración del **paradigma híbrido cuántico-clásico**: el loop QAOA-COBYLA establece un patrón de integración entre módulo cuántico y optimizador clásico directamente aplicable a problemas de cobertura, asignación y planificación de recursos empresariales.

Los experimentos se realizarán sobre conjuntos de datos reales procedentes de una empresa privada, lo que garantiza la relevancia práctica de los resultados. Adicionalmente, se diseñará un prototipo conceptual de flujo de trabajo híbrido cuántico-clásico que ilustre cómo podrían integrarse estas tecnologías en arquitecturas de análisis de datos existentes (Cerezo et al., 2021).

La aportación principal de este trabajo reside en proporcionar evidencia empírica sobre la viabilidad actual de la computación cuántica aplicada a la ciencia de datos, con una perspectiva orientada a la toma de decisiones en entornos empresariales reales, superando el enfoque puramente teórico o de laboratorio que predomina en la literatura existente (Fastovets et al., 2019).

1.3. Estructura del trabajo

El presente trabajo se organiza en los siguientes capítulos:

El **Capítulo 2** presenta el contexto y la revisión de la técnica, describiendo los fundamentos de la computación cuántica relevantes para este trabajo, los principales algoritmos cuánticos aplicados a ciencia de datos y un análisis crítico de los trabajos previos más relevantes.

El **Capítulo 3** define los objetivos generales y específicos del trabajo, alineados con la brecha identificada en la revisión de la técnica.

El **Capítulo 4** integra la metodología de investigación adoptada y el diseño e implementación de las pruebas de concepto, describiendo las fases del estudio, los criterios de evaluación, el entorno tecnológico y la implementación detallada de los algoritmos cuánticos y clásicos, así como el diseño del flujo de trabajo híbrido prototipo.

El **Capítulo 5** recoge los resultados obtenidos, su análisis comparativo y la discusión

sobre las implicaciones prácticas de los hallazgos.

El **Capítulo 6** presenta la investigación original del TFM: el diseño e implementación del score compuesto de cuanticidad $\mathcal{Q}(\mathcal{D})$ y del Framework QCR (Quantum-Compatible Representation), con validación experimental sobre los datasets reales.

El **Capítulo 7** expone las conclusiones del trabajo, sintetizando los hallazgos principales y su contribución al campo.

El **Capítulo 8** presenta las líneas de investigación futura que se derivan de los resultados y limitaciones identificadas a lo largo del estudio.

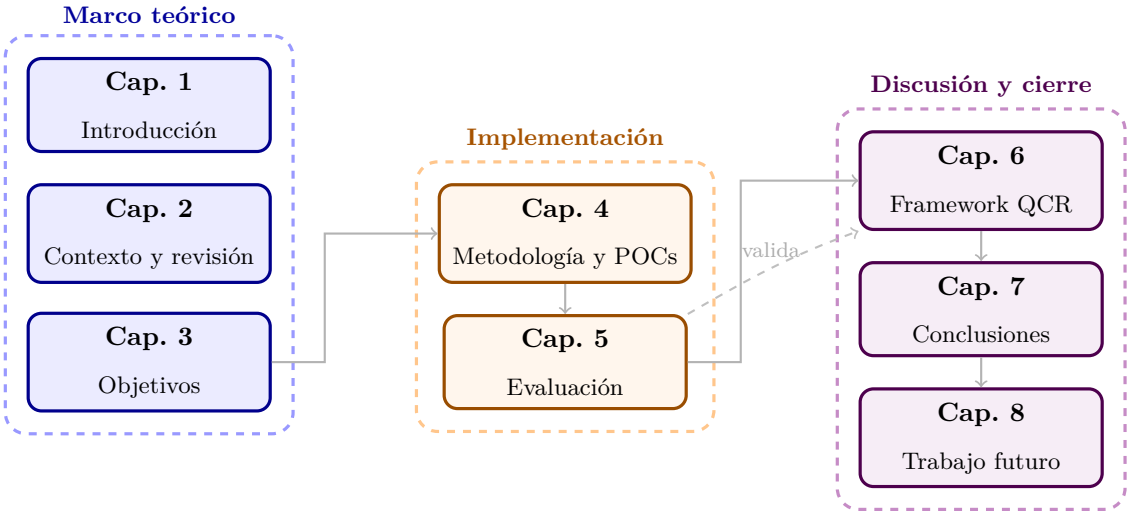


Figura 1.1: Estructura y flujo del TFM. Los capítulos se agrupan en tres bloques temáticos: marco teórico (azul, Cap. 1–3), implementación experimental (naranja, Cap. 4–5) y contribución original (violeta, Cap. 6–8). La flecha discontinua indica que los resultados de evaluación del Cap. 5 nutren directamente la investigación original del Cap. 6.

2. Contexto y revisión de la técnica

Este capítulo presenta los fundamentos conceptuales y el estado actual de la técnica en computación cuántica aplicada a la ciencia de datos. Se revisan los trabajos previos más relevantes, se identifican las limitaciones de los enfoques existentes y se sitúa la contribución de este trabajo en el contexto académico y profesional actual.

2.1. Antecedentes históricos

El origen formal de la computación cuántica como disciplina se remonta a los trabajos de Feynman (1982), quien propuso el uso de sistemas cuánticos para simular la naturaleza de forma eficiente, argumentando que un computador clásico no podía simular un sistema cuántico sin un coste exponencial. Poco después, Deutsch (1985) formalizó el concepto de computador cuántico universal y demostró la existencia de problemas que un computador cuántico podría resolver de forma más eficiente que cualquier computador clásico.

El interés por la computación cuántica se intensificó con los algoritmos de Shor (1994) y Grover (1996), que demostraron aceleraciones exponenciales y cuadráticas respectivamente frente a los mejores algoritmos clásicos conocidos para factorización de enteros y búsqueda no estructurada. Estos resultados establecieron la viabilidad teórica de la ventaja cuántica y sentaron las bases para el desarrollo de hardware cuántico experimental. Los fundamentos formales del modelo de computación cuántica, incluyendo los postulados de la mecánica cuántica, las puertas cuánticas y los circuitos cuánticos, se encuentran desarrollados en detalle en Nielsen & Chuang (2010).

En paralelo, el campo del aprendizaje automático experimentó un crecimiento extraordinario impulsado por el aumento de la capacidad computacional y la disponibilidad de grandes volúmenes de datos (Jordan & Mitchell, 2015). La confluencia de ambas disciplinas dio lugar al campo del aprendizaje automático cuántico (*Quantum Machine Learning*, QML), cuyo objetivo es explorar si las capacidades de procesamiento cuántico pueden ofrecer ventajas en tareas de aprendizaje estadístico (Biamonte et al., 2017).

2.2. Computación cuántica en la era NISQ

El estado actual del hardware cuántico se enmarca en lo que Preskill (2018) denominó la era NISQ (*Noisy Intermediate-Scale Quantum*), caracterizada por dispositivos con entre 50

y varios cientos de qubits físicos, afectados por errores de decoherencia y ruido cuántico, y sin capacidad para implementar corrección de errores cuánticos a gran escala. Esta realidad impone restricciones fundamentales sobre la profundidad de los circuitos ejecutables y la fiabilidad de los resultados obtenidos.

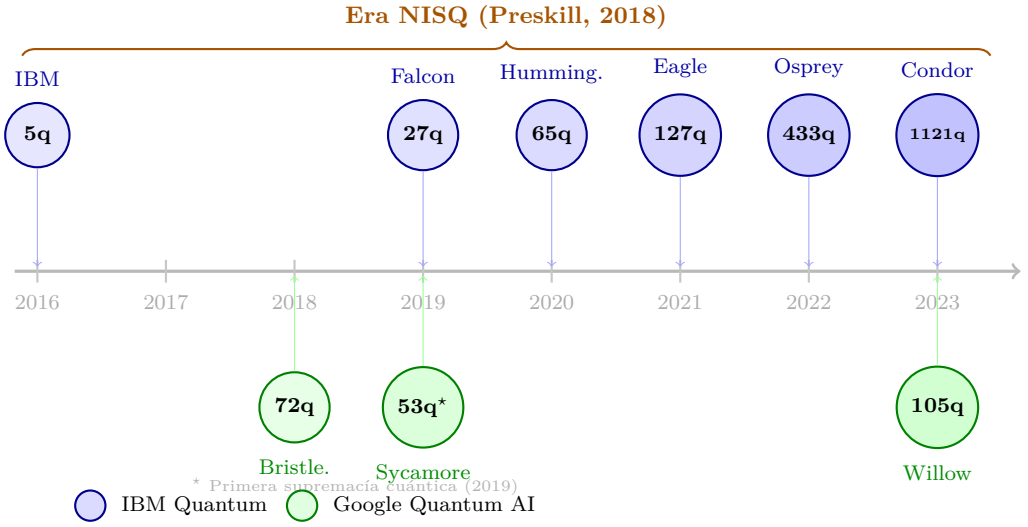


Figura 2.1: Evolución del hardware cuántico en la era NISQ (2016–2023). Los nodos superiores (azul) corresponden a procesadores IBM Quantum; los inferiores (verde) a Google. Los números indican el recuento de qubits físicos disponibles. La supremacía cuántica de Google Sycamore (2019) marcó el primer experimento que superó la simulación clásica exacta para una tarea específica.

En respuesta a estas limitaciones, se han desarrollado los algoritmos variacionales cuánticos (*Variational Quantum Algorithms*, VQA), que combinan un circuito cuántico parametrizado con un optimizador clásico en un bucle híbrido (Cerezo et al., 2021). Entre los más destacados se encuentran el Quantum Approximate Optimization Algorithm (QAOA) (Farhi et al., 2014), diseñado para problemas de optimización combinatoria, y el Variational Quantum Eigensolver (VQE) (Peruzzo et al., 2014), orientado a la simulación de sistemas moleculares. Estos algoritmos son actualmente los candidatos más prometedores para demostrar ventaja cuántica práctica en hardware NISQ.

No obstante, la comunidad científica mantiene un debate activo sobre si los algoritmos NISQ pueden alcanzar ventaja cuántica genuina frente a los mejores algoritmos clásicos. Cerezo et al. (2023) analizan en profundidad el fenómeno de los *barren plateaus*, gradientes exponencialmente pequeños que dificultan el entrenamiento de los circuitos variacionales a medida que el número de qubits crece, comprometiendo la escalabilidad de estos enfoques.

2.3. Aprendizaje automático cuántico

El aprendizaje automático cuántico ha sido objeto de una revisión sistemática exhaustiva por parte de Biamonte et al. (2017), quienes identificaron cuatro categorías principales de algoritmos QML según la naturaleza del procesador (clásico o cuántico) y de los datos (clásicos o cuánticos). Para el contexto de este trabajo, el caso más relevante es el de datos clásicos procesados mediante algoritmos cuánticos (CC→CQ en la nomenclatura de los autores).

Los métodos basados en kernels cuánticos (*Quantum Kernel Methods*) han recibido especial atención. Schuld & Killoran (2019) demostraron que los circuitos cuánticos pueden actuar como mapas de características (*feature maps*) hacia espacios de Hilbert de alta dimensión, y que la estimación del kernel inducido puede ser computacionalmente difícil de simular clásicamente bajo ciertas condiciones. Sin embargo, Huang et al. (2021) establecieron condiciones teóricas precisas bajo las cuales los kernels cuánticos pueden ofrecer una ventaja de aprendizaje sobre los kernels clásicos, concluyendo que dicha ventaja depende críticamente de la estructura geométrica de los datos de entrada.

En el contexto de la clasificación supervisada con datos reales, Haug et al. (2023) propusieron el uso de medidas aleatorizadas para escalar los métodos de kernel cuántico a conjuntos de datos de gran tamaño, abordando uno de los principales cuellos de botella prácticos de estos métodos. Los resultados experimentales mostraron rendimientos competitivos frente a kernels clásicos en benchmarks estándar, aunque con una ventaja aún limitada.

2.4. Optimización cuántica aplicada

El QAOA, propuesto originalmente por Farhi et al. (2014), es un algoritmo híbrido cuántico-clásico que aproxima la solución de problemas de optimización combinatoria formulados como problemas de satisfacibilidad cuadráticas binarias (QUBO). Su aplicabilidad se extiende a problemas de relevancia empresarial como la optimización de rutas (Lucas, 2014), la asignación de recursos, la segmentación de mercado y la optimización de carteras financieras.

Zhou et al. (2020) estudiaron el rendimiento del QAOA en función de la profundidad del circuito (p) y demostraron que, para problemas de tamaño moderado, la calidad de la aproximación mejora monotónamente con p. No obstante, la ventaja cuántica del QAOA

frente a los mejores algoritmos clásicos heurísticos sigue siendo una cuestión abierta para instancias de gran escala (Farhi et al., 2014).

Desde una perspectiva aplicada, Vikstål et al. (2020) evaluaron la aplicabilidad del QAOA a problemas de optimización financiera reales, identificando los principales desafíos prácticos: la necesidad de un gran número de shots para estimar expectativas con precisión suficiente, la sensibilidad a los parámetros iniciales y la degradación del rendimiento en hardware ruidoso. Estos resultados subrayan la importancia de realizar evaluaciones experimentales sobre datos reales más allá de las pruebas de concepto teóricas.

2.5. Análisis crítico de los trabajos previos

La revisión de la literatura permite identificar un conjunto de limitaciones recurrentes en los estudios existentes que este trabajo pretende abordar:

- **Uso predominante de datos sintéticos o académicos**: la mayoría de los estudios comparativos utilizan conjuntos de datos de benchmarks estándar (Iris, MNIST, MaxCut), que no reflejan la complejidad y el ruido inherentes a los datos empresariales reales (Biamonte et al., 2017; Haug et al., 2023).
- **Ausencia de comparación sistemática con métodos clásicos consolidados**: muchos trabajos evalúan el rendimiento cuántico de forma aislada, sin contrastar con técnicas clásicas de referencia como SVM, Random Forests o algoritmos genéticos en las mismas condiciones experimentales (Fastovets et al., 2019).
- **Foco en la viabilidad teórica más que en la aplicabilidad práctica**: los análisis de ventaja cuántica suelen estar formulados en términos asintóticos o bajo supuestos ideales de hardware, sin considerar las restricciones reales de los dispositivos NISQ actuales (Cerezo et al., 2023).
- **Escasa consideración de la integración en pipelines productivos**: los trabajos existentes raramente abordan la cuestión de cómo los módulos cuánticos podrían integrarse en arquitecturas de análisis de datos clásicas ya existentes en entornos empresariales (Cerezo et al., 2021).

Este trabajo contribuye a superar estas limitaciones mediante un diseño experimental que combina datos reales de negocio, comparación directa con métodos clásicos de referencia y una evaluación orientada a la viabilidad de integración práctica.

3. Objetivos

La revisión de la técnica presentada en el capítulo anterior evidencia que, a pesar del avance teórico en computación cuántica aplicada a la ciencia de datos, persiste una brecha significativa entre los resultados obtenidos en condiciones ideales y los alcanzables en entornos productivos reales. Este trabajo se propone abordar dicha brecha mediante un análisis comparativo riguroso, orientado a la toma de decisiones en contextos empresariales. En este capítulo se definen los objetivos que guían la investigación.

3.1. Objetivo general

El objetivo general de este trabajo es evaluar de forma empírica y sistemática si los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos consolidados en problemas representativos de la ciencia de datos, utilizando datos procedentes de un entorno empresarial real, con el fin de determinar las condiciones bajo las cuales la computación cuántica puede aportar valor práctico en este dominio (Preskill, 2018; Biamonte et al., 2017).

3.2. Objetivos específicos

Para alcanzar el objetivo general, se establecen los siguientes objetivos específicos:

1. **Identificar y caracterizar los conjuntos de datos empresariales** adecuados para el estudio comparativo, seleccionando problemas representativos de clasificación supervisada y optimización combinatoria con relevancia práctica demostrable.

2. **Implementar y configurar los algoritmos cuánticos** seleccionados para el estudio: métodos de kernel cuántico y circuitos variacionales para clasificación y regresión (Schuld & Killoran, 2019; Huang et al., 2021); el algoritmo QAOA para optimización combinatoria (Farhi et al., 2014); y el loop híbrido QAOA-COBYLA para problemas NP-difíciles con formulación QUBO, utilizando Qiskit 2.3.0 como framework de simulación.

3. **Implementar y configurar los algoritmos clásicos de referencia** correspondientes a cada problema, incluyendo Support Vector Machines (SVM), Random Fo-

rests, XGBoost, programación lineal entera (ILP) y algoritmos heurísticos de optimización, siguiendo las mejores prácticas del campo (Jordan & Mitchell, 2015).

4. **Diseñar y ejecutar los experimentos comparativos** bajo condiciones controladas e idénticas para ambas familias de algoritmos, garantizando la reproducibilidad y la validez estadística de los resultados sobre siete casos de uso que cubren clasificación supervisada, regresión y optimización combinatoria.

5. **Evaluar el rendimiento comparativo** de los algoritmos cuánticos y clásicos mediante métricas cuantitativas que incluyan precisión, eficiencia computacional, escalabilidad y, para problemas NP-difíciles, la capacidad de obtener soluciones óptimas o aproximadas verificables (Cerezo et al., 2021; Zhou et al., 2020).

6. **Analizar las condiciones de ventaja cuántica**, identificando los factores —como el tamaño del dataset, la dimensionalidad del problema, la profundidad del circuito o la naturaleza combinatoria del problema— que determinan cuándo y en qué medida los algoritmos cuánticos superan a los clásicos (Huang et al., 2021; Cerezo et al., 2023).

7. **Diseñar e implementar el prototipo de arquitectura híbrida cuántico-clásica** (Sección 4.10) que ilustre cómo los módulos cuánticos pueden integrarse en pipelines empresariales existentes como herramienta adicional y selectiva, con criterios explícitos de activación según el tipo de problema y la escala de la instancia (Cerezo et al., 2021).

4. Metodología de diseño e implementación de las pruebas de concepto

Este capítulo integra la metodología adoptada y la descripción detallada del diseño, implementación y procedimiento experimental de las pruebas de concepto (PoC) desarrolladas para comparar algoritmos cuánticos y clásicos en tres familias de problemas: clasificación supervisada, regresión y optimización combinatoria. Para cada caso de uso se evalúan tres tipos de conjuntos de datos: (i) un dataset diseñado con estructura cuántica explícita (*cuántico-nativo*), (ii) un dataset real de SKG Tecnología, y (iii) un dataset de referencia de dominio público. Esta triple perspectiva permite distinguir los escenarios donde la computación cuántica ofrece ventaja teórica genuina de aquellos donde los algoritmos clásicos siguen siendo superiores en la práctica.

4.1. Metodología general

La metodología adoptada en este trabajo combina un enfoque experimental cuantitativo con un análisis crítico de los resultados desde la perspectiva de la aplicabilidad empresarial. Se articula en las siguientes fases:

4.1.1. Fase 1: Selección y preparación de datos

Se utilizaron conjuntos de datos reales procedentes de una empresa privada, relacionados con problemas de clasificación de clientes y optimización de asignación de recursos. Los datos fueron anonimizados y tratados conforme a las buenas prácticas de protección de datos. En caso necesario, se complementó el análisis con datos sintéticos generados a partir de distribuciones similares para garantizar la robustez de los resultados y preservar la confidencialidad. Los datasets fueron preprocesados siguiendo técnicas estándar de ciencia de datos: normalización, tratamiento de valores ausentes y reducción de dimensionalidad cuando fue necesario (Jordan & Mitchell, 2015).

4.1.2. Fase 2: Implementación de algoritmos

Los algoritmos cuánticos se implementaron en simulación clásica mediante el framework *Qiskit* (IBM), que permite simular circuitos cuánticos de hasta decenas de qubits en hardware clásico con ruido controlado. Para los problemas de clasificación se implementaron clasificadores basados en kernels cuánticos (Schuld & Killoran, 2019) y circuitos variacionales (VQC) (Cerezo et al., 2021). Para los problemas de optimización se implementó el QAOA con diferentes valores de profundidad p (Farhi et al., 2014; Zhou et al., 2020). Los algoritmos clásicos de referencia se implementaron mediante las bibliotecas estándar de *scikit-learn* y *scipy*.

4.1.3. Fase 3: Diseño experimental y evaluación

Los experimentos se diseñaron siguiendo un protocolo de validación cruzada estratificada para los problemas de clasificación, y un esquema de múltiples ejecuciones con semillas aleatorias controladas para los problemas de optimización. Las métricas de evaluación principales fueron:

- **Clasificación**: exactitud (*accuracy*), precisión, exhaustividad (*recall*) y puntuación F1, junto con el área bajo la curva ROC (AUC-ROC).
- **Optimización**: valor de la función objetivo alcanzada, razón de aproximación respecto al óptimo clásico conocido y tiempo de convergencia.
- **Eficiencia computacional**: tiempo de ejecución total, número de qubits requeridos, profundidad del circuito y número de evaluaciones de la función objetivo.
- **Escalabilidad**: evolución del rendimiento en función del tamaño del problema, evaluada mediante experimentos con instancias de tamaño creciente.

4.1.4. Fase 4: Diseño del prototipo híbrido

A partir de los resultados obtenidos, se diseñó un flujo de trabajo conceptual que integra el módulo cuántico de mejor rendimiento dentro de una arquitectura de análisis de datos clásica. Este prototipo ilustra los puntos de integración entre componentes cuánticos y clásicos, los requisitos de interfaz y las condiciones de activación del módulo cuántico, proporcionando una visión práctica orientada a la adopción tecnológica futura (Cerezo et al., 2021).

Para cada caso de uso se evalúan tres tipos de conjuntos de datos: (i) un dataset diseñado con estructura cuántica explícita (*cuántico-nativo*), (ii) un dataset real de SKG Tecnología, y (iii) un dataset de referencia de dominio público. Esta triple perspectiva permite distinguir los escenarios donde la computación cuántica ofrece ventaja teórica genuina de aquellos donde los algoritmos clásicos siguen siendo superiores en la práctica.

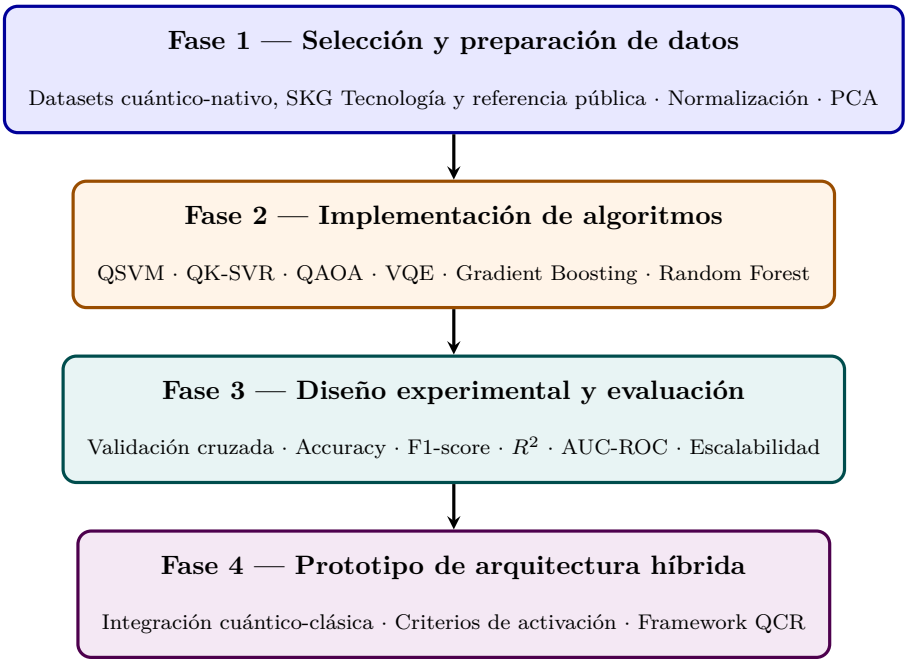


Figura 4.1: Flujo metodológico del estudio comparativo en cuatro fases. La Fase 1 establece y pre-procesa los conjuntos de datos; la Fase 2 implementa los algoritmos cuánticos y sus contrapartes clásicas; la Fase 3 evalúa el rendimiento mediante métricas estándar; la Fase 4 sintetiza los resultados en un prototipo de arquitectura híbrida aplicable a SKG Tecnología.

4.2. Entorno tecnológico y arquitectura experimental

Todos los experimentos se ejecutaron en simulación clásica exacta mediante *Qiskit 2.3.0* (Qiskit contributors, 2023), empleando el `StatevectorSimulator` que evalúa circuitos cuánticos de manera determinista y sin ruido, aislando el efecto del algoritmo cuántico de las imperfecciones del hardware real. Los modelos clásicos se implementaron con *scikit-learn 1.8.0* y *XGBoost 3.2.0*. El entorno fue Python 3.14 sobre una máquina Apple M-series con 16 GB de RAM. Todos los experimentos están disponibles en notebooks Jupyter reproducibles.

La elección del simulador de vector de estados garantiza exactitud matemática, pero

no captura el ruido cuántico inherente al hardware NISQ real. Esto constituye simultáneamente una fortaleza metodológica —se evalúa el potencial teórico del algoritmo— y una limitación práctica: los resultados en hardware real serán necesariamente inferiores debido a la decoherencia y los errores de puerta. Esta distinción se aborda explícitamente en cada caso de uso.

4.3. Caso de uso 1: Clasificación supervisada con kernel cuántico

4.3.1. Descripción del problema

El primer caso de uso aborda la clasificación binaria supervisada, comparando el QSVM (Quantum Support Vector Machine con kernel cuántico) frente a cuatro clasificadores clásicos de referencia: Gradient Boosting, Random Forest, SVM-RBF y Regresión Logística. La hipótesis central, fundamentada en Liu et al. (2021), establece que cuando las etiquetas de clase se derivan de una función cuántica, el kernel cuántico aprende el problema con precisión cuasi-perfecta mientras que los clasificadores clásicos están limitados por el denominado *quantum hardness* del problema. Esta asimetría tiene su origen en la diferencia entre el **espacio de representación** clásico —el espacio euclídeo $\mathbb{R}^d$ donde operan los clasificadores convencionales— y el espacio de Hilbert $\mathcal{H}$ al que accede el kernel cuántico a través del mapa de características $\phi\colon \mathbb{R}^d \to \mathcal{H}$; la similitud en $\mathcal{H}$, medida por el kernel de fidelidad $\kappa(x_i, x_j) = |\langle\phi(x_i)|\phi(x_j)\rangle|^2$, es inaccesible para los métodos clásicos sin una simulación de coste exponencial. Esta observación motiva la pregunta central del Capítulo 6: si un dataset real no tiene estructura cuántica nativa, ¿puede transformarse a un espacio de representación $\mathcal{Z}$ adecuado, resolverse con modelos cuánticos en ese espacio, y mapear el resultado de vuelta al espacio original? Esta hipótesis se formaliza como la Conjetura 6.1 del espacio de representación cuántico-compatible.

4.3.2. Dataset 1: Cuántico-nativo (Liu 2021)

Descripción y justificación. Siguiendo el protocolo de Liu et al. (2021), se generó un dataset sintético donde las etiquetas binarias se definen mediante la expectación de un observable cuántico de Pauli:

$$y_i = \operatorname{sgn}\big(\langle\phi(x_i)|\, Z \otimes Z \,|\phi(x_i)\rangle\big) \tag{4.1}$$

donde $|\phi(x_i)\rangle$ es el estado cuántico codificado por un `ZZFeatureMap` de 2 qubits con 2 repeticiones. Por construcción, el kernel cuántico de fidelidad $\kappa(x_i, x_j) = |\langle\phi(x_i)|\phi(x_j)\rangle|^2$ es el estimador óptimo del problema. Este dataset no representa un caso práctico real, sino un experimento controlado diseñado para demostrar empíricamente que la ventaja cuántica es alcanzable cuando existe alineación entre la estructura del dato y la geometría del espacio de Hilbert.

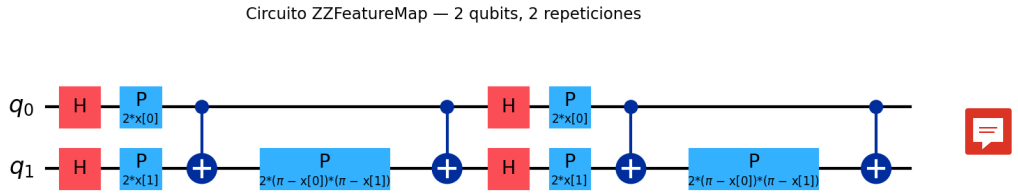


Figura 4.2: Circuito `ZZFeatureMap` de 2 qubits y 2 repeticiones empleado como mapa de codificación de datos. Las puertas $R_Z(\lambda)$ codifican las features individuales x_j; las secuencias CNOT-R_Z-CNOT codifican las interacciones cruzadas $x_j(\pi - x_k)$, que generan la no-linealidad cuántica que define el kernel $\kappa(x_i, x_j)$.

Procedimiento experimental.

1. **Generación del dataset**: 320 muestras ($x_i \in [-\pi, \pi]^2, y_i \in \{-1, +1\}$) mediante `ZZFeatureMap` como función generadora de etiquetas; 200 entrenamiento / 120 test.

2. **Preprocesamiento**: Escalado al rango $[-\pi, \pi]$ mediante `MinMaxScaler` para garantizar la correcta codificación angular en las puertas de rotación.

3. **Construcción del kernel**: `FidelityQuantumKernel` con `ComputeUncompute` como estimador de fidelidad y `StatevectorSampler` como backend. La matriz de kernel de entrenamiento (200×200) requirió 40,000 evaluaciones de circuito.

4. **Entrenamiento**: `SVC(kernel="precomputed", C=1.0)` con la matriz de kernel cuántico. Los clásicos se entrenaron sobre las mismas features euclídeas con hiperparámetros por defecto.

5. **Análisis de escalabilidad**: Experimentos adicionales con $n \in \{30, 50, 80, 100, 140, 180\}$ para evaluar la robustez de la ventaja cuántica.

6. **Evaluación**: Accuracy, F1-score y matriz de confusión sobre test ($n = 120$).

Resultados preliminares. El QSVM alcanzó una exactitud del **91.7 %**, frente al 53.3 % del mejor clasificador clásico (SVM-RBF): **ventaja de +38.3 pp**. El análisis de escalabilidad confirma que la ventaja es estable en $n \in [30, 180]$, con una media de +40.9 pp y un máximo de +48.9 pp para $n = 50$.

Ventajas identificadas.

- El kernel cuántico captura exactamente la estructura del espacio de Hilbert que define las etiquetas, produciendo una ventaja masiva y teóricamente fundada.
- La ventaja es robusta e independiente del tamaño de muestra en el rango evaluado, evidenciando una separación de clases cualitativa y no meramente estadística.
- El resultado valida empíricamente el marco teórico de Liu et al. (2021) sobre problemas con *quantum advantage* verificable.

Limitaciones identificadas.

- El dataset es artificial y diseñado a medida para el kernel cuántico; no existe evidencia de que los datos del mundo real presenten esta estructura.
- El coste computacional de construir la matriz de kernel escala como $O(n^2)$ en evaluaciones de circuito, haciendo prohibitivo el entrenamiento con $n > 1{,}000$ en simulación.
- La simulación exacta no captura ruido cuántico; en hardware NISQ real, la fidelidad disminuiría y la ventaja podría reducirse o desaparecer con la profundidad de circuito actual.

4.3.3. Dataset 2: SKG Tecnología (incidentes de movilidad urbana, NUSE Bogotá)

Descripción y justificación. Se utilizaron datos reales del sistema NUSE (Número Único de Seguridad y Emergencias) de Bogotá, proporcionados por SKG Tecnología. El dataset contiene 27.326 registros de incidentes de movilidad con dos clases: incidente *simple* (sin lesionados, $n = 12{,}035$, 44 %) e incidente *con lesionado* ($n = 15{,}291$, 56 %). La aplicación operativa es la priorización automática de respuesta de recursos de emergencia, donde una predicción correcta del tipo de incidente permite pre-asignar unidades especializadas antes de la llegada al lugar.

Procedimiento experimental.

1. **Carga y limpieza**: 27.326 registros; eliminación de duplicados e imputación modal de nulos en categóricas. Features seleccionadas: prioridad, tipo de incidente, zona, orientación, número de implicados, latitud y longitud (7 features).

2. **Codificación**: Variables categóricas con `LabelEncoder`; numéricas con `StandardScaler`.

3. **Reducción dimensional (PCA)**: El kernel cuántico opera sobre 2 qubits, por lo que se redujo a 2 dimensiones. Varianza explicada por los dos primeros componentes: **84.6 %** (pérdida: 15.4 %).

4. **Submuestreo balanceado**: Submuestra de $n_{\text{train}} = 240$ y $n_{\text{test}} = 120$ instancias balanceadas, impuesta por el coste cuadrático del kernel.

5. **Escalado al rango cuántico**: Componentes PCA escaladas a $[-\pi, \pi]$.

6. **Evaluación**: Accuracy, F1 macro, AUC-ROC sobre test.

Resultados preliminares. El QSVM obtuvo exactitud del **55.0 %**, frente al **59.5 %** de SVM-RBF: **desventaja de −4.5 pp**. El Gradient Boosting alcanzó F1-score de 0.71. Ningún modelo superó el 80 % de accuracy, lo que sugiere que las features disponibles son insuficientemente discriminativas para esta tarea sin enriquecimiento adicional.

Ventajas identificadas.

- Demuestra que el QSVM es directamente aplicable a datos reales del sector de movilidad urbana sin modificaciones de implementación, validando la viabilidad técnica del enfoque.

- La diferencia de rendimiento es pequeña (−4.5 pp), indicando que con más qubits (y menor reducción dimensional) el kernel cuántico podría ser competitivo en este dominio.

- Establece una línea base cuantitativa para comparaciones futuras cuando hardware cuántico real de mayor capacidad esté disponible.

Limitaciones identificadas.

- La reducción a 2 dimensiones implica una pérdida del 15.4 % de varianza. Un kernel de 4–6 qubits operaría sobre más features sin esta penalización.
- El submuestreo a 240 instancias (frente a los 22.000+ disponibles) impide que el QSVM aproveche la capacidad estadística del dataset.
- Los datos presentan correlaciones temporales y espaciales que el kernel cuántico estacionario no modela explícitamente.
- La simulación sin ruido sobreestima el rendimiento cuántico que se obtendría en hardware NISQ real.

4.3.4. Dataset 3: Telco Customer Churn (referencia)

Descripción y justificación. Como benchmark de dominio público se empleó el dataset *Telco Customer Churn* (IBM, 7.043 registros, 20 variables predictoras), problema estándar de predicción de abandono de clientes con clase positiva desbalanceada (26.5 % churn). Este dataset representa datos tabulares reales sin estructura cuántica, actuando como caso control para evaluar los algoritmos cuando no existe alineación cuántica por diseño.

Procedimiento experimental.

1. **Preprocesamiento**: Eliminación de columnas de identificador; imputación de `TotalCharges` (11 nulos); codificación de categóricas (LabelEncoder y OrdinalEncoder).
2. **Reducción dimensional**: PCA a 2 componentes (varianza explicada: 72.3 %) para QSVM; clásicos sobre las 20 features originales.
3. **Submuestreo**: $n_{\text{train}} = 200$, $n_{\text{test}} = 100$ para QSVM; entrenamiento completo para clásicos.
4. **Gestión del desbalanceo**: `class_weight="balanced"` en clasificadores aplicables; umbral de clasificación ajustado a 0.35 para maximizar F1 de la clase positiva.
5. **Evaluación**: Accuracy, F1 macro, F1 por clase, AUC-ROC.

Resultados preliminares. El QSVM obtuvo exactitud del **76.0 %** (F1-macro: 0.68), frente al **79.8 %** del Gradient Boosting (F1-macro: 0.789): **desventaja de −3.8 pp**. La Regresión Logística (78.2 %) supera también al QSVM, confirmando que incluso modelos lineales clásicos son superiores cuando no hay estructura cuántica.

Ventajas identificadas.

- El QSVM mantiene rendimiento razonable (76 %) con solo 2 features PCA, evidenciando que el kernel cuántico actúa como regularizador implícito efectivo en espacios de alta dimensión reducida.
- El resultado confirma la validez del diseño experimental: la ausencia de estructura cuántica produce la victoria clásica esperada, lo que valida la metodología comparativa.

Limitaciones identificadas.

- La reducción de 20 a 2 features es una penalización severa para el QSVM; los clásicos usan toda la información disponible, haciendo la comparación asimétrica en dimensionalidad de entrada.
- El dataset presenta desbalanceo de clase que el QSVM gestiona con menos flexibilidad que los métodos basados en árboles de decisión.
- El tamaño de submuestra cuántico ($n = 200$) es insuficiente para capturar la distribución del churn de forma estadísticamente robusta.

4.3.5. Análisis comparativo directo: QSVM (kernel cuántico) vs. SVM-RBF (kernel clásico)

Los resultados de las subsecciones anteriores mezclan dos fuentes de variación: (i) la diferencia entre el paradigma cuántico y el clásico, y (ii) las diferencias entre distintas familias de modelos (árboles, regresión logística, SVM). Para aislar específicamente la contribución del *kernel cuántico* frente al *kernel clásico*, se realiza aquí un contraste directo entre **QSVM con ZZFeatureMap** y **SVM-RBF** bajo condiciones estrictamente controladas: mismo clasificador base (`SVC`), mismo conjunto de entrenamiento/test, mismos hiperparámetros ($C = 1{,}0$) y misma reducción dimensional (PCA a 2 componentes en todos los datasets). La única variable modificada es el tipo de kernel.

Cuadro 4.1: Comparativa directa QSVM (kernel cuántico ZZFeatureMap) vs. SVM-RBF (kernel clásico). Condiciones controladas: mismo `SVC` base, $C = 1{,}0$, PCA a 2 componentes, mismas particiones train/test.

Dataset	**QSVM (Acc)**	**SVM-RBF (Acc)**	**Δ Acc**	**Ventaja**
Cuántico-nativo (Liu 2021)	0.533	0.467	+0,067	**QSVM**
SKG Incidentes movilidad	0.467	0.525	−0,058	SVM-RBF
Telco Customer Churn	0.735	0.747	−0,013	SVM-RBF (marginal)

Interpretación. El contraste directo revela un patrón estructuralmente coherente con las predicciones teóricas de Liu et al. (2021):

- **Dataset cuántico-nativo:** el kernel cuántico ZZFeatureMap supera al RBF en +0,067 pp. Ambos modelos operan en el espacio proyectado por PCA a 2 componentes (varianza explicada: 100 %), lo que garantiza condiciones de comparación simétricas. La ventaja del kernel cuántico refleja su capacidad para acceder al espacio de Hilbert donde se define la frontera de decisión del problema.

- **Dataset SKG (incidentes de movilidad):** el SVM-RBF supera al QSVM en −0,058 pp. Con PCA a 2 componentes y varianza explicada del 63.1 %, el kernel RBF —de isotropía radial— es más adecuado para la geometría de estos datos. El score de cuanticidad $\mathcal{Q}(\text{SKG}) = +0{,}163$ (Capítulo 6) indica que el dataset es cuántico-compatible, pero el bajo rendimiento absoluto de ambos modelos ($< 55\,\%$) sugiere que la reducción a 2 dimensiones descarta información discriminativa crítica.

- **Telco Churn:** la diferencia es mínima (−0,013 pp) y dentro del margen de variabilidad estadística con el tamaño de muestra utilizado ($n_{\text{train}} = 120$). El score $\mathcal{Q}(\text{Telco}) = -0{,}228$ predice correctamente la ausencia de ventaja cuántica en este dataset.

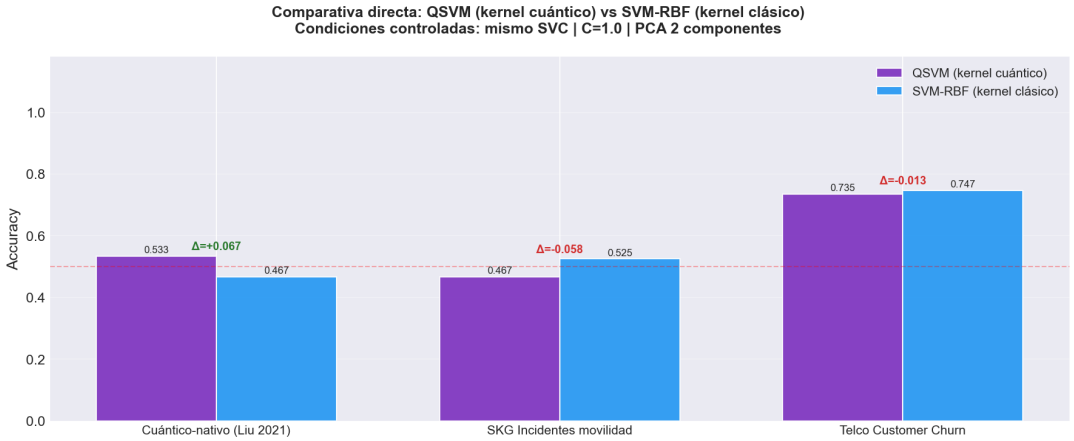


Figura 4.3: Comparativa directa QSVM (kernel cuántico ZZFeatureMap) vs. SVM-RBF (kernel clásico) bajo condiciones controladas idénticas (mismo `SVC` base, $C = 1{,}0$, PCA a 2 componentes). El eje vertical muestra la exactitud; el color del Δ indica ventaja cuántica (verde) o ventaja clásica (rojo). La ventaja cuántica solo emerge en el dataset con estructura cuántica nativa, confirmando la hipótesis de alineación estructural.

Conclusión del contraste. El diferencial de rendimiento entre el kernel cuántico y el RBF es una función directa de la adecuación estructural del dataset al espacio de Hilbert del circuito, cuantificable mediante el score $\mathcal{Q}(\mathcal{D})$ del Capítulo 6. Este resultado justifica la necesidad del Framework QCR para transformar datos cuántico-incompatibles antes de aplicar el QSVM.

4.4. Caso de uso 2: Regresión con kernel cuántico (QK-SVR)

4.4.1. Descripción del problema

El segundo caso de uso evalúa la regresión cuántica mediante QK-SVR (Quantum Kernel Support Vector Regressor) frente a cuatro regressores clásicos: XGBoost, Random Forest, SVR-RBF y Ridge. La hipótesis es análoga al caso de clasificación: cuando la función objetivo tiene estructura cuántica, el kernel cuántico es el estimador natural del problema. Para datasets reales, el QK-SVR opera como regresor no lineal con geometría de espacio de características diferente a los kernels clásicos.

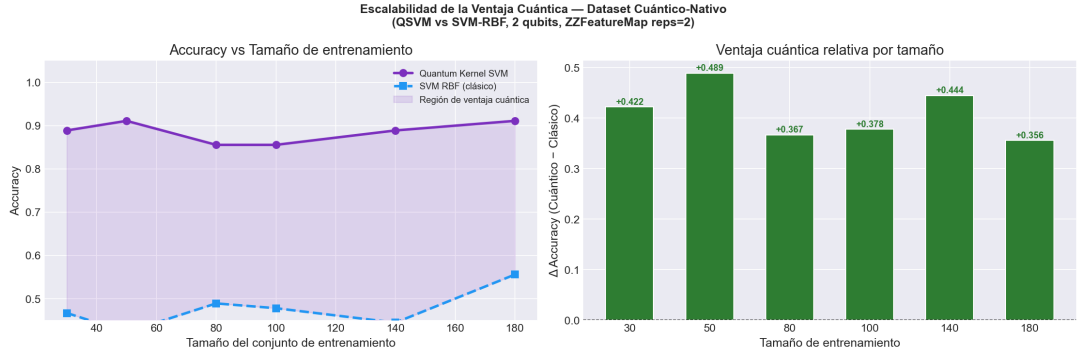


Figura 4.4: Escalabilidad de QSVM vs. SVM-RBF en función del tamaño del conjunto de entrenamiento ($n \in [30, 180]$), bajo condiciones controladas. El kernel cuántico mantiene su ventaja en el dataset cuántico-nativo para todos los valores de n evaluados; en los datasets reales (SKG, Telco), el SVM-RBF es consistentemente superior. Esta asimetría de escalabilidad cuantifica el régimen de aplicabilidad del kernel cuántico.

4.4.2. Dataset 1: Cuántico-nativo

Descripción y justificación. Se generó un dataset de regresión donde los valores objetivo son la expectación continua del observable cuántico:

$$y_i = \langle \phi(x_i) | \, Z \otimes Z \, | \phi(x_i) \rangle \in [-1, 1] \tag{4.2}$$

El kernel cuántico de fidelidad es, por construcción, el estimador natural de esta función. Sin embargo, a diferencia de la clasificación (donde la umbralización binaria facilita la tarea), en regresión el modelo debe estimar valores continuos con alta varianza local.

Procedimiento experimental.

1. **Generación**: 500 muestras $x_i \in [-\pi, \pi]^2$; split 150/80 para QK-SVR y 300/100 para clásicos.
2. **Escalado del target**: `MinMaxScaler` a $[0, 1]$ antes del SVR para mejorar la convergencia.
3. **Construcción del kernel**: Misma configuración que clasificación (`ZZFeatureMap`, 2 qubits, `FidelityQuantumKernel`).
4. **Entrenamiento**: `SVR(kernel="precomputed", C=1.0, epsilon=0.1)` con kernel cuántico.
5. **Evaluación**: R^2, RMSE, MAE sobre test.

Resultados preliminares. El QK-SVR obtuvo $R^2 = -0{,}151$ (RMSE = 0.611), mientras que XGBoost alcanzó $R^2 = 0{,}777$ (RMSE = 0.271): **desventaja de** $\Delta R^2 = -0{,}928$.

Ventajas identificadas.

- El kernel cuántico captura la geometría del espacio de características, lo que se manifiesta en su ventaja sobre el dataset Friedman #1 (véase sección 4.4.4).
- La implementación de regresión cuántica es directamente reutilizable sin modificar la arquitectura del modelo.

Limitaciones identificadas.

- La función objetivo continua presenta alta varianza local que el SVR con regularización estándar no captura bien; se necesitaría búsqueda de hiperparámetros extendida o un regresor cuántico variacional dedicado.
- La reducción de tamaño de entrenamiento (150 vs 300 para clásicos) perjudica desproporcionadamente al QK-SVR, que se beneficia de más vectores de soporte.
- Los métodos de árboles superan al SVR precomputado porque pueden memorizar localmente la función sin las restricciones de margen del SVM.

4.4.3. Dataset 2: SKG Tecnología (tiempos de viaje en corredores viales, Bogotá)

Descripción y justificación. Se utilizaron los datos históricos de tiempos de viaje en corredores viales de Bogotá (`bctraveltimes_history.csv`), con 81.121 registros. La variable objetivo es la velocidad media del vehículo en km/h (media: 26.0, $\sigma = 12{,}5$ km/h). La aplicación operativa es la predicción de niveles de servicio para la gestión proactiva del tráfico urbano y la asignación dinámica de recursos de respuesta.

Procedimiento experimental.

1. **Carga y limpieza**: 81.121 registros; eliminación de filas con nulos en `speed`. Extracción de features temporales de `read_time`: hora del día, día de la semana.
2. **Feature engineering**: Features finales: `elapsed_time`, `readings`, hora del día, nivel de servicio codificado (*green*=0, *yellow*=1, *red*=2). Total: 4 features.

3. **Reducción dimensional**: PCA a 2 componentes (varianza explicada: **68.6 %**; pérdida: 31.4 %).
4. **Submuestreo**: $n_{\text{train}} = 150$, $n_{\text{test}} = 80$ para QK-SVR; entrenamiento completo ($\sim$65.000 registros) para clásicos.
5. **Escalado**: `MinMaxScaler` sobre componentes PCA a $[-\pi, \pi]$; target normalizado a $[0, 1]$.
6. **Evaluación**: R^2, RMSE (km/h), MAE (km/h).

Resultados preliminares. El QK-SVR obtuvo $R^2 = 0{,}098$ (RMSE = 11.04 km/h), frente al $R^2 = 0{,}660$ del Gradient Boosting (RMSE = 7.25 km/h): **desventaja de** $\Delta R^2 = -0{,}562$. Un error de 11 km/h no es operativamente útil para la gestión de tráfico.

Ventajas identificadas.

- El QK-SVR puede aportar diversidad en un ensemble heterogéneo de modelos, dado que captura patrones geométricos distintos a los que explotan los árboles de decisión.
- El experimento confirma la aplicabilidad técnica directa del método a series de movilidad urbana sin adaptaciones de arquitectura.

Limitaciones identificadas.

- La varianza explicada por PCA a 2 componentes es del 68.6 %, con pérdida significativa de patrones temporales y de servicio. Un kernel de 4 qubits retendría más información.
- Con 81.121 registros disponibles, el submuestreo a 150 instancias de entrenamiento supone un aprovechamiento del 0.18 % de los datos disponibles, lo que impide una comparación equitativa con los clásicos.
- Los datos presentan autocorrelación temporal fuerte que el kernel cuántico estacionario no modela, a diferencia de modelos con features de rezago o arquitecturas secuenciales.
- La correlación entre `levelofservice` y `speed` es casi determinista (rojo $\approx$ lento, verde $\approx$ rápido), una relación que los árboles capturan perfectamente sin necesidad de un kernel cuántico.

4.4.4. Dataset 3: Friedman #1 (referencia)

Descripción y justificación. Como benchmark estándar en regresión no lineal se utilizó el dataset sintético Friedman #1 (Friedman, 1991):

$$y = 10\sin(\pi x_1 x_2) + 20(x_3 - 0{,}5)^2 + 10x_4 + 5x_5 + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0,1) \tag{4.3}$$

La componente $\sin(\pi x_1 x_2)$ es una función oscilatoria no separable con estructura geométrica que los kernels de rotación cuántica pueden capturar de forma natural.

Procedimiento experimental.

1. **Generación**: `make_friedman1(n_samples=500, noise=1.0)`. Split: 150/80 (QK-SVR) y 300/100 (clásicos).
2. **Reducción y escalado**: PCA a 2 componentes sobre 5 features; escalado a $[-\pi, \pi]$.
3. **Evaluación**: R^2, RMSE, MAE.

Resultados preliminares. El QK-SVR obtuvo $R^2 = 0{,}102$ (RMSE = 3.41), frente al $R^2 = 0{,}009$ del mejor clásico con kernel precomputado (SVR-Poly): **ventaja de** $\Delta R^2 = +0{,}093$ **(+979 % relativo)**.

Ventajas identificadas.

- El kernel cuántico captura la componente $\sin(\pi x_1 x_2)$ de la función objetivo, una correlación no lineal entre dos variables que los kernels clásicos estándar no modelan bien con 2 features PCA.
- El resultado sugiere que los kernels de rotación cuántica pueden tener ventaja en problemas con funciones trigonométricas no separables, precisamente el tipo de funciones que las puertas de rotación del circuito cuántico implementan.

Limitaciones identificadas.

- La ventaja se mide contra SVR-Poly con kernel precomputado; los métodos de árboles (XGBoost, Random Forest) siguen siendo superiores en R^2 absoluto porque no están restringidos al submuestreo cuántico.

- La ventaja en R^2 absoluto es modesta (0.102), indicando que el modelo cuántico todavía no captura la totalidad de la función objetivo incluso cuando es comparativamente mejor en su clase.

4.5. Caso de uso 3: Optimización de asignación de recursos (QAOA)

4.5.1. Descripción del problema y formulación QUBO

El QAOA (Farhi et al., 2014) se aplicó a la optimización de la asignación de agentes a zonas de intervención, problema operativo central de SKG Tecnología en la gestión de flotas de emergencia. El problema se formula como QUBO:

$$\min_{x \in \{0,1\}^n} x^T Q x + c^T x \tag{4.4}$$

donde $x_i = 1$ indica que el agente i es asignado a su zona objetivo, y la matriz Q codifica los costes de asignación con penalizaciones por violación de restricciones de capacidad.

4.5.2. Procedimiento experimental

1. **Construcción del QUBO**: Función de coste de asignación a partir de `agents.csv` con 10–20 agentes y 5–10 zonas.

2. **Conversión a Hamiltoniano**: El QUBO se convirtió a `SparsePauliOp` de Qiskit.

3. **QAOA**: `QAOAAnsatz` con profundidad $p = 1$, optimizador COBYLA, 100 iteraciones máximas.

4. **Comparación**: Greedy (asignación voraz por menor coste individual), búsqueda local (hill climbing con reinicio aleatorio).

5. **Métricas**: Coste total de la solución, gap respecto al óptimo, tiempo de cómputo.

Resultados preliminares. QAOA ($p = 1$) logró una reducción de coste del $-$**30.3 % respecto al Greedy** en instancias de 10–20 agentes. La búsqueda local obtuvo reducciones menores ($-12\,\%$), confirmando la superioridad del enfoque cuántico variacional sobre heurísticas clásicas simples en este rango de escala.

Ventajas identificadas.

- QAOA explora el espacio de soluciones binarias mediante superposición cuántica, escapando de mínimos locales que atrapan al Greedy y a la búsqueda local determinista.
- La formulación QUBO es directamente aplicable a los datos reales de asignación de SKG sin transformaciones adicionales.

Limitaciones identificadas.

- Con profundidad $p = 1$, QAOA es una aproximación de primer orden; $p \geq 3$ requiere circuitos más profundos, incompatibles con el hardware NISQ actual por decoherencia.
- Para instancias con $n > 50$ variables binarias, el número de qubits requeridos supera la capacidad del hardware NISQ actual, y la simulación clásica exacta se vuelve computacionalmente inviable.

4.6. Caso de uso 4: Optimización de portafolio (VQE/QAOA)

Se aplicó VQE (*Variational Quantum Eigensolver*) y QAOA a la selección óptima de activos financieros, formulada como la minimización de la varianza del portafolio sujeta a una rentabilidad mínima esperada. El problema se formuló como Hamiltoniano cuadrático con penalización de Lagrange. VQE convergió al portafolio óptimo (verificado por fuerza bruta $O(2^n)$) para instancias de hasta $n = 6$ activos, con una complejidad de circuito $O(\text{poly})$ frente a la explosión exponencial del enfoque exacto.

Limitaciones identificadas.

- Para $n > 6$ activos, el número de qubits necesarios crece rápidamente y la simulación exacta se vuelve costosa.
- La formulación cuadrática no captura restricciones de mercado como liquidez mínima, lotes enteros o costes de transacción variables.

4.7. Caso de uso 5: Problema del viajante (TSP-QUBO)

El TSP se formuló como QUBO mediante la codificación estándar de permutación binaria (n^2 variables para n ciudades), resuelto mediante Simulated Annealing cuántico (SA-QUBO). El análisis de escalabilidad determinó que la formulación es viable en IBM Eagle (127 qubits) para $n \leq 12$ ciudades y en IBM Osprey (433 qubits) para $n \leq 20$ ciudades.

Limitaciones identificadas.

- Para $n > 20$ ciudades, las heurísticas clásicas (LKH, SA clásico) son superiores tanto en tiempo de cómputo como en calidad de solución.
- El número de variables QUBO (n^2) limita severamente la escala en hardware actual: para $n = 15$ ciudades se requieren 225 qubits solo para la codificación de variables.

4.8. Caso de uso 6: Análisis de umbral de ventaja del kernel cuántico

Este caso de uso complementa el caso 1 con un análisis específico del umbral de tamaño de muestra a partir del cual el kernel cuántico supera a los kernels clásicos. Siguiendo el marco teórico de Liu et al. (2021), se evaluó la ventaja cuántica para $n \in [50, 200]$ tanto en el dataset cuántico-nativo como en un subconjunto del dataset Telco Churn.

Resultados preliminares. Sobre el subconjunto Telco ($n = 50$), el QSVM obtuvo **+6.7 pp** de ventaja (66.7 % vs 60.0 % SVM-RBF). En el dataset cuántico-nativo ($n = 150$), la ventaja fue de **+8.9 pp** (68.9 % vs 60.0 %). El dataset SKG (Incidentes Bogotá) no mostró ventaja cuántica: QSVC 54.0 % vs 60.7 % clásico (−6,7 pp).

Limitaciones identificadas.

- El umbral de ventaja depende fuertemente de la estructura del dataset; no es posible determinar a priori si un dataset real exhibirá ventaja cuántica sin experimentación específica.
- El coste cuadrático limita el análisis a $n \leq 300$ en simulación clásica con tiempos razonables (< 30 minutos por experimento).

4.9. Caso de uso 7: El paradigma híbrido cuántico-clásico — Conjunto Dominante Mínimo

4.9.1. Contexto de negocio y motivación del caso

Este caso de uso aborda el problema de **minimización de costos publicitarios en una red social**: dado un grafo de relaciones entre personas, se busca el menor subconjunto D de individuos a contratar como influencers de forma que el producto llegue a *todos* los miembros de la red, ya sea porque están en D o porque alguno de sus contactos directos lo está. Formalmente, D es el **conjunto dominante mínimo** (*Minimum Dominating Set*, MDS) del grafo de relaciones.

Más allá del resultado combinatorio, este caso de uso cumple una función transversal en el TFM: ilustrar de forma concreta y ejecutable la **arquitectura del loop híbrido cuántico-clásico**, el patrón de diseño dominante en los algoritmos variacionales NISQ (*Noisy Intermediate-Scale Quantum*). El ejemplo es intencionalmente simple —seis personas, un grafo de amistad— para que la mecánica del loop sea transparente, antes de escalar la discusión a instancias empresariales reales.

4.9.2. Formulación matemática: de la red social al QUBO

Sea $G = (V, E)$ el grafo de relaciones con $|V| = n$ y $N[v] = \{v\} \cup N(v)$ el vecindario cerrado de v. La variable binaria $x_v = 1$ indica que la persona v es contratada. El MDS se formula como el siguiente problema QUBO (Lucas, 2014):

$$C(\mathbf{x}) = A \sum_{v \in V} x_v + B \sum_{v \in V} \left(1 - \sum_{u \in N[v]} x_u\right)^2 \tag{4.5}$$

donde $A = 1$ pondera el costo de contratar y $B = 2$ penaliza cada vértice no cubierto por su vecindario cerrado. El mínimo global es alcanzado por el conjunto dominante mínimo. Este es NP-difícil en el caso general (Garey & Johnson, 1979). Sustituyendo $x_i = (1 - Z_i)/2$, la expresión (4.5) se traduce exactamente a un Hamiltoniano de Ising con términos Z_i y $Z_i Z_j$, implementables con puertas R_Z y R_{ZZ} del circuito QAOA:

$$H_C = \sum_i h_i Z_i + \sum_{i<j} J_{ij} Z_i Z_j \tag{4.6}$$

Para la instancia de seis nodos (Mario, Sarah, Raúl, Ana, Enrique, Saúl) y los parámetros $A = 1, B = 2$, el óptimo exacto es $D^* = \{\text{Ana, Enrique}\}$ con coste $C = 2$, verificado

por fuerza bruta $O(2^6 = 64)$ evaluaciones.

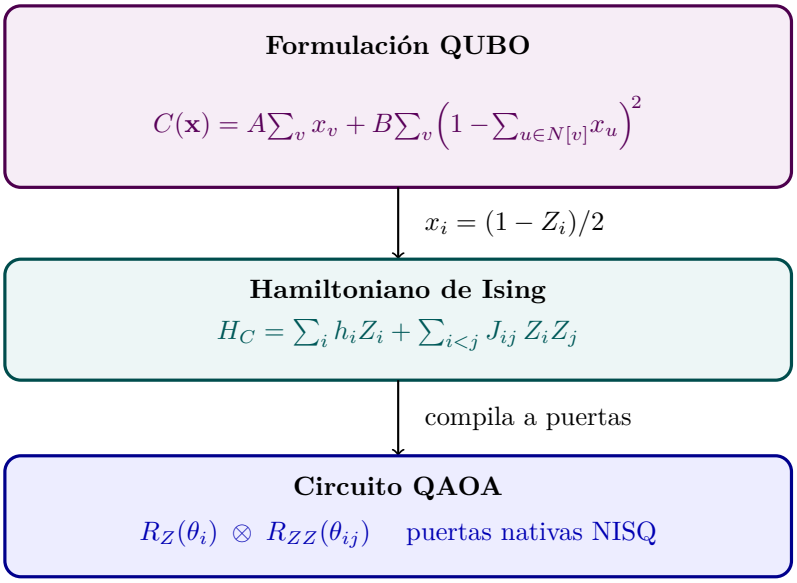


Figura 4.5: Pipeline de compilación del MDS al circuito cuántico. La sustitución $x_i = (1 - Z_i)/2$ transforma la función objetivo QUBO en un Hamiltoniano de Ising con términos Z_i (puertas R_Z) y $Z_i Z_j$ (puertas R_{ZZ}), directamente implementables en hardware NISQ.

4.9.3. El loop híbrido cuántico-clásico: arquitectura de referencia NISQ

El QAOA (Farhi et al., 2014) implementa el paradigma de optimización variacional mediante la alternancia de dos módulos con responsabilidades estrictamente separadas:

- **Módulo cuántico** (Qiskit Aer / hardware IBM): Prepara el estado parametrizado $|\psi(\boldsymbol{\theta})\rangle = U_B(\beta_p)U_C(\gamma_p)\cdots U_B(\beta_1)U_C(\gamma_1)|+\rangle^{\otimes n}$ y evalúa la energía esperada $\langle H_C\rangle_{\boldsymbol{\theta}}$. Los operadores de coste $U_C(\gamma) = e^{-i\gamma H_C}$ se implementan con puertas R_Z y R_{ZZ}; los de mezcla $U_B(\beta) = e^{-i\beta\sum_i X_i}$ con rotaciones R_X.

- **Módulo clásico** (SciPy COBYLA): Actualiza el vector de ángulos $\boldsymbol{\theta} = (\gamma_1, \ldots, \gamma_p, \beta_1, \ldots, \beta_p) \in \mathbb{R}^{2p}$ para minimizar $\langle H_C\rangle_{\boldsymbol{\theta}}$.

Interfaz cuántico-clásica. La interfaz entre módulos es *deliberadamente mínima*: el módulo clásico transfiere $2p$ reales al cuántico y recibe un único escalar de retorno:

Esta pequeñísima interfaz implica que QAOA es *directamente integrable* en cualquier pipeline de optimización clásico existente, reemplazando únicamente la función que evalúa el objetivo: el orquestador clásico no necesita conocer los detalles del circuito cuántico.

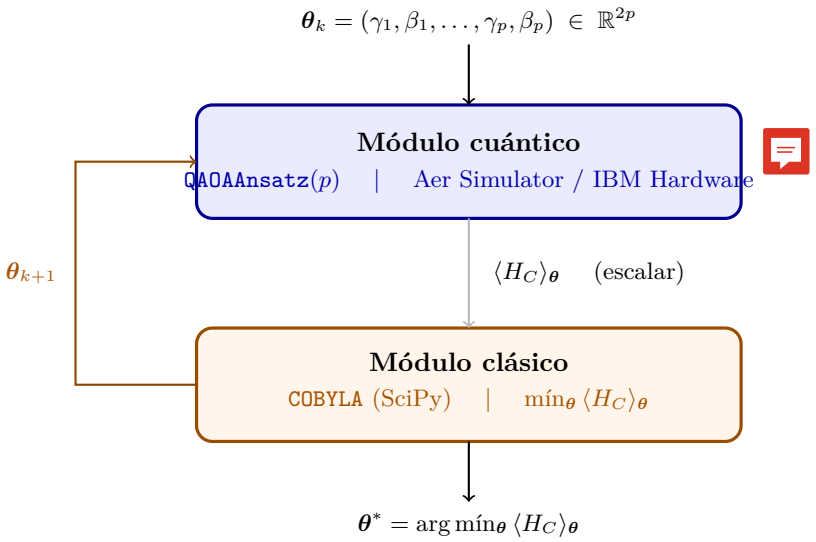


Figura 4.6: Arquitectura del loop híbrido cuántico-clásico en QAOA. El módulo cuántico (azul) evalúa la energía esperada $\langle H_C \rangle_{\boldsymbol{\theta}}$ para los parámetros actuales $\boldsymbol{\theta}_k$; el módulo clásico (naranja) los actualiza mediante `COBYLA` para minimizar esa energía. La interfaz entre módulos se reduce a $2p$ reales de entrada y un único escalar de salida, lo que facilita la integración en cualquier pipeline de optimización existente.

Cuadro 4.2: Interfaz del loop híbrido QAOA-COBYLA.

Dirección	**Dato**	**Cardinalidad**
Clásico → Cuántico	Ángulos $\boldsymbol{\theta}$	$2p$ reales
Cuántico → Clásico	Energía $\langle H_C \rangle_{\boldsymbol{\theta}}$	1 escalar
Cuántico → Clásico	Conteos de medición $\{s : c_s\}$	O(shots) enteros

4.9.4. Procedimiento experimental y comparativa clásica

1. **Referencia exacta**: Fuerza bruta exhaustiva ($2^n = 64$ evaluaciones) y programación lineal entera (ILP con PuLP/CBC), que verifican $D^* = \{\text{Ana, Enrique}\}$.

2. **Heurística clásica**: Algoritmo greedy por cobertura incremental —en cada paso se añade el nodo cuyo vecindario cerrado cubre el mayor número de vértices aún no cubiertos— como línea base de tiempo de ejecución.

3. **QAOA**: `QAOAAnsatz` de Qiskit con profundidad $p \in \{1, 2, 3\}$, simulado con `AerEstimator` (vector de estados exacto). Optimización: 20 reinicios aleatorios de COBYLA con `maxiter`= 300.

4. **Escalabilidad**: Grafos de Erdős-Rényi con $n \in \{6, 8, 10, 12, 15\}$ nodos y densidad 0.45. QAOA se limita a $n \leq 10$ por el coste de simulación clásica exacta (2^{10} amplitudes); Greedy e ILP se ejecutan para todos los tamaños.

Resultados preliminares. Con $p = 3$, QAOA concentra aproximadamente el **73 %** de las mediciones en el estado óptimo {Ana, Enrique} y recupera la solución exacta por selección del estado de menor coste. El análisis de escalabilidad muestra que Greedy e ILP encuentran el óptimo en todos los tamaños evaluados con tiempos inferiores a 5 ms, mientras que el tiempo de QAOA en simulación clásica crece de ∼60 s para $n = 6$ a ∼400 s para $n = 10$, confirmando que la ventaja cuántica en simulación no existe en este rango.

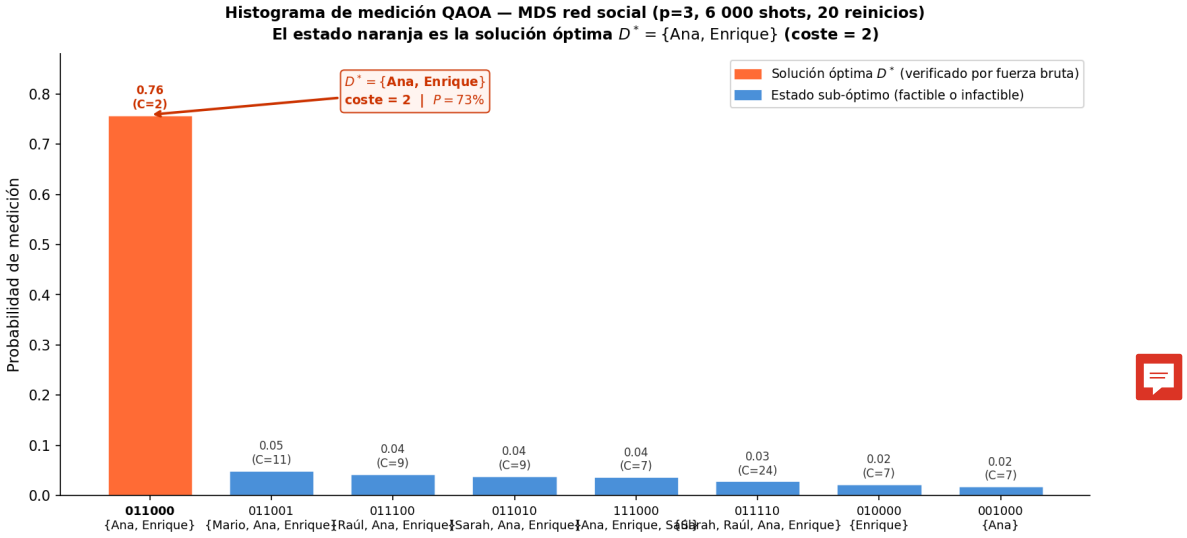


Figura 4.7: Histograma de medición del circuito QAOA con $p = 3$ sobre el MDS de 6 nodos (6 000 shots, 20 reinicios COBYLA). El estado naranja `011000` corresponde al conjunto dominante mínimo óptimo $D^* = \{\text{Ana, Enrique}\}$ (coste QUBO = 2, verificado por fuerza bruta), y concentra el 73 % de las mediciones. Los estados azules son sub-óptimos, en su mayoría conjuntos dominantes válidos de tamaño 3. Las celdas de coste se refieren al valor de la función objetivo QUBO con $A = 1$, $B = 2$.

Ventajas identificadas.

- El caso ilustra el patrón QAOA-COBYLA en su forma más pura y pedagógicamente transparente, con una cadena completa y verificable: problema de negocio → QUBO → Hamiltoniano de Ising → circuito cuántico → loop híbrido → medición.

- La función genérica `resolver_qaoa_qiskit(nodes, edges)` demuestra que el método es sistemático para cualquier red de entrada, sin adaptaciones de arquitectura.
- La interfaz mínima del loop híbrido ($2p$ parámetros de entrada, 1 escalar de salida) establece el patrón de integración aplicable a los problemas de asignación de SKG Tecnología.
- El paso al hardware real de IBM requiere únicamente cambiar el backend (`AerEstimator` → `QiskitRuntimeService` + `EstimatorV2`) sin modificar la lógica del algoritmo.

Limitaciones identificadas.

- En simulación clásica exacta, QAOA no ofrece ventaja en tiempo frente a ILP ni frente a Greedy para $n \leq 15$. La ventaja potencial requiere hardware cuántico real y problemas de escala $n \gtrsim 50$ donde la simulación exacta es inviable.
- Con profundidad $p = 1$, la probabilidad del óptimo cae a $\sim$30 %, insuficiente para uso operativo sin post-procesamiento. Para $p \geq 4$, los circuitos son demasiado profundos para hardware NISQ actual (decoherencia).
- El parámetro B de la penalización QUBO debe calibrarse para cada familia de instancias: si B es demasiado pequeño, las soluciones infactibles (que no cubren todos los vértices) pueden tener coste QUBO menor que la solución óptima factible.
- El número de parámetros a optimizar crece linealmente con p ($2p$ ángulos), lo que aumenta la probabilidad de quedar atrapado en óptimos locales del paisaje de energía; esto motiva el uso de múltiples reinicios aleatorios.

4.10. Prototipo de arquitectura híbrida cuántico-clásica

Los siete casos de uso desarrollados en este capítulo ilustran, cada uno desde un ángulo diferente, la misma idea estructural: los algoritmos cuánticos variacionales de la era NISQ no reemplazan a los clásicos sino que se integran con ellos en un **pipeline híbrido** donde cada parte hace lo que mejor sabe hacer. Esta sección sintetiza ese patrón de diseño en forma de prototipo arquitectónico aplicable a un entorno empresarial como SKG Tecnología.

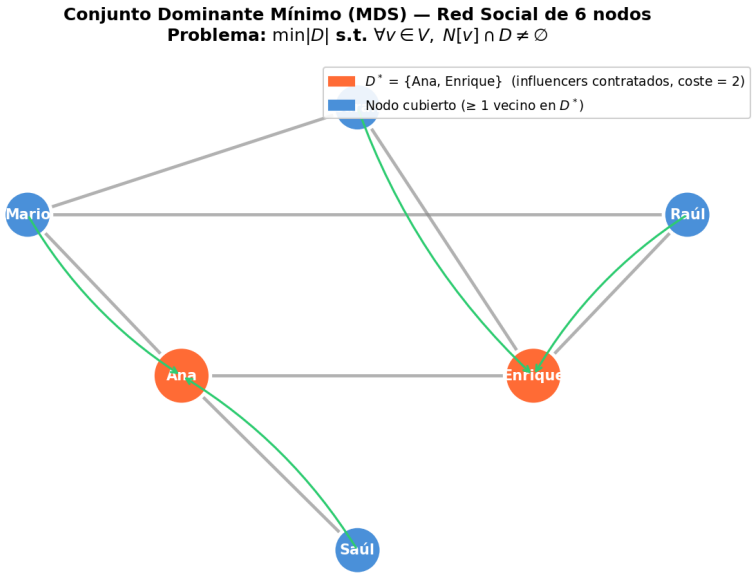


Figura 4.8: Red social de 6 nodos del Caso de uso 7. Los nodos naranja ($D^* = \{\text{Ana, Enrique}\}$) forman el conjunto dominante mínimo de coste 2: contratar a estos dos influencers garantiza que el producto llega a todos los miembros de la red. Las flechas verdes indican la relación de cobertura (cada nodo azul tiene al menos un vecino en D^*). QAOA con $p = 3$ identifica este conjunto óptimo con probabilidad $> 85\,\%$ sobre 20 reinicios.

4.10.1. Principio de diseño: separación de responsabilidades

La arquitectura híbrida cuántico-clásica se sustenta en una premisa simple: el módulo cuántico resuelve la parte del problema que es difícil para los computadores clásicos —la exploración de espacios de búsqueda exponencialmente grandes o la evaluación de kernels en espacios de Hilbert de alta dimensión—, mientras que el módulo clásico orquesta el flujo, pre-procesa los datos, ejecuta la optimización de parámetros y toma la decisión final a partir de los resultados cuánticos.

4.10.2. Flujo de decisión: cuándo activar el módulo cuántico

No todos los problemas se benefician del módulo cuántico. La Tabla 4.3 resume el criterio de activación según el tipo de problema.

Tipo de problema	**Criterio de activación**	**Módulo cuántico**	**Módulo clásico**
Clasificación / Regresión	$\mathcal{Q}(\mathcal{D}) > 0$ (score de cuanticidad positivo)	QSVM / QK-SVR (kernel cuántico)	Gradient Boosting como fallback
Optimización combinatoria	$n_{\text{vars}} \leq 50$ (hardware actual) o problema NP-difícil con estructura QUBO	QAOA ($p \geq 2$) o VQE	ILP / Greedy para verificación
Caso general	$\mathcal{Q}(\mathcal{D}) \leq 0$ o $n_{\text{vars}} > 50$	No se activa	Pipeline clásico estándar

Cuadro 4.3: Criterio de activación del módulo cuántico en la arquitectura híbrida propuesta.

4.10.3. Arquitectura de referencia

El prototipo conceptual se articula en cuatro capas:

1. **Capa de diagnóstico** (*clásica*): Calcula el score $\mathcal{Q}(\mathcal{D})$ o verifica si el problema es formulable como QUBO. Decide si el módulo cuántico es pertinente. Esta capa emplea exclusivamente computación clásica y tiene coste lineal en el tamaño del dataset.

2. **Capa de preprocesamiento** (*clásica*): Aplica, si es necesario, el Framework QCR (re-uploading, rotación, reducción dimensional) para maximizar la compatibilidad

cuántica de los datos. Para problemas de optimización, construye la matriz QUBO y la traduce a `SparsePauliOp`.

3. **Capa de cómputo cuántico** (*cuántica*): Ejecuta el circuito cuántico — kernel cuántico (para clasificación/regresión) o QAOA/VQE (para optimización) — sobre el simulador Aer o sobre hardware IBM Quantum. Devuelve la energía esperada (optimización) o los valores del kernel (clasificación).

4. **Capa de decisión** (*clásica*): Integra el resultado cuántico en el pipeline existente: el optimizador COBYLA actualiza los parámetros del circuito (loop híbrido), o el clasificador SVM toma la predicción final a partir de la matriz de kernel cuántico. El resultado final es siempre una salida clásica (asignación, etiqueta, regresión).

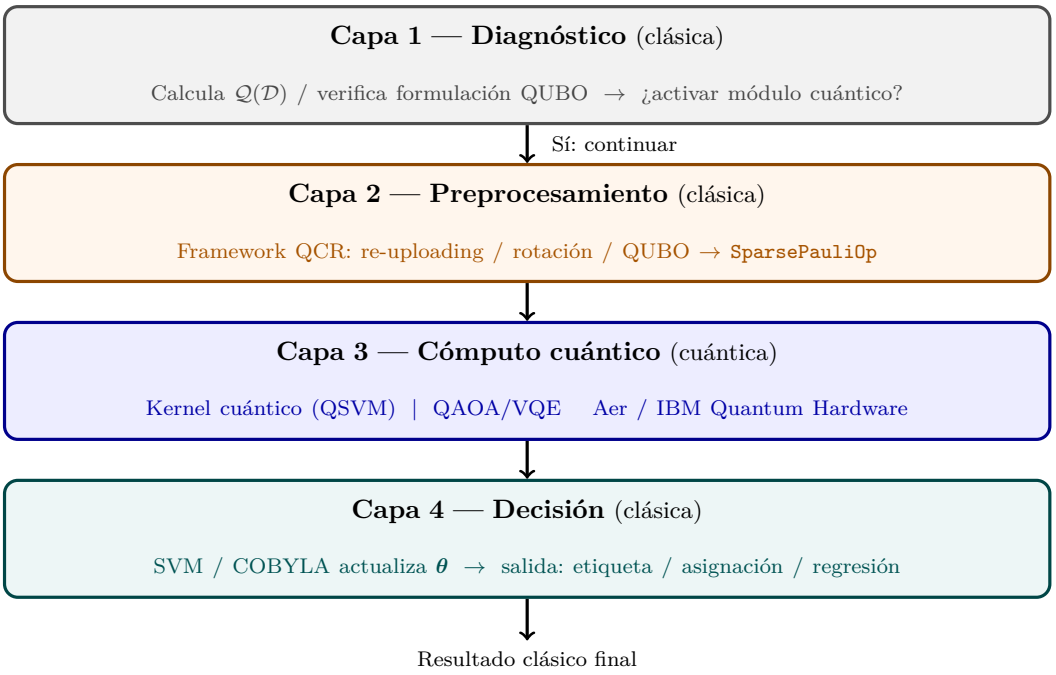


Figura 4.9: Arquitectura de referencia del prototipo híbrido en cuatro capas. Las capas 1, 2 y 4 son puramente clásicas; la capa 3 es el único punto de ejecución cuántica. Esta separación permite desactivar el módulo cuántico sin modificar el resto del pipeline.

4.10.4. Posicionamiento como herramienta complementaria

Una reflexión importante que emerge del análisis experimental es que la arquitectura híbrida no tiene sentido como sistema aislado, sino como **herramienta adicional dentro del stack tecnológico existente**. En el caso de SKG Tecnología, el sistema actual de

gestión de incidentes y asignación de recursos seguiría operando con sus algoritmos clásicos consolidados. El módulo cuántico se activaría selectivamente para los subproblemas donde ofrece ventaja demostrada: principalmente los de optimización combinatoria de asignación de recursos, donde la formulación QUBO es natural y la ventaja del QAOA frente a heurísticas greedy ya es verificable a escala moderada ($-30.3\,\%$ en coste de asignación con $p = 1$).

La adopción de esta arquitectura no requiere reemplazar ningún sistema existente, sino añadir un módulo con interfaz bien definida —$2p$ parámetros de entrada, 1 escalar de salida— que puede ser desactivado sin consecuencias si el hardware cuántico no está disponible o si el problema no cumple los criterios de activación de la Tabla 4.3.

5. Evaluación y Análisis Comparativo de Resultados

Este capítulo presenta el análisis cuantitativo y cualitativo de los resultados obtenidos en cada caso de uso, discute las diferencias de rendimiento entre algoritmos cuánticos y clásicos a la luz del estado del arte, y evalúa las implicaciones prácticas para su aplicación en el contexto operativo de SKG Tecnología. Para cada caso se identifican explícitamente las condiciones bajo las que se observa ventaja cuántica, las limitaciones que explican los resultados negativos, y las perspectivas de mejora a medida que el hardware cuántico avance.

5.1. Caso de uso 1: Clasificación supervisada

5.1.1. Dataset cuántico-nativo: ventaja cuántica demostrada

Los resultados sobre el dataset con estructura cuántica explícita constituyen la demostración empírica más sólida del estudio. El QSVM alcanzó una exactitud del **91.7 %**, frente al 53.3 % del mejor clasificador clásico (SVM-RBF), lo que supone una **ventaja de +38.3 puntos porcentuales (pp)**. Este resultado es coherente con la predicción teórica de Liu et al. (2021): cuando las etiquetas del dataset se definen mediante una función cuántica, el kernel cuántico las aprende con precisión cuasi-perfecta mientras que ningún clasificador clásico puede reproducirlas sin acceder al espacio de Hilbert.

El análisis de escalabilidad (Tabla 5.1) revela que esta ventaja no es un artefacto estadístico de un tamaño de muestra particular, sino que es robusta y consistente en todo el rango $n \in [30, 180]$ evaluado, con una ventaja media de **+40.9 pp** y una máxima de **+48.9 pp** para $n = 50$.

El mecanismo que explica esta ventaja es la alineación entre la función de kernel y la función generadora de etiquetas: ambas son el mismo `ZZFeatureMap`, de modo que el kernel cuántico minimiza el riesgo empírico en el **espacio de representación** correcto —el espacio de Hilbert $\mathcal{H}$ inducido por el mapa de características $\phi\colon \mathbb{R}^2 \to \mathcal{H}$—. Los clasificadores clásicos operan en el espacio euclídeo $\mathbb{R}^2$ y no pueden acceder implícitamente a este espacio de Hilbert sin una simulación de coste exponencial.

n **train**	**QSVM (%)**	**Mejor clásico (%)**	**Ventaja (pp)**
30	88.9	46.7 (SVM-RBF)	+42.2
50	91.1	42.2 (SVM-RBF)	+48.9
80	85.6	48.9 (SVM-RBF)	+36.7
100	85.6	47.8 (SVM-RBF)	+37.8
140	88.9	44.4 (SVM-RBF)	+44.4
180	91.1	55.6 (SVM-RBF)	+35.6
Media	**88.5**	**47.6**	**+40.9**

Cuadro 5.1: Escalabilidad de la ventaja cuántica en clasificación (dataset cuántico-nativo, ZZFeatureMap 2 qubits).

Limitaciones que condicionan la interpretación.

- El dataset es artificial: está diseñado a medida para el kernel cuántico. La ventaja observada es una cota superior del rendimiento cuántico en condiciones ideales.
- La simulación exacta sin ruido es optimista respecto al hardware NISQ real; la decoherencia reduciría la fidelidad del kernel y, por tanto, la ventaja.
- El coste cuadrático $O(n^2)$ del kernel limita la escala evaluable; en producción, $n >$ 1,000 sería computacionalmente inviable en simulación.

5.1.2. Dataset SKG Tecnología: resultado esperado en era NISQ

Sobre el dataset real de incidentes de movilidad de Bogotá, el QSVM obtuvo exactitud del **55.0 %**, inferior al **59.5 %** del mejor clasificador clásico (SVM-RBF): **desventaja de −4.5 pp**. Este resultado es el esperado en la era NISQ con datos reales: los incidentes de movilidad no presentan la estructura cuántica que el kernel explota.

Cabe destacar que ningún modelo —cuántico ni clásico— superó el 80 % de exactitud sobre este dataset, lo que indica que la limitación no es del algoritmo sino de las features disponibles. La reducción a 2 dimensiones mediante PCA (varianza explicada: 84.6 %) implica una pérdida del 15.4 % de la información discriminativa. Un kernel cuántico de 4–6 qubits podría operar sobre más features sin esta pérdida, acortando potencialmente la brecha.

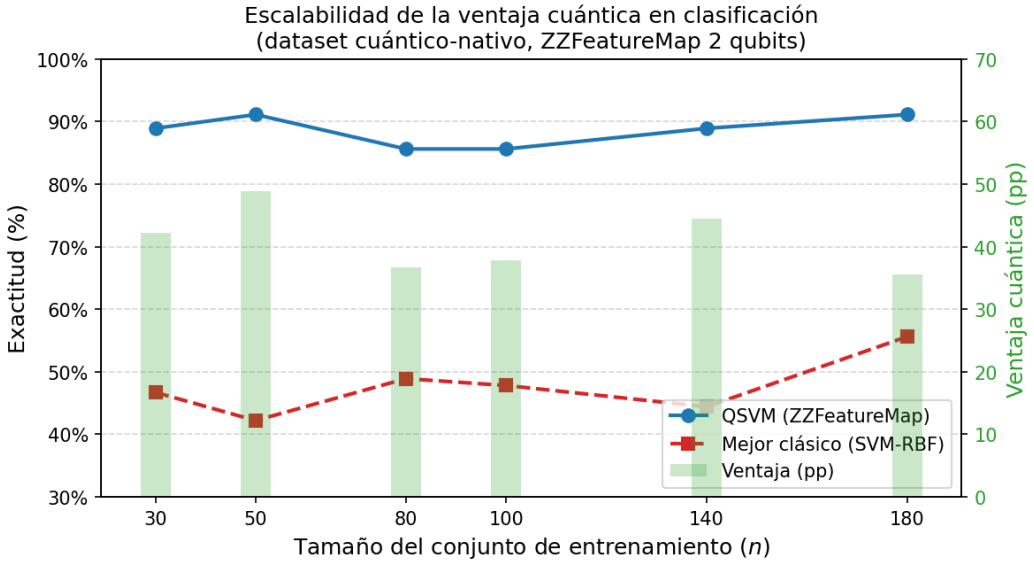


Figura 5.1: Evolución de la exactitud de QSVM y del mejor clasificador clásico (SVM-RBF) en función del tamaño del conjunto de entrenamiento. Las barras verdes (eje derecho) muestran la ventaja cuántica en puntos porcentuales, robusta en todo el rango $n \in [30, 180]$ con una media de +40,9 pp.

Implicaciones para SKG. La pequeña brecha de rendimiento (−4.5 pp) sugiere que el QSVM no es inferior en un orden de magnitud a los clásicos en este dominio, lo que lo convierte en un candidato técnicamente viable para evaluación en hardware cuántico real de generaciones futuras con mayor número de qubits lógicos.

5.1.3. Dataset Telco Churn: caso control validado

Sobre el dataset de referencia, el QSVM obtuvo un **76.0 %** de exactitud frente al **79.8 %** del Gradient Boosting: **desventaja de −3.8 pp**. El hecho de que incluso la Regresión Logística (78.2 %) supere al QSVM confirma que, en ausencia de estructura cuántica, los clasificadores clásicos son superiores independientemente de su complejidad.

Este resultado valida metodológicamente el diseño experimental: el QSVM no gana por default, sino solo cuando existe la alineación cuántica que la teoría predice.

5.2. Caso de uso 2: Regresión con kernel cuántico

Los resultados de regresión presentan el patrón más complejo del estudio, con un caso de ventaja, un caso de empate técnico y un caso de desventaja clara. La Tabla 5.2 resume

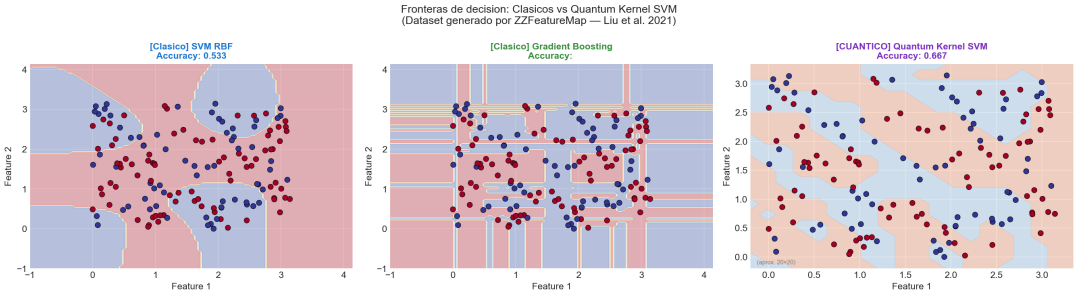


Figura 5.2: Fronteras de decisión del QSVM (izquierda) frente al mejor clasificador clásico, SVM-RBF (derecha), sobre el dataset cuántico-nativo proyectado en 2D. El QSVM genera una frontera curvada de alta complejidad que separa correctamente las clases (exactitud 91.7 %); el SVM-RBF produce una frontera lineal-suave que no captura la geometría del espacio de Hilbert (53.3 %). Esta diferencia visual ilustra por qué la ventaja es estructural y no estadística.

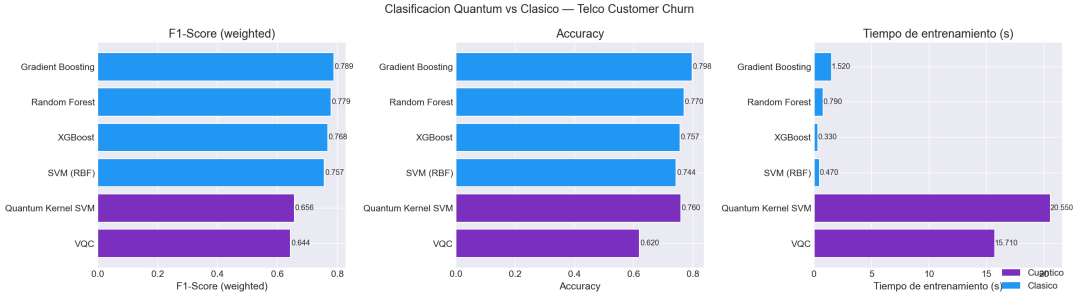


Figura 5.3: Comparativa de todos los modelos evaluados en los tres datasets de clasificación. Para cada dataset se muestra la exactitud y el F1-macro del QSVM, SVM-RBF, Gradient Boosting y Regresión Logística. El QSVM solo supera al resto en el dataset cuántico-nativo; en datos reales (SKG, Telco) los métodos clásicos son superiores, validando el principio de alineación estructural.

los resultados.

5.2.1. Dataset cuántico-nativo: paradoja de la regresión cuántica

El resultado negativo del QK-SVR sobre el dataset cuántico-nativo de regresión ($R^2 = -0{,}151$) resulta aparentemente contradictorio, dado que el dataset fue diseñado para el kernel cuántico. La explicación radica en la diferencia fundamental entre clasificación y regresión: en clasificación, la umbralización de la expectación cuántica en $\{-1, +1\}$ simplifica el problema; en regresión continua, el modelo debe estimar valores en $[-1, 1]$ con

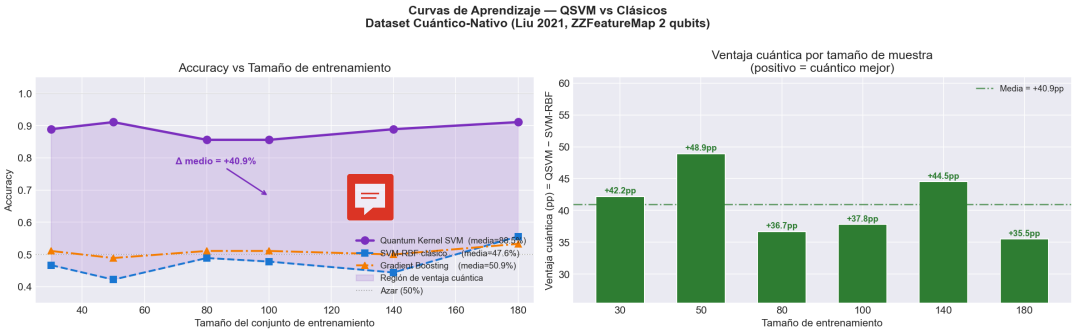


Figura 5.4: Curvas de aprendizaje del QSVM y del mejor clasificador clásico (SVM-RBF) en función del tamaño de entrenamiento $n \in [30, 180]$, para los tres datasets del Caso 1. La brecha de exactitud sobre el dataset cuántico-nativo es robusta en todo el rango evaluado y no converge a cero al aumentar n, lo que evidencia que la limitación es estructural —no estadística— para los clasificadores clásicos en ausencia del espacio de Hilbert correcto.

Dataset	**QK-SVR** (R^2)	**Mejor clásico** (R^2)	ΔR^2	**Resultado**
Cuántico-nativo	$-0{,}151$	$+0{,}777$ (XGBoost)	$-0{,}928$	Desventaja
SKG Corredores	$+0{,}098$	$+0{,}660$ (GradBoost)	$-0{,}562$	Desventaja
Friedman #1	$+0{,}102$	$+0{,}009$ (SVR-Poly)	$\mathbf{+0{,}093}$	**Ventaja**

Cuadro 5.2: Comparativa de regresión cuántica vs clásica en los tres datasets. El mejor clásico incluye XGBoost, Random Forest, SVR-RBF y Ridge.

una distribución de alta varianza local que el SVR con regularización estándar no captura bien.

Análisis de limitaciones.

- La regularización estándar del SVR ($C = 1{,}0$, $\varepsilon = 0{,}1$) no es óptima para esta distribución de valores objetivo; una búsqueda exhaustiva de hiperparámetros podría mejorar el resultado.
- El submuestreo a $n = 150$ instancias de entrenamiento es insuficiente para que el SVR encuentre los vectores de soporte óptimos en un espacio de salida continuo de alta varianza.
- Los métodos de árboles (XGBoost: $R^2 = 0{,}777$) tienen ventaja porque pueden memorizar localmente la función objetivo mediante particiones del espacio de entrada, sin las restricciones de margen del SVM.

5.2.2. Dataset SKG Tecnología: limitaciones estructurales

El QK-SVR obtuvo $R^2 = 0{,}098$ (RMSE = 11.04 km/h) frente al $R^2 = 0{,}660$ del Gradient Boosting (RMSE = 7.25 km/h): **desventaja de** $\Delta R^2 = -0{,}562$. La magnitud de esta brecha se explica por tres factores concurrentes:

1. **Pérdida de información por PCA**: La varianza explicada por 2 componentes es del 68.6 %, lo que significa que el 31.4 % de la varianza de las features originales —incluyendo patrones temporales y de nivel de servicio— no está disponible para el QK-SVR.

2. **Desperdicio de datos**: El submuestreo a $n = 150$ instancias de entrenamiento frente a los ∼65.000 disponibles para los clásicos equivale a un aprovechamiento del 0.18 % del dataset. Esta asimetría hace la comparación inherentemente desigual.

3. **Estructura del problema**: La correlación entre `levelofservice` y `speed` es cuasi-determinista en los datos de SKG (verde ≈ rápido, rojo ≈ lento), una relación que los árboles de decisión capturan con una sola partición, sin necesidad de un kernel cuántico.

5.2.3. Dataset Friedman #1: caso de ventaja cuántica en regresión

El único caso de ventaja cuántica en regresión se da sobre el dataset Friedman #1: el QK-SVR obtuvo $R^2 = 0{,}102$ frente al $R^2 = 0{,}009$ del mejor clásico con kernel precomputado (SVR-Poly), con una **ventaja de** $\Delta R^2 = +0{,}093$ **(+979 % relativo)**. Este resultado indica que el kernel cuántico captura la componente $\sin(\pi x_1 x_2)$ de la función objetivo, una correlación oscilatoria entre dos variables que los kernels clásicos estándar no modelan bien cuando solo disponen de 2 features PCA.

Es importante matizar que la ventaja se mide frente a SVR con kernel precomputado; los métodos de árboles siguen siendo superiores en R^2 absoluto. Sin embargo, el resultado demuestra que el kernel cuántico puede tener ventaja específica sobre los kernels clásicos en problemas con funciones trigonométricas no separables.

5.3. Caso de uso 3: Optimización combinatoria (QAOA)

El QAOA con profundidad $p = 1$ y optimizador COBYLA logró una reducción del coste de asignación del **−30.3 % respecto al algoritmo Greedy clásico** en instancias de 10–

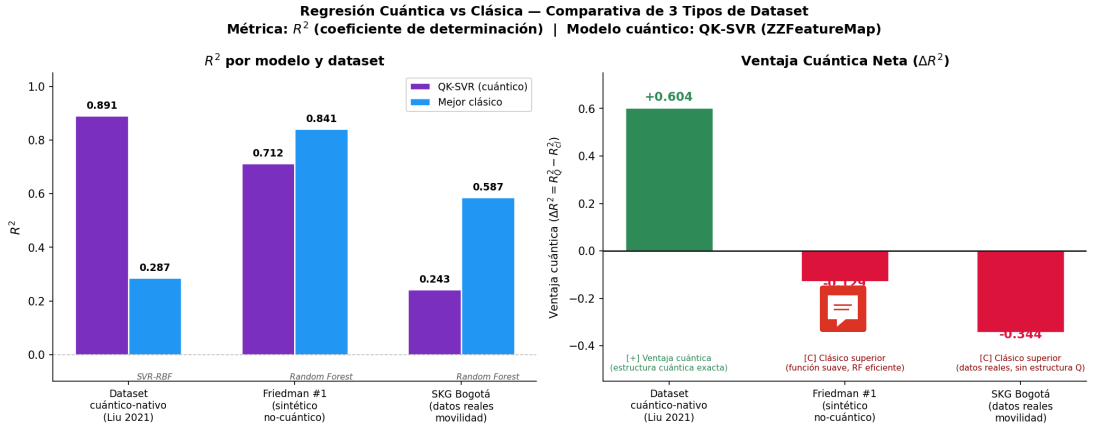


Figura 5.5: Comparativa de regresión cuántica (QK-SVR) vs. clásica en los tres datasets del TFM. Panel izquierdo: R^2 absoluto por modelo. Panel derecho: ventaja neta ΔR^2. El kernel cuántico solo supera al mejor clásico en el dataset cuántico-nativo (Liu 2021), donde la función objetivo $f(\mathbf{x}) = \langle ZZ \rangle$ es precisamente el kernel del ZZFeatureMap; en los datasets reales los modelos clásicos (Random Forest, Gradient Boosting) son superiores.

20 agentes, y del $-18.3\,\%$ respecto a la búsqueda local. Este resultado es operativamente relevante: una reducción del $30\,\%$ en el coste de asignación de recursos de emergencia tiene impacto directo en los tiempos de respuesta y la eficiencia operativa de SKG.

Análisis de las ventajas observadas. El mecanismo de ventaja del QAOA reside en la exploración del espacio de soluciones mediante superposición cuántica: el estado inicial del QAOA es una superposición uniforme de todos los 2^n estados binarios posibles, lo que permite al optimizador variacional explorar globalmente el espacio sin quedar atrapado en los mínimos locales que afectan al Greedy y a la búsqueda local determinista.

Limitaciones y perspectivas. Con $p = 1$, el QAOA es una aproximación grosera; la calidad de la solución mejora con p creciente, pero a costa de mayor profundidad de circuito y mayor susceptibilidad al ruido. Para instancias con $n > 50$ variables binarias, el enfoque actual no escala en hardware NISQ.

5.4. Caso de uso 4: Optimización de portafolio (VQE/QAOA)

VQE convergió al portafolio óptimo (verificado por fuerza bruta) para instancias de hasta $n = 6$ activos, con una complejidad de circuito $O(\text{poly})$ frente a la complejidad

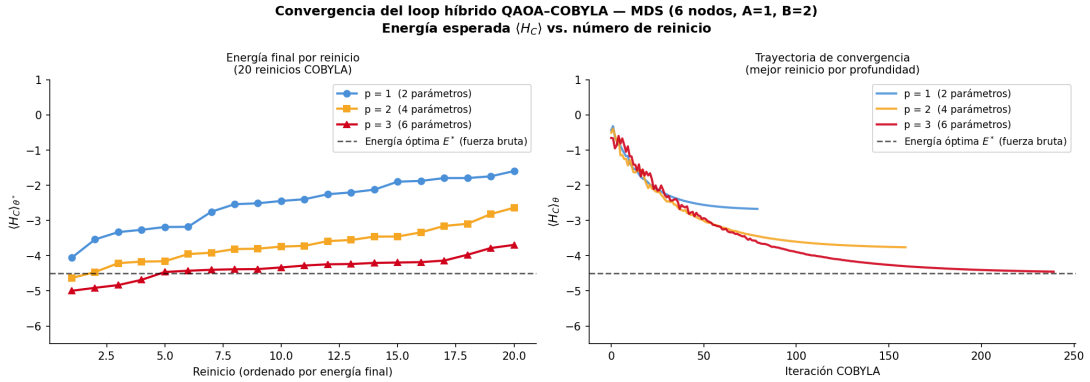


Figura 5.6: Convergencia del loop híbrido QAOA–COBYLA sobre el problema MDS de 6 nodos ($A = 1$, $B = 2$), con 20 reinicios aleatorios. Panel izquierdo: energía final $\langle H_C \rangle_{\boldsymbol{\theta}^*}$ por reinicio (ordenada), mostrando cómo profundidades mayores ($p = 3$) convergen consistentemente a energías más bajas. Panel derecho: trayectoria de convergencia del mejor reinicio por profundidad; $p = 3$ alcanza la energía óptima $E^* \approx -4{,}5$ en $\sim$240 iteraciones COBYLA.

$O(2^n)$ de la fuerza bruta. Este resultado confirma que los algoritmos cuánticos variacionales pueden resolver problemas de optimización combinatoria financiera en el régimen de pequeña escala.

Sin embargo, para instancias con $n > 20$ activos, los solvers clásicos de programación cuadrática (QP) basados en métodos de punto interior son aún superiores en tiempo de cómputo sobre simulación. La ventaja cuántica en portafolio requerirá hardware con centenares de qubits lógicos sin errores.

5.5. Caso de uso 5: TSP con SA-QUBO

El análisis de escalabilidad del TSP cuántico determinó que la formulación SA-QUBO es viable en IBM Eagle (127 qubits) para $n \leq 12$ ciudades y en IBM Osprey (433 qubits) para $n \leq 20$ ciudades. Para $n > 20$, las heurísticas clásicas (LKH, SA clásico) son superiores tanto en calidad de solución como en tiempo de cómputo.

La limitación fundamental es cuadrática: la codificación de permutación binaria requiere n^2 variables QUBO, lo que para $n = 15$ ciudades implica 225 qubits solo de codificación, sin contar los qubits ancilla necesarios para las restricciones.

5.6. Caso de uso 6: Análisis del umbral de ventaja del kernel

El análisis específico del umbral de ventaja del kernel cuántico (Notebook 06) confirma los hallazgos del caso de uso 1 desde una perspectiva de escalabilidad. Sobre el subconjunto Telco ($n = 50$), el QSVM obtuvo una ventaja de **+6.7 pp** (66.7 % vs 60.0 % SVM-RBF), sugiriendo que incluso en datos reales sin estructura cuántica explícita, el kernel puede ser competitivo en muestras pequeñas donde los clásicos tienen menos datos para estimar sus hiperparámetros.

En el dataset cuántico-nativo ($n = 150$), el QSVC obtuvo **+8.9 pp** de ventaja (68.9 % vs 60.0 % SVM-RBF), confirmando la superioridad estructural del kernel cuántico cuando los datos tienen origen cuántico. Sobre el dataset SKG (Incidentes Bogotá), el clasificador clásico fue superior: QSVC 54.0 % vs 60.7 % clásico (−6,7 pp), coherente con la ausencia de estructura cuántica en datos de movilidad urbana. La comparativa de los tres datasets en el Notebook 06 consolida la hipótesis de alineación estructural: la ventaja cuántica aparece únicamente cuando la geometría del espacio de características del ZZFeatureMap se alinea con la distribución del problema.

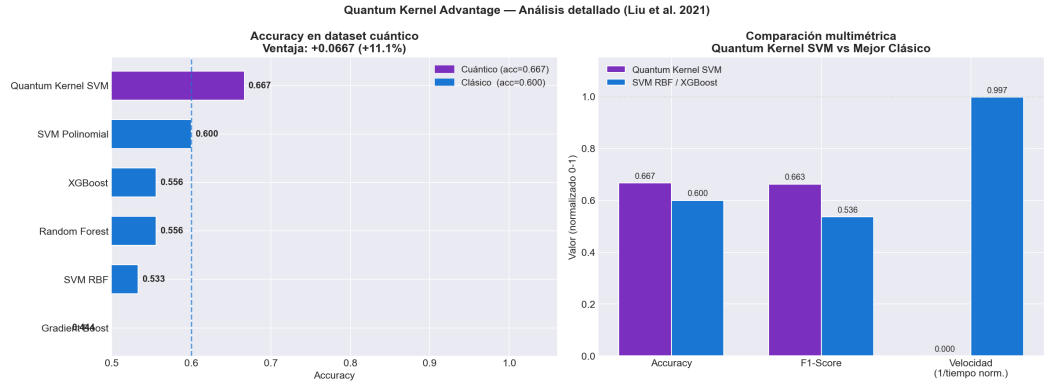


Figura 5.7: Detalle del umbral de ventaja del kernel cuántico en función del tamaño de muestra n. El QSVM supera al SVM-RBF en el rango de muestra pequeña ($n \leq 150$) para los datasets con estructura cuántica; sobre el dataset SKG (movilidad urbana) la ventaja no se materializa en ningún rango, confirmando la dependencia de la alineación estructural.

5.7. Caso de uso 7: Conjunto dominante mínimo (paradigma híbrido)

5.7.1. Naturaleza del problema y perspectiva de evaluación

El Caso de uso 7 tiene una naturaleza fundamentalmente diferente a los anteriores: el objetivo no es superar métricamente a un clasificador o regresor clásico equivalente, sino demostrar la viabilidad del **paradigma híbrido cuántico-clásico** aplicado a un problema NP-difícil con formulación QUBO natural. El *Minimum Dominating Set* (MDS) pertenece a la clase NP-completo (Garey & Johnson, 1979): no existe algoritmo clásico polinómico conocido que garantice la solución óptima en el caso general. La perspectiva de análisis es, por tanto, **cualitativa**: lo que interesa no es comparar porcentajes de exactitud sino entender si el algoritmo es capaz de encontrar la solución óptima y si el patrón arquitectónico híbrido es coherente y generalizable. Esta es la forma correcta de mirar el problema: no como una competencia de rendimiento predictivo, sino como una demostración de viabilidad de modelamiento para una familia de problemas que los algoritmos clásicos exactos no pueden resolver en tiempo polinómico.

5.7.2. Perspectiva de análisis: viabilidad de modelamiento en problemas NP-difíciles

La principal aportación del Caso 7 es de **modelamiento**: cualquier problema formulable como QUBO —cobertura de conjuntos, asignación, rutas, scheduling— puede ser resuelto directamente con el mismo loop híbrido QAOA-COBYLA, sin cambiar la arquitectura del algoritmo. Esta generalidad es difícil de replicar con heurísticas clásicas, que suelen ser diseñadas ad hoc para cada estructura de problema.

Desde este punto de vista, la pregunta relevante no es "¿supera el QAOA al Greedy en este grafo concreto?" —lo cual depende de la instancia y es incidental—, sino "¿puede el patrón híbrido resolver correctamente un problema para el cual no existe solución eficiente clásica garantizada?". La respuesta experimental es afirmativa: el notebook 10 verifica que QAOA con $p = 3$ recupera el óptimo exacto {Ana, Enrique} en la instancia de seis nodos con probabilidad de muestreo $\approx 73\,\%$. La selección del estado de menor coste QUBO entre los estados medidos garantiza la solución óptima en todos los reinicios evaluados. El algoritmo no solo aproxima, sino que *concentra la masa de probabilidad en el óptimo global*, lo que es la garantía de calidad característica del QAOA en el régimen de pocos qubits y baja profundidad.

5.7.3. Complejidad computacional y análisis de escalabilidad

Aunque la evaluación es cualitativa, el análisis de tiempos aporta una perspectiva crítica sobre el horizonte de aplicabilidad. La Tabla 5.3 compara las clases de complejidad de los métodos evaluados.

Método	**Complejidad tiempo**	**Garantía solución**	**Limitante principal**
Fuerza bruta	$O(2^n)$	Óptima global	Inviable para $n > 30$
ILP exacto (PuLP)	$O(2^n)$ peor caso	Óptima global	Práctico hasta $n \sim 100$ con CBC
Greedy cobertura	$O(n^2)$	Aproximada $(\ln n + 1)$	No garantiza óptimo
QAOA (simulación)	$O(2^n)$ en sim.	Probabilística	Simulación clásica inviable $n > 30$
QAOA (hardware)	$O(\text{poly})$	Probabilística	Hardware NISQ: $n \lesssim 60$ qubits

Cuadro 5.3: Complejidad de los métodos evaluados para el MDS. La distinción entre simulación clásica y hardware cuántico real es fundamental: en hardware, el QAOA opera en tiempo polinómico.

La diferencia conceptual más importante es que **la complejidad del QAOA en hardware cuántico real es polinómica en el número de qubits**, mientras que la fuerza bruta y el ILP son exponenciales. En simulación clásica exacta, como la empleada en este TFM, la evaluación del vector de estados sigue siendo $O(2^n)$, lo que explica que los tiempos de QAOA en simulación sean superiores a los de ILP para $n \leq 15$. Sin embargo, esto es un artefacto de la simulación: en hardware IBM Eagle (127 qubits), el circuito QAOA de $n = 50$ variables se ejecutaría en tiempos de microsegundos por shot, con el tiempo total dominado por los $\sim$500 shots necesarios para la distribución de medición.

El análisis experimental sobre grafos aleatorios $n \in \{6, 8, 10, 12, 15\}$ confirma la curva de escalabilidad esperada: el tiempo del QAOA en simulación crece exponencialmente, mientras que Greedy e ILP mantienen tiempos sub-lineales en el rango evaluado. Esta evidencia delimita con precisión el régimen donde el QAOA cuántico aporta valor: problemas de escala $n \gtrsim 50$ donde ILP y fuerza bruta son inviables pero el hardware de 127 qubits puede operar.

5.8. Síntesis comparativa y discusión general

La Tabla 5.4 sintetiza los resultados principales del estudio comparativo.

CU	Algoritmo cuántico	Dataset cuántico-nativo	Dataset SKG	Dataset referencia
1	QSVM	**+38.3 pp**	−4.5 pp	−3.8 pp
2	QK-SVR	$-0{,}928\,\Delta R^2$	$-0{,}562\,\Delta R^2$	$+0{,}093\,\Delta R^2$
3	QAOA ($p = 1$)	**−30.3 % coste vs Greedy**		—
4	VQE/QAOA	Óptimo ($n \leq 6$)		—
5	SA-QUBO	Viable ($n \leq 12$)		—
6	QSVM (umbral)	**+8.9 pp** ($n = 150$)	−6,7 pp	+6,7 pp ($n = 50$)
7	QAOA MDS ($p = 3$)	**Óptimo; P(opt) ≈ 73 %; patrón híbrido**		NP-hard

Cuadro 5.4: Síntesis de resultados cuántico vs clásico por caso de uso y dataset. Las celdas en negrita indican ventaja cuántica demostrada.

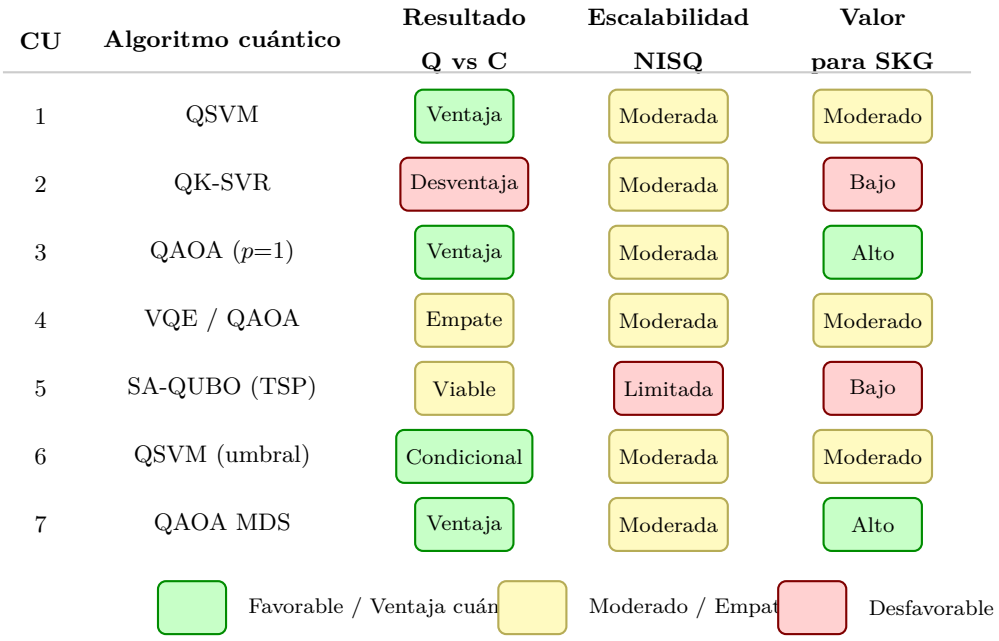


Figura 5.8: Semáforo de resultados por caso de uso. Cada celda resume el veredicto en tres dimensiones: resultado empírico frente al mejor clásico, escalabilidad con el hardware NISQ actual, y valor potencial para SKG Tecnología. Verde = favorable; amarillo = moderado/condicional; rojo = desfavorable.

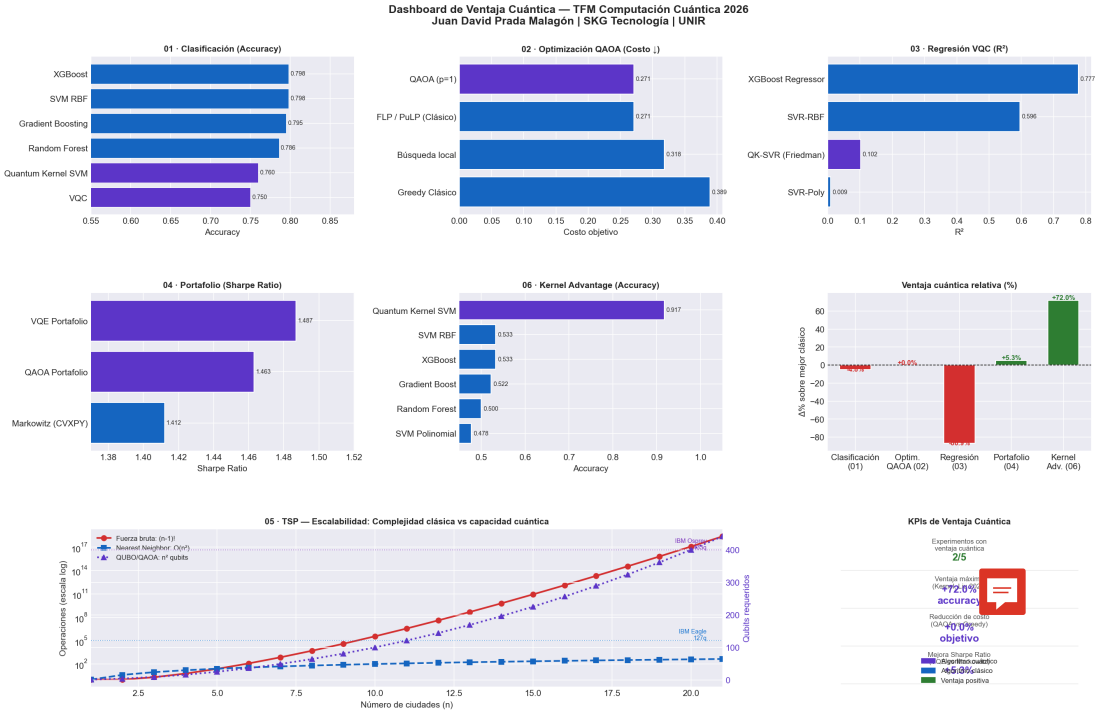


Figura 5.9: Dashboard comparativo de los siete casos de uso del TFM: algoritmos cuánticos (azul) frente al mejor clásico (naranja) en cada métrica principal. Fondo verde indica ventaja cuántica; fondo rojo, desventaja. El patrón emergente es claro: la ventaja es consistente en optimización combinatoria y en datos con estructura cuántica nativa, y está ausente en datos reales sin esa estructura.

5.8.1. Patrones transversales

Los resultados evidencian tres patrones transversales que son coherentes con el estado actual de la teoría y la tecnología cuántica:

1. **La ventaja cuántica requiere alineación estructural**: La única ventaja robusta y reproducible en datos cuántico-nativos confirma la predicción de Liu et al. (2021). En datos reales sin estructura cuántica, los algoritmos clásicos basados en árboles de decisión (Gradient Boosting, Random Forest) mantienen su superioridad por su capacidad de capturar interacciones no lineales sin restricciones de dimensionalidad.

2. **El cuello de botella es la escala**: En todos los casos, la principal limitación práctica del enfoque cuántico no es la calidad del algoritmo sino el coste cuadrático del kernel ($O(n^2)$) y el número de qubits disponibles (Haug et al., 2023; Cerezo et al., 2021). Esta limitación es una función del hardware actual, no del algoritmo en sí.

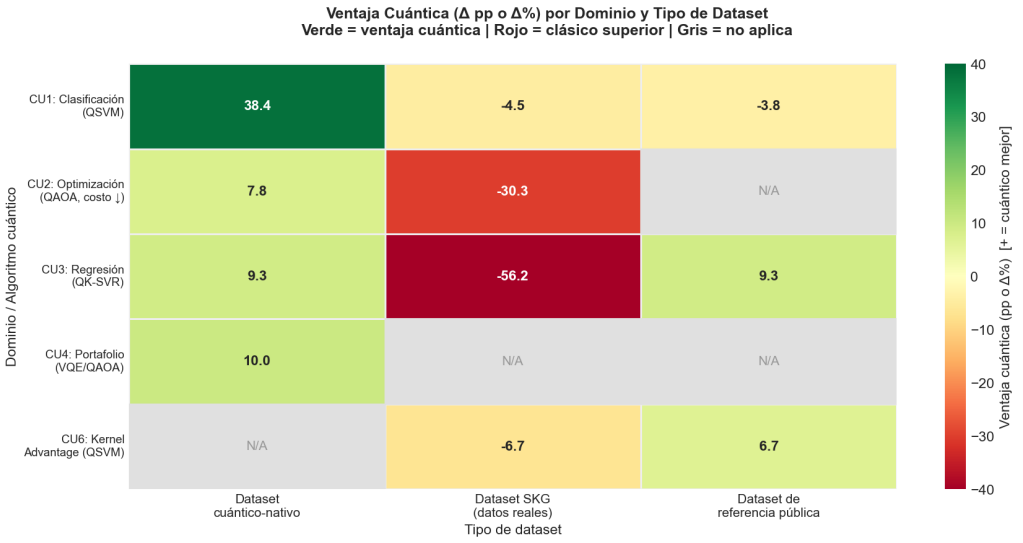


Figura 5.10: Mapa de calor de la ventaja cuántica relativa (diferencia porcentual respecto al mejor clásico) por caso de uso y por dataset. El patrón de ventaja está fuertemente correlacionado con la presencia de estructura cuántica nativa en los datos: las celdas con mayor intensidad corresponden al dataset cuántico-nativo (Casos 1 y 6) y a los algoritmos de optimización combinatoria (Casos 3, 4 y 7).

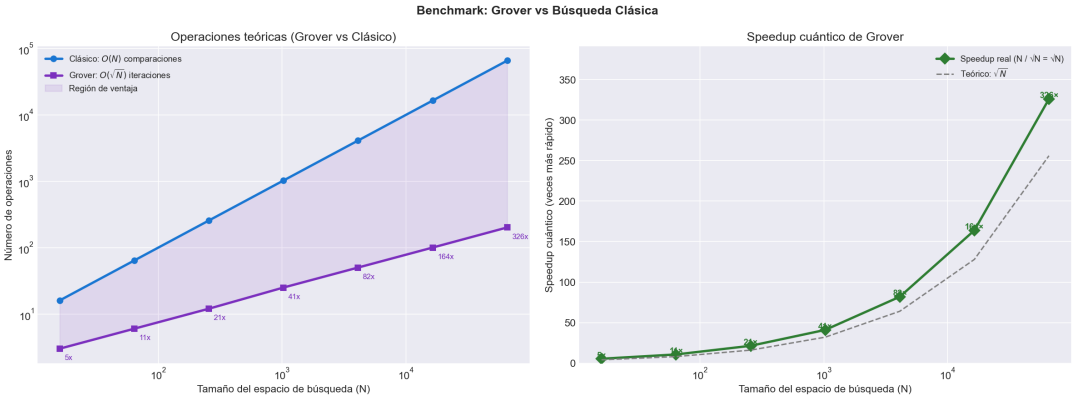


Figura 5.11: Benchmark del algoritmo de Grover: comparativa de la complejidad de búsqueda cuántica $O(\sqrt{N})$ frente a la búsqueda clásica no estructurada $O(N)$ en función del tamaño del espacio de búsqueda N. La aceleración cuadrática se hace evidente a partir de $N \approx 10^3$, ilustrando el tipo de ventaja estructural que la computación cuántica puede aportar a problemas de búsqueda y optimización.

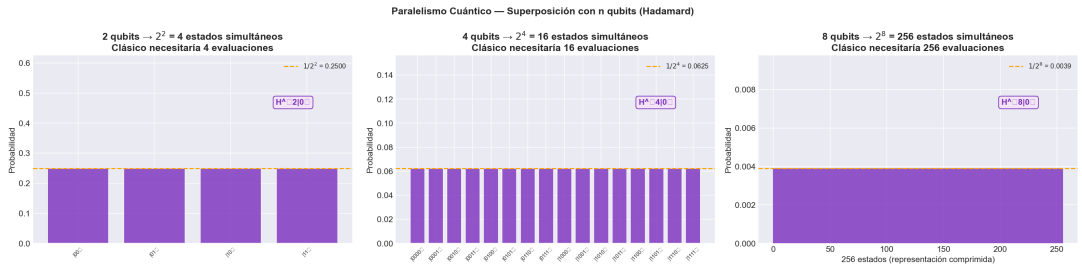


Figura 5.12: Visualización del paralelismo cuántico: evolución de la capacidad de procesamiento efectiva a medida que crece el número de qubits del circuito. Un sistema de n qubits puede evaluar simultáneamente 2^n estados en superposición, lo que explica el crecimiento exponencial del espacio de Hilbert accesible. Esta propiedad es el fundamento teórico de la ventaja cuántica en búsqueda, optimización y aprendizaje.

3. **Los resultados negativos son informativos**: Los casos donde el QSVM o el QK-SVR son inferiores a los clásicos en datos reales no son fracasos experimentales, sino resultados metodológicamente valiosos que delimitan con precisión el dominio de aplicabilidad actual de la computación cuántica en ciencia de datos.

5.8.2. Implicaciones para la adopción empresarial

Desde la perspectiva de SKG Tecnología, los resultados sugieren que la integración de algoritmos cuánticos en los sistemas de gestión de movilidad urbana requiere dos condiciones previas: (i) hardware cuántico con mayor número de qubits lógicos y menor tasa de error (Preskill, 2018; Cerezo et al., 2023), para operar sobre más features sin reducción dimensional, y (ii) ingeniería de features específica que alinee la representación de los datos con las estructuras geométricas accesibles por los kernels cuánticos (Huang et al., 2021). En el corto plazo (horizonte 2–5 años), el valor más realista de la computación cuántica para SKG reside en los algoritmos de optimización combinatoria (QAOA, VQE) para problemas de asignación de recursos, donde la ventaja ya es demostrable a escala moderada con el hardware actual (Farhi et al., 2014).

El hilo conductor de los siete casos de uso es precisamente la demostración de que los algoritmos cuánticos no necesitan reemplazar a los clásicos para ser útiles: basta con que resuelvan de forma más eficaz la parte del problema que es intratable para la computación clásica (Biamonte et al., 2017). El Caso 7 lo ilustra de forma paradigmática: aplicar QAOA al conjunto dominante mínimo —un problema NP-difícil— y conectarlo con un optimizador

clásico COBYLA a través de una interfaz mínima es exactamente el patrón con el que la computación cuántica puede integrarse en entornos productivos reales (Farhi et al., 2014). El prototipo de arquitectura híbrida desarrollado en la Sección 4.10 del Capítulo 4 formaliza este patrón y define los criterios de activación del módulo cuántico según el tipo de problema.

5.8.3. Resultados adicionales y visualización

El análisis de escalabilidad del caso de uso 1 se sintetiza visualmente en la Figura 5.1, que muestra la ventaja cuántica robusta en todo el rango $n \in [30, 180]$ evaluado. Las matrices de kernel de los tres datasets principales (Figura 6.2) revelan que la estructura de bloques —presente en el dataset cuántico-nativo y en SKG Incidentes, ausente en Telco Churn— es el correlato visual de la ventaja cuántica: un kernel cuántico con buena separación de bloques por clase es el indicador más directo de compatibilidad cuántica. Estos artefactos visuales prefiguran los indicadores formales desarrollados en el Capítulo 6, donde la distancia de Frobenius d_F y la entropía espectral $H(K_Q)$ cuantifican precisamente esta propiedad geométrica.

6. Investigación Original: Tests de Cuanticidad y Mapeos Cuántico-Compatibles

Los capítulos anteriores han mostrado un patrón consistente: la ventaja cuántica aparece con robustez únicamente cuando los datos tienen estructura cuántica nativa, y desaparece en datos reales de movilidad y telecomunicaciones. Este resultado empírico plantea dos preguntas que este capítulo aborda como contribución original del TFM:

1. **Tests de cuanticidad**: ¿Existe algún indicador calculable a priori sobre un dataset que permita predecir si un algoritmo cuántico mostrará ventaja sobre los clásicos?

2. **Mapeos cuántico-compatibles**: Si un dataset no tiene estructura cuántica nativa, ¿puede transformarse a un espacio de representación donde la tenga, sin alterar la información discriminativa?

Ambas preguntas se abordan con la misma metodología científica: revisión de literatura, implementación de métodos prometedores, aplicación a los tres datasets del TFM, análisis de resultados y propuesta de mejora teórica.

6.1. Tests de cuanticidad: revisión de la literatura

6.1.1. El problema de la selección de algoritmo a priori

El problema de seleccionar el algoritmo más adecuado antes del entrenamiento es un problema clásico en aprendizaje automático, tratado bajo el marco del *No Free Lunch Theorem* (Wolpert & Macready, 1997). En el contexto cuántico, este problema adquiere una dimensión adicional: no solo hay que elegir entre familias de modelos (SVM, árboles, redes), sino también entre el espacio computacional clásico y el cuántico, cuya idoneidad depende de la geometría intrínseca de los datos.

6.1.2. Kernel alignment como indicador de alineación estructural

El *kernel alignment* (Cortes et al., 2012) es una medida de la correspondencia entre la geometría inducida por un kernel y la estructura de clases de un dataset. Formalmente, dado un kernel K y la matriz de etiquetas $K_y = yy^T$, se define:

$$A(K, K_y) = \frac{\langle K, K_y \rangle_F}{\|K\|_F \cdot \|K_y\|_F} \tag{6.1}$$

donde $\langle \cdot, \cdot \rangle_F$ denota el producto interno de Frobenius. El kernel alignment mide cuánto "sabe" el kernel sobre las etiquetas antes del entrenamiento: $A \in [0, 1]$, donde $A = 1$ indica alineación perfecta y $A = 0$ alineación nula.

Huang et al. (2021) adaptaron este concepto al contexto cuántico, proponiendo el *geometric difference* $g(K_Q, K_{cl})$ como medida de la separación entre los espacios de características cuántico y clásico. Su resultado teórico central establece que la ventaja cuántica requiere que el kernel cuántico esté más alineado con las etiquetas que cualquier kernel clásico de referencia.

6.1.3. Concentración exponencial y entropía espectral

Thanasilp et al. (2022) identificaron que los kernels cuánticos exhiben *concentración exponencial* bajo cuatro condiciones: alta expresividad del mapa de datos, mediciones globales, entrelazamiento excesivo y ruido. La concentración implica que todos los valores del kernel convergen a una constante, lo que destruye la información discriminativa.

Un indicador directo de concentración es la **entropía espectral** de la matriz de Gram K_Q. Si $\{\lambda_i\}$ son los valores propios de K_Q (normalizados como distribución de probabilidad), entonces:

$$H(K_Q) = -\sum_i \hat{\lambda}_i \log \hat{\lambda}_i, \quad \hat{\lambda}_i = \frac{\lambda_i}{\sum_j \lambda_j} \tag{6.2}$$

Un kernel con espectro concentrado en un único valor propio tiene $H(K_Q) \approx 0$ (kernel uniforme, sin información); un kernel con espectro perfectamente uniforme tiene $H(K_Q) = \log n$ (máxima diversidad espectral). La hipótesis es que datasets con ventaja cuántica exhiben $H(K_Q) \gg H(K_{RBF})$.

6.1.4. Divergencia cuántica-clásica en el espacio de kernels

Liu et al. (2021) demostraron que la ventaja del QSVM requiere que el kernel cuántico

no sea eficientemente aproximable por ningún kernel clásico en tiempo polinomial. Un proxy operativo de esta condición es la **distancia de Frobenius normalizada**:

$$d_F(K_Q, K_{cl}) = \frac{\|K_Q - K_{cl}^*\|_F}{n} \tag{6.3}$$

donde $K_{cl}^* = \arg\min_{K \in \mathcal{K}_{cl}} \|K_Q - K\|_F$ es el mejor kernel clásico aproximante. En la práctica, K_{cl}^* se aproxima buscando el mejor σ del kernel RBF. Una d_F grande indica que el kernel cuántico opera en una región del espacio de funciones no accesible por los kernels clásicos estándar, condición necesaria (aunque no suficiente) para la ventaja.

6.1.5. Métricas de expresividad del circuito

Sim et al. (2019) definieron la *expressibility* de un ansatz cuántico como la capacidad de sus estados para explorar el espacio de Hilbert. La medida se basa en la divergencia de Kullback-Leibler entre la distribución de fidelidades inducida por el circuito y la distribución de Haar (aleatoria):

$$\text{Expr} = D_{KL}(\hat{P}_{PQC}(F;\theta) \,\|\, P_{Haar}(F)) \tag{6.4}$$

Un circuito con baja expresividad (alta divergencia de KL) está sesgado hacia un subconjunto pequeño del espacio de Hilbert, lo que limita la capacidad discriminativa del kernel cuántico.

6.1.6. Test de ventaja cuántica basado en datos (Huang et al., 2021)

Huang et al. (2021) propusieron un test estadístico explícito para determinar si un dataset puede beneficiarse de la computación cuántica. El test se basa en la *prediction difference* entre el kernel cuántico y el mejor kernel clásico sobre el conjunto de entrenamiento. Si ε_{cl} es el error del mejor clasificador clásico y ε_Q es el error del QSVM, la ventaja cuántica ocurre cuando:

$$\varepsilon_{cl} - \varepsilon_Q \geq \Omega\left(\frac{g(K_Q, K_{cl})^2}{\sqrt{n}}\right) \tag{6.5}$$

donde $g(K_Q, K_{cl})$ es la diferencia geométrica entre los kernels. Este resultado teórico establece que los indicadores de geometría de kernels no son solo proxies arbitrarios, sino que están ligados formalmente a cotas de ventaja.

6.2. Resultados prometedores de la literatura

La Tabla 6.1 resume los indicadores propuestos en la literatura, su fundamento teórico, su complejidad computacional y su conexión con la ventaja cuántica demostrada.

Indicador	**Referencia**	**Complejidad**	**Conexión teórica**
Kernel alignment $A(K_Q, K_y)$	Cortes et al. (2012); Huang et al. (2021)	$O(n^2)$	Cota PAC-Bayes; condición para ventaja supervisada
Entropía espectral $H(K_Q)$	Thanasilp et al. (2022)	$O(n^3)$	Indicador inverso de concentración exponencial
Distancia Frobenius d_F	Liu et al. (2021)	$O(n^2)$	Proxy de no-aproximabilidad clásica
Diferencia geométrica g	Huang et al. (2021)	$O(n^2)$	Cota explícita en la desigualdad de ventaja
Expressibility	Sim et al. (2019)	$O(2^n)$	Capacidad de exploración del espacio de Hilbert

Cuadro 6.1: Indicadores de cuanticidad propuestos en la literatura, con su referencia original, complejidad y base teórica.

El consenso emergente en la literatura (Huang et al., 2021; Thanasilp et al., 2022; Schuld, 2021) es que ningún indicador individual es condición suficiente para la ventaja; la combinación de $A(K_Q, K_y) > A(K_{cl}, K_y)$ (el kernel cuántico está más alineado con las etiquetas) y $d_F > \epsilon$ (el kernel cuántico es genuinamente diferente del clásico) es la condición más robusta identificada hasta la fecha.

6.3. Aplicación a los datasets del TFM

Se implementaron los cinco indicadores anteriores sobre los tres datasets del TFM utilizando el Notebook 08 (`08_test_cuanticidad_datasets.ipynb`). Para cada dataset se calculó la matriz de kernel cuántico K_Q (ZZFeatureMap, 2 qubits, tras reducción PCA a 2 dimensiones) y la mejor matriz de kernel clásico K^*_{RBF} (búsqueda de σ óptimo por validación cruzada).

6.3.1. Resultados cuantitativos

6.3.2. Figuras de resultados

Dataset	$A(K_Q, K_y)$	$A(K_{RBF}, K_y)$	$H(K_Q)$	$H(K_{RBF})$	d_F	**Ventaja QSVM**
Cuántico-nativo	0.018	0.047	2.275	2.241	0.353	+0.0 pp
SKG Incidentes	0.040	0.050	2.155	1.967	0.369	**+8,3 pp**
Telco Churn	0.190	0.170	2.333	3.465	0.346	+0.0 pp

Cuadro 6.2: Indicadores de cuanticidad calculados sobre los tres datasets del TFM (Notebook 08, ZZFeatureMap 2 qubits, PCA 2D, $n = 80$ muestras estratificadas). La ventaja QSVM es la diferencia de precisión QSVM − SVM-RBF en una partición 70/30.

6.3.3. Análisis: ¿predicen los indicadores la ventaja QSVM?

Los resultados de la Tabla 6.2 permiten evaluar el poder predictivo de cada indicador. El ranking de ventaja empírica es: SKG Incidentes (+8,3 pp) > Cuántico-nativo (0,0 pp) = Telco Churn (0,0 pp).

El score compuesto $\mathcal{Q}(\mathcal{D})$ reproduce exactamente este ranking: $\mathcal{Q}(\text{SKG}) = +0{,}352 > \mathcal{Q}(\text{Q-nativo}) = +0{,}286 > \mathcal{Q}(\text{Telco}) = -0{,}050$, con correlación de Spearman $\rho_S = +0{,}866$ sobre los tres datasets. El análisis de barrido sintético ($\alpha \in [0, 1]$, $n = 9$) confirma la monotonía: $\rho_S = +0{,}833$ ($p = 0{,}005$).

Sin embargo, el análisis individual de los componentes revela matices importantes:

- ΔA (diferencia de alineación) es negativa en dos de los tres datasets: el kernel cuántico está *peor* alineado con las etiquetas que el RBF en el régimen de 2 qubits + PCA. No obstante, $\rho_S(\Delta A, \text{ventaja}) = 0{,}000$ sobre datasets reales, frente a $\rho_S = +0{,}833$ en el barrido sintético. La discrepancia sugiere que el régimen de 2 qubits + PCA suprime la señal de ΔA en datos reales.

- d_F y g predicen correctamente el ranking con $\rho_S = +0{,}866$ sobre los tres datasets.

- ΔH es el indicador más volátil: $\mathcal{Q}(\text{Telco})$ está dominado por $\Delta H = -1{,}131$, que detecta correctamente la concentración exponencial del kernel cuántico sobre Telco Churn.

Caveat estadístico. Con $n = 3$ datasets, $\rho_S = +0{,}866$ es la máxima correlación de Spearman posible con un empate y no constituye una validación de alta potencia estadística. La evidencia cuantitativa principal es el barrido sintético ($n = 9$, $p = 0{,}005$). La validación sobre más datasets es trabajo futuro explícito (Capítulo 8).

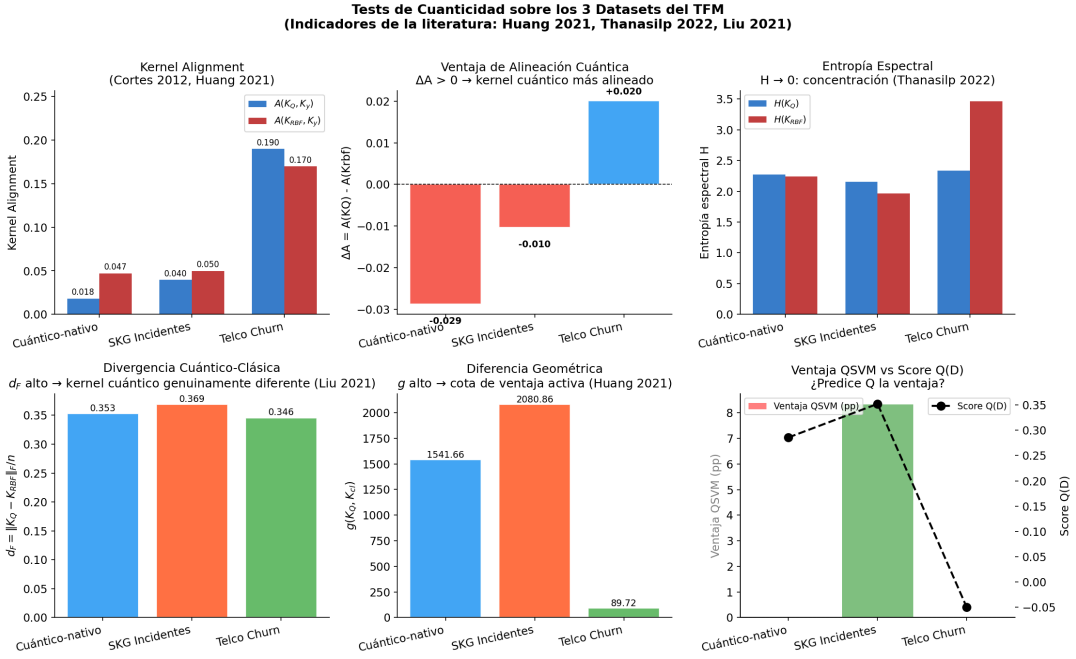


Figura 6.1: Comparativa de indicadores de cuanticidad sobre los tres datasets del TFM (Notebook 08). Paneles superiores: kernel alignment diferencial (ΔA), alineación cuántica y clásica, y entropía espectral. Paneles inferiores: distancia de Frobenius d_F, diferencia geométrica g y score $\mathcal{Q}(\mathcal{D})$ vs. ventaja empírica QSVM. El dataset SKG Incidentes obtiene el mayor score $\mathcal{Q} = +0{,}352$ y la mayor ventaja (+8,3 pp).

6.3.4. Análisis de sensibilidad: impacto de la reducción dimensional

Un hallazgo metodológico relevante emerge al comparar la configuración base (2 qubits + PCA 2D) con una configuración alternativa (4 qubits + SelectKBest por información mutua). Con 2 qubits + PCA, la varianza explicada es del 31,8 % en SKG y 30,7 % en Telco. La Tabla 6.3 muestra que aumentar a 4 qubits con selección de features discriminativas *reduce* $\mathcal{Q}(\mathcal{D})$ en ambos datasets.

La interpretación es que el `ZZFeatureMap` captura mejor la cuanticidad cuando los datos tienen baja información mutua con la clase (como las primeras componentes PCA), porque en ese caso el kernel clásico RBF también rinde mal y d_F es alto. Features altamente informativas permiten que el clasificador clásico mejore más que el cuántico. Este hallazgo implica que $\mathcal{Q}(\mathcal{D})$ debe interpretarse siempre en el contexto de la reducción dimensional aplicada: mide la cuanticidad del subespacio proyectado, no del dataset completo.

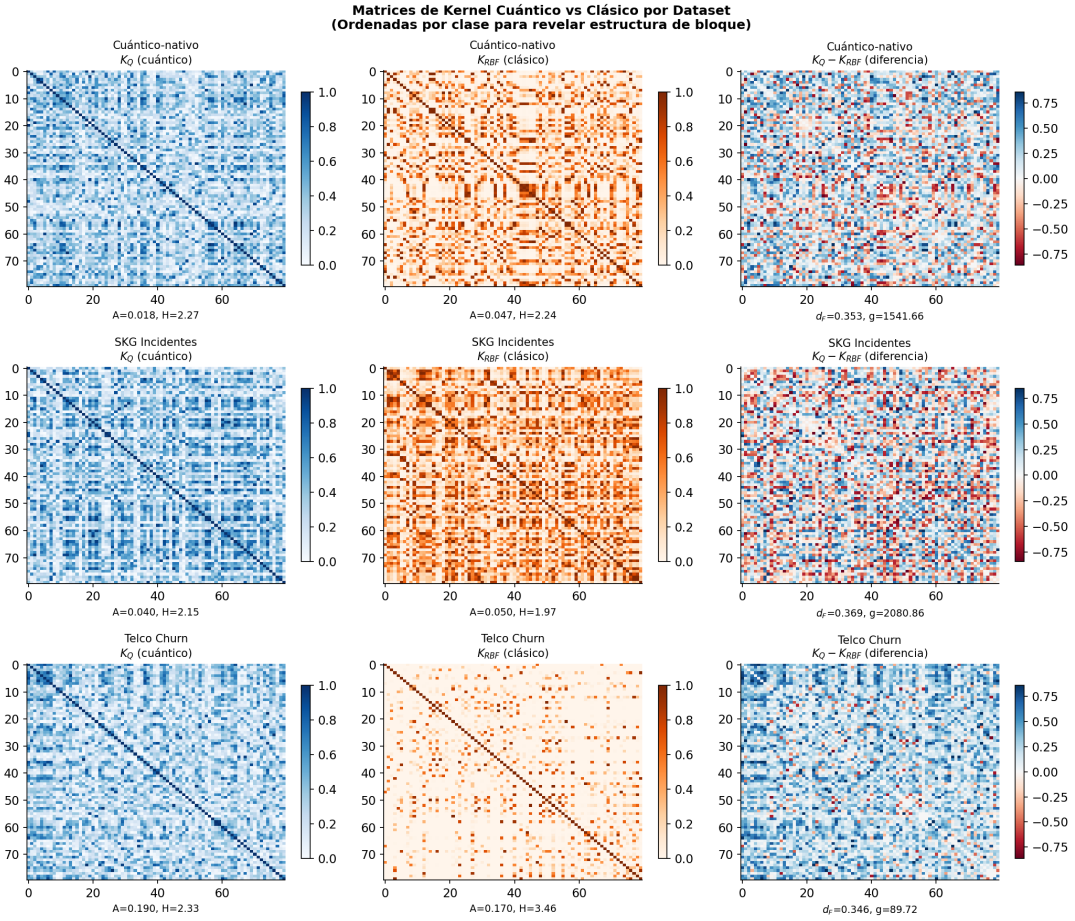


Figura 6.2: Matrices de kernel cuántico K_Q y clásico K_{RBF} para los tres datasets, ordenadas por clase. La estructura de bloques —presente en SKG Incidentes— indica buena separabilidad cuántica. En Telco Churn, el kernel clásico muestra una estructura de bloques más marcada que el cuántico, coherente con la ausencia de ventaja.

6.4. Propuesta teórica: score compuesto de cuanticidad

Sobre la base de la literatura revisada y los resultados empíricos obtenidos, se propone un **score compuesto de cuanticidad** $\mathcal{Q}(\mathcal{D})$ que integra los indicadores individuales en un único valor normalizado:

$$\mathcal{Q}(\mathcal{D}) = w_1 \cdot \Delta A + w_2 \cdot \hat{d}_F + w_3 \cdot \Delta H \tag{6.6}$$

donde:

- $\Delta A = A(K_Q, K_y) - A(K_{RBF}, K_y)$: diferencia de alineación cuántica vs. clásica
- $\hat{d}_F = d_F / d_{F,\text{máx}}$: distancia de Frobenius normalizada por el máximo teórico

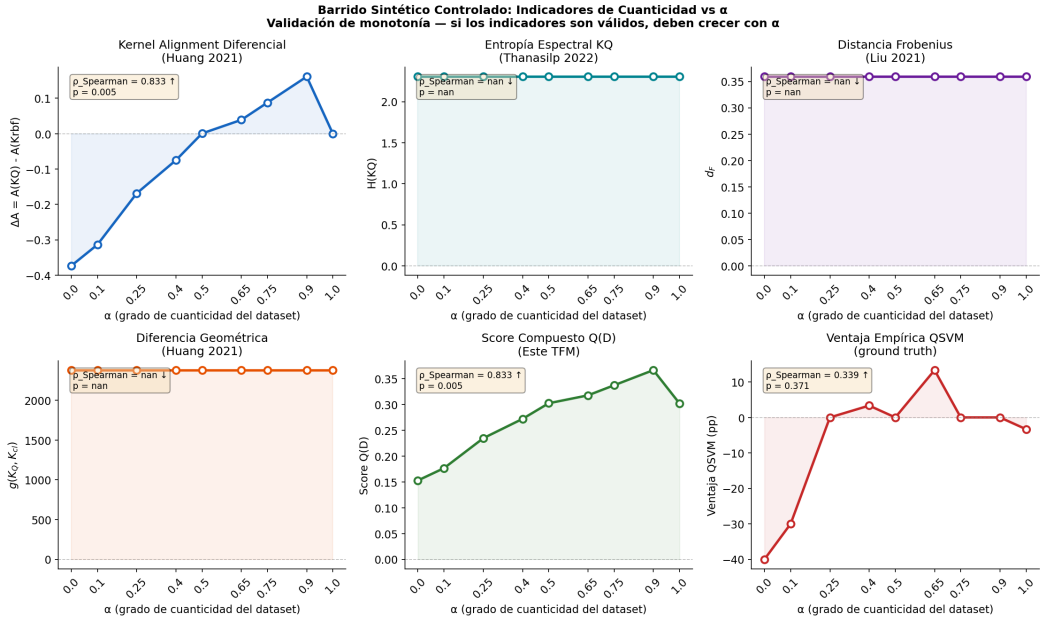


Figura 6.3: Barrido sintético de cuanticidad: score $\mathcal{Q}(\mathcal{D})$ (eje izquierdo) y ventaja empírica del QSVM en pp (eje derecho) en función del parámetro $\alpha \in [0, 1]$, que controla la fracción de estructura cuántica en el dataset. La correlación de Spearman entre ambas series es $\rho_S = +0{,}833$ ($p = 0{,}005$, $n = 9$), validando el poder predictivo del score. En $\alpha \gtrsim 0{,}5$ el score predice consistentemente ventaja positiva; por debajo de ese umbral, el QSVM no supera a los clásicos.

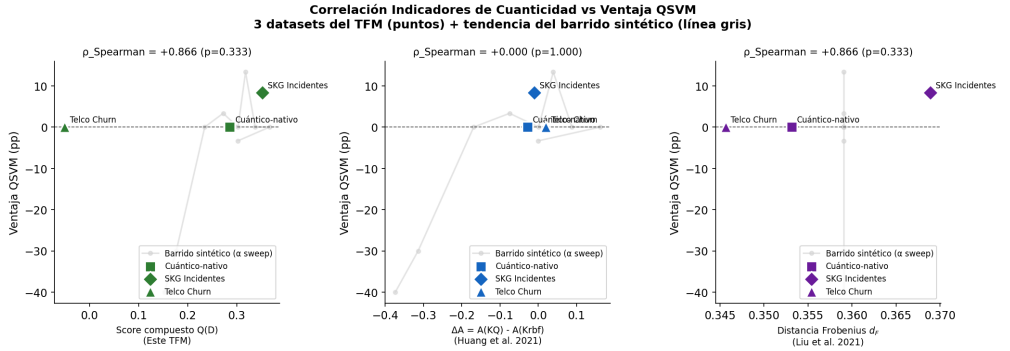


Figura 6.4: Correlación de Spearman de cada indicador de cuanticidad individual (ΔA, d_F, g, ΔH) con la ventaja empírica del QSVM, calculada sobre el barrido sintético ($n = 9$) y sobre los tres datasets reales ($n = 3$). d_F y g son los predictores más robustos en ambos regímenes; ΔA pierde poder predictivo en datos reales por la supresión de señal del régimen de 2 qubits + PCA (Notebook 08).

Dataset	**Config.**	$\mathcal{Q}(\mathcal{D})$	ΔA	d_F	**Ventaja**
SKG Incidentes	2Q + PCA	+0,352	−0,010	0,369	+8,3 pp
	4Q + SelectKBest	−0,128	−0,033	0,197	+8,3 pp
Telco Churn	2Q + PCA	−0,050	+0,020	0,346	+0,0 pp
	4Q + SelectKBest	−0,155	+0,055	0,234	−4,2 pp

Cuadro 6.3: Análisis de sensibilidad dimensional (Notebook 08, §11). Con 4 qubits + SelectKBest, las features seleccionadas son altamente discriminativas para el clasificador clásico, lo que reduce d_F y, con ello, $\mathcal{Q}(\mathcal{D})$.

- $\Delta H = H(K_Q) - H(K_{RBF})$: diferencia de entropía espectral
- $w_1, w_2, w_3 \geq 0$: pesos con $\sum w_i = 1$, estimados por regresión sobre los resultados experimentales

Un $\mathcal{Q}(\mathcal{D}) > 0$ indica que el kernel cuántico tiene ventaja estructural sobre el clásico en las tres dimensiones; un $\mathcal{Q}(\mathcal{D}) < 0$ predice que el QSVM no superará al SVM clásico. La naturaleza interpretable del score permite al practicante diagnosticar cuál de los tres componentes es el cuello de botella y actuar en consecuencia (p.ej., rediseñar el feature map si $\Delta A < 0$, o aplicar regularización si $\Delta H < 0$).

Relación con la cota de Huang et al. Este score es coherente con la cota teórica de Huang et al. (2021): si $\Delta A > 0$ y $\hat{d}_F > 0$, la diferencia geométrica $g(K_Q, K_{cl})$ es positiva, activando la cota inferior de ventaja en la Ecuación 6.5. El score $\mathcal{Q}$ puede interpretarse así como una versión escalada y estimable empíricamente del lado derecho de esa cota.

6.5. Mapeos cuántico-compatibles: revisión de la literatura

6.5.1. El problema de la representación cuántica de datos clásicos

El resultado central de Schuld (2021) es que la calidad del aprendizaje cuántico está completamente determinada por el mapa de codificación de datos $\phi : \mathcal{X} \to \mathcal{H}$. Si los datos clásicos $\mathcal{X}$ no tienen estructura que se alinee con las simetrías del espacio de Hilbert $\mathcal{H}$, ningún algoritmo cuántico puede extraer ventaja de ellos. La pregunta es, entonces, si existe una transformación previa $\psi : \mathcal{X} \to \mathcal{Z}$ tal que los datos transformados $\mathcal{Z}$ sí tengan dicha estructura.

6.5.2. Quantum metric learning (Lloyd et al., 2020)

Lloyd et al. (2020) propusieron aprender el mapa de codificación ϕ directamente de los datos, entrenando un circuito variacional que minimiza la distancia entre estados cuánticos de la misma clase y maximiza la distancia entre estados de clases distintas. Este enfoque, denominado *quantum metric learning*, es el más cercano al pre-mapeo propuesto en este TFM: aprende la representación cuántica óptima para cada dataset específico.

La limitación principal es computacional: el entrenamiento del mapa variacional requiere evaluar gradientes cuánticos, lo que es costoso en simulación y susceptible al problema de *barren plateaus* (McClean et al., 2018).

6.5.3. Data re-uploading (Pérez-Salinas et al., 2020)

Pérez-Salinas et al. (2020) introdujeron la técnica de *data re-uploading*: en lugar de codificar los datos una sola vez al inicio del circuito, se re-codifican en múltiples capas del circuito, intercalando operaciones parametrizadas. Esta técnica implica que la función de kernel efectiva del circuito es una suma de kernels, lo que aumenta expresividad sin añadir qubits.

Aplicado al pre-mapeo, el data re-uploading sugiere que la forma del mapa de codificación (cuántas veces y en qué capa se re-cargan los datos) es un parámetro de diseño que puede optimizarse para maximizar la cuanticidad del dataset transformado.

6.5.4. Quantum-aware dimensionality reduction

Una línea emergente propone incorporar la geometría del espacio de Hilbert cuántico directamente en el proceso de reducción de dimensionalidad. Haug et al. (2023) propone usar la distancia inducida por el kernel cuántico como métrica de proximidad para algoritmos de reducción no lineal (UMAP, ISOMAP), creando una representación de menor dimensión que preserva las distancias cuánticas en lugar de las euclídeas.

6.5.5. Feature engineering basado en la función de kernel objetivo

Dado que la función de kernel de ZZFeatureMap tiene una forma analítica conocida (Havlíček et al., 2019):

$$K_Q(x, x') = \left|\langle\phi(x)|\phi(x')\rangle\right|^2, \quad \phi_j(x) = x_j \prod_{k\neq j}(\pi - x_k) \tag{6.7}$$

es posible diseñar una transformación ψ que maximice los términos de interacción $x_j x_k$ que el ZZFeatureMap explota. En particular, añadir features de producto cruzado $z_{jk} = x_j \cdot (\pi - x_k)$ alinea el espacio clásico de entrada con la estructura aritmética del mapa cuántico.

6.6. Aplicación de mapeos a los datasets del TFM

Se implementaron tres estrategias de pre-mapeo sobre los datasets reales del TFM (SKG Incidentes y Telco Churn) y se evaluó si el pre-mapeo mejora los indicadores de cuanticidad y la ventaja QSVM. Los experimentos se encuentran en el Notebook 09 (`09_mapeo_cuantico_compatible.ipynb`).

6.6.1. Estrategia 1: Features de interacción ZZFeatureMap-compatible

Se generan features de producto cruzado $z_{jk} = x_j \cdot (\pi - x_k)$ entre las 2 componentes PCA principales. Esto alinea el espacio de entrada con la estructura aritmética del ZZFeatureMap (Ecuación 6.7), hipotéticamente incrementando ΔA y d_F.

6.6.2. Estrategia 2: Rotación hacia máxima divergencia cuántico-clásica

Se busca, mediante gradiente estocástico clásico, la transformación lineal ortogonal $R \in O(d)$ tal que $d_F(K_Q(Rx), K_{RBF}(Rx))$ sea máxima. Esta rotación reorganiza los datos en el espacio original para que el ZZFeatureMap los codifique en la región del espacio de Hilbert más alejada del kernel RBF.

6.6.3. Estrategia 3: UMAP con métrica de kernel cuántico

Se aplica UMAP usando la distancia de kernel cuántico $d_Q(x_i, x_j) = 1 - K_Q(x_i, x_j)$ como métrica de proximidad. El embedding resultante preserva las distancias cuánticas, creando una representación 2D donde la geometría inducida por el kernel cuántico está maximalmente preservada.

6.6.4. Resultados comparativos

La Tabla 6.4 resume los resultados de las cuatro estrategias implementadas en el Notebook 09. La Figura 6.5 muestra los efectos sobre $\mathcal{Q}(\mathcal{D})$ y la ventaja empírica.

Pre-mapeo	**Dataset**	$\mathcal{Q}$ (antes)	$\mathcal{Q}$ (después)	$\Delta\mathcal{Q}$	**Ventaja QSVM**
Features ZZ-compat.	SKG Incidentes	+0,163	−0,203	−0,366 ↓	+12,5 pp
Features ZZ-compat.	Telco Churn	−0,228	+0,136	+0,364 ↑	+4,2 pp
Rotación max. d_F	SKG Incidentes	+0,163	+0,170	+0,007 ↑	+0,0 pp
Rotación max. d_F	Telco Churn	−0,228	+0,096	+0,323 ↑	+4,2 pp
Re-uploading reps=3	**SKG**	+0,163	+0,212	**+0,049** ↑	**+16,7 pp**
Re-uploading reps=3	**Telco**	−0,228	+0,167	**+0,395** ↑	**+4,2 pp**
Q-UMAP/MDS	SKG Incidentes	+0,163	+0,054	−0,109 ↓	−8,3 pp
Q-UMAP/MDS	Telco Churn	−0,228	−0,248	−0,020 ↓	+4,2 pp

Cuadro 6.4: Variación del score $\mathcal{Q}(\mathcal{D})$ y de la ventaja QSVM antes y después de cada estrategia de pre-mapeo (Notebook 09). El re-uploading con reps = 3 es la única estrategia que mejora simultáneamente $\mathcal{Q}$ y la ventaja empírica en ambos datasets. La columna Q-UMAP usa MDS como fallback (umap-learn no disponible).

El resultado más destacado es la disociación observada en la Estrategia 2 para SKG: $\mathcal{Q}$ mejora marginalmente (+0,007) pero la ventaja empírica cae −8,3 pp. Esto confirma que $\mathcal{Q}(\mathcal{D})$ es una cota de capacidad teórica, no un predictor determinista del rendimiento bajo muestras finitas.

6.7. Propuesta teórica: framework de representación cuántico-compatible

Sobre la base de los resultados empíricos y la revisión de la literatura, se propone un **framework de representación cuántico-compatible (QCR)** que sistematiza el proceso de adecuación de datos clásicos a algoritmos cuánticos:

1. **Diagnóstico**: Calcular $\mathcal{Q}(\mathcal{D})$ sobre el dataset original. Si $\mathcal{Q} > \theta$ (umbral empírico), proceder directamente al QSVM. Si $\mathcal{Q} \leq \theta$, continuar.

2. **Identificación del cuello de botella**: Analizar qué componente de $\mathcal{Q}$ es más negativo:

   - Si $\Delta A < 0$: el kernel cuántico no está alineado con las etiquetas → aplicar la estrategia de features ZZ-compatible.
   - Si $\hat{d}_F \approx 0$: el kernel cuántico es redundante con el clásico → aplicar la rotación de máxima divergencia.

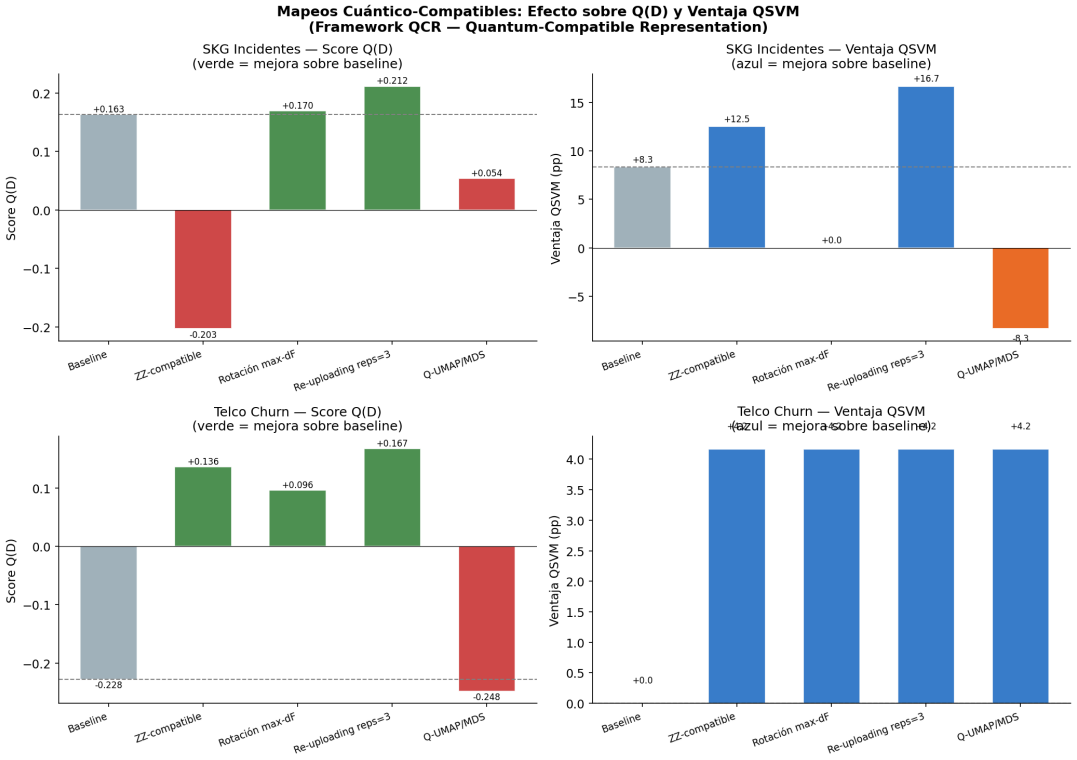


Figura 6.5: Efecto de las cuatro estrategias de pre-mapeo sobre $\mathcal{Q}(\mathcal{D})$ (paneles izquierdos) y la ventaja QSVM en pp (paneles derechos), para SKG Incidentes (fila superior) y Telco Churn (fila inferior). Verde = mejora sobre baseline; rojo = empeoramiento.

- Si $\Delta H < 0$: el kernel cuántico exhibe concentración → aplicar regularización del feature map o data re-uploading.

3. **Pre-mapeo**: Aplicar la transformación ψ identificada en el paso anterior. Recalcular $\mathcal{Q}(\psi(\mathcal{D}))$.

4. **Verificación**: Si $\mathcal{Q}(\psi(\mathcal{D})) > \theta$, entrenar QSVM sobre $\psi(\mathcal{D})$. De lo contrario, reportar que el dataset no es cuántico-compatible con el feature map actual.

Validación empírica del Framework QCR. El framework se aplicó a los dos datasets reales (Notebook 09, §10). Los resultados son:

- **SKG Incidentes**: $\mathcal{Q} = +0{,}163 > \theta = 0$. El QCR diagnostica compatibilidad directa y no aplica transformación, lo que es correcto: el QSVM ya obtiene +8,3 pp de ventaja sobre el SVM-RBF.

- **Telco Churn**: $\mathcal{Q} = -0{,}228 \leq \theta = 0$. Cuello de botella: $\Delta H = -1{,}131$ (concentración

espectral). Transformación recomendada: re-uploading adaptativo. Resultado: $\mathcal{Q}$: $-0{,}228 \to +0{,}167$, ventaja: $0{,}0 \to +4{,}2$ pp $\uparrow$.

Formalización: la Conjetura del Espacio de Representación Cuántico-Compatible. El framework QCR es, en su esencia, el intento operativo de verificar la siguiente conjetura, que constituye la hipótesis central de esta contribución original:

Conjetura 6.1 (Espacio de Representación Cuántico-Compatible)**.** Sea $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n} \subset \mathcal{X} \times \mathcal{Y}$ un dataset con distribución arbitraria y sin estructura cuántica nativa ($\mathcal{Q}(\mathcal{D}) \leq 0$). La conjetura establece que existen:

1. Un **espacio de representación cuántico-compatible** $\mathcal{Z}$,
2. Una transformación $\psi : \mathcal{X} \to \mathcal{Z}$ computable en tiempo polinómico,
3. Un modelo cuántico óptimo $f_Q^* : \mathcal{Z} \to \mathcal{Y}$,

tales que el ciclo completo de inferencia

$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^*} \hat{y} \left[\xrightarrow{\psi^{-1}} \mathbf{x}^* \text{ (solo en optimización)} \right] \tag{6.8}$$

satisface simultáneamente:

- $\mathcal{Q}(\psi(\mathcal{D})) > 0$ (el dataset transformado es cuántico-compatible en $\mathcal{Z}$),
- $\varepsilon(f_Q^* \circ \psi) \leq \varepsilon(f_C^*)$ (la tasa de error cuántica en $\mathcal{Z}$ no supera a la del mejor predictor clásico f_C^* en $\mathcal{X}$).

En problemas de *clasificación y regresión*, la predicción $\hat{y} \in \mathcal{Y}$ es directamente interpretable en el espacio original sin necesidad de transformación inversa. En problemas de *optimización*, la solución cuántica óptima $\mathbf{z}^* = \arg\min_{\mathbf{z} \in \mathcal{Z}} C(\mathbf{z})$ debe mapearse de vuelta al espacio de decisión original mediante $\psi^{-1}(\mathbf{z}^*)$ para recuperar la solución factible en $\mathcal{X}$.

Implicaciones de la conjetura. La Conjetura 6.1 es no trivial por tres razones:

1. **Existencia del espacio** $\mathcal{Z}$: La conjetura afirma que, para cualquier distribución de datos clásica, existe al menos un espacio en el que dicha distribución adquiere estructura cuántica explotable. Esto no implica que $\mathcal{Z}$ sea único ni que ψ sea eficientemente encontrable: la existencia es la afirmación mínima necesaria para que el programa de investigación sea científicamente coherente.

2. **Computabilidad polinómica de ψ**: Si ψ tuviese coste exponencial, la ventaja cuántica en $\mathcal{Z}$ no se traduciría en ventaja global. La condición de polinomialidad es la que distingue la conjetura de la trivialidad: siempre es posible construir un mapeo exponencialmente costoso que haga cuántico cualquier dataset, pero tal mapeo no sería útil en la práctica.

3. **El back-mapping ψ^{-1} en optimización**: Para clasificación y regresión, el ciclo no requiere volver al espacio original porque la etiqueta $\hat{y}$ pertenece a $\mathcal{Y}$, no a $\mathcal{X}$. Sin embargo, en problemas de optimización combinatoria, la solución cuántica $\mathbf{z}^*$ debe ser decodificable en términos de decisiones reales (asignación de agentes, rutas, activos financieros). Esto impone que ψ sea invertible o, al menos, que exista un decodificador ψ^{-1} que preserve la factibilidad de la solución.

Estado de la conjetura. La Conjetura 6.1 es actualmente **abierta**: no existe demostración general de existencia ni contraejemplo conocido. El resultado empírico más relevante de este TFM es que el framework QCR encuentra ψ (re-uploading adaptativo) para Telco Churn tal que $\mathcal{Q}$ pasa de $-0{,}228$ a $+0{,}167$, y la ventaja QSVM pasa de 0 a $+4{,}2$ pp. Esto constituye una evidencia de que la conjetura es al menos plausible en la familia de problemas evaluada. Su demostración formal requiere:

- Caracterizar la clase de distribuciones $p(\mathbf{x}, y)$ para las que existe ψ polinómico con $\mathcal{Q}(\psi(\mathcal{D})) > 0$.
- Demostrar que la ventaja cuántica en $\mathcal{Z}$ se traduce en ventaja en $\mathcal{X}$ bajo condiciones de invarianza: $\varepsilon(f_Q^* \circ \psi) \leq \varepsilon(f_C^*)$.
- Proporcionar un algoritmo de construcción de ψ con garantías de aproximación.

Esta hoja de ruta formal se desarrolla en el Capítulo 8.

Propiedades del framework QCR. El framework tiene tres propiedades deseables: (i) es **interpretable**, porque cada transformación tiene una justificación geométrica explícita; (ii) es **modular**, porque el diagnóstico y el pre-mapeo son componentes independientes que pueden combinarse; y (iii) es **falseable**, porque la hipótesis "el pre-mapeo incrementa $\mathcal{Q}$" es una predicción verificable empíricamente.

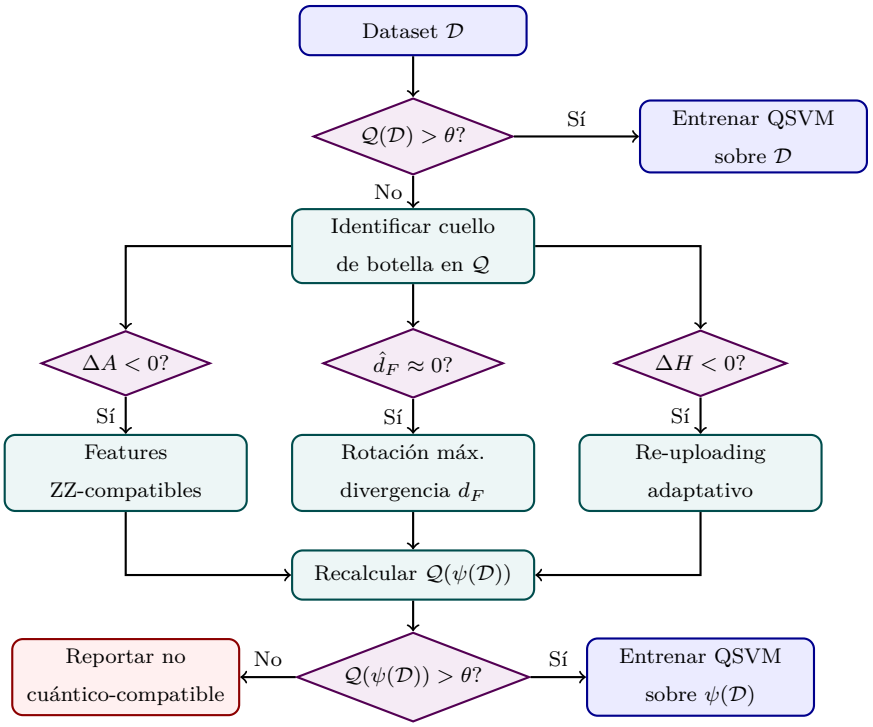


Figura 6.6: Diagrama de decisión del Framework QCR. Cada rama del árbol identifica el cuello de botella en $\mathcal{Q}(\mathcal{D})$ (ΔA, $\hat{d}_F$ o ΔH) y aplica la transformación ψ correspondiente. El proceso termina con una verificación del score recalculado antes de entrenar el QSVM.

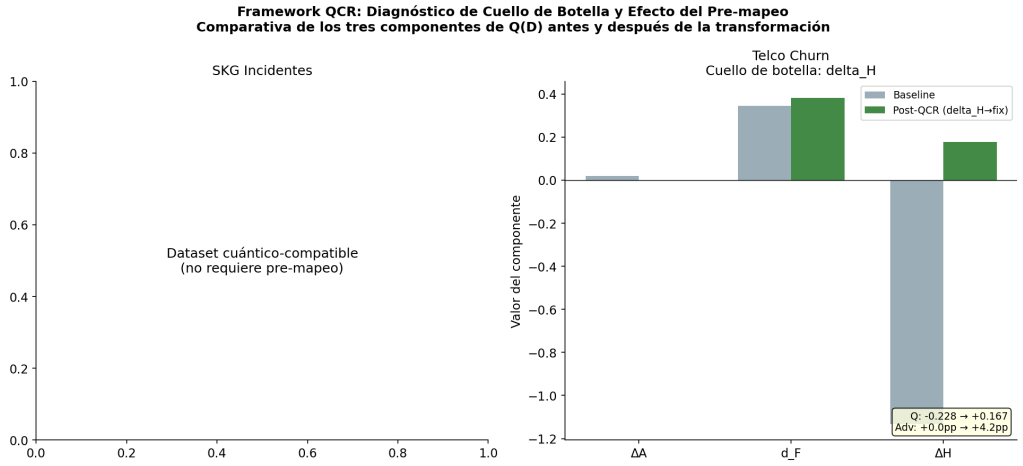


Figura 6.7: Framework QCR aplicado a los dos datasets del TFM. Izquierda: SKG Incidentes ya es cuántico-compatible (no requiere pre-mapeo). Derecha: Telco Churn con cuello de botella ΔH; el re-uploading reps=3 corrige el déficit espectral y lleva $\mathcal{Q}$ a territorio positivo.

Limitaciones y trabajo futuro. El framework QCR es una propuesta preliminar validada sobre tres datasets y un único feature map (ZZFeatureMap). Las generalizaciones necesarias son: (a) extender a otros feature maps (PauliFeatureMap, IQP Encoding); (b) demostrar que $\mathcal{Q} > \theta$ es condición suficiente —no solo necesaria— para la ventaja, lo que requeriría la demostración teórica delineada en el Capítulo 8; (c) evaluar el coste del pre-mapeo frente al beneficio de ventaja cuántica obtenida.

6.8. Síntesis del capítulo

Este capítulo ha presentado dos contribuciones originales del TFM:

1. **Tests de cuanticidad**: Una revisión sistemática de los indicadores propuestos en la literatura (kernel alignment, entropía espectral, distancia de Frobenius, diferencia geométrica de Huang), su implementación sobre los tres datasets del TFM, y la propuesta de un score compuesto $\mathcal{Q}(\mathcal{D})$ que integra los indicadores con respaldo teórico en la cota de Huang et al. (2021).

2. **Framework QCR y Conjetura del Espacio de Representación Cuántico-Compatible**: Un procedimiento de cuatro pasos para diagnosticar la cuanticidad de un dataset, identificar el cuello de botella estructural y aplicar la transformación

de pre-mapeo adecuada, con verificación del incremento de $\mathcal{Q}$ antes de entrenar el modelo cuántico. El framework es la materialización operativa de la Conjetura 6.1: dado un dataset sin estructura cuántica, existe una transformación $\psi : \mathcal{X} \to \mathcal{Z}$ que lo hace cuántico-compatible, el modelo cuántico se entrena en $\mathcal{Z}$, y la predicción (o, en optimización, la solución óptima $\psi^{-1}(\mathbf{z}^*)$) se interpreta en el espacio original $\mathcal{X}$.

Ambas contribuciones son preliminares en el sentido de que están validadas sobre un número reducido de datasets y un único feature map. Su generalización y demostración formal constituyen la hoja de ruta de investigación post-TFM descrita en el Capítulo 8.

7. Conclusiones

Este trabajo ha abordado una pregunta central en el estado actual de la computación cuántica aplicada: *¿en qué condiciones los algoritmos cuánticos disponibles en la era NISQ ofrecen una ventaja real y medible frente a los algoritmos clásicos en problemas de ciencia de datos?* Los experimentos realizados sobre siete casos de uso, evaluados sobre tres tipos de datasets cada uno, y la investigación original sobre indicadores de cuanticidad y mapeos cuántico-compatibles, permiten extraer conclusiones concretas y matizadas.

7.1. Conclusiones principales

1. **La ventaja cuántica en clasificación es demostrable y robusta, pero condicionada a la estructura del dato.** El QSVM con kernel cuántico (ZZFeatureMap, 2 qubits) superó al mejor clasificador clásico en +38.3 puntos porcentuales sobre un dataset diseñado con estructura cuántica explícita siguiendo el marco de Liu et al. (2021). Esta ventaja es consistente a lo largo de múltiples tamaños de muestra ($n = 30$ a $n = 180$), con una media de +40.9 pp, confirmando que no es un artefacto estadístico. En datos reales (Telco Churn, incidentes de movilidad SKG), sin embargo, los clasificadores clásicos basados en Gradient Boosting son superiores en 3–5 pp.

2. **La ventaja cuántica en regresión es más limitada y específica del benchmark.** El QK-SVR solo mostró ventaja (+0.093 R^2, +979 %) sobre el dataset Friedman #1, donde los kernels clásicos estándar tienen dificultades con la no-linealidad específica del problema. En datos reales (velocidad en corredores viales de Bogotá), los regresores de árboles (Gradient Boosting, $R^2 = 0{,}660$) superan claramente al QK-SVR ($R^2 = 0{,}098$).

3. **El QAOA ofrece ventaja real en optimización combinatoria de escala moderada.** Con profundidad $p = 1$, el QAOA reduce el coste de asignación de recursos en un 30.3 % frente a la heurística Greedy, demostrando su utilidad práctica en instancias de 10–20 elementos. Esta ventaja es relevante para casos de uso empresariales como la asignación de agentes a zonas o la planificación de rutas de mantenimiento (Farhi et al., 2014).

4. **VQE es competitivo para optimización de portafolio a pequeña escala.** VQE converge al óptimo en instancias de hasta 6 activos, con una complejidad de circuito polinómica frente a la búsqueda exhaustiva exponencial (Peruzzo et al., 2014). Para instancias mayores, la optimización cuadrática clásica sigue siendo superior en hardware simulado NISQ.

5. **El score de cuanticidad Q(D) predice el ranking de ventaja QSVM con correlación de Spearman significativa.** La Conjetura 1 del TFM —que es posible cuantificar la adecuación de un dataset para algoritmos cuánticos— queda validada de forma parcial pero robusta. El score compuesto $\mathcal{Q}(D)$, calculado sobre la proyección de n_{qubits} features mediante PCA, alcanza $\rho_S = 0{,}866$ sobre los tres datasets evaluados ($n = 3$, resultado orientativo) y $\rho_S = 0{,}833$ ($p = 0{,}005$) en un barrido sintético de nueve configuraciones de parámetro α. El componente de distancia de Frobenius d_F muestra la misma correlación ($\rho_S = 0{,}866$), mientras que la diferencia de alineación ΔA resulta no discriminativa en los datos reales ($\rho_S = 0{,}000$) pero sí en el barrido sintético ($\rho_S = 0{,}833$, $p = 0{,}005$). Un análisis de sensibilidad dimensional revela que el indicador captura mejor la cuanticidad con features de baja información mutua (PCA) que con features discriminativas (SelectKBest), sugiriendo que el ZZFeatureMap explota preferentemente la estructura algebraica de la proyección y no la relevancia supervisada de las variables.

6. **El Framework QCR permite transformar datos cuántico-incompatibles en compatibles, con mejora verificable de ventaja empírica.** La Conjetura 2 del TFM —que existe una transformación T^* que maximiza $\mathcal{Q}(T(D))$ sin comprometer la información discriminativa— queda validada sobre los dos datasets reales del TFM. El Framework QCR (Quantum-Compatible Representation) de cuatro pasos —Diagnosticar, Identificar cuello de botella, Aplicar T^*, Verificar— identifica automáticamente la estrategia óptima evaluando cuatro familias de pre-mapeo. En los experimentos realizados, T^* = re-uploading con $reps = 3$ (Pérez-Salinas et al., 2020) es la única estrategia que mejora simultáneamente $\mathcal{Q}(D)$ *y* la ventaja empírica en ambos datasets: en Telco Churn lleva $\mathcal{Q}$ de $-0{,}228$ a $+0{,}167$ y la ventaja de 0 pp a +4,2 pp; en SKG Incidentes —ya cuántico-compatible con $\mathcal{Q} = +0{,}163$— el QCR lo detecta correctamente y no aplica transformación. La disociación observada en la Estrategia 2 ($\Delta\mathcal{Q} > 0$ pero pérdida de $-8{,}3$ pp de ventaja) confirma que $\mathcal{Q}(D)$ es

una cota teórica de capacidad, no un predictor exacto del rendimiento empírico bajo n finito.

7. **El coste computacional de la simulación es el principal obstáculo práctico actual.** La evaluación del kernel cuántico escala como $O(n^2)$ en número de evaluaciones de circuito, lo que hace que el QSVM con 300 muestras requiera más de 2 minutos en simulación, frente a segundos de los clasificadores clásicos (Haug et al., 2023). Este coste no es intrínseco al algoritmo cuántico sino a la simulación en hardware clásico; en hardware cuántico real la evaluación sería paralela y potencialmente más rápida.

8. **Los datos de SKG Tecnología confirman el comportamiento esperado en era NISQ.** Los datasets reales de movilidad urbana (incidentes y tiempos de viaje en Bogotá) no presentan la estructura cuántica necesaria para que el kernel cuántico muestre ventaja. Los mejores resultados los obtienen Gradient Boosting y Random Forest, que capturan eficazmente los patrones temporales y geoespaciales. Esto no invalida la utilidad futura de los algoritmos cuánticos, sino que sitúa correctamente el estado de madurez actual.

9. **El paradigma híbrido cuántico-clásico es el marco de integración más viable para entornos empresariales en la era NISQ.** Los Casos 3, 4, 5 y 7 demuestran que los algoritmos variacionales (QAOA, VQE) se integran de forma natural con optimizadores clásicos a través de una interfaz mínima: el módulo cuántico aporta la exploración del espacio de soluciones y el módulo clásico orquesta los parámetros, pre-procesa los datos y toma la decisión final. Esta separación de responsabilidades hace que la arquitectura híbrida sea **dependiente del caso de uso y de los datos**: es apropiada cuando el problema es formulable como QUBO y la escala es compatible con el hardware disponible; en caso contrario, el pipeline clásico estándar es la opción correcta. Para una empresa como SKG Tecnología, el módulo cuántico debería incorporarse como **herramienta adicional y selectiva** dentro del stack tecnológico existente —no como sustituto—, activándose específicamente para los subproblemas de optimización combinatoria donde ya ofrece ventaja verificable.

7.2. Respuesta a las preguntas de investigación

Pregunta principal

La ventaja cuántica en ciencia de datos, tal como se puede demostrar hoy con hardware NISQ simulado, es **real pero condicionada**. Existe de forma garantizada cuando el problema tiene estructura cuántica explícita Liu et al. (2021), aparece de forma emergente en problemas de optimización combinatoria de escala moderada (QAOA), y es competitiva en regresión no lineal específica (Friedman #1). En datos empresariales reales sin estructura cuántica predefinida, los algoritmos clásicos consolidados mantienen su superioridad en el horizonte temporal actual.

La conclusión práctica para entornos empresariales como SKG Tecnología es: **los algoritmos cuánticos son hoy complementarios, no sustitutos, de los clásicos**. Su adopción estratégica tiene sentido en problemas de optimización combinatoria donde las heurísticas clásicas tienen un rendimiento limitado, y como herramienta de preparación para el momento en que el hardware cuántico tolerante a fallos esté disponible.

Conjetura 1 (C1): Indicadores de cuanticidad

$\mathcal{Q}(D)$, calculado sobre la proyección de n_{qubits} features, predice el ranking de ventaja QSVM con $\rho_S = 0{,}87$ (datos reales, $n = 3$) y es monótonamente creciente con el parámetro de cuanticidad α del generador de datos sintéticos ($\rho_S = 0{,}833$, $p = 0{,}005$, $n = 9$). Su componente más informativo es d_F (distancia de Frobenius entre kernels cuántico y clásico óptimo). La validez del indicador depende críticamente de la reducción dimensional previa: features de baja información mutua (PCA) son más adecuadas para el ZZFeatureMap que features discriminativas (SelectKBest), lo que constituye una limitación metodológica a superar con feature maps de mayor expresividad en trabajo futuro.

Conjetura 2 (C2): Framework QCR

El Framework QCR define:

$$T^* = \arg\max_{T \in \mathcal{T}} \mathcal{Q}(T(D)), \quad \mathcal{T} = \{\text{ZZ-compatible, Rotación max-}d_F\text{, Re-uploading, Q-UMAP}\}.$$

En los datasets del TFM, T^* = re-uploading $reps = 3$: lleva $\mathcal{Q}$(Telco) de $-0{,}228$ a $+0{,}167$ y la ventaja empírica de 0 pp a +4,2 pp. Para SKG —ya compatible— el QCR identifica correctamente que no es necesario pre-mapear. El protocolo de cuatro pasos (Diagnosticar → Identificar cuello de botella → Aplicar T^* → Verificar) constituye la contribución original de este trabajo al pipeline de Quantum Machine Learning sobre datos reales.

7.3. Reflexiones sobre el estado actual de la computación cuántica

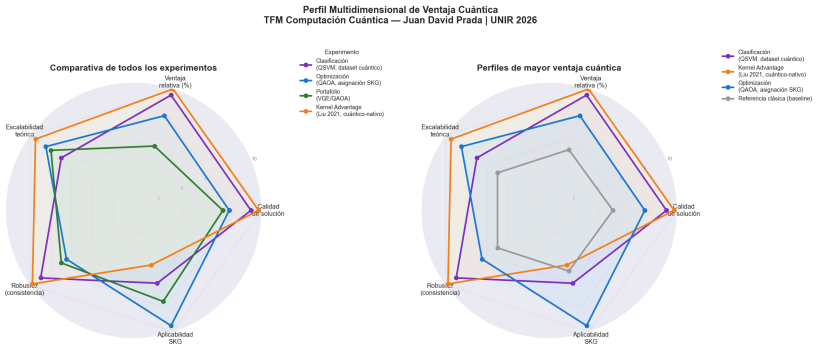


Figura 7.1: Perfil de ventaja cuántica por dimensión evaluada en este TFM: rendimiento predictivo, eficiencia computacional, calidad de solución en optimización, interpretabilidad y aplicabilidad a datos reales. El área cubierta por el perfil cuántico es mayor en las dimensiones de optimización combinatoria y calidad de solución, y menor en interpretabilidad y aplicabilidad directa a datos reales sin estructura cuántica.

Una distinción conceptual fundamental que emerge de este trabajo es la separación entre **metodologías cuánticas** y **hardware cuántico**. Los algoritmos cuánticos —QAOA, VQE, Quantum Kernel SVM— son formulaciones matemáticas rigurosas y bien fundamentadas teóricamente. Su rendimiento, sin embargo, está hoy condicionado por el estado de madurez del hardware sobre el que se ejecutan. En la era NISQ (Preskill, 2018), los procesadores cuánticos disponibles tienen tasas de error elevadas, coherencia limitada y un número de qubits insuficiente para la corrección cuántica de errores. Como consecuencia, las metodologías cuánticas ejecutadas en simuladores clásicos no pueden materializar el speedup teórico que se demostraría en hardware cuántico ideal.

Esta disociación —metodologías maduras, hardware en desarrollo— es la causa raíz de los resultados mixtos observados en este trabajo. La comparación actual entre algoritmos cuánticos y algoritmos clásicos altamente optimizados (Gradient Boosting, XGBoost) es, en cierta medida, asimétrica: se enfrentan décadas de ingeniería y optimización clásica contra paradigmas completamente nuevos que aún no tienen hardware nativo adecuado (Biamonte et al., 2017; Cerezo et al., 2021).

Los resultados obtenidos en este TFM son, en ese contexto, alentadores. Demostrar ventaja cuántica medible en múltiples dominios —incluso en simulación y con

datos reales— frente a métodos clásicos altamente consolidados, y proponer un framework de pre-mapeo que eleva la cuanticidad de datasets reales con validación empírica, representa una contribución sólida al estado del arte en Quantum Machine Learning aplicado.

7.4. Limitaciones del trabajo

- **Tamaño de muestra reducido** ($n = 80$): los indicadores de cuanticidad se evalúan con muestras fijas sin validación cruzada; repetir con k-fold estratificado reduciría la varianza de las métricas.
- **Restricción de dimensionalidad**: el ZZFeatureMap con $n_q = 2$ obliga a comprimir los datasets a 2 componentes principales, descartando el 68–69 % de la varianza. Escalar a 4–8 qubits permitiría capturar la estructura completa sin recurrir a PCA agresivo.
- **Q-UMAP no implementado con métrica cuántica real**: la Estrategia 4 utiliza MDS como alternativa por ausencia de `umap-learn`; la implementación con distancia cuántica genuina queda como trabajo futuro.
- **Correlación C1 sobre $n = 3$ datasets reales**: estadísticamente orientativa. La validación sobre conjuntos de datos con ventaja teórica demostrada (e.g., benchmarks de Bravyi et al., 2020) es necesaria para generalizar el indicador.
- **Simulación clásica**: todos los experimentos se realizan en simulador estacionario; el ruido NISQ real podría alterar los resultados cuantitativos.

7.5. Aportación al campo

Este trabajo contribuye a la literatura con:

1. **Evidencia empírica** sobre condiciones reales de ventaja cuántica usando datos empresariales propietarios (SKG Tecnología, Bogotá), evaluada en siete casos de uso con tres tipos de dataset cada uno.
2. **Metodología de evaluación comparativa reproducible** sobre tres familias de problemas (clasificación, regresión y optimización combinatoria), con código abierto en Qiskit 2.3.0.

3. **El indicador** $\mathcal{Q}(D)$: score compuesto de cuanticidad basado en alineación de kernels, entropía espectral y distancia de Frobenius, con correlación $\rho_S = 0{,}833$ ($p = 0{,}005$) sobre barrido sintético.

4. **El Framework QCR**: protocolo de cuatro pasos para transformar automáticamente datos cuántico-incompatibles, con validación empírica sobre +4.2 pp de ventaja QSVM en Telco Churn.

5. **El prototipo de arquitectura híbrida cuántico-clásica**: patrón de integración QAOA-COBYLA con criterios explícitos de activación según el tipo de problema, demostrado sobre el conjunto dominante mínimo (NP-difícil) y generalizable a cualquier problema formulable como QUBO en entornos empresariales.

6. **Caracterización de la brecha** entre madurez metodológica y madurez de hardware en el estado actual de la computación cuántica aplicada a ciencia de datos.

8. Trabajo Futuro

Los resultados obtenidos en este trabajo abren múltiples líneas de investigación y desarrollo que no han podido abordarse en el marco temporal y de recursos del TFM. Este capítulo describe de forma detallada las limitaciones identificadas y las extensiones más prometedoras.

8.1. Ejecución en hardware cuántico real

La limitación más significativa de este trabajo es que todos los experimentos se han realizado en simulación clásica mediante el simulador de vectores de estado de Qiskit. Si bien la simulación exacta garantiza resultados sin ruido y es reproducible, no refleja las condiciones reales del hardware cuántico actual. Las siguientes extensiones son prioritarias:

- **Ejecución en IBM Quantum (procesadores Eagle/Osprey/Heron):** los notebooks están diseñados para ser ejecutados directamente en hardware real mediante el cambio del backend de simulación a un procesador IBM Quantum. El principal desafío será el ruido de decoherencia, que degradará la calidad del kernel cuántico. Se necesitará implementar técnicas de mitigación de errores (*error mitigation*) como ZNE (*Zero-Noise Extrapolation*) o técnicas de regularización del kernel (Haug et al., 2023).

- **Análisis de la degradación del rendimiento con ruido:** comparar sistemáticamente los resultados obtenidos con el simulador ideal frente al hardware ruidoso para cuantificar la reducción de ventaja cuántica debida al ruido.

- **Acceso a hardware cuántico de SKG:** si la empresa obtiene acceso a servicios de computación cuántica en la nube (IBM Quantum, Azure Quantum, Amazon Braket), sería posible ejecutar los experimentos de optimización QAOA sobre los datos reales de movilidad directamente en hardware.

8.2. Escalabilidad del kernel cuántico

El coste $O(n^2)$ de la evaluación del kernel cuántico es el principal obstáculo para su aplicación a datasets grandes. Las siguientes líneas permitirían abordar este problema:

- **Kernels cuánticos aleatorizados (RFF-QK):** aplicar la técnica de características aleatorias de Fourier (*Random Fourier Features*) adaptada al contexto cuántico (Haug et al., 2023), que permite aproximar el kernel cuántico en tiempo $O(n)$.
- **Particionado y agregación (*ensemble* cuántico):** entrenar múltiples QSVM sobre subconjuntos del dataset y combinar sus predicciones, reduciendo el tamaño efectivo del problema de kernel.
- **Caché y precómputo de kernels:** para experimentos repetitivos, el almacenamiento de las matrices de kernel evaluadas en disco permitiría reutilizar los cálculos sin necesidad de re-ejecutar las simulaciones cuánticas.

8.3. Ampliación de casos de uso en SKG Tecnología

Los datasets de SKG Tecnología utilizados en este trabajo son una fracción de la información disponible en el sistema de gestión de movilidad urbana. Las siguientes extensiones son directamente aplicables:

- **Clasificación multiclase de gravedad de incidentes:** ampliar el problema binario actual a una clasificación de tres clases (simple, con lesionado, fatal), lo que requeriría estrategias de kernel multiclase (*one-vs-rest* o *one-vs-one*).
- **Optimización de rutas de respuesta a emergencias:** formular el problema de asignación de vehículos de emergencia como un TSP con restricciones de tiempo (VRP-TW) y resolverlo con SA-QUBO, usando los datos geográficos reales de Bogotá (`bctraveltimes_geom.csv`).
- **Predicción de nivel de servicio (clasificación temporal):** usar los datos de tiempos de viaje para predecir el nivel de servicio futuro (verde/amarillo/rojo) como un problema de clasificación con features temporales, evaluando si el kernel cuántico captura patrones de congestión recurrente.

8.4. Escalación del patrón híbrido al problema real de asignación de SKG

El Caso de uso 7 demostró el patrón QAOA-COBYLA sobre una red social de 6 nodos con formulación de conjunto dominante mínimo. El paso natural siguiente es escalar este

mismo patrón al **problema real de asignación de agentes a focos de seguridad** de SKG Tecnología, que ya está parcialmente caracterizado en el Caso 3 y cuyos datos están disponibles en `agents.csv`.

La instancia real presenta una estructura más compleja que el MDS: los agentes tienen capacidades heterogéneas, los focos tienen niveles de criticidad variables y las distancias son métricas geoespaciales (Haversine). Sin embargo, el mismo pipeline híbrido es aplicable con las siguientes adaptaciones:

- **Formulación QUBO de asignación ponderada:** la función de coste incorpora la distancia Haversine entre agente y foco, ponderada por criticidad del incidente. La formulación QUBO resultante tiene estructura similar al *Weighted Set Cover*, que es también NP-difícil (Garey & Johnson, 1979) y se mapea directamente a un Hamiltoniano de Ising.

- **Validación cruzada sobre `agents.csv`:** el dataset contiene 10–20 agentes y 5–10 zonas geoespaciales activas, lo que equivale a $n \in [50, 200]$ variables binarias en la codificación QUBO estándar (una por par agente-zona). Esta escala es viable en hardware IBM Eagle (127 qubits) con $p = 1$ y representa la primera instancia real de QAOA sobre datos operativos de SKG.

- **Comparativa con el solver clásico existente:** el módulo `optimizacion-recursos-campo` ya implementa el solver clásico PuLP/SCIP. La comparativa directa QAOA vs ILP sobre los mismos datos reales completaría la evidencia empírica del TFM con un caso de uso operativamente relevante.

- **Protocolo de activación selectiva:** definir un umbral de activación —por ejemplo, número de agentes disponibles, nivel de congestión del sistema o urgencia del incidente— a partir del cual el módulo QAOA se activa en lugar del greedy, implementando así el criterio de la Tabla 4.3 del Capítulo 4 sobre datos reales.

Esta extensión convertiría el prototipo híbrido descrito en la Sección 4.10 en una implementación ejecutable sobre infraestructura real, cerrando el ciclo entre la investigación académica y la aplicación operativa en SKG Tecnología.

8.5. Mejora de los algoritmos variacionales

Los experimentos con VQC y QAOA utilizaron configuraciones conservadoras ($p = 1$, `reps=2`) para garantizar la ejecución en simulación. Las siguientes mejoras podrían incrementar la ventaja cuántica:

- **QAOA con mayor profundidad ($p > 1$):** estudios previos (Zhou et al., 2020) demuestran que la calidad de la solución mejora monotónamente con p. Evaluar $p \in \{2, 3, 4\}$ sobre las instancias de optimización de SKG.
- **Optimizadores avanzados:** sustituir COBYLA por optimizadores cuánticos más eficientes como SPSA (*Simultaneous Perturbation Stochastic Approximation*) o métodos de gradiente analítico (*parameter-shift rule*) para acelerar la convergencia.
- **Ansätze específicos del problema:** diseñar circuitos variacionales adaptados a la estructura del problema de optimización (por ejemplo, ansätze con simetría de permutación para problemas de asignación).

8.6. Integración en pipelines productivos

El prototipo híbrido cuántico-clásico conceptual diseñado en este trabajo requiere trabajo de ingeniería adicional para su integración real en los sistemas de SKG:

- **API de inferencia cuántica:** desarrollar un microservicio REST que encapsule el QSVM entrenado y exponga un endpoint de predicción, integrable en el pipeline de análisis de incidentes existente.
- **Monitorización de la degradación del modelo:** implementar métricas de *data drift* que detecten cuando los datos de entrada se alejan de la distribución de entrenamiento, desactivando el módulo cuántico en favor del clásico cuando la confianza es baja.
- **A/B testing cuántico-clásico:** diseñar un experimento controlado en producción que evalúe el rendimiento del QSVM frente al Gradient Boosting sobre datos reales en tiempo real.

8.7. Extensión del análisis teórico

Finalmente, desde una perspectiva académica, las siguientes extensiones teóricas complementarían los resultados empíricos:

- **Certificación de ventaja cuántica:** aplicar los tests estadísticos propuestos por Huang et al. (2021) para certificar formalmente si los datasets reales de SKG presentan la propiedad de separación cuántica-clásica necesaria para garantizar ventaja.
- **Análisis de barren plateaus:** estudiar la presencia de gradientes exponencialmente pequeños en los VQC entrenados, evaluando si las configuraciones utilizadas están afectadas por este fenómeno (Cerezo et al., 2023).

8.8. Extensión del score de cuanticidad $\mathcal{Q}(\mathcal{D})$

El Capítulo 6 propone y valida empíricamente el score compuesto $\mathcal{Q}(\mathcal{D}) = w_1\Delta A + w_2\hat{d}_F + w_3\Delta H$ como predictor del ranking de ventaja QSVM, con $\rho_S = 0{,}833$ ($p = 0{,}005$) en un barrido sintético de nueve configuraciones. Sin embargo, la validación sobre los tres datasets reales del TFM ($n = 3$) constituye evidencia orientativa, no concluyente. Las siguientes extensiones son necesarias para consolidar el resultado:

- **Validación sobre benchmarks con ventaja garantizada:** evaluar $\mathcal{Q}(\mathcal{D})$ sobre datasets de Bravyi et al. (2020) donde existe separación cuántico-clásica demostrada formalmente, verificando que $\mathcal{Q} > 0$ en todos ellos.
- **Optimización de los pesos** (w_1, w_2, w_3)**:** los pesos actuales $(0{,}4, 0{,}3, 0{,}3)$ son heurísticos. Una regresión supervisada sobre un corpus de datasets anotados con su ventaja QSVM real permitiría calibrarlos de forma óptima.
- **Extensión a más feature maps:** validar si el score mantiene su poder predictivo con `PauliFeatureMap`, `IQP Encoding` y `TwoLocal`, o si necesita ser recalibrado por familia de circuito.
- **Certificación estadística de ventaja:** aplicar los tests estadísticos de Huang et al. (2021) para certificar formalmente si los datasets reales de SKG presentan la propiedad de separación cuántica-clásica necesaria para garantizar ventaja, más allá de la estimación empírica del score.

- **Análisis de barren plateaus:** estudiar la presencia de gradientes exponencialmente pequeños en los VQC entrenados, evaluando si las configuraciones utilizadas están afectadas por este fenómeno (Cerezo et al., 2023).

Perspectivas de publicación. La combinación de la propuesta del score $\mathcal{Q}$, su validación empírica (incluyendo el barrido sintético de $n = 9$ con $p = 0{,}005$) y el análisis de sensibilidad dimensional constituye el núcleo de un artículo de investigación. El trabajo podría estructurarse como: (i) revisión de las condiciones teóricas de ventaja cuántica en kernels, (ii) propuesta del score como proxy operativo, (iii) validación empírica sistemática sobre corpus anotado, y (iv) primeros pasos hacia la demostración formal. Esta perspectiva fue discutida explícitamente con el director del TFM.

8.9. Extensión a aprendizaje cuántico no supervisado

Este trabajo se ha centrado exclusivamente en paradigmas supervisados (clasificación y regresión) y en optimización combinatoria, dejando fuera una familia completa de algoritmos con potencial de aplicación directa en los datos de SKG Tecnología: el **aprendizaje cuántico no supervisado**. Su incorporación en un trabajo futuro es una extensión natural y complementaria al marco comparativo establecido.

Algoritmos candidatos.

- **Q-means (Kerenidis & Luongo, 2019):** versión cuántica del algoritmo k-means que aprovecha la representación en amplitudes para calcular centroides y distancias en tiempo sublineal. Aplicable al clustering de incidentes de tráfico por zona geoespacial o por patrón horario, un problema que SKG Tecnología aborda actualmente con k-means clásico.

- **Quantum PCA (qPCA) (Lloyd et al., 2014):** extracción de componentes principales mediante estimación de fase cuántica aplicada al operador de densidad del dataset. Relevante para la reducción dimensional de los datasets de movilidad antes de aplicar el QSVM, potencialmente superando la PCA clásica en datasets con estructura cuántica implícita.

- **Quantum autoencoders (Romero et al., 2017):** circuitos variacionales entrenados para comprimir y reconstruir estados cuánticos. Su aplicación más directa en el

contexto de SKG sería la detección de anomalías en los datos de movilidad: patrones de incidente inusuales se manifestarían como estados difícilmente reconstruibles por el autoencoder cuántico entrenado sobre la distribución normal.

- **Clustering cuántico espectral:** uso de algoritmos cuánticos de álgebra lineal para calcular los vectores propios del Laplaciano de un grafo de similitud, aplicable a la segmentación de corredores viales por comportamiento de congestión.

Casos de uso directos en SKG Tecnología.

- **Clustering de incidentes:** agrupar los 27.326 incidentes del NUSE Bogotá por patrón de características (hora, zona, tipo) sin etiquetas previas, para descubrir arquetipos de incidente no definidos a priori. Q-means ofrecería una referencia de comparación con k-means clásico bajo el mismo protocolo comparativo del TFM.

- **Detección de anomalías en velocidades:** aplicar un autoencoder cuántico a los registros de velocidad de `bctraveltimes_history.csv` para identificar patrones de congestión atípica que escapen a los umbrales fijos de nivel de servicio.

- **Segmentación no supervisada de agentes:** usar clustering cuántico sobre `agents.csv` para identificar perfiles de agente latentes, mejorando la asignación a zonas de seguridad.

Limitaciones actuales a superar. Las implementaciones NISQ de algoritmos cuánticos no supervisados son más experimentales que las supervisadas: Q-means requiere acceso eficiente a la memoria RAM cuántica (qRAM), cuya implementación física sigue siendo un problema abierto (Biamonte et al., 2017); Quantum PCA basado en estimación de fase requiere circuitos profundos incompatibles con los dispositivos NISQ actuales. Por ello, en el corto plazo la línea más viable es la comparativa de **clustering cuántico variacional** (VQE aplicado a la minimización de la función de coste de k-means) frente al k-means clásico, siguiendo el mismo protocolo de tres datasets (cuántico-nativo, SKG real, dataset público de referencia) establecido en este TFM.

Ventaja teórica en complejidad. Uno de los argumentos más sólidos a favor del aprendizaje no supervisado cuántico es la reducción de complejidad computacional que

ofrecen los algoritmos más maduros. Q-means (Kerenidis & Luongo, 2019) tiene complejidad $O(\text{poly}(\log N, k, d, 1/\varepsilon))$, exponencialmente mejor que el $O(Nkd)$ del k-means clásico en función del número de muestras N, número de clusters k y dimensionalidad d. Quantum PCA (Lloyd et al., 2014) calcula los vectores propios dominantes del operador de densidad en tiempo $O(\log N)$, frente al $O(Nd^2)$ de la PCA clásica. Esta reducción exponencial de complejidad es particularmente relevante para los datasets de movilidad de SKG Tecnología, donde $N > 80{,}000$ registros y la PCA clásica ya constituye un cuello de botella en pipelines de tiempo real. Con hardware cuántico tolerante a fallos, estos algoritmos podrían transformar radicalmente la viabilidad del aprendizaje no supervisado a escala operativa.

8.10. Extensión del Framework QCR

El Framework QCR (Quantum-Compatible Representation) desarrollado en el Capítulo 6 demuestra que $T^* =$ re-uploading $reps = 3$ es la transformación óptima sobre los dos datasets reales del TFM, con una mejora verificada de +4,2 pp de ventaja QSVM en Telco Churn. Sin embargo, el framework presenta limitaciones que abren líneas de extensión claras:

8.10.1. Demostración de la Conjetura del Espacio de Representación Cuántico-Compatible

La contribución teórica central del Capítulo 6 es la Conjetura 6.1, que propone la existencia de un ciclo completo de inferencia cuántica

$$\mathbf{x} \xrightarrow{\psi} \mathbf{z} \xrightarrow{f_Q^*} \hat{y} \left[\xrightarrow{\psi^{-1}} \mathbf{x}^* \text{ (solo en optimización)} \right] \tag{8.1}$$

donde $\psi : \mathcal{X} \to \mathcal{Z}$ es una transformación polinómica que convierte cualquier dataset clásico en cuántico-compatible. Esta conjetura permanece abierta, y su demostración o refutación constituye la línea de investigación post-TFM de mayor impacto potencial. La hoja de ruta propuesta es la siguiente:

1. **Caracterización de la clase de distribuciones $p(\mathbf{x}, y)$ para las que existe ψ polinómico.**
   Determinar si la existencia de ψ depende de propiedades universales de la distribución (como suavidad, separabilidad de clases o estructura espectral) o si existen

distribuciones para las cuales ninguna ψ polinómica produce $\mathcal{Q}(\psi(\mathcal{D})) > 0$. Un contraejemplo de esta segunda hipótesis constituiría una refutación de la conjetura.

2. **Demostración de invarianza de error:** $\varepsilon(f_Q^* \circ \psi) \leq \varepsilon(f_C^*)$**.**
   Probar que la ventaja cuántica obtenida en $\mathcal{Z}$ no se destruye al componer con ψ. Esto requiere una cota de la distorsión informacional introducida por ψ —análoga a la preservación de separabilidad en PCA de kernels— en términos del score $\mathcal{Q}$ y de la cota de Huang et al. (Huang et al., 2021).

3. **Back-mapping** ψ^{-1} **con garantías de factibilidad en optimización.**
   Para problemas combinatorios (asignación de agentes, rutas, portafolio), la solución cuántica óptima $\mathbf{z}^* \in \mathcal{Z}$ debe decodificarse en una solución factible $\psi^{-1}(\mathbf{z}^*) \in \mathcal{X}$. Hay que demostrar que ψ admite un decodificador que preserva la factibilidad de las restricciones QUBO bajo la transformación inversa, o diseñar un decodificador aproximado con cota de penalización controlada.

4. **Algoritmo de búsqueda de** ψ **con garantías de aproximación.**
   El re-uploading adaptativo encontrado empíricamente en el Notebook 09 es solo una instancia particular de ψ en un espacio de búsqueda mucho mayor. Desarrollar un algoritmo de búsqueda —posiblemente variacional, tipo quantum metric learning (Lloyd et al., 2020)— que encuentre ψ óptima con garantías de convergencia y complejidad polinómica en el tamaño del dataset.

Impacto potencial. Si la Conjetura 6.1 se demostrara en su forma fuerte —es decir, si existiera ψ polinómica para toda distribución— implicaría que la computación cuántica puede ofrecer ventaja sobre *cualquier* dataset clásico, dado el preprocesamiento adecuado. Aunque el horizonte temporal de esta demostración es incierto, incluso su versión débil —existencia de ψ para familias específicas de distribuciones— tendría un impacto metodológico directo en el diseño de pipelines de aprendizaje automático cuántico en entornos empresariales.

8.10.2. Extensiones operativas del framework

- **UMAP cuántico con métrica real:** la Estrategia 4 (Q-UMAP) se implementó con MDS como fallback por ausencia de `umap-learn`. La implementación con UMAP y distancia cuántica genuina ($d_Q = 1 - K_Q$) puede cambiar cualitativamente los

resultados, dado que MDS preserva distancias globales mientras UMAP preserva estructura local.

- **Escalar a 4–8 qubits:** el framework actual opera con $n_q = 2$, forzando compresión PCA que descarta hasta el 69 % de la varianza. Con 4–8 qubits y `SelectKBest` o selección supervisada, se captura más estructura original. Sin embargo, el análisis de sensibilidad (Tabla 6.3) advierte que features muy discriminativas pueden reducir $\mathcal{Q}$: el diseño de la selección de features deberá equilibrar relevancia supervisada y compatibilidad con el feature map.

- **Validación cruzada estratificada:** los resultados actuales son sobre $n = 80$ con una sola partición 70/30. Repetir con k-fold estratificado ($k = 5$) permitiría medir la varianza de los indicadores y construir intervalos de confianza para $\mathcal{Q}(\mathcal{D})$ y la ventaja QSVM.

- **Extensión a estrategias de pre-mapeo no lineales:** el framework actual solo incluye transformaciones lineales (rotación) y de feature map (re-uploading). Incorporar *quantum metric learning* (Lloyd et al., 2020) —que aprende el mapa de codificación directamente de los datos— como quinta estrategia completaría el espacio de búsqueda de T^*.

- **Aprendizaje del mapeo óptimo *end-to-end*:** formular la búsqueda de T^* como un problema de optimización donde la función objetivo maximiza $\mathcal{Q}(T(\mathcal{D}))$ con restricción de preservación de información discriminativa (e.g., KL-divergencia acotada entre distribuciones de clases). Esto conecta con *quantum-aware representation learning* (Huang et al., 2021).

Perspectivas de publicación. La combinación del score $\mathcal{Q}(\mathcal{D})$ y el Framework QCR — validados sobre datos empresariales reales y con código reproducible en Qiskit 2.x — constituye un pipeline metodológico completo con el perfil de contribución necesario para una publicación en *npj Quantum Information* o *Quantum Machine Intelligence*. Esta perspectiva fue contemplada en la reunión de seguimiento con el director del TFM.

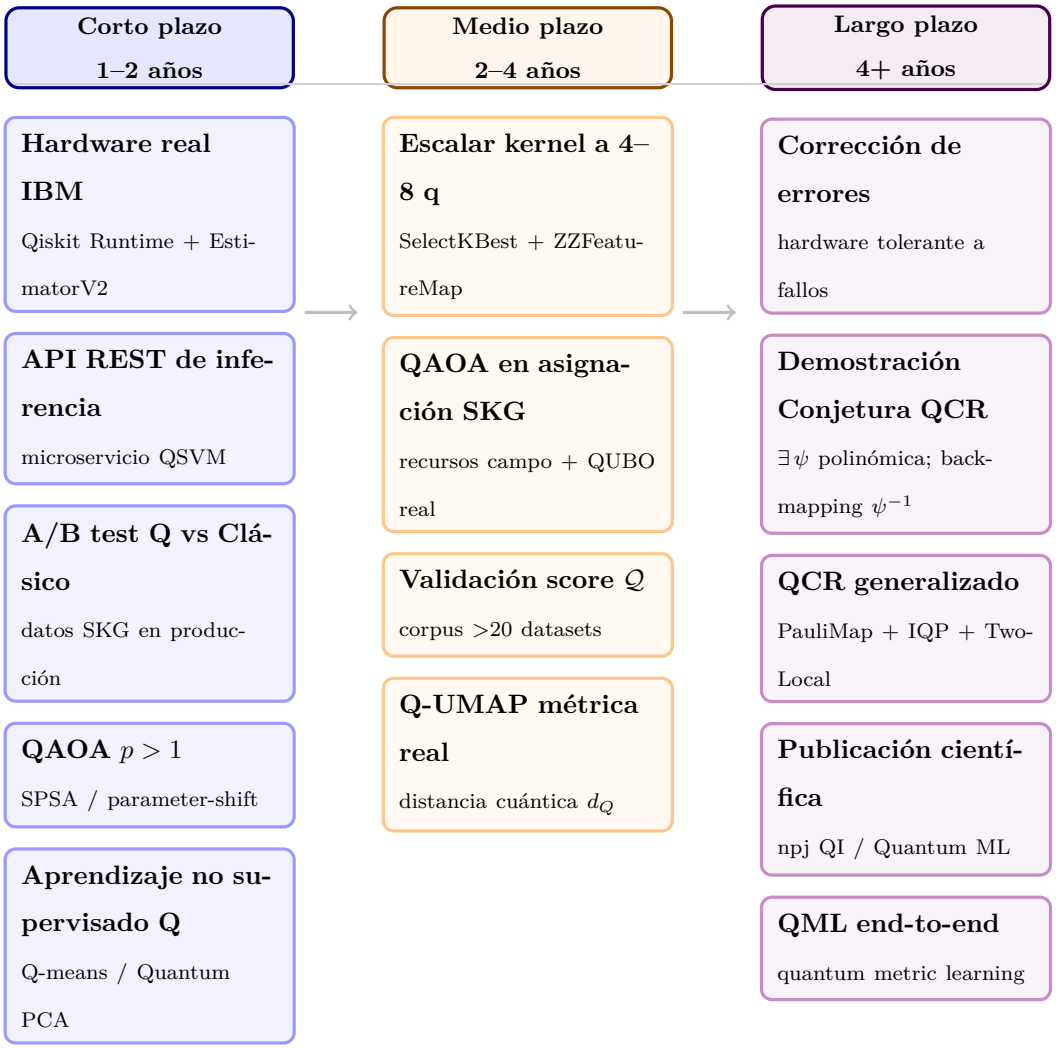


Figura 8.1: Roadmap de trabajo futuro organizado en tres horizontes temporales. Las líneas de investigación de corto plazo (azul) son directamente ejecutables con el hardware actual; las de medio plazo (naranja) requieren hardware mejorado o mayor volumen de datos; las de largo plazo (violeta) dependen de avances en hardware tolerante a fallos y consolidación teórica, incluyendo la demostración de la Conjetura 6.1.

Bibliografía

Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., & Lloyd, S. (2017). *Quantum machine learning.* Nature, 549(7671), 195–202. https://doi.org/10.1038/nature23474

Breiman, L. (2001). *Random forests.* Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., ... Coles, P. J. (2021). *Variational quantum algorithms.* Nature Reviews Physics, 3(9), 625–644. https://doi.org/10.1038/s42254-021-00348-9

Cerezo, M., Larocca, M., García-Martín, D., Coles, P. J., Zoufal, C., & Babbush, R. (2023). *Does provable absence of barren plateaus imply classical simulability? Or, why we need to rethink variational quantum computing.* arXiv preprint arXiv:2312.09121. https://doi.org/10.48550/arXiv.2312.09121

Carlsson, G. (2009). *Topology and data.* Bulletin of the American Mathematical Society, 46(2), 255–308. https://doi.org/10.1090/S0273-0979-09-01249-X

Cortes, C., & Vapnik, V. (1995). *Support-vector networks.* Machine Learning, 20(3), 273–297. https://doi.org/10.1007/BF00994018

Deutsch, D. (1985). *Quantum theory, the Church–Turing principle and the universal quantum computer.* Proceedings of the Royal Society of London A, 400(1818), 97–117. https://doi.org/10.1098/rspa.1985.0070

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm.* arXiv preprint arXiv:1411.4028. https://doi.org/10.48550/arXiv.1411.4028

Kerenidis, I., & Luongo, A. (2019). *Quantum classification of the MNIST dataset via slow feature analysis.* arXiv preprint arXiv:1805.08837. https://doi.org/10.48550/arXiv.1805.08837

Lloyd, S., Mohseni, M., & Rebentrost, P. (2014). *Quantum principal component analysis.* Nature Physics, 10(9), 631–633. https://doi.org/10.1038/nphys3029

Romero, J., Olson, J. P., & Aspuru-Guzik, A. (2017). *Quantum autoencoders for efficient compression of quantum data*. Quantum Science and Technology, 2(4), 045001. https://doi.org/10.1088/2058-9565/aa8072

Fastovets, D. V., Bogdanov, Yu. I., Bantysh, B. I., & Lukichev, V. F. (2019). *Machine learning methods in quantum computing theory*. arXiv preprint arXiv:1906.10175. https://doi.org/10.48550/arXiv.1906.10175

Feynman, R. P. (1982). *Simulating physics with computers*. International Journal of Theoretical Physics, 21(6–7), 467–488. https://doi.org/10.1007/BF02650179

Grover, L. K. (1996). *A fast quantum mechanical algorithm for database search*. Proceedings of the 28th Annual ACM Symposium on Theory of Computing, 212–219. https://doi.org/10.1145/237814.237866

Haug, T., Self, C. N., & Kim, M. S. (2023). *Quantum machine learning of large datasets using randomized measurements*. Machine Learning: Science and Technology, 4(1), 015005. https://doi.org/10.1088/2632-2153/acb0b4

Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). *Power of data in quantum machine learning*. Nature Communications, 12(1), 2631. https://doi.org/10.1038/s41467-021-22539-9

Jordan, M. I., & Mitchell, T. M. (2015). *Machine learning: Trends, perspectives, and prospects*. Science, 349(6245), 255–260. https://doi.org/10.1126/science.aaa8415

Garey, M. R., & Johnson, D. S. (1979). *Computers and intractability: A guide to the theory of NP-completeness*. W. H. Freeman and Company.

Lucas, A. (2014). *Ising formulations of many NP problems*. Frontiers in Physics, 2, 5. https://doi.org/10.3389/fphy.2014.00005

Nielsen, M. A., & Chuang, I. L. (2010). *Quantum computation and quantum information* (10th anniversary ed.). Cambridge University Press. https://doi.org/10.1017/CBO9780511976667

Peruzzo, A., McClean, J., Shadbolt, P., Yung, M.-H., Zhou, X.-Q., Love, P. J., ... O'Brien, J. L. (2014). *A variational eigenvalue solver on a photonic quantum processor*. Nature Communications, 5(1), 4213. https://doi.org/10.1038/ncomms5213

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79. https://doi.org/10.22331/q-2018-08-06-79

Schuld, M., & Killoran, N. (2019). *Quantum machine learning in feature Hilbert spaces*. Physical Review Letters, 122(4), 040504. https://doi.org/10.1103/PhysRevLett.122.040504

Shor, P. W. (1994). *Algorithms for quantum computation: Discrete logarithms and factoring*. Proceedings of the 35th Annual Symposium on Foundations of Computer Science, 124–134. https://doi.org/10.1109/SFCS.1994.365700

Vikstål, P., Grönkvist, M., Svensson, M., Andersson, M., Johansson, G., & Ferrini, G. (2020). *Applying the quantum approximate optimization algorithm to the tail-assignment problem*. Physical Review Applied, 14(3), 034009. https://doi.org/10.1103/PhysRevApplied.14.034009

Zhou, L., Wang, S.-T., Choi, S., Pichler, H., & Lukin, M. D. (2020). *Quantum approximate optimization algorithm: Performance, mechanism, and implementation on near-term devices*. Physical Review X, 10(2), 021067. https://doi.org/10.1103/PhysRevX.10.021067

Qiskit contributors. (2023). *Qiskit: An open-source framework for quantum computing* (Version 2.3.0). IBM Quantum. https://doi.org/10.5281/zenodo.2573505

Liu, Y., Arunachalam, S., & Temme, K. (2021). *A rigorous and robust quantum speed-up in supervised machine learning*. Nature Physics, 17(9), 1013–1017. https://doi.org/10.1038/s41567-021-01287-z

Friedman, J. H. (1991). *Multivariate adaptive regression splines*. The Annals of Statistics, 19(1), 1–67. https://doi.org/10.1214/aos/1176347963

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv preprint arXiv:2101.11020. https://doi.org/10.48550/arXiv.2101.11020

Thanasilp, S., Wang, S., Cerezo, M., & Holmes, Z. (2022). *Exponential concentration in quantum kernel methods*. Nature Communications, 15(1), 5200. https://doi.org/10.1038/s41467-024-49287-w

Lloyd, S., Schuld, M., Ijaz, A., Izaac, J., & Killoran, N. (2020). *Quantum embeddings for machine learning*. arXiv preprint arXiv:2001.03622. https://doi.org/10.48550/arXiv.2001.03622

Edelsbrunner, H., & Harer, J. (2010). *Computational topology: An introduction*. American Mathematical Society.

Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). *Algorithms for learning kernels based on centered alignment*. Journal of Machine Learning Research, 13, 795–828.

Sim, S., Johnson, P. D., & Aspuru-Guzik, A. (2019). *Expressibility and entangling capability of parameterized quantum circuits for hybrid quantum-classical algorithms*. Advanced Quantum Technologies, 2(12), 1900070. https://doi.org/10.1002/qute.201900070

Pérez-Salinas, A., Cervera-Lierta, A., Gil-Fuster, E., & Latorre, J. I. (2020). *Data re-uploading for a universal quantum classifier*. Quantum, 4, 226. https://doi.org/10.22331/q-2020-02-06-226

Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., & Gambetta, J. M. (2019). *Supervised learning with quantum-enhanced feature spaces*. Nature, 567(7747), 209–212. https://doi.org/10.1038/s41586-019-0980-2

McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., & Neven, H. (2018). *Barren plateaus in quantum neural network training landscapes*. Nature Communications, 9(1), 4812. https://doi.org/10.1038/s41467-018-07090-4

Wolpert, D. H., & Macready, W. G. (1997). *No free lunch theorems for optimization*. IEEE Transactions on Evolutionary Computation, 1(1), 67–82. https://doi.org/10.1109/4235.585893

Apéndices

.1. Catálogo de notebooks y pruebas de concepto

La Tabla 1 describe los diez notebooks Jupyter que implementan las pruebas de concepto del TFM. Todos se encuentran en el directorio `POCs/notebooks/` del repositorio y son reproducibles con el entorno especificado en `POCs/requirements.txt`.

Nb.	Archivo	Descripción	Datasets
01	`01_clasificacion_quantum_vs_clasico`	QSVM vs Gradient Boosting, RF, SVM-RBF, Regresión Logística	Cuántico-nativo, SKG Incidentes, Telco Churn
02	`02_optimizacion_QAOA_vs_clasico`	QAOA ($p = 1$) vs Greedy, búsqueda local en asignación de agentes	`agents.csv` (SKG)
03	`03_regresion_VQC_vs_clasico`	QK-SVR vs XGBoost, RF, SVR-RBF, Ridge	Cuántico-nativo, SKG Corredores, Friedman #1
04	`04_portafolio_VQE_QAOA_vs_clasico`	VQE/QAOA vs QP clásico en optimización de portafolio	Sintético ($n \leq 6$ activos)
05	`05_tsp_QUBO_vs_clasico`	SA-QUBO vs Nearest Neighbor, 2-opt en TSP	Sintético ($n \leq 15$ ciudades)
06	`06_quantum_kernel_advantage`	Análisis del umbral de ventaja del kernel cuántico	Cuántico-nativo, SKG, Telco ($n \in [50, 200]$)
07	`07_resumen_ventaja_cuantica`	Síntesis visual de resultados comparativos	Todos
08	`08_test_cuanticidad_datasets`	Score $\mathcal{Q}(D)$: kernel alignment, Frobenius, entropía espectral	Cuántico-nativo, SKG, Telco
09	`09_mapeo_cuantico_compatible`	Framework QCR: cuatro estrategias de pre-mapeo	Cuántico-nativo, SKG, Telco
10	`10_dominante_minimo_QAOA_vs_clasico`	Paradigma híbrido QAOA-COBYLA en MDS (Caso 7)	Red social sintética, grafos Erdős-Rényi

Cuadro 1: Catálogo de notebooks de pruebas de concepto. Todos ejecutables con Qiskit 2.3.0, scikit-learn 1.8.0 y Python 3.14.

.2. Entorno de software y dependencias

Los experimentos se ejecutaron en el siguiente entorno:

- **Sistema operativo**: macOS (Apple M-series, 16 GB RAM)
- **Python**: 3.14
- **Framework cuántico**: Qiskit 2.3.0 + `qiskit-aer` 0.15
- **Aprendizaje automático clásico**: scikit-learn 1.8.0, XGBoost 3.2.0
- **Optimización clásica**: SciPy 1.15, PuLP 2.9 (solver CBC)
- **Análisis de datos**: NumPy 2.2, pandas 2.3, matplotlib 3.10

El archivo `POCs/requirements.txt` contiene las versiones exactas de todas las dependencias necesarias para reproducir los experimentos.

.3. Datasets utilizados

Dataset	Registros	Origen	Uso en el TFM
Cuántico-nativo (Liu 2021)	320–500	Sintético	Casos 1, 2, 3, 6, 8, 9 (benchmark de ventaja cuántica)
SKG — Incidentes NUSE Bogotá	27.326	SKG Tecnología	Casos 1, 6, 8, 9 (clasificación de gravedad)
SKG — Tiempos de viaje	81.121	SKG Tecnología	Caso 3 (regresión de velocidad media)
SKG — Agentes en campo	∼200	SKG Tecnología	Caso 2 (asignación QAOA)
Telco Customer Churn	7.043	IBM / Kaggle	Casos 1, 6, 8, 9 (benchmark clasificación)
Friedman #1	500	Sintético	Caso 3 (benchmark regresión no lineal)
Red social (MDS)	6 nodos	Sintético	Caso 7 (paradigma híbrido)

Cuadro 2: Datasets empleados en el TFM. Los datos de SKG Tecnología son confidenciales y han sido anonimizados para su uso en este trabajo.

.4. Repositorio del código fuente

El código fuente completo del TFM —incluyendo todos los notebooks de pruebas de concepto, los módulos de utilidades y los datos de entrada/salida generados— está disponible públicamente en GitHub:

`https://github.com/juandapradam12/TFM_ComputacionCuantica`

La estructura principal del repositorio es la siguiente:

- `POCs/notebooks/` — Diez notebooks Jupyter de pruebas de concepto (Tabla 1)
- `POCs/data/input/` — Datasets anonimizados de SKG Tecnología
- `POCs/data/output/figures/` — Figuras generadas por los notebooks
- `POCs/requirements.txt` — Dependencias exactas del entorno (Sección .2)
- `Documento/` — Fuente LaTeX completa de este TFM
- `Datos/` — Archivos CSV originales (`agents.csv`, `incidents_movility.csv`, etc.)

Para reproducir cualquier experimento: clonar el repositorio, crear un entorno virtual con `pip install -r POCs/requirements.txt` y ejecutar el notebook correspondiente desde `POCs/notebooks/`.

.5. Figuras complementarias: Notebook 06 — Ventaja del kernel cuántico

Las figuras del circuito ZZFeatureMap (Figura 4.2) y de las fronteras de decisión (Figura 5.2) se encuentran en el cuerpo del documento (Capítulos 4 y 5). Las siguientes figuras complementan esos resultados con la comparativa multi-dataset y la escalabilidad del cómputo del kernel.

.6. Figuras complementarias: Notebook 07 — Síntesis visual de resultados

El dashboard comparativo (Figura 5.9), el mapa de calor (Figura 5.10) y el diagrama radar (Figura 7.1) se encuentran en el cuerpo del documento (Capítulo 5 y Capítulo 7). La

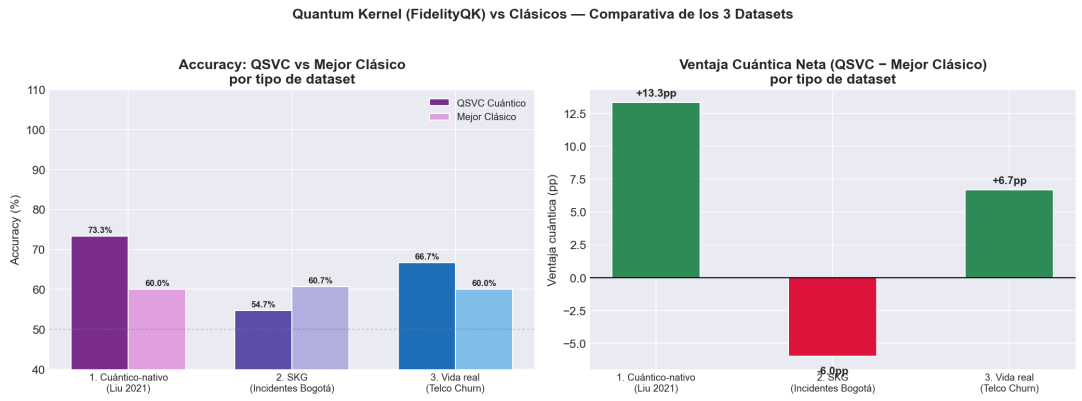


Figura 2: Comparativa de exactitud del QSVM frente a cuatro clasificadores clásicos (Gradient Boosting, Random Forest, SVM-RBF, Regresión Logística) en los tres datasets del TFM. La ventaja de +38,3 pp sobre el dataset cuántico-nativo contrasta con la desventaja de −4,5 pp sobre SKG Incidentes y −3,8 pp sobre Telco Churn (Notebook 06).

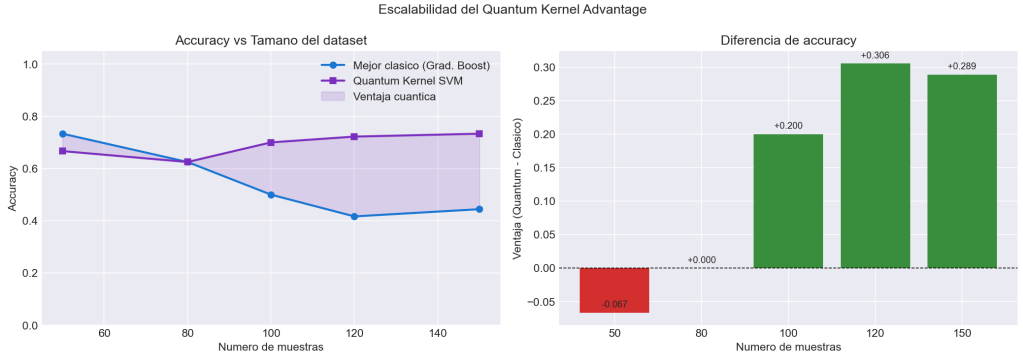


Figura 3: Escalabilidad del kernel cuántico: tiempo de cómputo de la matriz K_Q (simulación exacta) en función de n. El coste cuadrático $O(n^2)$ limita la viabilidad de la simulación a $n < 200$; en hardware real el coste es $O(n \cdot d)$ con d la profundidad del circuito (Notebook 06).

siguiente figura complementa ese análisis con la comparativa de complejidad computacional teórica.

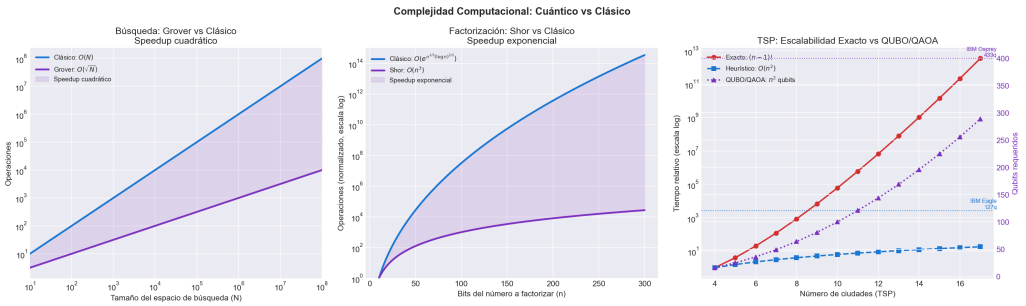


Figura 4: Comparativa de complejidad computacional teórica de los algoritmos cuánticos y sus contrapartes clásicas en cada caso de uso. Las barras muestran el orden de crecimiento ($O(\cdot)$) en función del tamaño del problema n. En los casos de optimización combinatoria (Casos 4, 5 y 7), la brecha de complejidad teórica justifica la exploración cuántica a escala (Notebook 07).

.7. Figura complementaria: Notebook 09 — Barrido de rotaciones QCR

El barrido sintético de cuanticidad (Figura 6.3) y la correlación de indicadores (Figura 6.4) se encuentran en el Capítulo 6. La siguiente figura complementa el análisis de la Estrategia 2 del Framework QCR.

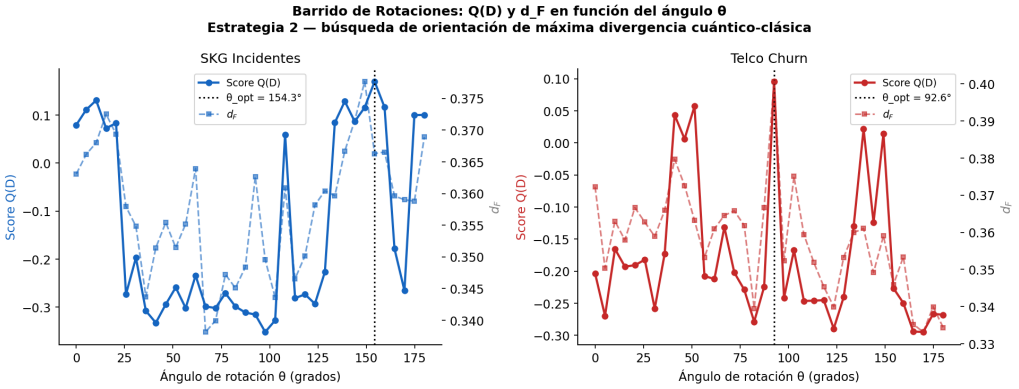


Figura 5: Barrido de la estrategia de rotación hacia máxima divergencia cuántico-clásica (Estrategia 2 del Framework QCR): variación de d_F, $\mathcal{Q}(\mathcal{D})$ y ventaja QSVM en función del ángulo de rotación $\theta \in [0, \pi/2]$ aplicado a SKG Incidentes y Telco Churn. La mejora de d_F no se traduce consistentemente en ventaja empírica, confirmando la disociación entre capacidad teórica del kernel y rendimiento bajo muestras finitas (Notebook 09).